Cultural and Social History

The Journal of the Social History Society

ISSN: 1478-0038 (impresa) 1478-0046 (en línea). Página de la revista: https://www.tandfonline.com/loi/rfcs20

Confrontar lo digital

Tim Hitchcock

Para citar este artículo: Tim Hitchcock (2013) Confronting the Digital, Cultural and Social History, 10:1, 9-23, DOI: 10.2752/147800413X13515292098070

Enlace a este artículo: https://doi.org/10.2752/147800413X13515292098070

Publicado en línea: 01 de mayo de 2015.

Envíe su artículo a esta revista

Visualizaciones del artículo: 1902

Ver artículos relacionados

Artículos que lo citan: 32. Ver artículos que lo citan

FORO DE DEBATE

CONFRONTAR LO DIGITAL

O CÓMO LA ESCRITURA ACADÉMICA DE LA HISTORIA PERDIÓ EL RUMBO

Tim Hitchcock

University of Hertfordshire

RESUMEN Este texto de discusión sostiene que el diseño y la estructura de los recursos históricos en línea, y el proceso de búsqueda y descubrimiento que encarnan, generan una serie de problemas sustanciales para los historiadores. El descubrimiento guiado por algoritmos y formas engañosas de búsqueda, un OCR deficiente y todos los sesgos de selección de una nueva edición del archivo impreso occidental han cambiado el modo en que investigamos el pasado, así como el carácter subyacente del objeto de estudio (el texto heredado). El artículo sostiene que los historiadores académicos, en buena medida, no han sabido responder eficazmente a estos desafíos y sugiere que, si bien han preservado la forma de las buenas prácticas académicas, han ignorado principios subyacentes importantes.

Palabras clave: humanidades digitales, historia digital, estándares, investigación académica, referencias, OCR, búsqueda

Estamos a mitad de camino de lo que con frecuencia se ha descrito como una revolución. En los últimos quince años se han digitalizado billones de palabras de texto impreso, que se han puesto a disposición de un público ávido en un formato que permite la búsqueda por palabras clave. Sólo Google Books ha digitalizado unos siete millones de los que, según sus estimaciones, son 1.3 mil millones de volúmenes, 1 y en los próximos diez años el archivo de materiales impresos anteriores a 1900 en la mayoría de las grandes lenguas estará disponible para la búsqueda por palabras clave. 2 Estamos presenciando la creación del archivo impreso occidental, segunda edición. Ya hoy es posible investigar y escribir una historia creíble y basada en evidencia sobre muchos temas utilizando exclusivamente fuentes en línea. Esto no implica que el proceso esté completo, ni siquiera cerca de estarlo. Apenas hemos comenzado a digitalizar materiales manuscritos, efímeros, imágenes y objetos. Persisten además cuestiones serias sobre qué debería digitalizarse a continuación y qué impacto tiene esa selección en la orientación de la investigación académica. 3 Pero lo logrado es, de todos modos, notable. Gran Bretaña ha estado a la vanguardia de la campaña internacional para hacerlo posible, y su comunidad académica —y la comunidad más amplia de investigadores que trabajan sobre temas británicos— ha sido su mayor beneficiaria. En particular, los historiadores que trabajan sobre la historia británica moderna temprana y del siglo XIX han recibido como obsequio el período y el lugar más exhaustivamente digitalizados del mundo. Entre Google Books, Early English Books Online (EEBO) y Eighteenth Century Collections Online (ECCO), The Times Digital

Dirección para correspondencia: Professor Tim Hitchcock, University of Hertfordshire, Hatfield, Hertfordshire, AL10 9AB, UK. Correo electrónico: T.Hitchcock@herts.ac.uk Archive, las colecciones de periódicos de la British Library, Project Gutenberg y el Million Book Project, los Parliamentary Papers, los censos del siglo XIX, la Clergy of the Church of England Database y Old Bailey Online, entre una multitud de otros recursos similares, la historia británica, y más particularmente la inglesa, se ha beneficiado de manera más integral que cualquier otra disciplina humanística de la llegada del 'archivo infinito'. 4

Por supuesto, los historiadores académicos no pidieron estos recursos y, en su mayor parte, tampoco han sido directamente responsables de su creación. 5 En términos de la cantidad total de material histórico digitalizado disponible, sólo una ínfima fracción se ha producido en un entorno universitario y bajo dirección académica. Disponemos de estas riquezas electrónicas, en cambio, porque Google vio una oportunidad de captar usuarios y contenidos, y porque Cengage/Gale, ProQuest, BrightSolid y Ancestry.co.uk supieron reconocer rápidamente una demanda insatisfecha y forjar nuevos modelos de negocio en un sector editorial en rápida transformación. Y disponemos de estos recursos porque las instituciones encargadas de preservar nuestros archivos y memorias, y de ponerlos a disposición de un público más amplio, han estado dispuestas a colaborar con el sector privado para asegurar su creación oportuna. Estas colecciones en línea están disponibles en gran medida gracias al trabajo de bibliotecarios, archivistas y empresarios, más que de académicos. 6 Ciertamente, se han destinado grandes sumas de dinero público, buena parte distribuida entre académicos tras un riguroso proceso de evaluación por pares, a la investigación digital, pero con un efecto relativamente escaso. David Thomas estima que, entre el JISC, el AHRC, el Wellcome Trust y el New Opportunities Fund, se han gastado como mínimo £137.5 millones en los sectores archivístico, público y universitario directamente en la creación de recursos digitales (sin contar las grandes sumas gastadas en creación digital en el contexto de proyectos esencialmente no digitales). 7 Pero incluso el reducido número de sitios web 'académicos' que esta financiación ayudó a crear ha tenido una suerte muy dispar. De los 155 proyectos financiados con 50 millones de libras por el New Opportunities Fund entre 1999 y 2004, sólo 30 muestran indicios de desarrollo tras su finalización formal, mientras que 83 han languidecido sin cambios. Otros 25 han desaparecido por completo. 8 La fuerza impulsora que condujo a la creación de los principales recursos de los que los historiadores dependen hoy para llevar adelante su investigación y su docencia cotidianas provino de fuera de la academia, y esto ha dado como

resultado recursos web diseñados e implementados para otros fines y otros públicos.

En paralelo a estos desarrollos se ha producido una segunda revolución digital que incide de manera igualmente directa en cómo practicamos la escritura académica de la historia. Así como las fuentes primarias que utilizamos se han vuelto digitales, la propia historia que creamos se ha convertido en una nueva forma digital. Desde nuestras solicitudes de financiamiento hasta nuestras notas y bibliografías, nuestra prosa, los borradores que enviamos, los informes de evaluación por pares, las pruebas de imprenta y las separatas, lo que alguna vez fue un sistema mecánico que marchaba al ritmo de una imprenta se ha convertido en un proceso semimágico de producción y reproducción silenciosas. Para irritación de los bibliotecarios, seguimos produciendo monografías del tamaño de un ladrillo y versiones impresas de revistas académicas, pero éstas son las pieles vacías que dejó al mudar un animal que se marchó hace mucho tiempo.

Al igual que con nuestras fuentes primarias recién convertidas en electrónicas, este proceso digital de publicación se ha creado en otro lugar y para otros fines. En el contexto británico, el principal mecanismo para solicitar financiamiento a un consejo de investigación (el sistema Je-S) se creó a instancias de las disciplinas STEM y de sus organismos de financiamiento. Durante sus primeros años de funcionamiento se ocupó exclusivamente del trabajo de físicos, ingenieros y biólogos. El papel relativamente subalterno de los investigadores de humanidades en el mundo más amplio del financiamiento de la investigación en el Reino Unido, y su tardía inclusión en el sistema Je-S, mucho después de que su formato básico quedara grabado en piedra, han hecho que éste y otros sistemas similares en todo el mundo se diseñaran en torno a las necesidades de las STEM y no de las humanidades. 9 Las categorías de evaluación, las etiquetas y los procesos que sustentan Je-S han debido, necesariamente, o bien diseñarse para satisfacer a los usuarios más activos del sistema (los académicos de STEM), o bien reducirse al mínimo común denominador más bajo y más banal, que abarca la forma menos mala en la que todos los consejos de investigación pudieron ponerse de acuerdo. Y así como nuestras fuentes primarias han servido de base para un nuevo modelo de negocio innovador, los editores se apresuraron a ver las oportunidades de absorber y 'monetizar' nuestro proceso de producción recién digitalizado. Nuestras revistas académicas, en particular, han sido arrancadas gradualmente de manos de los académicos e insertadas en un sistema internacional y casi monopólico de edición comercial. Las revistas científicas se han concentrado en

mayor medida en manos de un pequeño número de grandes editoriales comerciales. 10 Pero en el campo de la historia, Sage, Maney, Elsevier, OUP y CUP han cortejado y absorbido agresivamente un gran número de revistas, asumiendo la producción de muchas publicaciones que tradicionalmente eran gestionadas en su totalidad por pequeños grupos de académicos de forma cooperativa. Persiste en cierta medida una economía mixta de producción, y la creciente importancia de la publicación en acceso abierto (una vez más, encabezada por las STEM) ayuda a mitigar el impacto directo de estos desarrollos, pero las grandes editoriales comerciales operan actualmente un casi monopolio de las ventas y la distribución. Al empaquetar pequeñas revistas de humanidades (las hipotecas subprime de este mercado en particular) en grandes colecciones fofas con una o dos publicaciones 'imprescindibles' en su centro, los editores han encontrado en la práctica una nueva forma de vendernos con ganancia nuestra propia producción académica. Sólo las grandes editoriales cuentan con la infraestructura necesaria para crear las ediciones en línea que la mayoría de nosotros lee hoy y que constituyen la base de las métricas de citación y de todas las jerarquías y marcas de prestigio utilizadas para separar a los pocos de los muchos. Como autores y evaluadores, miembros de consejos directivos y editores, hemos estado plenamente implicados en este proceso, pero no podemos afirmar que hayamos tenido mucha influencia sobre él.

*

Quizás sorprendentemente, estos desarrollos parecen haber tenido escaso impacto real en el tipo de historia que escribimos y han pasado en gran medida inadvertidos para la profesión. Cada nuevo recurso web ha sido recibido con suspiros de aprecio y con la feliz constatación de que ya no necesitamos dejar nuestros cálidos escritorios en un frío día de invierno, mientras que las maravillas del 'control de cambios' han vuelto casi placenteras las quejumbrosas tareas de corrección de pruebas y corrección de estilo. Muchos historiadores se preguntarán por qué deberíamos preocuparnos si somos los beneficiarios involuntarios de un recurso nuevo y maravilloso creado con algún otro propósito. ¿Por qué preocuparse si las editoriales comerciales internacionales usan nuestras revistas como productos gancho y señuelos, si todavía podemos investigar y escribir una historia que otros historiadores pueden leer? Un vistazo rápido a los catálogos de las editoriales y a artículos de revistas recientes podría reforzar esta conclusión. A corto plazo, estos desarrollos parecen haber tenido pocos efectos negativos sobre la academia o sobre la práctica de la escritura académica de la

historia. Seguimos produciendo libros y artículos muy parecidos a los escritos hace treinta años, sin hacer casi ninguna concesión a la manera radicalmente distinta en que trabajamos hoy. Seguimos publicando monografías impresas de autoría individual que buscan demostrar en silencio que cada uno de nosotros ha realizado el arduo viaje físico al archivo y de regreso y, de manera aún más desconcertante, colecciones en varios volúmenes de 'fuentes primarias', muchas de las cuales también están disponibles en línea. Y luego usamos estos artefactos de la investigación académica, diseñados para satisfacer las necesidades tecnológicas de los tipos móviles (incluida esa herramienta de búsqueda hermosa pero esencialmente antediluviana, el índice), como parte de un sistema ampliado de juicio y debate académicos. Serán las monografías impresas las que sistemáticamente reciban doble ponderación en el kafkiano proceso de evaluación por pares que es el Research Excellence Framework (REF) en el Reino Unido, y las que constituyan la carne y la sangre de la masacre de mentes jóvenes que es la titularidad académica (tenure) en Norteamérica. Aunque la mayoría de los académicos usa internet como herramienta de búsqueda, sus notas al pie remiten a una consulta directa y física de una edición impresa. La gran mayoría tanto de los artículos de revistas como de las fuentes impresas modernas tempranas y del siglo XIX se consulta hoy en línea, y se espiga su contenido pertinente mediante búsquedas por palabras clave. Sin embargo, las referencias a estos materiales todavía se hacen a un ejemplar impreso en el estante de una biblioteca, lo que implica un proceso de lectura inmersiva. Al persistir en una serie de formatos obsoletos e ignorar resueltamente el carácter inmediato de las representaciones electrónicas que efectivamente consultamos, se ha minimizado sutilmente el impacto de la nueva tecnología. La historia como disciplina, en gran medida ajena a la producción de recursos digitales y aparentemente desinteresada en cambiar el modo en que ilustra su investigación para dar cabida a lo digital, ha escondido la cabeza en la arena y ha intentado ignorar la cuestión por completo.

No es una postura que podamos permitirnos mantener. La historia como disciplina académica, en su formulación profesional y posrankeana, se basa en una serie de prácticas destinadas a garantizar el uso crítico de la evidencia y el desarrollo claro y citable de la argumentación. Lo que distingue a la escritura académica de la historia de los relatos populistas que sólo buscan entretener es que proporciona a un lector crítico las herramientas para rastrear la evidencia hasta su origen y desarmar los bloques y fragmentos de detalle que componen un argumento. Irónicamente, al persistir en las formas tradicionales de publicación,

aparentamos reclamar 'autoridad' y trazabilidad, pero no estamos a la altura de esas pretensiones. Si la disciplina de la escritura académica está diseñada para permitir que la evidencia se verifique y que el proceso de investigación se reconstruya, entonces hemos abandonado los estándares que heredamos mientras mantenemos su forma vacía.

Para tomar un solo ejemplo de esta desconexión entre el proceso de investigación y su representación, muchos de nosotros usamos y citamos periódicos de los siglos XVIII y XIX como simples referencias impresas, sin mencionar cómo llegamos al artículo, la página y el número específicos. Al hacerlo, tergiversamos activamente las limitaciones dentro de las cuales trabajamos. Como ECCO, Google Books y los demás proveedores comerciales de material impreso histórico están ansiosos por entregar grandes cantidades de texto electrónico con rapidez, recurren a una metodología de captura de texto conocida como reconocimiento óptico de caracteres, u OCR. Para las formas más simples de la mayor parte del material impreso posterior a la década de 1840 (en particular, de sus variedades más costosas), esta metodología funciona razonablemente bien. Pero no produce resultados confiables cuando se aplica a publicaciones modernas tempranas, al material impreso barato y cotidiano del siglo XIX o a cualquier forma de composición compleja, como tablas, listas y anuncios. El OCR se ha combinado además con un sistema de mapeo gráfico que asocia cadenas de texto procesado por OCR con ubicaciones particulares en una imagen de la página original, lo que permite que los resultados de búsqueda aparezcan resaltados. 11 Es esta combinación de mapeo gráfico y OCR la que utilizan la Burney Collection of Eighteenth Century Newspapers, Google Books y The Times Digital Archive, junto con la gran mayoría de los sitios similares. Pero el OCR de la Burney Collection tiene una tasa de exactitud de caracteres del 75.6 por ciento —casi uno de cada cuatro caracteres es erróneo—, lo que da una tasa global de exactitud de palabras del 65 por ciento, que cae al 48.4 por ciento cuando se consideran las 'palabras significativas', del tipo que los historiadores usan para las búsquedas por palabras clave. 12 Los motores de búsqueda asociados a sitios web como la Burney Collection han adoptado una estrategia de búsqueda 'difusa' que ayuda adivinando qué es un nombre y qué no, reconociendo problemas comunes del OCR y ampliando de hecho el alcance de una búsqueda para incluir posibles variantes. Pero llega un punto a partir del cual la búsqueda 'difusa' sencillamente produce resultados cada vez más aleatorios, a medida que los errores de OCR se ven agravados por criterios de búsqueda cada vez más amplios. Y como al usuario sólo se le presenta una imagen del original, no hay modo de juzgar la calidad de

los resultados. Irónicamente, la flexibilidad y la sofisticación de nuestra capacidad humana para interpretar textos de mala calidad se han utilizado para ocultar las limitaciones de lo digital y de lo asistido por computadora. Una selección completamente aleatoria de texto en bruto procesado por OCR de la Burney Collection refleja la calidad de lo que la mayoría de nosotros buscamos, la mayor parte del tiempo:

It is frippofed that we have actually 40 Frigates at Sea for the ProteEaion of our Trade. r The St. Domingo Fleet is fafely arrived at La Rochelle vith a rich t Cargo. ltsArrival is the more agreeable to the Merchants, as there was not a Ship of tde whole Fleet infui ed." Extrolg of a Lette?-from Mr, Coxvwood, Afate of tThe Wfter, ViWlsaller, from Cork fir Ne-w-rork, dated P3qlon, March So. "On the z6th of January we fell in with an American Privateer, comnmanded by CQrptain Bailey, called the Flower of the Sea, of 26 Guns and sSo Men, to which l'Velil we were obliged to itrike after difcharging our Guns, fix tour Pounders. We 'were towed into this Place by the Privateer the 23d infiant, after a rely da1n- gerous Paffage, having carried away all our Malts. 13

Esto significa, en primer lugar, que no hay manera de verificar lo que se está buscando, ya que no existe un modo sencillo de descubrir cómo es el texto en bruto. Descargando un PDF de la imagen de la página original y aplicándole un sistema local de OCR, es posible aproximarse al texto subyacente que se utilizó para la búsqueda, pero el texto real del sitio original permanece oculto, sin excepción, en todos los grandes recursos comerciales que incluyen textos históricos. En segundo lugar, existe un sesgo automático respecto de lo que se puede encontrar, que conduce siempre e ineludiblemente al mismo subconjunto de texto una y otra vez, sin forma de saber en qué consiste realmente ese subconjunto. En esencia, el 52 por ciento de la Burney Collection y una proporción similar de otros recursos son completamente imposibles de encontrar y, lo que es igual de importante, siempre será el mismo 52 por ciento, determinado por la tipografía, la diagramación, la tinta que traspasa el papel y una multitud de otros factores que nadie ha investigado a fondo. Si se quiere usar estos materiales para rastrear datos tabulares, o anuncios que incluyen elementos gráficos, o cualquier texto que normalmente aparezca en cursiva, en gran medida no hay suerte. En un nivel más fundamental, el problema es que, mientras creemos estar buscando en periódicos, en realidad estamos buscando en representaciones del texto marcadamente inexactas, ocultas detrás de una imagen de mala calidad. Y, lo que es aún más condenatorio, al citar un ejemplar impreso del original nos negamos

luego a documentar nuestro recorrido de investigación, lo que dificulta que otros critiquen el proceso. Muchos historiadores argumentarían que esto simplemente reproduce el azar de la investigación tradicional sobre material impreso. Los avatares de la conservación, los sesgos del catálogo y las taxonomías intelectuales dentro de las cuales trabajamos constituyen componentes integrales de nuestra metodología de investigación y siempre han moldeado nuestras conclusiones. Pero mientras que las tecnologías de la biblioteca y el archivo físicos son inteligibles para la mayoría de los investigadores de humanidades y constituyen el objeto de estudio principal de la mayor parte de la investigación posmodernista, no estamos igualmente prevenidos para trabajar con fuentes digitales.

Nuestro enfoque acrítico del OCR es sólo un ejemplo de una serie de cuestiones más amplias que plantea nuestra creciente dependencia de la propia búsqueda por palabras clave. Todos lo hacemos. Ya se trate de una búsqueda rápida de un nombre, un lugar o una palabra descriptiva, nuestro primer punto de consulta ya no es la biblioteca, y ciertamente no una enciclopedia o un diccionario impresos, sino Google o Wikipedia. Si se quiere conocer la superficie de Hertfordshire en acres legales, se recurre a Wikipedia. 14 Si se quiere consultar el contexto jurídico del procesamiento de la vagancia en la década de 1760, probablemente se acuda a ECCO y se lea una de las varias ediciones del manual de justicia de paz de Burn publicadas en esa década y disponibles en línea, llegando al texto pertinente mediante una búsqueda por palabras clave (y descubriendo de paso varias discusiones sobre la vagancia que no figuran en el índice ni en la tabla de contenidos).

La llegada de la búsqueda por palabras clave ha sido enormemente liberadora. Pero también ha provocado un desarraigo sustancial del conocimiento, el arrancamiento de raíz, o 'googleización', de los componentes de lo que alguna vez fue un conjunto coherente de creencias y de sistemas para descubrir información y aplicarle taxonomías. En los sistemas de clasificación Decimal Dewey y de la Library of Congress (y en todos sus imitadores menos exitosos) están incorporadas fronteras disciplinares claras que restringen el modo en que un lector imagina su tema y el paisaje intelectual por el que navega. La historia académica se construyó sobre este entramado de comprensión y tradicionalmente se ha mantenido dentro de sus límites: si somos expertos en algo, es en cómo usar una biblioteca y un archivo. La llegada de la búsqueda por palabras clave nos permite escapar de este sistema de conocimiento posilustrado, pero también

elimina el marco de crítica de fuentes y de clasificación del que hemos llegado a depender, y que suponemos tácitamente compartido con nuestros lectores, cuando remitimos a una edición o a un archivo específicos. En consecuencia, la llegada de la búsqueda por palabras clave nos desafía a ser aún más honestos de lo que exige la forma de una nota al pie tradicional acerca de cómo buscamos la evidencia, qué es lo que estamos buscando y cómo esas búsquedas separan lo pertinente de lo imposible de encontrar. Una nota al pie tradicional siempre ha sido una forma abreviada que sólo puede entenderse aplicando un conocimiento compartido de la tecnología del archivo y de la biblioteca. La búsqueda por palabras clave amenaza con volver nuestras notas al pie esencialmente ininteligibles. Y es difícil evitar la impresión de que la mayoría de los historiadores académicos han optado por no involucrarse en este proceso ni cuestionar su propia práctica académica.

Esto quizás sea comprensible, ya que los motores de búsqueda militan activamente en contra de los buenos estándares académicos. En un mundo ideal, citaríamos las búsquedas que hemos utilizado para construir nuestro corpus de evidencia (quizás en forma de enlaces seguros y repetibles). Pero como los motores de búsqueda de los que dependemos no se construyeron pensando principalmente en un público académico, no lo hacen posible y, en cambio, tergiversan y oscurecen de hecho el carácter de cada búsqueda. Existe una amplia literatura sobre el funcionamiento del algoritmo de Google y sobre cómo hacer que el propio sitio web ascienda en la lista de resultados para captar la atención de un público ávido. 15 Pero esta literatura no aborda qué se excluye de los resultados ni cómo se representan los resultados en pantalla.

Hay dos cuestiones en particular que plantean serios problemas desde la perspectiva de la escritura académica de la historia. En primer lugar, desde 2009 Google ha convertido su 'personalized search facility' [función de búsqueda personalizada] en estándar para todos los usuarios. 16 Ésta se basa ya sea en el propio historial de búsqueda o en el de la computadora que se está usando para priorizar los resultados para cada usuario, poniendo en primer plano los sitios visitados en el pasado y privilegiando los resultados de recursos geográficamente cercanos (privilegiando resultados británicos si se busca desde una dirección IP en Gran Bretaña). Con cierto esfuerzo es posible desactivar esta función, pero muy pocas personas lo hacen, ya que funciona como un filtro extremo en un contexto en el que la mayoría de la gente se siente abrumada por el volumen de datos en línea. En otras palabras, las innovaciones de Google implican tanto que los

investigadores son dirigidos cada vez más hacia conjuntos de material en línea que ya han usado antes, en detrimento de un paisaje de conocimiento más amplio, como, lo que es más significativo, que es improbable que dos investigadores obtengan los mismos resultados a partir de la misma consulta. Podríamos especificar los criterios de búsqueda que nos condujeron a un determinado corpus de evidencia, pero eso seguiría sin permitirnos cumplir esa función crítica y académica de permitir que otro investigador siga nuestros pasos. O bien, si se quisiera documentar en una nota al pie el proceso de búsqueda que condujo a un sitio o a un dato particular, habría que incluir tanto la fecha exacta como el historial de búsqueda completo de la computadora utilizada.

La otra cuestión es que Google en realidad no cuenta los resultados, aunque parezca hacerlo. En cambio, estima el número de coincidencias sobre la base de la velocidad con la que localiza los primeros casos. En otras palabras, el motor de búsqueda en realidad sólo mide cuán rápido puede localizar las primeras diez o cien 'coincidencias' y luego extrapola un número a partir de estas dos medidas. 17 Si se buscara 'eighteenth-century crime' [delito en el siglo XVIII] como frase única (y dependiendo del historial de búsqueda de la computadora que se esté usando), se podría obtener lo que dice ser 'About 66,700 results' [Aproximadamente 66,700 resultados] en '(0.30 seconds)' [(0.30 segundos)]. Diez minutos después, la misma búsqueda podría arrojar fácilmente 79,000 coincidencias en 0.23 segundos.

Pero eso es sólo un fragmento del problema. Si se empieza a hacer clic en la fila de resultados al pie de la página, avanzando hasta el último resultado, resulta que esta búsqueda inicial sobre 'eighteenth-century crime' sólo encontró en realidad 199 sitios pertinentes. Cuanto más general es el término de búsqueda, mayor es probablemente la diferencia entre el número de 'coincidencias' declarado y el número real de enlaces devueltos. Una búsqueda por palabras clave de una frase como 'cleaning products' [productos de limpieza] puede fácilmente declarar 22 millones de resultados, pero producir sólo 953 enlaces. 18

Podría argumentarse que esto no importa mientras se encuentre lo que se busca, mientras los resultados sean 'suficientemente buenos'. Pero debemos recordar que estos resultados declarados moldean y distorsionan de hecho nuestra visión intelectual del mundo, que se está tergiversando la forma del archivo y de la biblioteca con los que trabajamos. Se nos induce a suponer que hay más material sobre el delito en el siglo XVIII, o incluso sobre productos de limpieza, del que realmente existe, y quedamos encandilados por una imagen de datos ilimitados a

una escala que nunca podríamos digerir. Intelectualmente, 66,700 sitios web son una propuesta muy distinta de 199: lo primero está más allá del alcance humano, accesible sólo a un alto sacerdocio de programadores y analistas, mientras que lo segundo es una semana de trabajo duro para un buen investigador.

Por supuesto, la respuesta sencilla es ignorar el número en la parte superior de la pantalla y hacer lo que todos hacemos: revisar los sitios que aparecen en la primera o la segunda página, confiando en que el algoritmo de Google los priorice y entregue primero los más pertinentes. Y si no encontramos lo que buscamos, podemos reformular la búsqueda e intentarlo de nuevo. Mientras evitemos deliberadamente cualquier intento de incorporar el proceso de búsqueda al modo en que representamos nuestra investigación, esto no plantea problemas. Citando el libro o la revista física que subyace a la imagen electrónica que efectivamente leemos, e ignorando por completo el proceso de búsqueda, podemos eludir la cuestión. Pero esta estrategia se basa en la creencia de que el algoritmo que Google utiliza para jerarquizar sus resultados realmente servirá tanto para entregar lo que se busca como para representar lo que efectivamente existe ahí fuera, y de que lo que está 'ahí fuera' es en realidad una cantidad conocida y no el objeto desconocido de la propia investigación. Muchos de quienes nos formamos en las destrezas tradicionales de biblioteca e investigación y trabajamos con materiales producidos antes de la llegada de lo en línea probablemente nos sentimos razonablemente cómodos con nuestro conocimiento de qué es lo que estamos buscando. La mayoría de los investigadores de cierta edad pasaron años familiarizándose con la forma física de los restos textuales de generaciones anteriores, y nuestra visión intelectual del mundo quedó moldeada de manera irreformable por los sistemas de conocimiento incorporados en bibliotecas y archivos. Pero a los investigadores más jóvenes se los ha dejado nadar (o ahogarse) en un mar de texto desarraigado localizado mediante búsquedas por palabras clave, mientras que incluso los investigadores mayores usan estos métodos de descubrimiento de manera acrítica. Una de las grandes ventajas del catálogo de biblioteca a la antigua, del tipo que ocupaba un lugar de honor en la Round Reading Room del British Museum, era que permitía evaluar de un solo vistazo la totalidad de los fondos de la biblioteca. Su simple materialidad permitía que el conocimiento que transmitía sobre la extensión de los fondos de la biblioteca se comunicara en silencio y se aceptara sin crítica. Que la propia tesis doctoral o el último libro ocuparan apenas unas pocas páginas de entradas de entre 400 volúmenes ofrecía una medida segura de su importancia (o de su

irrelevancia). Hemos optado por no trasladar ese conocimiento tácito a nuestras herramientas de búsqueda en línea.

Los historiadores que trabajan con materiales británicos modernos tempranos tienen algunas ventajas. Las colecciones de periódicos en línea reflejan con razonable exactitud los proyectos de microfilmación subyacentes a partir de los cuales se crearon, y ECCO y EEBO, aunque distan mucho de ser exhaustivos, tienen la gran ventaja de haber sido catalogados de acuerdo con (y sobre el telón de fondo de) el English Short Title Catalogue (ESTC). A pesar del problema paralizante de la calidad del OCR, es posible encontrar la mayoría de los ítems de ECCO remitiéndose a los datos de catalogación generados por el ESTC (o bien tener una certeza razonable de que un ítem determinado realmente no está allí, y no simplemente mal catalogado). Pero en cuanto se sale del mundo localista de la Gran Bretaña moderna temprana, la situación se vuelve menos satisfactoria. La mayor colección de material digitalizado en la web es Google Books, que promete representar nuestro cuerpo heredado de literatura de manera formal y académica: siete millones de volúmenes hasta ahora, centrados principalmente en obras en inglés del siglo XIX. Google Books pretende, en esencia, catalogar su colección de un modo que refleje las formas tradicionales de taxonomía intelectual pero, al igual que ocurre con los problemas del OCR y de la búsqueda, esto tergiversa el objeto de estudio.

El primer problema es que Google Books adolece de un problema de control de calidad. Hay páginas ilegibles, páginas escaneadas en el orden equivocado y páginas con partes cortadas que, a menos que Google emprenda un programa de correcciones retrospectivas (lo que no ocurrirá), nunca volverán a encontrarse. Estos materiales están ahora, en esencia, perdidos para la investigación académica. No se trata de una crítica a Google, sino más bien de parte de la tasa normal de error que se produce cada vez que se crea una nueva 'edición' de un texto (razón por la cual los historiadores se preocupan por las 'ediciones').

Pero un problema mucho mayor son los 'metadatos' deficientes. 19 Los metadatos son información acerca de un texto o una obra, o de una página web. La ficha de un libro en un catálogo físico de fichas es metadato: el título, el autor, el editor, la fecha de publicación, el número de páginas, etcétera. Los metadatos en línea pueden incluir tipos de archivo, medidas de complejidad textual e idioma. Concebiblemente, también podrían incluir otra información, como cuántas personas han accedido al ítem y qué más han descargado. La dificultad es que, si

esto se hace mal en un entorno en línea (tanto como en una biblioteca física), ya no es posible encontrar las cosas.

A primera vista, mediante la página de Búsqueda avanzada de libros de Google, es posible usar los metadatos para restringir los resultados en un grado notable y apuntar con precisión a un tema y a un asunto. Se puede usar toda la potencia de una búsqueda booleana (AND OR NOT); se puede hacer una búsqueda de frase en el texto completo; se puede seleccionar el idioma y la materia. Para la mayoría de nosotros, esto va mucho más allá del punto en el que la tecnología se convierte en magia.

Pero en cuanto se empieza a examinar con detenimiento los resultados, comienzan a surgir problemas. Google Books se ha catalogado con un sistema llamado BISAC (Book Industry Standards and Communication) en lugar del sistema de la Library of Congress o del Decimal Dewey. BISAC fue diseñado por el Book Industry Study Group (BISG) en nombre de los editores para ayudar a las librerías a gestionar y exhibir sus existencias, y su uso ha provocado profundos errores sistémicos que hacen que muchos volúmenes de Google Books sean extremadamente difíciles de localizar. En palabras del BISG, este sistema 'categorize[s] books based on topical content' [categoriza (los) libros según su contenido temático] y los asigna a 'merchandising themes' [temas de comercialización]. 20 Si se usa la Búsqueda avanzada de libros de Google para la materia 'history' [historia], o incluso para la etiqueta de materia que se sugiere como ejemplo, 'medieval history' [historia medieval], en la primera página no aparece ni un solo volumen reconociblemente de 'historia' o de 'historia medieval' (historia medieval sólo devuelve dos resultados de entre siete millones de libros). En sí mismo, esto no es un problema grave, ya que pocas personas abordan sus búsquedas con estas clasificaciones temáticas amplias, pero refleja una cuestión más amplia relativa a la calidad y el carácter de los metadatos utilizados para crear Google Books, que tergiversa de hecho lo que allí hay. De manera más general, a los materiales históricos en línea se les ha aplicado un poco apetecible popurrí de estándares de metadatos que convierte su descubrimiento, en cualquier contexto, en un tiro al blanco informativo de dudoso valor.

Las taxonomías del conocimiento que hemos heredado siguen teniendo un valor real: constituyen la forma más sofisticada de relación con la cultura heredada que poseemos actualmente, y son estos sistemas de conocimiento los que sustentan el trabajo de todos los historiadores. En otras palabras, deberíamos preservar y

seguir aplicando sistemas más antiguos de comprensión del pasado. Pero para hacerlo necesitamos involucrarnos mucho más directamente de lo que lo hemos hecho hasta ahora con las tecnologías de las que rápidamente estamos llegando a depender. Por el momento las usamos para hacernos la vida más fácil, mientras fingimos que no existen. Estamos perdidos en un mundo de referencias y evidencias que la mayoría de nosotros no comprende y que actualmente no contamos con las herramientas críticas para representar. Siempre ha habido problemas con la calidad de las tecnologías de las que dependemos, ya se tratara de una enciclopedia o de una base de datos en línea. De hecho, el proceso de digitalización ha puesto de relieve de manera sustancial las incoherencias y la mala calidad de muchas obras de referencia clásicas. 21 Pero como la mayoría de nosotros recibió al menos una introducción a la bibliotecología como parte de su formación, estábamos parcialmente prevenidos. El carácter oculto de los equivalentes digitales del catálogo de fichas, creados con un lenguaje y unas herramientas que pocos de nosotros entendemos, agrava el problema. Normalmente llamo a esto el efecto IKEA, porque se nos conduce a través de un sistema hacia una conclusión particular, sin señalización ni mapa. En una expresión acuñada por Bill Turkel, es el 'Las Vegas syndrome' [síndrome de Las Vegas]: todo son invitaciones a jugar, sin carteles de salida ni indicación de las probabilidades; una partida de dados intelectual en la que la esperanza se impone a la experiencia y al juicio sereno. Usamos la Burney Collection y Google Books de todos modos, jugando una especie de ruleta de la investigación disfrazada de erudición tradicional.

*

Hasta aquí, este artículo se ha concentrado en lo que está mal en los recursos que usamos y ha dado a entender que bibliotecarios, multinacionales, programadores y matemáticos nos vendieron un producto defectuoso. Pero eso sería culpar al mecánico y a los constructores de la carretera por los actos del conductor ebrio al volante. Nuestra propia falta de compromiso es igualmente significativa. No hemos establecido los nuevos sistemas de referencia y validación necesarios que harían transparente y repetible nuestro uso de estos recursos. 22 Todavía no he visto un trabajo de historia académica que sea explícito acerca de su dependencia de la búsqueda por palabras clave y de las fuentes electrónicas. Como editores y autores, aceptamos y escribimos notas al pie que tergiversan el proceso de investigación. Como docentes, en gran medida no logramos inculcar una relación crítica con el texto electrónico real que pedimos a nuestros estudiantes que lean y,

en cambio, los alentamos a fingir que están sentados con un libro polvoriento en las manos. Y como intelectuales pagados con fondos públicos, ignoramos nuestra obligación de cuestionar la calidad de los datos que encontramos en el mundo en general.

En parte, la respuesta es sencilla. Lo que se requiere es una comprensión mucho más clara, por parte de todos nosotros, de qué creemos exactamente que estamos haciendo con las fuentes y de cómo se corresponden con lo que producimos como investigadores. Necesitamos tomar distancia e interrogar explícitamente cómo se relacionan las taxonomías del conocimiento más antiguas con las iteraciones más nuevas de la representación, y tener claro qué formas de representación y citación académicas son más útiles y satisfacen más plenamente los requisitos de reproducibilidad y trazabilidad. Necesitamos interrogar la criba y la selección incorporadas en el texto procesado por OCR; necesitamos registrar nuestras búsquedas como parte de nuestra metodología de investigación (y formar a nuestros estudiantes para que lo hagan); y necesitamos citar los sitios web y recursos en línea que efectivamente usamos, en lugar de fingir que no existen. En el entorno académico maduro que heredamos, muchas de estas tareas se delegaban en archivistas y bibliotecarios, lo que nos permitía construir sobre sus cimientos incuestionados. Pero como esos cimientos se han desplazado, necesitamos volver a inspeccionar toda la estructura.

Esto, al menos, nos obligaría a un estándar académico más elevado, pero no abordaría la oportunidad que lo en línea y lo digital también presentan. Puesto que todos usamos búsquedas por palabras clave para localizar textos en un mar de conocimiento desarraigado, es hora de interrogar con más seriedad lo que este nuevo entorno de conocimiento hace posible, al tiempo que somos más honestos acerca de lo que dificulta.

En 1962, Louis Mumford observó que 'minds unduly fascinated by computers carefully confine themselves to asking only the kind of question that computers can answer' [las mentes indebidamente fascinadas por las computadoras se limitan cuidadosamente a plantear sólo el tipo de pregunta que las computadoras pueden responder]. 23 En las últimas dos décadas, los historiadores que siguen presentando su investigación como lectura de 'libros y artículos' se han limitado a plantear sólo el tipo de preguntas que los libros y artículos físicos pueden responder. Cincuenta años es mucho tiempo en la informática (y en la investigación histórica), y es hora de averiguar si una relación crítica y

conscientemente académica con las computadoras y el archivo infinito no podría permitirnos ahora hacer algo más. Es algo maravilloso cuando una búsqueda por palabras clave devuelve una cita demoledora y un ejemplo contundente. La observación de Louis Mumford citada más arriba se localizó precisamente de este modo. Pero eso no es investigación.

Además de desafiar nuestros sistemas de representación y transmisión de la investigación académica, la digitalización del archivo infinito ofrece una manera de hacer más de lo que nunca antes había sido posible. Ahora podemos relacionarnos con ese nuevo recurso de nuevas maneras, pero para ello necesitamos investigadores capaces de trabajar con fuentes antiguas en su nuevo ropaje digital y que reconozcan que lo digital las vuelve diferentes. No se trata sólo de ser explícitos acerca de nuestro uso de la búsqueda por palabras clave: se trata de ir más allá de una forma tradicional de investigación académica hacia el modelado de datos y hacia lo que Franco Moretti llama 'distant reading' [lectura distante]. 24 Necesitamos reconocer que ya no estamos leyendo libros y artículos, sino trabajando con enormes corpus de texto digital, en los que la diferencia entre un volumen y otro es poco más que una o dos líneas de metadatos.

A pesar de las salvedades sobre el OCR y los metadatos expuestas más arriba, la existencia de una edición digital del archivo impreso occidental nos permite comenzar a modelar su contenido de nuevas maneras. Con un esfuerzo mínimo podemos simplemente contar palabras y ver cómo se distribuyen entre años, lugares de publicación, géneros y formatos, y comparar los resultados con la versión de esta misma información incorporada en la investigación académica posilustrada (todo sistema de catalogación es un intento de mapear precisamente esto). ¿Las novelas se volvieron más largas además de más numerosas? ¿Cómo se distribuían las palabras entre los géneros? ¿Qué cambia cuando se mide el texto en lugar de los 'libros'? O, de manera más ambiciosa, podríamos usar las herramientas de la minería de datos y de la lingüística de corpus para categorizar el material heredado según su contenido textual y semántico, rastreando conjuntos de emociones, ideas o formas descriptivas a través de obras que durante mucho tiempo han estado separadas por formas de clasificación más antiguas. Mapear el lenguaje siempre cambiante del afecto, por ejemplo, a través de los géneros y medido en relación con la densidad textual, nos daría nuevas formas de caracterizar y conectar colecciones de texto dispares: crónicas policiales y novelas; poesía y preceptos jurídicos. Tenemos la oportunidad tanto

de poner a prueba y revisar las taxonomías del conocimiento que heredamos como de extenderlas, de toscas pilas de libros a sutiles mapas de significado.

Quizás contra lo que dicta la intuición, esto no socavaría las formas tradicionales de investigación académica, sino que las fortalecería y les daría mayor alcance intelectual. Crear esta nueva edición infinita del archivo impreso occidental como objeto de estudio por derecho propio, y mapear la distribución del lenguaje sobre su superficie, elevaría el estándar crítico con el que leemos todo tipo de evidencia. Proporcionaría un contexto nuevo y sutil para cada palabra y cada frase. En el proceso, volvería más convincente tanto el tipo de 'descripción densa' que ha resultado tan productiva en nuevas comprensiones durante las últimas tres décadas como el uso de citas y ejemplos en la descripción sintética. Si tan sólo pudiéramos representar el proceso de investigación que nos condujo hasta allí de una manera explícita y académica, y si pudiéramos comprometernos a formar a nuestros estudiantes en las destrezas críticas que necesitan para navegar este mar de datos, podríamos tener una materia que se pareciera más a una 'disciplina' de lo que se parece en este momento. No se trata simplemente de estar a la altura de los estándares académicos que heredamos, sino de ir más allá de ellos.

Ha pasado una docena de años desde que se lanzaron en la World Wide Web los primeros grandes recursos históricos, y una década desde que la publicación en línea del primer censo demostró más allá de toda duda razonable la existencia de una profunda demanda popular de historia en línea, y la distancia que la historia académica había recorrido inadvertidamente respecto de ese público más amplio. Pero los historiadores académicos todavía no han abordado eficazmente las implicaciones de lo en línea y lo digital para su investigación, ni han estado a la altura del desafío que estos recursos plantean. Necesitamos saber sobre OCR y metadatos, y sin duda necesitamos aprender a usar las herramientas de la minería de datos, los SIG y la lingüística de corpus; y necesitamos ser capaces de manejar las herramientas de visualización a gran escala, impulsadas por las ciencias duras, la teoría de redes y el análisis de 'big data' del tipo implementado en el Google NGram viewer. 25 Y necesitamos hacerlo al mismo tiempo que preservamos los valores y las prácticas que sustentan la historia académica tradicional, yendo a la vez más allá de los estándares académicos que heredamos. Necesitamos exigir que los recursos que pagan nuestras universidades, y las revistas para las que todos evaluamos y que editamos, estén a la altura del desafío de lo digital, al tiempo que nos aseguramos de que nuestros estudiantes estén

preparados con las destrezas y la experiencia que necesitan para navegar este nuevo mar de datos.

NOTAS

- En una entrada del blog corporativo, del 5 de agosto de 2010 (8:26 a.m.), Leonid Taycher, ingeniero de software empleado por Google, afirmó que había 129,864,880 libros en el mundo. Véase Leonid Taycher, 'Books of the World, Stand up and Be Counted! All 129,864,880 of You' (http://booksearch.blogspot.co.uk/2010/08/books-of-world-stand-up-and-becounted.html); Google Books Search (http://booksearch.blogspot.co.uk/).
- El atolladero jurídico en el que se ha visto envuelto el Google Books Settlement en los Estados Unidos probablemente tenga un impacto significativo en el desarrollo de este nuevo entorno digital, pero las iniciativas
- emprendidas tanto en Europa como en los Estados Unidos para crear 'bibliotecas digitales nacionales' y el continuo interés comercial y estatal en el proyecto más amplio sugieren que no habrá una desaceleración sustancial en el ritmo de la digitalización en un futuro cercano. Sobre los problemas asociados al Google Books Settlement, véase James Grimmelmann, 'The Elephantine Google Books Settlement', 24 de agosto de 2011 (http://works.bepress.com/cgi/viewcontent.cgi?article=1031&context=james_grimmelmann).
- La relativa escasez de materiales no occidentales disponibles en formato digital es particularmente digna de mención, y sugiere que el propio proceso de digitalización está reproduciendo de hecho una especie de hegemonía cultural occidental que no sería aceptable si fuera producto de una política deliberada.
- Véanse Google Books (http://books.google.co.uk/bkshp?hl=en&tab=wp), Early English Books Online (EEBO) (http://eebo.chadwyck.com/home) y Eighteenth Century Collections Online (ECCO) (http://gale.cengage.co.uk/product-highlights/history/eighteenthcentury-collections-online.aspx), The Times Digital Archive (http://gale.cengage.co.uk/ times.aspx/), las colecciones de periódicos de la British Library (http://www.bl.uk/welcome/ newspapers.html), Project Gutenberg (http://www.gutenberg.org/) y el Million Book Project (http://archive.org/details/millionbooks), los Parliamentary Papers (http://parlipapers. chadwyck.co.uk/marketing/index.jsp), los Nineteenth Century Censuses (http://www. nationalarchives.gov.uk/records/census-records.htm), la Clergy of the Church of England Database

(http://www.theclergydatabase.org.uk/index.html) y Old Bailey Online (http://www.oldbaileyonline.org/). Incluso el pequeño subconjunto de fuentes primarias para la historia británica de 1500 a 1900 disponible a través del sitio Connected Histories (http://www. connectedhistories.org/Default.aspx), que actualmente (6 de diciembre de 2011) excluye todos los libros e incluye sólo colecciones más grandes que cumplen un estándar mínimo de presentación académica, supera los diez mil millones de palabras de texto y las 140,000 imágenes. Cabe señalar que el autor ha dedicado los últimos doce años a ayudar a crear cuatro recursos web sustanciales: Old Bailey Online; London Lives, 1690-1800, (http://www. londonlives.org/); Connected Histories, y Locating London's Past (http://www. locatinglondon.org/index.html), y está plenamente implicado en el proceso y en el proyecto.

- Esto no pretende denigrar los numerosos proyectos de digitalización, principalmente de pequeña escala, dirigidos por académicos y orientados en general a abordar preguntas de investigación específicas. Transcribe Bentham (http://www.ucl.ac.uk/transcribe-bentham/), The Newton Project (http://www. newtonproject.sussex.ac.uk/prism.php?id=1) y The Electronic Enlightenment (http:// www.e-enlightenment.com/), por tomar sólo tres ejemplos entre muchos otros, representan un alto estándar académico y fueron creados en busca de respuestas a preguntas académicas serias. Pero, por su naturaleza, y en comparación con los grandes proyectos comerciales de digitalización, representan una pequeña parte de un paisaje en línea más amplio de materiales históricos.
- Muchos de los bibliotecarios y archivistas involucrados en el proceso más amplio de digitalización son empleados de universidades o de grandes bibliotecas de investigación y se considerarían a sí mismos 'académicos', pero la adopción generalizada del término 'alt-ac' (alternative-academic, académico alternativo) para describir las carreras de las personas involucradas refleja la distancia entre la disciplina académica profesional de la historia y las personas más plenamente comprometidas con el proyecto más amplio. Véase Bethany Nowviskie, '#alt-ac: Alternate Academic Careers for Humanities Scholars', 3 de enero de 2010 (http://nowviskie.org/2010/alt-ac/, consultado el 4 de mayo de 2012).
- Valerie Johnson y David Thomas, 'New Universes or Black Holes? Does Digital Change Anything?', en Toni Weller (ed.), History in the Digital Age (Oxon. and London, en prensa, 2012). Esta cifra excluye los datos de la British Library (que no estaban disponibles) y el dinero generado para organizaciones como los

National Archives mediante su participación en proyectos digitales comerciales. Cabe señalar que incluso este total de diez años resulta ínfimo frente a

- la suma que se gasta cada año en apoyar formas más tradicionales de investigación humanística.
- Véase Nancy L. Maron y Matthew Loy, 'Funding for Sustainability: How Funders' Practices Influence the Future of Digital Resources', junio de 2011, p. 9, nota 3 (http://www.jisc.ac.uk/media/documents/programmes/contentalliance/ sandrfundingforsus tainability.pdf). De los proyectos del NOF, aproximadamente el 15 por ciento estaba radicado en universidades y otro 20 por ciento en instituciones académicas reconocidas como los National Archives y la British Library, pero los proyectos de todo el programa sufrieron una tasa de fracaso similar.
- El sistema Je-S entró en funcionamiento en mayo de 2003, y el primer uso del sistema por parte del AHRB/C se registró en junio de 2005. Véase Je-S Help (https://je-s.rcuk.ac.uk/Handbook/index.htm# pages/JeSHelpdesk.htm).
- Es difícil acceder a información local y específica de cada disciplina en este ámbito, pero para una visión general de los patrones de concentración de la edición de revistas en el conjunto de la academia, véase Corinne M. Flick (en cooperación con el Oxford Internet Institute), Geographies of the World's Knowledge (Oxford, 2011), http://www.oii.ox.ac.uk/publications/convoco_ geographies_en.pdf, pp.14-19. A nivel internacional, los actores más grandes son Elsevier, Wiley, Springer y Taylor and Francis.
- El sistema más común utilizado para este 'mapeo gráfico' se llama Olive. Véase http:// www.olivesoftware.com/.
- Simon Tanner, Trevor Muñoz y Pich Hemy Ros, 'Measuring Mass Text Digitization Quality and Usefulness', D-Lib Magazine, 15(7/8) (2009), http://www.dlib.org/dlib/ july09/munoz/07munoz.html. Se destaca aquí la Burney Collection sólo porque existe una evaluación detallada de ella. Es en gran medida representativa de otros sitios que ofrecen texto procesado por OCR, y mejor que muchos.
- Seventeenth and Eighteenth Century Burney Collection of newspapers (http://www. bbk.ac.uk/lib/elib/databases/newspapers/burney): Daily Advertiser (London, England), Saturday 16 May 1778; Issue 14784, Gale Document Number: Z2000162519. Esta selección de OCR en bruto se construyó encadenando fragmentos de texto expuestos como parte de los resultados de

búsqueda en Connected Histories. Es imposible enlazar directamente a este texto, ya que el sistema de licencias utilizado por Gale Cengage incorpora datos de acceso local en la URL. Una transcripción exacta de este texto diría: '"It is supposed that we have actually 40 Frigates at Sea for the Protection of our Trade. The St. Domingo Fleet is safely arrived at La Rochelle with a rich Cargo. Its Arrival is the more agreeable to the Merchants, as there was not a Ship of the whole Fleet insured." Extract of a Letter from Mr. Coxwood, mate of the Ulster, Victualler from Cork for New-York, dated Boston, March 30. "On the 26 th of January we fell in with an American Privateer, commanded by Captain Bailey, called the Flower of the Sea, of 26 Guns and 180 Men, to which Vessel we were obliged to strike after discharging our Guns, six four Pounders. We were towed into this Place by the Privateer the 23d instant, after a very dangerous Passage, having carried away all our Masts."' ["Se supone que tenemos actualmente 40 fragatas en el mar para la protección de nuestro comercio. La flota de Santo Domingo ha llegado a salvo a La Rochelle con un rico cargamento. Su llegada resulta tanto más grata para los comerciantes cuanto que no había un solo barco de toda la flota asegurado". Extracto de una carta del Sr. Coxwood, oficial del Ulster, buque de avituallamiento de Cork a Nueva York, fechada en Boston el 30 de marzo. "El 26 de enero nos topamos con un corsario estadounidense, comandado por el capitán Bailey, llamado Flower of the Sea, de 26 cañones y 180 hombres, ante cuyo buque nos vimos obligados a arriar bandera tras disparar nuestros cañones, seis de cuatro libras. Fuimos remolcados a este lugar por el corsario el 23 del corriente, tras una travesía muy peligrosa, en la que perdimos todos nuestros mástiles".]

- Según Wikipedia, la superficie en acres legales del condado administrativo de Hertfordshire en 1891 era de 406,932. El artículo correspondiente cita en nota al pie el informe censal de esa fecha. Véase 'Administrative counties of England' en Wikipedia (http://en.wikipedia.org/wiki/Administrative_counties_of_England#Area_and_population, consultado el 6 de diciembre de 2011). Curiosamente, usuarios más sofisticados, que conocieran más a fondo el paisaje digital y las fuentes originales, podrían haber recurrido a la edición altamente académica y exhaustiva de este material disponible a través de Histpop: The Online Historical Population Reports Project (http://www.histpop.org/ohpr/servlet/Show?page=Home), un sitio que ofrece acceso completo a los informes censales originales. Pero si lo hubieran hecho, se habrían encontrado con tres superficies distintas para Hertfordshire en 1891: la del condado antiguo, la del condado

- administrativo (utilizada en Wikipedia) y la del condado de registro.
- Véanse, por ejemplo, Arel Dornfest y Tara Calishain, Google Hacks: Tips and Tools for Smarter Searching, 3rd edn (Sebastopol, CA, 2006) y David Viney, Get to the Top on Google: Tips and Techniques to Get Your Site to the Top of Google and Stay There (London, 2008).
- Para un relato accesible de estos desarrollos, y de la evolución del algoritmo de Google en general, véase Steven Levy, 'Exclusive: How Google's Algorithm Rules the Web', Wired, 22 de febrero de 2010 (http://www.wired.com/magazine/2010/02/ff_ google_algorithm/).
- La descripción que Google ofrece de este proceso hace de sus resultados siempre cambiantes una auténtica virtud: 'When you perform a search, the results are often displayed with the information: About XXXX results (X seconds). Google's calculation of the total number of search results is an estimate. We understand that a ballpark figure is valuable, and by providing an estimate rather than an exact account, we can return quality search results faster. In addition, when you click on the next page of search results, the total number of search results can change. Google's search index is constantly changing, and your second search results page may come from a slightly different version of the index than the first page.' [Cuando usted realiza una búsqueda, los resultados suelen mostrarse con la información: Aproximadamente XXXX resultados (X segundos). El cálculo que hace Google del número total de resultados de búsqueda es una estimación. Entendemos que una cifra aproximada es valiosa y, al proporcionar una estimación en lugar de un recuento exacto, podemos devolver resultados de búsqueda de calidad con mayor rapidez. Además, cuando usted hace clic en la página siguiente de resultados, el número total de resultados puede cambiar. El índice de búsqueda de Google cambia constantemente, y su segunda página de resultados puede provenir de una versión del índice ligeramente distinta de la de la primera página.] (http://support.google. com/webmasters/bin/answer.py?hl=en&answer=70920).
- Estas búsquedas se realizaron desde mi computadora personal, ubicada en Muswell Hill, Reino Unido, el 8 de diciembre de 2011 y, como se explica en el texto, no pueden repetirse ni citarse de manera efectiva.
- Véase Geoffrey Nunberg, 'Google Books: A Metadata Train Wreck', Language Log, 29 de agosto de 2009 (http://languagelog.ldc.upenn.edu/nll/?p=1701).

- Véase la página web del BISG que anuncia los encabezamientos de materia BISAC, edición 2011 (http://www. bisg.org/publications/product.php?p=149, consultado en diciembre de 2011).
- Quizás sea odioso señalar un solo ejemplo, pero sólo cuando el proyecto de la Clergy of the Church of England Database intentó utilizar la información detallada contenida en la Guide to the Local Administrative Units of England de la Royal Historical Society (Frederic A. Young, vol. 1, 1979, vol. 2, 1991) se hizo evidente el carácter incoherente de muchas de sus entradas.
- Uno vuelve la mirada hacia la Royal Historical Society, la Historical Association o la British Academy, o espera una orientación clara de las principales editoriales y revistas académicas.
- Lewis Mumford, 'The Sky Line "Mother Jacob's Home Remedies"', New Yorker, 1 de diciembre de 1962, p. 148 (http://www.newyorker.com/archive/1962/12/01/1962_12_01_148_TNY_CARDS_000269697). Esta observación se hizo como un comentario al margen dirigido a los urbanistas en una reseña de un libro de Jane Jacobs. Se localizó a partir de una referencia medio recordada en un artículo de un periódico popular que desde entonces he tirado, y de una búsqueda en Google de la frase 'questions that computers can answer' [preguntas que las computadoras pueden responder].
- Franco Moretti, Graphs, Maps, Trees: Abstract Models for a Literary History (London, 2005).
- Jean-Baptiste Michel*, Yuan Kui Shen, Aviva Presser Aiden, Adrian Veres, Matthew K. Gray, William Brockman, The Google Books Team, Joseph P. Pickett, Dale Hoiberg, Dan Clancy, Peter Norvig, Jon Orwant, Steven Pinker, Martin A. Nowak and Erez Lieberman Aiden*, 'Quantitative Analysis of Culture Using Millions of Digitized Books', Science (published online ahead of print:, 16 December 2010, http://www.sciencemag.org/content/331/6014/176.full).