盟

Artículo

# Desempeño comparativo de YOLOv8, YOLOv9, YOLOv10 y YOLOv11 para el análisis del diseño de página en imágenes de documentos históricos

Eder Silva dos Santos Júnior * , Thuanne Paixão and Ana Beatriz Alvarez

PAVIC Laboratory, University of Acre (UFAC), Rio Branco 69915-900, Brazil; thuannepaixao@gmail.com (T.P.); ana.alvarez@ufac.br (A.B.A.)

* Correspondencia: eng.edersilva@gmail.com

Resumen: La digitalización de documentos históricos resulta de interés por muchas razones, entre ellas la preservación histórica, la accesibilidad y la posibilidad de realizar búsquedas. Uno de los principales desafíos de la digitalización de periódicos antiguos es el complejo análisis del diseño de página, en el que deben determinarse los tipos de contenido del documento. En este contexto, este artículo presenta una evaluación de los métodos YOLO más recientes para el análisis del diseño de página de documentos históricos. En primer lugar, se creó y se puso a disposición un nuevo conjunto de datos denominado BHN, que se destaca como el primer conjunto de datos de periódicos históricos brasileños para la detección del diseño de página. Los experimentos se realizaron con las arquitecturas YOLOv8, YOLOv9, YOLOv10 y YOLOv11. Para el entrenamiento, la validación y la prueba de los modelos se combinaron los siguientes conjuntos de datos de periódicos históricos: BHN, GBN y Printed BlaLet GT. Para evaluar el desempeño de los modelos se utilizaron la exhaustividad (recall), la precisión y la precisión media promedio (mAP). Los resultados indican que el modelo con mejor desempeño fue YOLOv8, con un Recalltest del 81% y un mAPtest del 89%. Este artículo ofrece elementos de juicio sobre las ventajas de estos modelos en la detección del diseño de página de documentos históricos y, además, contribuye a mejorar la conversión de imágenes de documentos a formatos editables y accesibles.

Palabras clave: documentos históricos; análisis del diseño de página; aprendizaje profundo; detección de objetos; YOLO

## 1. Introducción

Numerosos proyectos de digitalización masiva han cobrado relevancia en distintas partes del mundo [1]. Estas iniciativas permiten convertir a formato digital materiales de gran importancia histórica, cultural y literaria que, de otro modo, normalmente sólo podrían encontrarse en museos [2,3]. Sin embargo, investigar sobre imágenes digitales es una tarea difícil; en consecuencia, el material disponible para el estudio no se ha explorado por completo. Este problema comenzó a abordarse a principios de la década de 1990, cuando empezaron a desarrollarse algoritmos de análisis de imágenes de documentos con el objetivo de extraer información de ellas de manera semejante a como lo haría un ser humano [4].

Un enfoque ampliamente utilizado para extraer texto de imágenes es el reconocimiento óptico de caracteres (OCR, por sus siglas en inglés), una técnica capaz de convertir documentos digitales en documentos legibles por máquina [5]. Una de las etapas del OCR es el análisis del diseño de página, que consiste en localizar las regiones del diseño presentes en las imágenes de los documentos y que tiene una importancia fundamental para obtener un buen resultado de OCR [6]. Aunque el OCR ha tenido un buen desempeño con documentos modernos, su rendimiento se reduce significativamente cuando se trata de documentos históricos [5,7].

En el caso de los periódicos históricos, los desafíos del proceso de análisis del diseño de página son evidentes, debido a características como los distintos tamaños y estilos de fuente, la cantidad de columnas,

Editor académico: Pedro Couto

Recibido: 15 de febrero de 2025

Revisado: 7 de marzo de 2025

Aceptado: 7 de marzo de 2025

Publicado: 14 de marzo de 2025

Cita: Santos Júnior, E.S.d.; Paixão, T.; Alvarez, A.B. Comparative Performance of YOLOv8, YOLOv9, YOLOv10, and YOLOv11 for Layout Analysis of Historical Documents Images. Appl. Sci. 2025, 15, 3164. https://doi.org/10.3390/app15063164

Copyright: © 2025 de los autores. Licenciatario MDPI, Basilea, Suiza. Este artículo es de acceso abierto y se distribuye según los términos y condiciones de la licencia Creative Commons Attribution (CC BY) (https://creativecommons.org/licenses/by/4.0/).

el ancho de las columnas, la presencia de divisores de columna, etc. [8]. Según [9], la mayoría de los algoritmos descritos en la bibliografía se desarrollaron para reconocer documentos contemporáneos, como revistas y libros, con diseños y fuentes más regulares. Por esta razón, los sistemas de OCR de código abierto existentes, como Tesseract y EasyOCR, no son capaces de identificar correctamente las regiones de texto de los periódicos históricos, lo que compromete el resultado final del OCR [6].

Los estudios relacionados muestran que, en los últimos años, los métodos basados en aprendizaje profundo se han convertido en los más populares entre los investigadores para el análisis del diseño de documentos [10]. El uso de arquitecturas avanzadas como los modelos YOLO, por ejemplo, en tareas de detección de objetos ofrece una potente combinación de precisión y velocidad [11-13], crucial para el análisis del diseño de página.

Cabe destacar los siguientes estudios: la ref. [14] utilizó el enfoque de Faster RCNN y Mask R-CNN como un marco unificado de detección de objetos gráficos para el análisis del diseño de gráficos; la ref. [15] utilizó redes siamesas, que consisten en dos redes neuronales convolucionales idénticas, para detectar manuscritos árabes; la ref. [16] propuso LayoutLM, un algoritmo capaz de modelar conjuntamente las interacciones entre el texto y la información de diseño en imágenes de documentos escaneados; la ref. [17] propuso DocFormer, una arquitectura multimodal basada en transformers para la tarea de comprensión visual de documentos (Visual Document Understanding); la ref. [18] propuso LayoutLMv3, el primer modelo multimodal que no depende de una CNN preentrenada ni de Faster R-CNN para extraer características visuales; [19] presentó DiffusionDet, un nuevo marco que formula la detección de objetos como un proceso de difusión con eliminación de ruido que va de cajas ruidosas a cajas de objetos; la ref. [20] propuso el Real-Time Detection Transformer (RT-DETR), un detector de objetos basado en transformers para tiempo real que evita el uso de NMS; la ref. [21] presentó DocLayout-YOLO, un enfoque novedoso que mejora la exactitud manteniendo las ventajas de velocidad mediante optimizaciones específicas para documentos tanto en el preentrenamiento como en el diseño del

modelo; la ref. [22] propuso DocFusion, un modelo generativo ligero para tareas de análisis sintáctico de documentos; la ref. [23] realizó un análisis comparativo entre las arquitecturas YOLOv5s y YOLOv5m aplicadas a un conjunto de datos propio que contenía principalmente imágenes de libros en inglés y árabe; la ref. [24] aplicó un modelo YOLOv8 de alta exactitud a tres conjuntos de datos de imágenes de documentos: ICDAR-POD, PubLayNet e IIIT-AR-13K; la ref. [25] propuso un modelo de DLA de una sola etapa, un former de fusión cruzada multiescala denominado YOLOLayout; la ref. [26] entrenó y evaluó un modelo para la detección del diseño y el OCR de documentos históricos del siglo XIX, y el método propuesto se comparó con el motor de OCR estándar Tesseract; la ref. [27] propuso EDocNet, una red neuronal convolucional ligera compuesta por múltiples capas separables en profundidad para analizar documentos de dispositivos electrónicos.

Más recientemente, las arquitecturas basadas en transformers, como DocFormer y LayoutLM, también han surgido como una alternativa prometedora [10]. Sin embargo, los modelos basados en YOLO ofrecen beneficios significativos, como la inferencia en tiempo real y una menor complejidad computacional, lo que los hace más adecuados para aplicaciones en las que la velocidad es esencial. Además, la necesidad de grandes volúmenes de datos etiquetados para entrenar transformers puede ser un obstáculo en el caso de los documentos históricos, para los que la cantidad de datos disponibles es reducida. Mientras que los transformers requieren grandes volúmenes de datos anotados para lograr un desempeño satisfactorio, YOLO es más robusto con conjuntos más pequeños. Asimismo, modelos como LayoutLM están más orientados a tareas que implican interpretación semántica y extracción de texto, mientras que YOLO se especializa en la detección eficiente de objetos dentro de imágenes.

En este contexto, se observa un número limitado de estudios relacionados sobre el análisis del diseño de página en documentos históricos germano-brasileños con técnicas de aprendizaje profundo. Al considerar los conjuntos de datos de periódicos históricos con tipografía gótica, como el German–Brazilian Newspaper (GBN) Dataset, creado en el estudio de [6] con anotaciones para el análisis del diseño de página y el OCR, y el conjunto de datos Printed BlaLet GT [28], no se encontraron referencias que investigaran el análisis del diseño de página. Por lo tanto, existe un vacío en la bibliografía que debe llenarse en lo que respecta al uso de técnicas de aprendizaje profundo en periódicos históricos germano-brasileños.

Este trabajo propone un nuevo conjunto de datos anotado para el análisis del diseño de página de periódicos históricos brasileños y, además, realiza un análisis comparativo del desempeño de las arquitecturas YOLOv8 a YOLOv11 sobre un conjunto de datos combinado, a fin de investigar cuál es la mejor para la tarea de OCR. Así, este estudio aporta un conjunto de datos original para enriquecer el área del análisis del diseño de página de documentos históricos, en la que escasean los datos disponibles —especialmente los anotados— para estudios de detección del diseño. Además, los resultados obtenidos revelan el desempeño de los modelos YOLO actuales en un conjunto de datos compilado para esta aplicación, lo que muestra el potencial de los modelos para futuras investigaciones y para el desarrollo de tecnologías de OCR más robustas para el reconocimiento de documentos históricos.

En síntesis, las principales contribuciones de este estudio son:

- Creación y puesta a disposición de un conjunto de datos de periódicos históricos brasileños para el análisis del diseño de página, denominado "Brazilian Historical Newspaper" [Periódico Histórico Brasileño] (BHN). Como una de las principales contribuciones de este artículo, se creó el primer conjunto de datos de periódicos históricos brasileños con anotaciones para la detección del diseño de página.
- Elaboración de un conjunto de datos combinado, que reúne los conjuntos de datos BHN, GBN y Printed BlaLet GT, compuesto por 459 imágenes de documentos históricos anotadas para el análisis del diseño de página. Tras organizar los datos y revisar las anotaciones, el conjunto de datos se puso a disposición del público en el sitio web de Roboflow (www.roboflow.com, consultado el 25 de septiembre de 2024).
- Análisis comparativo del desempeño de las arquitecturas YOLOv8, YOLOv9, YOLOv10 y YOLOv11 en la tarea de análisis del diseño de página, entrenadas sobre el conjunto de datos combinado. Como se explica en la Sección 2.3, estas arquitecturas se seleccionaron por su velocidad, su facilidad de implementación y su adecuación a la tarea de análisis del diseño de página. Este artículo pone de relieve el potencial de estas arquitecturas en el análisis del diseño de página, en el que se obtuvieron resultados significativos que no sólo demuestran la eficacia de las arquitecturas, sino que también motivan nuevas investigaciones científicas en el área.

Este artículo se organiza de la siguiente manera: la Sección 2 aborda la metodología general utilizada en la investigación; la Sección 3 presenta los resultados y la discusión; y, por último, la Sección 4 contiene las conclusiones de la investigación y sugerencias para estudios futuros.

## 2. Materiales y métodos

La metodología general seguida en esta investigación se ilustra en la Figura 1, que muestra el proceso desde la fusión del conjunto de datos hasta la evaluación de los algoritmos de aprendizaje profundo.

Figura 1. Diagrama de flujo del experimento llevado a cabo.

Para los experimentos se seleccionaron tres conjuntos de datos con anotaciones para el análisis del diseño de página que mejor cumplían los requisitos del estudio: el conjunto de datos BHN (nuestro conjunto de datos), el conjunto de datos GBN

y el conjunto de datos Printed Black Letter GT (BlaLet GT), que luego se combinaron en un único conjunto de datos. Este proceso se describe con más detalle en las Secciones 2.1 y 2.2. Tras organizar los datos y revisar las marcaciones con la herramienta roboflow, el conjunto de datos se dividió en conjuntos de entrenamiento, validación y prueba, y las anotaciones se exportaron en el formato adecuado para las arquitecturas.

A continuación, las cuatro arquitecturas seleccionadas (YOLOv8, YOLOv9, YOLOv10 y YOLOv11), que se explican en la Sección 2.3, se entrenaron con los datos de entrenamiento y validación. Los algoritmos de entrenamiento se ejecutaron con los hiperparámetros presentados en la Sección 2.4, y se generaron los pesos personalizados de cada arquitectura. Luego, estos modelos se aplicaron al conjunto de prueba para obtener las métricas de evaluación, que proporcionan el desempeño de los modelos. Para comparar las arquitecturas se seleccionaron las principales métricas de detección de objetos descritas en la Sección 2.5.

Los experimentos se implementaron en el software VS Code, un entorno de desarrollo integrado (IDE, por sus siglas en inglés) en el que se compiló el código y se pudieron entrenar y evaluar los algoritmos. En el IDE se utilizó el lenguaje de programación Python, elegido porque se usa ampliamente en el campo del aprendizaje profundo [29].

## 2.1. Conjunto de datos propuesto: Brazilian Historical Newspaper (BHN)

El conjunto de datos se elaboró con imágenes de páginas de periódicos históricos brasileños. Estas imágenes se obtuvieron gratuitamente del sitio web de la Biblioteca Nacional Digital de Brasil (BND) (https://bndigital.bn.gov.br/, consultado el 6 de septiembre de 2024). Dado el foco en los documentos históricos, se seleccionaron dos periódicos de la categoría "19th century periodicals" [publicaciones periódicas del siglo XIX]: el "Compilador Mineiro" y el "Recopilador Sergipano".

A continuación, se descargaron en formato .png todas las imágenes disponibles en la BND de estos dos periódicos. Esto dio como resultado un total de 140 imágenes de periódicos brasileños para la construcción del conjunto de datos propuesto. Para anotar estos datos se utilizó la herramienta roboflow, un sitio web en el que es posible crear conjuntos de datos, preprocesarlos, dividir los datos en entrenamiento, validación y prueba, entre otros usos [30]. Allí fue posible cargar las imágenes y marcar las anotaciones, también denominadas verdad de referencia (Ground Truth, GT) del conjunto de datos.

En la detección de objetos, la GT consiste en cuadros delimitadores que indican la ubicación del objeto, los cuales deben estar presentes en el conjunto de datos para entrenar el algoritmo, que utiliza esta información como referencia para validar el aprendizaje. Además de aprender a localizar las regiones del diseño del documento, el algoritmo debe aprender a especificar la categoría de la región. En las imágenes del conjunto de datos se observó la presencia de las siguientes categorías: texto, imagen, gráfico, tabla y separador.

La Figura 2a muestra uno de los ejemplos del conjunto de datos y la Figura 2b, la GT correspondiente, realizada manualmente con roboflow. En este caso, el cuadro delimitador violeta indica que la región corresponde a la clase texto, mientras que el color verde remite a la clase gráfico y el color rojo, a la clase separador.

El BHN es el primer conjunto de datos de periódicos históricos brasileños marcado para la detección del diseño de página y puede descargarse mediante el siguiente enlace: https://app.roboflow.com/myworkspace-wzeqx/brazilian_historical_newspaper/4 (consultado el 6 de septiembre de 2024). En esta versión, el conjunto de datos, con un total de 140 imágenes, se divide en un 80% para entrenamiento (112 imágenes)

y un 20% para validación (28 imágenes). Cabe señalar que la clase separador se descartó del conjunto de datos porque no representa un contenido tan importante para el análisis del diseño de página como, por ejemplo, las regiones de texto, que son esenciales para la tarea de OCR.

Para los experimentos con los detectores de objetos, el conjunto de datos BHN se fusionó con otros dos conjuntos de datos de periódicos históricos, como se describe en la Sección 2.2. Esto dio como resultado un conjunto de datos unificado con un mayor número de imágenes, lo que permitió entrenar los modelos con más datos y lograr una mejor generalización.

(a)

Figura 2. Marcaciones de imágenes del conjunto de datos BHN, que muestran: (a) imagen fuente; (b) verdad de referencia, donde el cuadro delimitador violeta indica la clase texto, el color verde indica la clase gráfico y el color rojo indica la clase separador.

## 2.2. Conjunto de datos combinado y preprocesamiento

En este estudio se decidió combinar el conjunto de datos propuesto (BHN) con otros conjuntos de datos de periódicos históricos de la bibliografía, a fin de ejecutar los experimentos con un conjunto de datos más robusto. Buscamos en la bibliografía conjuntos de datos de periódicos históricos germano-brasileños u otros periódicos similares.

En [31] se elaboró una lista de tales conjuntos de datos que cumplían los siguientes requisitos: 1. deben estar abiertos para fines de investigación académica; 2. deben ser de fácil acceso y descarga; 3. deben estar compuestos, al menos en parte, por imágenes de periódicos históricos en lengua alemana; y 4. deben contener anotaciones del diseño de página (es decir, la GT).

Así, se utilizó un total de tres conjuntos de datos de periódicos históricos, incluido el BHN, con marcaciones adecuadas para la tarea de detección del diseño de página en documentos históricos. La Tabla 1 presenta una descripción de los conjuntos de datos, con información sobre la calidad de las imágenes, los puntos por pulgada (DPI), el formato y el número de páginas de los conjuntos de datos.

| Conjunto de datos | Imágenes | | | Páginas |
|---|---|---|---|---|

| | Calidad | DPI | Formato | |
|---|---|---|---|---|
| BlaLet GT | Gris | 224-521 | TIFF | 167 |
| GBN | Bitonal / RGB | 300 / 600 | PNG | 152 |
| BHN (nuestro) | RGB | 96 | PNG | 140 |

Tabla 1. Características de los conjuntos de datos seleccionados.

El primer conjunto de datos seleccionado fue el GBN Dataset (https://web.inf.ufpr.br/vri/databases/gbn/, consultado el 24 de agosto de 2023), que consta de 152 imágenes de páginas en color de ocho periódicos distintos pertenecientes al proyecto digital dbp de la iniciativa Dokumente.br, cuyo objetivo es reconstruir digitalmente la colección completa de estos periódicos [6]. El segundo conjunto de datos elegido, denominado BlaLet GT Dataset (https://github.com/impresso/NZZ-black-letter-ground-truth, consultado el 26 de octubre de 2023), contiene 167 imágenes de páginas del periódico suizo Neue Zürcher Zeitung [28]. Por último, el tercer conjunto de datos utilizado es el BHN, propuesto en este artículo y ya explicado en la Sección 2.1.

Los conjuntos de datos seleccionados presentan imágenes con un estilo de diseño similar, compuestas por páginas escaneadas de periódicos impresos entre los siglos XVIII y XX. Además de las imágenes, los conjuntos de datos incluyen la GT, que consiste en anotaciones de las coordenadas de cada elemento de contenido de las páginas.

Una vez seleccionados y organizados estos conjuntos de datos, los tres conjuntos se fusionaron para formar un único conjunto de datos con 459 imágenes de periódicos históricos, de las cuales 321 se destinaron al entrenamiento (70%), 69 a la validación (15%) y 69 a la prueba (15%). El procedimiento de combinación de los conjuntos de datos y su separación en datos de entrenamiento, validación y prueba también se realizó con roboflow. La Figura 3 muestra algunos ejemplos de imágenes del conjunto de datos final.

Figura 3. Imágenes de muestra del conjunto de datos.

Los conjuntos de datos originales comprendían las clases Texto, Imagen, Gráfico, Tabla y Separador. En los experimentos descartamos la categoría separador del conjunto de datos final, ya que no aporta información significativa para la comprensión del documento. La Tabla 2 muestra las clases evaluadas y el número de instancias de cada clase. Puede observarse que la distribución de las clases está desbalanceada: las clases mayoritarias son Texto y Gráfico, con un mayor número de instancias, y las clases minoritarias son Tabla e Imagen.

| Descripción | Cantidad |
|---|---|
| Texto | 14.333 |
| Imagen | 23 |
| Gráfico | 462 |
| Tabla | 42 |

Tabla 2. Clases evaluadas en los experimentos.

Las marcaciones se revisaron al final del proceso para corregir cuadros delimitadores incorrectos. La versión final del conjunto de datos, denominada merged_historical_newspaper Dataset (https://app.roboflow.com/myworkspace-wzeqx/merged_historical_newspaper/1, consultado el 25 de septiembre de 2024), está disponible en formato digital para su descarga. Cabe señalar que las imágenes tenían resoluciones distintas, pero en esta versión se redimensionaron a un tamaño estándar de 640 × 640 píxeles, como paso de preprocesamiento en la implementación de los experimentos.

## 2.3. Arquitecturas utilizadas

Las arquitecturas YOLOv8, YOLOv9, YOLOv10 y YOLOv11 se seleccionaron por sus probadas capacidades de desempeño en la detección de objetos y por su versatilidad en distintos escenarios. Los modelos YOLO son conocidos por su velocidad para detectar objetos en comparación con otros métodos de detección, como los transformers, que en general requieren más potencia de cómputo y más tiempo de inferencia. Esto es esencial en escenarios de digitalización a gran escala.

En tareas en tiempo real o que involucran grandes volúmenes de documentos históricos, la eficiencia de YOLO puede ser una ventaja significativa. Además, en el caso de los documentos históricos, en los que los datos son escasos y ruidosos, el uso de YOLO permite un pipeline más simple y eficiente para el entrenamiento y la inferencia. Así, los modelos YOLO se eligieron por su velocidad, su simplicidad y su adecuación a la tarea de detección del diseño de página.

A continuación se describen algunas de las características de cada arquitectura:

- YOLOv8: Este algoritmo de última generación puede utilizarse para tareas de detección de objetos, clasificación de imágenes y segmentación de instancias [32]. YOLOv8 fue desarrollado por Ultralytics, que incorporó varios cambios en la arquitectura y en la experiencia del desarrollador, así como mejoras respecto de YOLOv5. YOLOv8 utiliza un modelo sin anclas (anchor-free) con un

cabezal desacoplado para procesar de forma independiente las tareas de objetualidad, clasificación y regresión. Este diseño permite que cada rama se concentre en su tarea y mejora la exactitud global del modelo. En la capa de salida de YOLOv8, los autores utilizaron la función sigmoide como función de activación para la puntuación de objetualidad, que representa la probabilidad de que el cuadro delimitador contenga un objeto.

- YOLOv9: YOLOv9 se lanzó en febrero de 2024 [33] como una actualización de las versiones anteriores. YOLOv9 presenta dos innovaciones clave: el marco Programmable Gradient Information (PGI) y la Generalized Efficient Layer Aggregation Network (GELAN). El marco PGI busca abordar el problema de los cuellos de botella de información, inherentes a las redes neuronales profundas, además de hacer que los mecanismos de supervisión profunda sean compatibles con arquitecturas ligeras. Al implementar PGI, tanto las arquitecturas ligeras como las profundas pueden aprovechar mejoras sustanciales en exactitud, ya que PGI exige información de gradiente confiable durante el entrenamiento, lo que mejora la capacidad de la arquitectura para aprender y realizar predicciones exactas.
- YOLOv10: YOLOv10 [34] establece un nuevo estándar en la detección de objetos en tiempo real al abordar las deficiencias de las versiones anteriores de YOLO e incorporar estrategias de diseño innovadoras. Su capacidad para ofrecer una alta exactitud con un bajo costo computacional lo convierte en una opción ideal para una amplia gama de aplicaciones del mundo real. Para abordar la dependencia de la supresión de no máximos (Non-Maximum Suppression, NMS) y las ineficiencias arquitectónicas de las versiones anteriores de YOLO, YOLOv10 introduce asignaciones duales consistentes para el entrenamiento sin NMS y una estrategia holística de diseño del modelo orientada a la eficiencia y la exactitud. Así, sus principales características son el entrenamiento sin NMS, el diseño holístico del modelo y las características mejoradas del modelo.
- YOLOv11: Según [35], YOLOv11 representa el avance más reciente de la familia YOLO: se basa en las fortalezas de sus predecesores e introduce funcionalidades y optimizaciones innovadoras orientadas a mejorar el desempeño en diversas tareas de visión por computadora. La arquitectura de YOLOv11 cuenta con capacidades optimizadas de extracción de características, lo que permite capturar detalles intrincados en las imágenes [36]. Este modelo admite una variedad de aplicaciones, entre ellas la detección de objetos en tiempo real, la segmentación de instancias y la estimación de pose, lo que le

permite identificar objetos con exactitud independientemente de su orientación, escala o tamaño, y lo vuelve versátil para sectores como la agricultura y la vigilancia. El modelo YOLOv11 utiliza técnicas de entrenamiento mejoradas que han dado lugar a mejores resultados en conjuntos de datos de referencia (benchmark). YOLOv11 está optimizado para aplicaciones en tiempo real, lo que garantiza un procesamiento rápido incluso en entornos exigentes.

## 2.4. Hiperparámetros de entrenamiento

Adoptamos los hiperparámetros de entrenamiento que se muestran en la Tabla 3. Cada modelo se entrenó durante 100 épocas, con un tamaño de lote de 16, un tamaño de imagen de 640 × 640, una tasa de aprendizaje de 0.01 y un momento fijado en 0.937; todos los demás parámetros se mantuvieron en sus valores predeterminados. La elección de estos hiperparámetros se basó en trabajos relacionados sobre detección con modelos YOLO, como [37-41].

| Hiperparámetro | Valor |
|---|---|
| Épocas | 100 |
| Tamaño de lote | 16 |
| Tamaño de imagen | 640 × 640 |
| Tasa de aprendizaje | 0.01 |
| Momento | 0.937 |

Tabla 3. Hiperparámetros del experimento.

Es importante subrayar que, en los experimentos con las arquitecturas YOLO, se realizó un ajuste fino a partir de los modelos preentrenados YOLOv8s, YOLOv9s, YOLOv10s y YOLOv11s, donde "s" indica la versión pequeña (small), para asegurar un equilibrio entre velocidad y precisión. También cabe señalar que, en todos los experimentos, se guardaron los pesos de los mejores modelos para la etapa de prueba.

## 2.5. Métricas de evaluación

En los distintos conjuntos de datos anotados que utilizan los desafíos de detección de objetos y la comunidad científica, la métrica más empleada para medir la exactitud de las detecciones es la precisión media promedio (mAP) [42]. Para comprender la mAP es necesario tener presentes los conceptos de verdadero positivo, falso positivo y falso negativo, que se definen de la siguiente manera:

- Verdadero positivo (TP): detección correcta de un cuadro delimitador verdadero;
- Falso positivo (FP): detección incorrecta de un objeto inexistente o detección mal ubicada de un objeto existente;
- Falso negativo (FN): cuadro delimitador de la verdad de referencia que no fue detectado;

Las definiciones anteriores requieren además establecer qué son detecciones correctas e incorrectas. Un método habitual para ello es el uso de la intersección sobre la unión (IoU). Según [43], la IoU es una medida basada en el índice de Jaccard que mide el área de superposición entre el cuadro delimitador predicho Bp y el cuadro delimitador verdadero Bgt dividida por el área de su unión, tal como se describe matemáticamente en la Ecuación (1) y se ilustra en la Figura 4.

$$IoU = \text{área}(Bp \cap Bgt) / \text{área}(Bp \cup Bgt) \quad (1)$$

Figura 4. Ilustración que describe el cálculo de la IoU.

Luego, el valor de la IoU se compara con un umbral definido t para establecer cuándo una detección es correcta o incorrecta. Si IoU ≥ t, la detección se considera correcta. Si IoU < t, la detección se considera incorrecta.

Además de la mAP, otras métricas de evaluación utilizadas con frecuencia en problemas de detección son la precisión y la exhaustividad (recall) [42], que también se adoptan en el proceso de evaluación. A continuación se explica cada una de estas métricas de detección.

- Precisión: mide la calidad del modelo a través de su capacidad para encontrar verdaderos positivos entre todas las predicciones positivas [42]. Matemáticamente, la exactitud viene dada por la Ecuación (2), donde TP es el número de verdaderos positivos y FP es el número de falsos positivos.
  $$\text{Precisión} = TP / (TP + FP) = TP / \text{todas las detecciones} \quad (2)$$
- Exhaustividad (recall): se relaciona con la cantidad y mide la capacidad del modelo para encontrar verdaderos positivos en relación con el total de positivos [42]. Matemáticamente, la sensibilidad viene dada por la Ecuación (3), donde TP es el número de verdaderos positivos y FN es el número de falsos negativos.
  $$\text{Exhaustividad} = TP / (TP + FN) = TP / \text{todas las verdades de referencia} \quad (3)$$
- mAP: es una métrica de evaluación ampliamente utilizada para evaluar la calidad de los detectores de objetos [44]. Esta métrica es la más popular en los

desafíos de referencia (benchmark), como los desafíos COCO e ImageNET. La medida mAP, utilizada en problemas multiclase, se define a partir de la precisión promedio (AP, Average Precision) de cada clase.

La AP se calcula mediante la Ecuación (4) y se define como el área bajo la curva de precisión (P) × exhaustividad (R), donde M es el número de puntos interpolados.
$AP = \Sigma_{m=1}^{M} (R_m - R_{m-1}) \cdot P(R_m)$ (4)

Por lo tanto, la métrica mAP calcula la AP de cada categoría por separado y luego promedia esas AP entre todas las categorías. Este enfoque garantiza que el desempeño del modelo se evalúe para cada categoría individualmente, lo que proporciona una evaluación más completa del desempeño global del modelo [43]. La mAP se expresa matemáticamente mediante la Ecuación (5), donde N es el número de clases del problema.
$mAP = (1/N) \cdot \Sigma_{i=1}^{N} AP_i$ (5)

Es importante señalar que, en este trabajo, se seleccionó un umbral del 50% al evaluar las arquitecturas. En este caso, se utiliza la notación mAP50 para indicar el umbral.

## 3. Resultados y discusión

Esta sección analiza los resultados de la siguiente manera: la Sección 3.1, las métricas de evaluación obtenidas para cada modelo; en la Sección 3.2 se analizan algunos resultados cualitativos mediante la visualización de las predicciones de los modelos; y la Sección 3.3 presenta más detalles sobre el modelo con mejor desempeño.

### 3.1. Desempeño de los modelos

La Tabla 4 muestra los resultados, en términos de las métricas de evaluación, obtenidos por cada una de las arquitecturas en el conjunto de prueba. En los párrafos siguientes se discutirá una comparación del desempeño de las arquitecturas.

Es fácil ver que YOLOv8 obtuvo el mejor desempeño entre las arquitecturas evaluadas, con una mAP del 89.10%. Este modelo también tuvo la exhaustividad más alta (80.9%), lo que indica su capacidad superior para detectar una gran proporción de los objetos presentes, así como un buen desempeño general en la detección correcta de las regiones del diseño. Su estructura optimizada combina

eficiencia computacional con un buen poder de generalización, lo que puede explicar su desempeño superior.

| Arquitectura | Exhaustividad | Precisión | mAP50 |
|---|---|---|---|
| YOLOv8 | 0.809 | 0.845 | 0.891 |
| YOLOv9 | 0.712 | 0.754 | 0.757 |
| YOLOv10 | 0.495 | 0.949 | 0.692 |
| YOLOv11 | 0.801 | 0.854 | 0.871 |

Tabla 4. Comparación del desempeño de las arquitecturas.

Aunque presenta valores de exhaustividad (0.712) y precisión (0.754) más bajos que YOLOv8, YOLOv9 alcanza una mAP50 de 0.757, que aún puede considerarse aceptable en determinadas aplicaciones. Sin embargo, su desempeño relativamente inferior sugiere que es menos eficaz que YOLOv8 para detectar correctamente los elementos del diseño de los documentos. El modelo introdujo refinamientos en la estrategia de anclaje y mejoras en la extracción de características, pero es posible que no esté tan optimizado para el conjunto de datos utilizado.

La arquitectura YOLOv10, aunque tiene la exhaustividad más baja (0.495) y la peor mAP50 (0.692), presenta la precisión más alta (0.949) y supera a las demás arquitecturas en esta métrica. Esto sugiere que YOLOv10 es altamente selectivo, lo que se traduce en una alta exactitud a costa de una baja sensibilidad. Esta configuración puede ser inadecuada para tareas de detección en las que es necesario identificar todos los objetos relevantes, ya que una gran cantidad de ellos se pasa por alto. Estructuralmente, YOLOv10 se modificó para reducir los costos computacionales y mejorar la eficiencia energética, lo que puede haber afectado su capacidad de detección.

Por último, YOLOv11 obtuvo la segunda mejor mAP50 (0.871), casi igualando el desempeño global de YOLOv8. Además, esta arquitectura alcanzó valores equilibrados de exhaustividad (0.801) y precisión (0.854). Esta arquitectura podría ser una buena alternativa para aplicaciones que requieren un equilibrio entre exhaustividad y precisión, pese a no alcanzar una mAP50 tan alta como la de YOLOv8. Los cambios estructurales de la versión 11 se centraron en la integración de mecanismos de atención y en la optimización de parámetros, lo que puede explicar la mejora en la precisión respecto de YOLOv8.

En vista de lo anterior, YOLOv8 y YOLOv11 son los modelos más equilibrados y resultan preferibles para el análisis del diseño de página. YOLOv10, a pesar de su

alta precisión, tiene una baja capacidad de recuperación, lo que podría ser un problema para una detección completa. YOLOv9 tuvo un desempeño inferior, lo que sugiere que sus modificaciones estructurales pueden no ser ideales para esta tarea específica.

## 3.2. Algunos resultados visuales

Para ofrecer una visión cualitativa de los resultados, la Figura 5 muestra las predicciones de cada modelo YOLO entrenado para cuatro imágenes seleccionadas del conjunto de prueba. Al analizar las predicciones, se realizaron las siguientes observaciones:

- En la imagen de prueba 1 (Figura 5a), puede verse que YOLOv8 (Figura 5b) detecta correctamente todas las regiones deseadas, aunque produce dos falsos positivos para la clase Texto: uno en la parte inferior del documento, con una confianza de 0.25, y otro en la parte superior izquierda. YOLOv9 (Figura 5c), aunque detecta bien muchas regiones de la página, presenta limitaciones relacionadas con la fragmentación de los bloques de texto, bajas puntuaciones de confianza en áreas específicas y confusión entre clases cercanas. YOLOv10 (Figura 5d) logró detectar todas las regiones y generó un solo falso positivo, lo que demuestra su alta precisión, mostrada en la Tabla 4. YOLOv11 (Figura 5e) muestra un resultado similar al de YOLOv8, pero con tres falsos positivos de la clase Texto;
- En la imagen de prueba 2 (Figura 5f), que tiene un número elevado de instancias, todas de la clase Texto, las arquitecturas YOLOv8 (Figura 5g) y YOLOv11 (Figura 5j) tuvieron un mejor desempeño en la tarea de análisis del diseño de página. Sin embargo, puede verse que YOLOv9 (Figura 5h) y YOLOv10 (Figura 5i) no localizaron todas las regiones de texto, lo que concuerda con la menor exhaustividad de estas arquitecturas.

Figura 5. Predicciones realizadas por las arquitecturas sobre cuatro imágenes de prueba: (a) imagen de prueba 1, (b) YOLOv8, (c) YOLOv9, (d) YOLOv10, (e) YOLOv11, (f) imagen de prueba 2, (g) YOLOv8, (h) YOLOv9, (i) YOLOv10, (j) YOLOv11, (k) imagen de prueba 3, (l) YOLOv8, (m) YOLOv9, (n) YOLOv10, (o) YOLOv11, (p) imagen de prueba 4, (q) YOLOv8, (r) YOLOv9, (s) YOLOv10, (t) YOLOv11.

- En la imagen de prueba 3 (Figura 5k), puede verse que YOLOv8 (Figura 5l) identificó correctamente todas las regiones de texto, ya fuera en forma de

párrafo, título o subtítulo, y además detectó el elemento gráfico presente en la página. Sólo una sección del subtítulo no fue detectada por YOLOv8 y quedó fuera del cuadro delimitador generado para ese texto. YOLOv9 (Figura 5m) detectó menos elementos del diseño, omitió algunas partes del texto al producir cuadros delimitadores inexactos y dio lugar a falsos positivos para las clases gráfico y texto. YOLOv10 (Figura 5n) y YOLOv11 (Figura 5o), por su parte, alcanzaron un

- desempeño similar al de YOLOv8, y el resultado de YOLOv11 mostró cuadros delimitadores mejor ajustados a los bloques de texto;
- En la imagen de prueba 4 (Figura 5p), YOLOv8 (Figura 5q) detectó los bloques de texto y la imagen de la página del periódico de manera más exacta y consistente, con cuadros delimitadores que delimitan bien las columnas de texto. YOLOv9 (Figura 5r) reconoció correctamente la imagen de la página, pero no detectó todas las regiones de texto, por lo que una vez más tuvo un desempeño inferior al de YOLOv8. YOLOv10 (Figura 5s) obtuvo el peor resultado entre las arquitecturas para la imagen de prueba 4, al no detectar varias regiones de texto situadas justo debajo del título. Una vez más, YOLOv11 (Figura 5t) tuvo un desempeño cercano al de YOLOv8 y captó bien las regiones de texto y la imagen de la página.

En cuanto a los casos de fallo, puede verse que los modelos YOLO analizados revelan patrones de error distintos en la detección de los elementos del diseño en periódicos históricos. YOLOv8, pese a tener el mejor desempeño global, mostró dificultades para separar correctamente bloques de texto muy cercanos y agrupó columnas distintas en una sola región, lo que puede estar relacionado con su sensibilidad a la densidad textual. YOLOv9 tuvo un desempeño sólido, pero en algunos casos no detectó gráficos e imágenes, ya fuera porque ignoró estos elementos o porque los identificó de manera incompleta, posiblemente debido a su menor capacidad para captar patrones visuales no textuales. YOLOv10 mostró una mayor tendencia a los falsos positivos en áreas vacías, al detectar erróneamente elementos inexistentes, lo que puede atribuirse a su sensibilidad al ruido o a las variaciones del fondo de la página; además, algunas imágenes se detectaron de forma fragmentada, lo que sugiere dificultades para generalizar a ilustraciones de distintos formatos. YOLOv11, en cambio, tuvo la tasa más alta de omisión de gráficos e imágenes, posiblemente porque prioriza los patrones textuales sobre elementos visuales más variados, aunque fue más conservador en la detección de texto, lo que evitó agrupamientos indebidos, pero produjo algunas subdetecciones.

Estas deficiencias ponen de relieve desafíos comunes en la detección del diseño de documentos históricos, especialmente en la separación de texto denso, la identificación exacta de imágenes y gráficos y la minimización de falsos positivos en áreas vacías. Se considera que pueden lograrse mejoras mediante técnicas de preprocesamiento como el realce del contraste y la eliminación de ruido.

## 3.3. Detalles del mejor modelo (YOLOv8)

En síntesis, la arquitectura YOLOv8 resultó la más adecuada para la tarea de análisis del diseño de documentos debido a su desempeño equilibrado en todos los criterios, especialmente en exhaustividad y mAP50, lo que sugiere su mayor robustez para esta aplicación.

Para obtener una visión más detallada del desempeño de YOLOv8, la Tabla 5 muestra las métricas obtenidas por clase, cuyo conjunto de prueba se generó aleatoriamente sin la clase Tabla. En este caso, se obtuvo una mAP de 0.995 para la clase Imagen, 0.911 para la clase Texto y 0.768 para la clase Gráfico, ordenadas del resultado más alto al más bajo. La mayoría de las instancias pertenecen a la clase Texto, lo que facilita el aprendizaje de esta clase. Las regiones de la clase Imagen, aunque no son tan numerosas, pudieron ser reconocidas por el modelo. No así la clase Gráfico, que presenta patrones más complejos y uno de los menores números de instancias.

| Clases | Exhaustividad | Precisión | mAP50 |
|---|---|---|---|
| Texto | 0.825 | 0.888 | 0.911 |
| Imagen | 1.000 | 0.759 | 0.995 |
| Gráfico | 0.602 | 0.887 | 0.768 |
| todas | 0.809 | 0.845 | 0.891 |

Tabla 5. Desempeño de YOLOv8 por clase.

Así, desde un punto de vista individual, las mayores exactitudes se obtuvieron para las clases Texto e Imagen, con valores superiores al 90%. El algoritmo se destacó particularmente en la detección de regiones de la clase Imagen, con una mAP de casi el 100%. Por último, YOLOv8 alcanzó una mAP global de 0.891.

La Figura 6 muestra la matriz de confusión obtenida por YOLOv8 en el conjunto de prueba, en la que las filas indican la clase predicha y las columnas indican la clase verdadera correspondiente al objeto detectado por el modelo.

Figura 6. Matriz de confusión de YOLOv8.

Para la clase Gráfico se obtuvieron 26 verdaderos positivos, 13 falsos positivos y 7 falsos negativos. Para la clase Imagen, las dos instancias existentes se identificaron correctamente. Para la clase Tabla no hay instancias en el conjunto de prueba. Para la clase Texto se encontraron 2294 verdaderos positivos, 252 falsos positivos y 615 falsos negativos. Obsérvese la presencia de 611 falsos negativos de la clase Texto que se detectaron como fondo, así como de 252 regiones de fondo que se clasificaron incorrectamente como texto. Este error puede haberse debido al ruido del documento o a artefactos de escaneo. No obstante, la matriz de confusión refuerza la capacidad de YOLOv8s para detectar texto, ya que obtuvo un número elevado de verdaderos positivos para esta clase.

## 4. Conclusiones y trabajos futuros

Este artículo propone un conjunto de datos y presenta experimentos orientados a analizar el diseño de página de documentos históricos mediante técnicas de aprendizaje profundo, más específicamente, algoritmos de detección de objetos. Con roboflow se elaboró un conjunto de datos de periódicos brasileños denominado BHN, que contiene 140 imágenes de páginas de documentos y la verdad de referencia para la detección del diseño de página. A continuación, se combinaron tres conjuntos de datos de periódicos históricos, incluido el BHN, y se construyó un conjunto de datos combinado con un mayor número de imágenes. El resultado fue un conjunto de datos con 459 imágenes, que se separaron en 321 muestras de entrenamiento, 69 muestras de validación y 69 muestras de prueba.

Para este estudio se seleccionaron cuatro arquitecturas de detección de objetos de última generación. Los algoritmos se entrenaron con el conjunto de datos combinado y luego se evaluaron en el subconjunto de prueba, donde se constató que YOLOv8 tenía el mejor desempeño. Para YOLOv8 se obtuvo una mAP significativa del 89%. Este modelo fue capaz de extraer correctamente una gran cantidad de la información presente en los documentos, principalmente textos e imágenes, que fueron las dos clases más detectadas.

La introducción del conjunto de datos BHN y su combinación con otros conjuntos de datos históricos permitieron un análisis más robusto de las capacidades de estas arquitecturas. El BHN se destaca como el primer conjunto de datos orientado a la detección del diseño de página en periódicos históricos brasileños, lo que llena un vacío en la bibliografía y ofrece un recurso inédito para la comunidad científica.

Además de contribuir a la investigación en visión por computadora y aprendizaje automático, el BHN tiene aplicaciones directas en la preservación y la digitalización de la prensa histórica brasileña. Su uso puede facilitar la indexación automática de periódicos digitalizados, mejorar los sistemas de OCR y permitir búsquedas más eficientes en colecciones históricas, en beneficio de investigadores e instituciones dedicados a la preservación documental.

Por lo tanto, además de su impacto académico, los resultados de este trabajo tienen implicaciones directas para aplicaciones del mundo real. La detección precisa del diseño de página de periódicos históricos es un paso fundamental hacia la conversión automatizada de estos documentos a formatos accesibles y en los que se puedan realizar búsquedas. En proyectos a gran escala, como los repositorios digitales y las bibliotecas nacionales, la adopción de modelos de detección robustos puede acelerar significativamente los procesos de digitalización e indexación. Además, integrar estos modelos con sistemas de OCR puede mejorar la extracción automática de texto, al reducir los errores asociados a detecciones imprecisas y contribuir a una mejor recuperación de la información.

Cabe señalar también que la metodología propuesta puede aplicarse a otros conjuntos de datos, incluso a documentos contemporáneos, y sería útil para resolver diversos problemas en instituciones públicas y privadas, en el sentido de automatizar tareas de reconocimiento de información en documentos digitales o digitalizados. También podría implementarse una plataforma para transcribir el texto a partir de la imagen del documento, a fin de facilitar la investigación sobre documentos históricos por parte de especialistas de los campos de la historia y la arqueología, por ejemplo.

Para estudios futuros, interesa la idea de realizar un nuevo experimento con arquitecturas de detección basadas en transformers. También sería interesante investigar el uso de técnicas de aumento de datos para incrementar el número de imágenes del conjunto de datos y, posiblemente, mejorar aún más el desempeño. Otra idea prometedora para el avance científico en el área es investigar el impacto de la etapa de análisis del diseño de página en el desempeño final de motores de OCR de código abierto (como Tesseract y OCROpy).

Contribuciones de los autores: conceptualización, E.S.d.S.J. y A.B.A.; metodología, E.S.d.S.J.; software, E.S.d.S.J.; validación, E.S.d.S.J., T.P. y A.B.A.; análisis formal, E.S.d.S.J.; investigación, E.S.d.S.J., T.P. y A.B.A.; recursos, A.B.A.; curación de datos,

E.S.d.S.J.; redacción del borrador original, E.S.d.S.J. y T.P.; redacción, revisión y edición, E.S.d.S.J., T.P. y A.B.A.; visualización, E.S.d.S.J.; supervisión, A.B.A.; administración del proyecto, T.P. y A.B.A.; obtención de financiamiento, A.B.A. Todos los autores han leído y aceptado la versión publicada del manuscrito.

Financiamiento: Este trabajo contó con el apoyo del Laboratorio PAVIC de la Universidad de Acre, Brasil, beneficiado por incentivos fiscales de la SUFRAMA en virtud de la Ley brasileña n.º 8387/1991.

Declaración del comité de revisión institucional: No corresponde.

Declaración de consentimiento informado: No corresponde.

Declaración de disponibilidad de datos: Los datos se encuentran en el artículo.

Agradecimientos: Los autores agradecen el apoyo del Laboratorio PAVIC.

Conflictos de intereses: Los autores declaran no tener conflictos de intereses.

## Referencias


- Nguyen, T.T.; Le, H.; Nguyen, T.; Vo, N.D.; Nguyen, K. A brief review of state-of-the-art object detectors on benchmark document images datasets. Int. J. Doc. Anal. Recognit. IJDAR 2023, 26, 433-451. [CrossRef]
- Lopatin, L. Library digitization projects, issues and guidelines: A survey of the literature. Libr. Hi Tech 2006, 24, 273-289. [CrossRef]
- Barlindhaug, G. Artificial Intelligence and the Preservation of Historic Documents; University of Akron Press: Akron, OH, USA, 2022.
- Biffi, S. Document Layout Analysis: Segmentation and Classification with Computer Vision and Deep Learning Techniques. Master's Thesis, ING-Scuola di Ingegneria Industriale e dell'Informazione, Milan, Italy, 2016.
- Chandra, S.; Sisodia, S.; Gupta, P. Optical character recognition-A review. Int. Res. J. Eng. Technol. (IRJET) 2020, 7, 3037-3041.
- Araújo, A.B. Análise de layout de página em jornais históricos germano-brasileiros. Master's Thesis, UFPR-Federal University of Paraná, Curitiba, Brazil, 2019.
- Jannidis, F.; Kohle, H.; Rehbein, M. Digital Humanities; Springer: Berlin/Heidelberg, Germany, 2017.
- Zhu, W.; Sokhandan, N.; Yang, G.; Martin, S.; Sathyanarayana, S. DocBed: Amulti-stage OCR solution for documents with complex layouts. In Proceedings

of the AAAI Conference on Artificial Intelligence, Online, 22 February-1 March 2022; Volume 36, pp. 12643-12649. [CrossRef]
- Dai-Ton, H.; Duc-Dung, N.; Duc-Hieu, L. An adaptive over-split andmerge algorithm for page segmentation. Pattern Recognit. Lett. 2016, 80, 137-143. [CrossRef]
- Shehzadi, T.; Stricker, D.; Afzal, M.Z. A hybrid approach for document layout analysis in document images. In Proceedings of the International Conference on Document Analysis and Recognition, Athens, Greece, 30 August-4 September 2024; Springer: Berlin/Heidelberg, Germany, 2024; pp. 21-39.
- Cong, X.; Li, S.; Chen, F.; Liu, C.; Meng, Y. A review of YOLO object detection algorithms based on deep learning. Front. Comput. Intell. Syst. 2023, 4, 17-20. [CrossRef]
- Lavanya, G.; Pande, S.D. Enhancing Real-time Object Detection with YOLOAlgorithm. EAI Endorsed Trans. Internet Things 2024, 10, 12.
- Wang, C.Y.; Liao, H.Y.M. YOLOv1 to YOLOv10: The fastest andmost accurate real-time object detection systems. APSIPA Trans. Signal Inf. Process. 2024, 13, e29.
- Saha, R.; Mondal, A.; Jawahar, C. Graphical object detection in document images. In Proceedings of the 2019 International Conference on Document Analysis and Recognition (ICDAR), Sydney, Australia, 20-25 September 2019; IEEE: Piscataway, NJ, USA, 2019; pp. 51-58.
- Alaasam, R.; Kurar, B.; El-Sana, J. Layout analysis on challenging historical arabic manuscripts using siamese network. In Proceedings of the 2019 International Conference on Document Analysis and Recognition (ICDAR), Sydney, Australia, 20-25 September 2019; IEEE: Piscataway, NJ, USA, 2019; pp. 738-742. [CrossRef]
- Xu, Y.; Li, M.; Cui, L.; Huang, S.; Wei, F.; Zhou, M. Layoutlm: Pre-training of text and layout for document image understanding. In Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, Virtual, 6-10 July 2020; pp. 1192-1200.
- Appalaraju, S.; Jasani, B.; Kota, B.U.; Xie, Y.; Manmatha, R. Docformer: End-to-end transformer for document understanding. In Proceedings of the IEEE/CVF International Conference on Computer Vision, Montreal, QC, Canada, 10-17 October 2021; pp. 993-1003.
- Huang, Y.; Lv, T.; Cui, L.; Lu, Y.; Wei, F. Layoutlmv3: Pre-training for document ai with unified text and image masking. In Proceedings of the 30th ACM

International Conference on Multimedia, Lisbon, Portugal, 10-14 October 2022; pp. 4083-4091. [CrossRef]
- Chen, S.; Sun, P.; Song, Y.; Luo, P. Diffusiondet: Diffusion model for object detection. In Proceedings of the IEEE/CVF International Conference on Computer Vision, Paris, France, 2-3 October 2023; pp. 19830-19843.
- Zhao, Y.; Lv, W.; Xu, S.; Wei, J.; Wang, G.; Dang, Q.; Liu, Y.; Chen, J. Detrs beat yolos on real-time object detection. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, Seattle, WA, USA, 17-18 June 2024; pp. 16965-16974.
- Zhao, Z.; Kang, H.; Wang, B.; He, C. Doclayout-yolo: Enhancing document layout analysis through diverse synthetic data and global-to-local adaptive perception. arXiv 2024, arXiv:2410.12628.
- Chai, M.; Shen, Z.; Zhang, C.; Zhang, Y.; Wang, X.; Dou, S.; Kang, J.; Zhang, J.; Zhang, Q. DocFusion: AUnified Framework for Document Parsing Tasks. arXiv 2024, arXiv:2412.12505.
- Salim, H.; Mustafa, F.S. A COMPREHENSIVE EVALUATION OF YOLOv5s AND YOLOv5m FOR DOCUMENT LAYOUT ANALYSIS. Eur. J. Interdiscip. Res. Dev. 2024, 23, 21-33.
- Deng, Q.; Ibrayim, M.; Hamdulla, A.; Zhang, C. The YOLOmodel that still excels in document layout analysis. Signal Image Video Process. 2024, 18, 1539-1548. [CrossRef]
- Gao, Z.; Li, S. YOLOLayout: Multi-Scale Cross Fusion Former for Document Layout Analysis. Int. J. Emerg. Technol. Adv. Appl. (IJETAA) 2024, 1, 8-15. [CrossRef]
- Fleischhacker, D.; Goederle, W.; Kern, R. Improving OCR Quality in 19th Century Historical Documents Using a Combined Machine Learning Based Approach. arXiv 2024, arXiv:2401.07787.
- Chen, H.C.; Wu, L.; Zhang, Y. EDocNet: Efficient Datasheet Layout Analysis Based on Focus and Global Knowledge Distillation. arXiv 2025, arXiv:2502.16541.
- Ströbel, P.; Clematide, S. Improving OCR of Black Letter in Historical Newspapers: The Unreasonable Effectiveness of HTR Models on Low-Resolution Images. In Proceedings of the Digital Humanities 2019 (DH2019), Utrecht, The Netherlands, 9-12 July 2019.
- Chollet, F. Deep Learning with Python; Simon and Schuster: NewYork, NY, USA, 2021.

- Kim, J.H.; Oh, W.J.; Lee, C.M.; Kim, D.H. Achieving optimal process design for minimizing porosity in additive manufacturing of Inconel 718 using a deep learning-based pore detection approach. Int. J. Adv. Manuf. Technol. 2022, 121, 2115-2134. [CrossRef]
- Sulzbach, L. Building a Dataset of Late Modern German-Brazilian Newspaper Advertisement Pages for Layout and Font Recognition. Bachelor's Thesis, UFPR-Federal University of Paraná, Curitiba, Brazil, 2022.
- Terven, J.; Córdova-Esparza, D.M.; Romero-González, J.A. A comprehensive review of yolo architectures in computer vision: From yolov1 to yolov8 and yolo-nas. Mach. Learn. Knowl. Extr. 2023, 5, 1680-1716. [CrossRef]
- Wang, C.Y.; Yeh, I.H.; Mark Liao, H.Y. Yolov9: Learning what you want to learn using programmable gradient information. In Proceedings of the European Conference on Computer Vision, Milan, Italy, 29 September-4 October 2024; Springer: Berlin/Heidelberg, Germany, 2024; pp. 1-21. [CrossRef]
- Wang, A.; Chen, H.; Liu, L.; Chen, K.; Lin, Z.; Han, J.; Ding, G. Yolov10: Real-time end-to-end object detection. arXiv 2024, arXiv:2405.14458.
- Sapkota, R.; Meng, Z.; Churuvija, M.; Du, X.; Ma, Z.; Karkee, M. Comprehensive performance evaluation of yolo11, yolov10, yolov9 and yolov8 on detecting and counting fruitlet in complex orchard environments. arXiv 2024, arXiv:2407.12040.
- Khanam, R.; Hussain, M. YOLOv11: An Overview of the Key Architectural Enhancements. arXiv 2024, arXiv:2410.17725.
- Ramos, L.; Casas, E.; Bendek, E.; Romero, C.; Rivas-Echeverría, F. Hyperparameter optimization of YOLOv8 for smoke and wildfire detection: Implications for agricultural and environmental safety. Artif. Intell. Agric. 2024, 12, 109-126. [CrossRef]
- Ji, X.; Wan, J.; Zhang, Y.; Yang, T.; Yang, Q.; Liao, J. Hydrospot-Yolo: Real-Time Water Hyacinth Detection in Complex Water Environments; Elsevier: Amsterdam, The Netherlands, 2024.
- Neupane, C.; Walsh, K.B.; Goulart, R.; Koirala, A. DevelopingMachine Vision in Tree-Fruit Applications-Fruit Count, Fruit Size and Branch Avoidance in AutomatedHarvesting. Sensors 2024, 24, 5593. [CrossRef] [PubMed]
- Liu, X.; Wang, Y.; Yu, D.; Yuan, Z. YOLOv8-FDD: A real-time vehicle detectionmethod based on improved YOLOv8. IEEE Access 2024, 12, 136280-136296. [CrossRef]

- Lee, Y.S.; Prakash Patil, M.; Kim, J.G.; Seo, Y.B.; Ahn, D.H.; Kim, G.D. Hyperparameter Optimization for Tomato Leaf Disease Recognition Based on YOLOv11m. Plants 2025, 14, 653. [CrossRef]
- Padilla, R.; Netto, S.L.; Da Silva, E.A. A survey on performance metrics for object-detection algorithms. In Proceedings of the 2020 international conference on systems, signals and image processing (IWSSIP), Niterói, Brazil, 1-3 July 2020; IEEE: Piscataway, NJ, USA, 2020; pp. 237-242. [CrossRef]
- Terven, J.; Cordova-Esparza, D.M.; Ramirez-Pedraza, A.; Chavez-Urbiola, E.A. Loss functions andmetrics in deep learning. A review. arXiv 2023, arXiv:2307.02694.
- Wang, B. A parallel implementation of computingmean average precision. arXiv 2022, arXiv:2206.09504.


Descargo de responsabilidad/Nota del editor: Las afirmaciones, opiniones y datos contenidos en todas las publicaciones corresponden exclusivamente a los autores y colaboradores individuales, y no a MDPI ni a los editores. MDPI y los editores declinan toda responsabilidad por cualquier daño a personas o bienes que resulte de las ideas, métodos, instrucciones o productos mencionados en el contenido.