American Stories: un conjunto de datos textuales estructurados a gran escala de periódicos históricos de los Estados Unidos

Melissa Dell1,2∗ , Jacob Carlson1 , Tom Bryan1 , Emily Silcock1 , Abhishek Arora1 , Zejiang Shen3 , Luca D'Amico-Wong1 , Quan Le4 , Pablo Querubin2,5 , Leander Heldring6

1Harvard University; Cambridge, MA, USA.

2National Bureau of Economic Research; Cambridge, MA, USA.

3Massachusetts Institute of Technology; Cambridge, MA, USA.

4Princeton University; Princeton, NJ, USA.

5New York University; New York, NY, USA.

6Kellogg School of Management, Northwestern University, Evanston, IL, USA.

∗Autora de correspondencia: melissadell@fas.harvard.edu.

Resumen

Los conjuntos de datos de texto completo existentes de periódicos estadounidenses de dominio público no reconocen las disposiciones (layouts), a menudo complejas, de las imágenes escaneadas de los periódicos y, como resultado, el contenido digitalizado mezcla textos de artículos, titulares, pies de imagen, anuncios y otras regiones de la disposición. La calidad del OCR también puede ser baja. Este estudio desarrolla un flujo de procesamiento (pipeline) novedoso, basado en aprendizaje profundo, para extraer los textos completos de los artículos a partir de imágenes de periódicos, y lo aplica a los casi 20 millones de escaneos de la colección de dominio público Chronicling America de la Biblioteca del Congreso. El flujo de procesamiento incluye detección de la disposición, clasificación de legibilidad, OCR personalizado y asociación de los textos de artículos que abarcan varios recuadros delimitadores. Para lograr una alta escalabilidad, se construye con arquitecturas eficientes diseñadas para teléfonos móviles. El conjunto de datos resultante, American Stories, proporciona datos de alta calidad que podrían utilizarse para el preentrenamiento de un

modelo de lenguaje de gran tamaño, con el fin de lograr una mejor comprensión del inglés histórico y del conocimiento histórico del mundo. El conjunto de datos también podría añadirse a la base de datos externa de un modelo de lenguaje aumentado por recuperación, para hacer más ampliamente accesible la información histórica, que abarca desde interpretaciones de acontecimientos políticos hasta detalles minuciosos de la vida de los antepasados de las personas. Además, los textos de artículos estructurados facilitan el uso de métodos basados en transformers para aplicaciones habituales de las ciencias sociales, como la clasificación temática, la detección de contenido reproducido y el agrupamiento de noticias. Por último, American Stories proporciona un enorme conjunto de datos de calidad plata para innovar en modelos multimodales de análisis de la disposición y en otras aplicaciones multimodales.

1 Introducción

Los periódicos locales históricos constituyen un enorme repositorio de textos sobre las comunidades estadounidenses y sus habitantes, que puede esclarecer temas que van desde el cambio semántico hasta la polarización política, la construcción de identidades nacionales y culturales y los detalles minuciosos de la vida cotidiana de los antepasados de las personas. Dada la enorme amplitud y profundidad de su contenido, los periódicos históricos han sido ampliamente estudiados; sin embargo, los conjuntos de datos de código abierto existentes de periódicos estadounidenses tienen limitaciones significativas que dificultan la medida en que los métodos modernos de aprendizaje profundo pueden aprovechar y liberar su contenido.

El proyecto Chronicling America de la Biblioteca del Congreso [19] es el principal conjunto de datos de dominio público de periódicos históricos estadounidenses. Consta de alrededor de 20 millones de escaneos de periódicos históricos y de sus textos digitalizados correspondientes. Su contenido se concentra antes de 1925, ya que ese contenido ha pasado al dominio

público. Chronicling America no reconoce las disposiciones de los periódicos, a menudo complejas, por lo que los textos digitalizados se ofrecen a nivel de página y con frecuencia mezclan titulares, artículos, anuncios, pies de imagen y otras regiones de contenido. Debido a que una proporción no trivial de los escaneos subyacentes es ilegible, abundan los textos incoherentes, y la ilegibilidad varía en el espacio y en el tiempo. Esto complica la aplicación de métodos estadísticos y de

procesamiento del lenguaje natural (PLN), y los datos no tienen calidad suficiente para utilizarse en el entrenamiento de un modelo de lenguaje de gran tamaño que logre una mejor comprensión del inglés histórico y del conocimiento histórico del mundo.

Para abordar estas limitaciones, desarrollamos un flujo de procesamiento para extraer a bajo costo textos digitalizados de artículos de alta calidad y regiones de la disposición a partir de escaneos de periódicos. En primer lugar, la detección de la disposición predice las coordenadas y las clases de las regiones de contenido (por ejemplo, artículos, titulares, líneas de autoría, anuncios, imágenes, etc.) mediante métodos de detección de objetos [34]. Luego, un clasificador de imágenes elimina los recuadros delimitadores de texto ilegibles. A continuación, digitalizamos las regiones de texto mediante una arquitectura novedosa de reconocimiento óptico de caracteres (OCR) que produce resultados precisos y altamente escalables dentro de nuestro presupuesto limitado. El énfasis en la rentabilidad hace que el flujo de procesamiento resulte accesible para otras personas con presupuestos limitados que quieran digitalizar colecciones masivas de documentos históricos. Por último, asociamos los recuadros delimitadores de titulares, líneas de autoría y artículos. No procesamos periódicos en lenguas extranjeras, ya que el OCR estándar suele tener un mal desempeño con la diversidad de lenguas y escrituras.

El conjunto de datos resultante, American Stories (Structured text on reporting in every state [texto estructurado sobre el periodismo en cada estado]), contiene 1.14 mil millones de regiones de contenido. El conjunto de datos tiene una amplia cobertura geográfica en todos los estados y contiene material que se remonta hasta el siglo XVII, aunque la mayor parte del contenido proviene de comienzos del siglo XX. La figura 1 muestra la distribución de los escaneos por años y por estados. La gran mayoría de American Stories es anterior al plazo de 72 años que el gobierno de los Estados Unidos aplica para liberar información personal (por ejemplo, la del censo) al dominio público.

Figura 1: Escaneos de la base de datos Chronicling America a lo largo del tiempo y del espacio.

Mostramos que el flujo de procesamiento produce predicciones precisas. Los textos resultantes podrían utilizarse para entrenar modelos de lenguaje históricos, o añadirse a una base de datos externa de un modelo de lenguaje aumentado por recuperación, para facilitar el estudio de temas que van desde los

acontecimientos internacionales hasta la historia familiar. Las disposiciones y los textos correspondientes podrían proporcionar un enorme conjunto de datos de calidad plata para aplicaciones como el análisis y la clasificación multimodales de la disposición. El conjunto de datos American Stories también produce un desempeño significativamente mejor en los análisis de ciencias sociales que el OCR de Chronicling America, y permite análisis que serían imposibles sin textos de artículos estructurados. Por ejemplo, agrupamos las representaciones vectoriales (embeddings) de los artículos para detectar qué noticias (por ejemplo, la Expedición contra Pancho Villa, 1916) recibieron mayor cobertura cada año.

El resto de este estudio se organiza de la siguiente manera. La sección 2 analiza la literatura relacionada y la sección 3 describe el conjunto de datos American Stories. La sección 4 presenta el flujo de procesamiento de digitalización y la sección 5 evalúa la calidad de los resultados. La sección 6 analiza aplicaciones y la sección 7 considera las limitaciones y el uso recomendado.

2 Literatura relacionada

Existen conjuntos de datos de periódicos de dominio público para muchos países, pero los flujos de procesamiento suelen ser propietarios, ya que lo habitual es tercerizar la digitalización a una empresa privada. Las bases de datos comerciales de periódicos tampoco divulgan sus flujos de procesamiento, lo que da como resultado una escasez de métodos de código abierto. El trabajo más estrechamente relacionado con American Stories es el conjunto de datos de código abierto Newspaper Navigator [15]. La diferencia principal, y crucial, entre American Stories y [15] es que [15] no detecta los recuadros delimitadores de los artículos. [15] se centra en 7 clases de contenido visual: titulares, fotografías, ilustraciones, mapas, historietas, caricaturas editoriales y anuncios. Distinguir los artículos permite la clasificación de legibilidad, la aplicación de un OCR personalizado y la asociación de artículos entre recuadros delimitadores. Estas tareas constituyen el núcleo de nuestra contribución y hacen posible su utilidad para aplicaciones posteriores. Además, el OCR de [15] se limita al OCR de Chronicling America, que, como mostramos, conduce a un deterioro de la calidad.

Si bien nos centramos exclusivamente en textos de periódicos que están, en su totalidad e indiscutiblemente, en el dominio público (por lo general, porque se publicaron hace más de 95 años), cabe señalar que nuestro flujo de procesamiento podría ayudar a resolver algunos de los problemas de derechos de autor que han

limitado la disponibilidad pública de los periódicos históricos. Fuera de los periódicos de mayor circulación del país, era poco frecuente que los diarios locales publicaran con un aviso de derechos de autor o que renovaran sus derechos, formalidades exigidas hasta la segunda mitad del siglo XX. Por ello, la mayoría de los diarios locales, hasta bien entrado el siglo XX, no están sujetos a derechos de autor. Sin embargo, estos diarios podían a veces imprimir contenido de terceros protegido por derechos de autor; por ejemplo, con frecuencia historietas, rara vez anuncios y, ocasionalmente, series de ficción sindicada [23]. Los artículos periodísticos individuales no renovaban sus derechos de autor, ya que registrar los derechos de las noticias de ayer carecía de valor comercial. Detectar regiones de contenido individuales (por ejemplo, para que los anuncios y las historietas pudieran recortarse y los textos de ficción eliminarse con un clasificador) es un requisito previo para eliminar el contenido potencialmente sujeto a derechos de autor. Algunos expertos en derechos de autor [23] han propuesto esto como una vía para hacer más accesibles los periódicos históricos.

3 Conjunto de datos

La tabla 1 describe American Stories, que suma 1.14 mil millones de recuadros delimitadores de regiones de contenido. Los titulares, las imágenes, las líneas de autoría y los pies de imagen se procesan con OCR si son legibles. El conjunto de datos contiene en promedio 3313 tokens por página, lo que da un total de 65.6 mil millones de tokens para el conjunto de datos completo.

	(1)	(2)	(3)	(4)	(5)	(6)	(7)	(8)	(9)
	Total	Recuadros delimitadores de texto				Otros recuadros delimitadores			
	Recuadros	Artículos	Titulares	Pies de imagen	Líneas de autoría	Imágenes	Anuncios	Tablas	Cabeceras
Legibles	-	335M	368M	9.7M	14.7M	-	-	-	-
Ilegibles	-	26M	27M	0.9M	2.5M	-	-	-	-
Dudo	-	77M	22M	1.3M	1.2M	-	-	-	-

sos									
Total	1.14B	438M	417M	11.9M	18.4M	9.1M	221M	16.3M	4.9M

Tabla 1: Estadísticas del conjunto de datos American Stories.

American Stories proporciona las clases y las coordenadas de todas las regiones de contenido. Con los metadatos proporcionados, a los usuarios les resulta sencillo vincular las coordenadas con los escaneos originales, que pueden descargarse desde el sitio web de la Biblioteca del Congreso. No aplicamos OCR a los anuncios porque a menudo tienen tipografías inusuales y disposiciones complejas, que incluyen texto de escena y tablas complejas con información de precios u horarios, lo que complica el OCR. La clase de tabla incluye datos tabulares de artículos, por ejemplo, nóminas de equipos deportivos. No los transcribimos porque detectar con precisión y armonizar la diversidad de disposiciones de las tablas es difícil con la tecnología actual. Los encabezados de los periódicos no se procesan con OCR porque la mayor parte de su información está contenida en los metadatos. Las cabeceras (que contienen información sobre suscripciones) y los números de página solían usar tipografías muy pequeñas y, por lo tanto, tienen una probabilidad desproporcionadamente alta de ser ilegibles; los números de página pueden inferirse a partir de los metadatos.

Cada región de texto se clasifica como legible, ilegible o dudosa, y en la figura 2 se muestran ejemplos de cada categoría. La categoría dudosa constituye la zona gris entre los textos claramente legibles y los claramente ilegibles, y se procesa con OCR. Los usuarios pueden eliminarla si desean limitarse a los textos de mayor calidad.

Una proporción considerable de contenido ilegible puede degradar el entrenamiento de modelos de lenguaje y sesgar las aplicaciones posteriores. Por ejemplo, es habitual que los científicos sociales construyan datos a partir de la presencia de palabras clave [9], asignando un resultado positivo si el término está presente y un resultado nulo en caso contrario. La ilegibilidad puede sesgar los análisis posteriores si está correlacionada con un factor subyacente no observado. La figura 3 muestra que la ilegibilidad está correlacionada con el espacio y el tiempo y, por lo tanto, es probable que esté correlacionada con factores no observados. Con nuestros datos, los investigadores pueden eliminar los periódicos con altas tasas de ilegibilidad, si lo desean, y evaluar de forma más realista la selección de lo que ingresa en la base de datos.

Figura 2: Ejemplos de clasificación de legibilidad, según las predicciones de nuestro modelo entrenado.

Figura 3: Artículos ilegibles en la base de datos Chronicling America a lo largo del tiempo y del espacio.

American Stories tiene una licencia Creative Commons CC-BY, para fomentar su uso generalizado. Los datos están disponibles en el Hugging Face Hub 1 . Los archivos sin procesar están en formato json, y el repositorio de Hugging Face incluye un script de instalación que permite descargar fácilmente tanto los datos sin procesar como los datos analizados, para facilitar el modelado del lenguaje y las aplicaciones de ciencias sociales computacionales. Los materiales complementarios y el archivo Readme del repositorio del conjunto de datos ofrecen una guía de uso detallada.

4 Métodos

Panorama general: El flujo de procesamiento de American Stories consta de cuatro pasos: detección de la disposición y de las líneas, clasificación de legibilidad, OCR y asociación de artículos. El flujo de procesamiento está disponible en Github 2 .

La modularidad del flujo de procesamiento ofrece varias ventajas. En términos teóricos, la localización (de disposiciones, líneas, palabras y caracteres) y el reconocimiento (de caracteres, afín a la clasificación) pueden basarse en características distintas de la imagen, lo que sugiere un diseño modular [31]. En términos prácticos, existen enormes diferencias en la cantidad de etiquetas necesarias para entrenar cada componente del flujo de procesamiento. La modularidad también conduce a una simplicidad arquitectónica. Sustituir un codificador por otro es sencillo, lo que hace que el flujo de procesamiento sea más personalizable y esté preparado para el futuro. Sería sencillo incorporar modelos estándar que realicen una única tarea del flujo de procesamiento, como Segment Anything [14] o un motor de OCR.

1 https://huggingface.co/datasets/dell-research-harvard/AmericanStories

2 https://github.com/dell-research-harvard/AmericanStories

El flujo de procesamiento de American Stories utiliza arquitecturas diseñadas para teléfonos móviles, Yolo v8 [34] y MobileNet v3 [10], porque la pérdida de

precisión en relación con modelos mucho más grandes era muy modesta y los costos de implementación eran más de un orden de magnitud menores. Si el presupuesto no es una limitación, sería sencillo sustituirlas por un vision transformer (por ejemplo, [4, 1, 21]) y un marco de detección de objetos de dos etapas (por ejemplo, [2]), variantes que [3] examinan cuantitativamente sobre Chronicling America.

El flujo de procesamiento se ejecutó en nodos de CPU de la serie F de Azure. Para el entrenamiento se utilizó una tarjeta GPU Nvidia A6000. Los detalles se describen en los materiales complementarios.

Detección de la disposición y de las líneas: Las coordenadas y las clases de las regiones de la disposición se detectan con Yolo v8 [34]; la figura 4 muestra ejemplos. Entrenamos el modelo de detección de la disposición con 2202 imágenes de periódicos etiquetadas, que comprenden 48 874 objetos de disposición, con un promedio de 22 objetos de disposición por página. Todas las anotaciones del flujo de procesamiento fueron creadas por asistentes de investigación de grado, con escaneos seleccionados aleatoriamente y mediante aprendizaje activo [27]. Para desarrollar un modelo de propósito general, anotamos escaneos de periódicos de dominio público y libres de derechos de autor de todo el período de los siglos XIX y XX. Los escaneos de Chronicling America constituyen el 13% de la muestra de entrenamiento.

Figura 4: Variedad de disposiciones de periódicos con los resultados de nuestro flujo de detección de la disposición superpuestos.

Para las regiones de contenido que se procesan con OCR, detectamos las líneas individuales dentro de cada región con Yolo v8, ya que las líneas son la entrada del OCR. El modelo se entrena con 4000 recortes de líneas sintéticos y 373 anotados. Yolo v8, al igual que otros marcos de detección de objetos, toma imágenes cuadradas como entrada. Cuando las relaciones de aspecto de las regiones de contenido difieren significativamente de un cuadrado, el desempeño posterior del OCR suele verse afectado negativamente. Por ello, para las regiones de contenido con una relación de aspecto mayor que 2:1 (el doble de altas que de anchas), dividimos la región de la disposición (con superposición), ejecutamos la detección de líneas sobre cada recuadro por separado y luego aplicamos supresión de no máximos de manera conjunta sobre las predicciones resultantes. Por la misma razón, antes de enviar las líneas al OCR, dividimos las líneas con una relación de aspecto inferior a 1:30 (treinta veces más anchas que altas).

Clasificación de legibilidad: Clasificamos las regiones de titulares, artículos, líneas de autoría y pies de imagen como legibles, ilegibles o dudosas (véase la figura 2) mediante un clasificador de imágenes con una red troncal (backbone) Mobilenet v3, entrenado con 1094 recortes de regiones de contenido con doble etiquetado.

OCR: Nos propusimos implementar un flujo de digitalización altamente preciso dentro de un presupuesto limitado de cómputo en la nube de 60 000 USD. Como se documenta en detalle en los materiales complementarios, las soluciones de OCR existentes no cumplían estos requisitos. Las soluciones comerciales eran demasiado costosas, y TrOCR Base [18] (un OCR secuencia a secuencia de código abierto, basado en transformers, que producía resultados precisos) era casi cincuenta veces más costoso de implementar en CPU en la nube que nuestro presupuesto. Los motores de OCR de código abierto más escalables producían resultados ruidosos incluso cuando se ajustaban con anotaciones de periódicos.

Cumplimos nuestros objetivos de precisión y de costo con el marco EfficientOCR [3]. EfficientOCR utiliza métodos de detección de objetos basados en aprendizaje profundo para localizar caracteres o palabras individuales en una imagen. El reconocimiento de caracteres o palabras se modela como un problema de recuperación de imágenes a nivel de carácter o de palabra, utilizando un codificador visual entrenado de forma contrastiva con recortes de caracteres o palabras, creados en gran medida mediante el aumento de tipografías digitales. En el momento de la inferencia, las representaciones vectoriales de caracteres o palabras se decodifican a texto en paralelo, recuperando su vecino más cercano en un índice fuera de línea de representaciones vectoriales de caracteres o palabras ejemplares, creado al renderizar imágenes de caracteres o palabras con una tipografía digital. Las distancias se calculan mediante la similitud del coseno con un backend Facebook Artificial Intelligence Similarly Search (FAISS) [11].

Alternar entre el reconocimiento de caracteres y el de palabras es importante. Hay muchos términos que no aparecerían ni siquiera en un diccionario muy extenso, ya que las columnas estrechas de los periódicos implican que las palabras cortadas con guion al final de las líneas sean frecuentes. 3 Los textos también presentan una distribución de cola larga de nombres propios y de siglas y palabras arcaicas. Por ello, en el momento de la inferencia, cada vez que un recorte de palabra queda por debajo de un umbral ajustado de similitud del coseno de 0.82 respecto de su vecino más cercano en el índice fuera de línea de representaciones vectoriales de palabras, aplicamos en su lugar EfficientOCR a

nivel de carácter a los recortes de los caracteres individuales dentro de la palabra. Los materiales complementarios ofrecen una descripción detallada del entrenamiento y la implementación.

Asociación de contenido: Asociamos los titulares entre sí (si abarcan varios recuadros), con las líneas de autoría (si las hay) y con el primer recuadro delimitador del artículo, mediante métodos basados en reglas que aprovechan la posición de los recuadros delimitadores de artículos y de líneas de autoría respecto de los titulares (véanse los materiales complementarios). Los métodos basados en reglas funcionan peor con artículos que abarcan varias columnas o páginas, para los que se requiere comprensión del lenguaje. Sin embargo, en una muestra etiquetada encontramos que solo alrededor del 3.8% de los artículos abarca varios recuadros delimitadores de artículo y solo el 0.2% abarca varias páginas, lo que significa que hay poco margen de mejora con métodos neuronales. (Los artículos que abarcan varias columnas y páginas se vuelven más comunes después del período de Chronicling America, a medida que baja el precio del papel y aumenta el tamaño de la tipografía). Dado que estos casos son poco frecuentes y nuestro presupuesto de cómputo es limitado, no asociamos entre sí varios recuadros delimitadores de artículo en esta versión, aunque podríamos hacerlo en el futuro mediante el método de codificador cruzado (cross-encoder) RoBERTa desarrollado en [29].

5 Evaluación del flujo de procesamiento

Medición: Utilizamos cuatro conjuntos de datos cuidadosamente construidos para evaluar el flujo de procesamiento:

- Escaneos de página completa: Dos anotadores estudiantes etiquetaron las regiones de la disposición e ingresaron a mano los textos de 10 escaneos de página completa, resolviendo manualmente todas las discrepancias. El conjunto consta de 597 regiones de contenido y 196 655 caracteres. Nos permite evaluar el flujo de procesamiento de extremo a extremo, lo que requiere escaneos de página completa transcritos, ya que el análisis de la disposición se aplica a nivel de página. Además, utilizamos esta muestra para evaluar la asociación de contenido. Contiene 214 pares de recuadros delimitadores titular-artículo.
- Muestra transcrita de un día por década: Para evaluar la detección de líneas y el OCR sobre contenido muy diverso, transcribimos a mano una muestra

seleccionada aleatoriamente de 50 líneas por cada década entre 1850 y 1920. Durante este período, la tecnología de impresión y de archivo cambia significativamente. En los materiales complementarios se muestran ejemplos de estas líneas de texto, con sus transcripciones de EffOCR correspondientes, como tabla 1.

- Transcripciones de líneas seleccionadas aleatoriamente de Carlson et al. [3]: Esta muestra se utiliza para informar comparaciones con otros marcos de detección de objetos, redes troncales y motores de OCR. Estas comparaciones se toman de [3], que desarrolla EfficientOCR. Esta muestra incluye 64 líneas de texto extraídas aleatoriamente de escaneos aleatorios de la colección Chronicling America.
- Muestra de legibilidad: Evaluamos la legibilidad en una muestra seleccionada aleatoriamente (a partir de los datos de entrenamiento de legibilidad), con doble etiquetado, de 100 recuadros delimitadores: 50 titulares y 50 artículos. No se incluyen transcripciones, ya que no podemos crear etiquetas de caracteres para el contenido ilegible.

Medimos la precisión del flujo de procesamiento con la tasa de error de caracteres (CER, por sus siglas en inglés), definida como la distancia de Levenshtein [16] entre el contenido digitalizado de extremo a extremo y la verdad de referencia (ground truth), dividida por la longitud de la verdad de referencia. El OCR se evalúa de manera similar mediante la tasa de error de caracteres sobre anotaciones de referencia de la disposición y de las líneas (y, por lo tanto, no incluye los errores de transcripción inducidos por errores en las predicciones de la disposición). También examinamos la tasa de no-palabras, ya que no requiere datos etiquetados costosos de crear y, por ello, puede evaluarse en una muestra mucho mayor, aunque es más difícil de interpretar. Para medir la calidad de la detección de la disposición y de las líneas, utilizamos la precisión media promedio (mAP@50:95) y, además, descomponemos qué parte de la tasa de error de caracteres global se debe a errores de detección de la disposición y de las líneas. Para la asociación de artículos completos, nos centramos en la confusión entre escaneos legibles e ilegibles. Por último, evaluamos la asociación de contenido mediante F1.

3 Nuestro diccionario de palabras consta de palabras renderizadas tres veces cada una: con todos los caracteres en minúscula, con todos en mayúscula (algo común en los titulares) y con la inicial en mayúscula. Seleccionamos las palabras tomando primero las 25 000 palabras principales de un diccionario moderno que

ordena las palabras por frecuencia [5]. Eliminamos 3999 palabras que nunca aparecen en una muestra de todos los escaneos de Chronicling America correspondientes a un día por década (de la década de 1850 a la de 1920), procesada con EfficientOCR a nivel de carácter. La inspección reveló que se trataba, de forma abrumadora, de palabras relacionadas con conceptos modernos, como la informática y la medicina moderna. Luego añadimos las 500 palabras que aparecen con mayor frecuencia en esta muestra pero que no eran palabras modernas frecuentes (en su mayoría términos de ámbitos arcaicos, como la medicina tradicional), y añadimos también números, contracciones, abreviaturas de estados y de meses, y signos de puntuación, hasta un total de 22 230 términos.

Evaluación global del flujo de procesamiento: La CER de extremo a extremo es de 0.051 (tabla 2), lo que muestra la alta precisión global del flujo de procesamiento. Algunos de los errores (por ejemplo, la confusión entre comas y puntos es particularmente frecuente) son sencillos de corregir en el posprocesamiento. Cuando aplicamos un corrector ortográfico liviano [5], la CER baja a 0.044. La corrección ortográfica produce un leve aumento de la CER en los titulares, probablemente debido a una mayor concentración de nombres propios.

	(1) Global	(2) Titulares	(3) Artículos	(4) Anuncios
Precisión media promedio	63.48	88.64	91.31	78.4
CER global (con corrección ortográfica)	.044	.092	.038	-
CER global	.051	.089	.049	-
CER debida al OCR	.043	.071	.039	-
CER debida a la detección de la disposición	.012	.018	.010	-
F1 de asociación de artículos	97.0	-	-	-

Tabla 2: Evaluación del flujo de procesamiento en diez escaneos etiquetados. La CER es la tasa de error de caracteres, descompuesta en errores del OCR y errores

de la detección de la disposición. El F1 de asociación de artículos evalúa la asociación de los titulares entre sí y con el primer recuadro delimitador del artículo. La corrección ortográfica se aplica después de EffOCR, mediante [5].

La figura 5 representa la tasa de no-palabras a nivel de escaneo en una muestra de un día por década, donde la tasa de no-palabras mide la proporción de términos que no figuran en un diccionario extenso de 82 765 términos [5]. Incluso con un OCR perfecto, la tasa de no-palabras podría ser apreciable, debido a las palabras cortadas con guion al final de las líneas, las siglas, los nombres propios y los términos arcaicos. La distribución de American Stories se concentra muy a la izquierda de la distribución de Chronicling America, lo que pone de relieve la calidad de nuestros textos. Es probable que las diferencias en la tasa de no-palabras entre Chronicling America y American Stories reflejen tanto diferencias en la calidad del OCR como diferencias en el filtrado del contenido según la legibilidad y el tipo de región de contenido, ya que Chronicling America digitaliza todos los textos que puede localizar en la página.

Figura 5: Distribuciones de la tasa de no-palabras de American Stories y de Chronicling America.

Evaluación de la detección de la disposición y de las líneas: La mAP, informada en la tabla 2, es alta, en particular para las clases de interés central, como los titulares (88.64) y los artículos (91.31). Confundir anuncios con artículos (que en este período suelen tener un aspecto similar) es relativamente común. Los anuncios que parecen artículos suelen procesarse bien con OCR y tienen textos en lenguaje natural, por lo que estos errores también son tolerables. La inmensa mayoría de las regiones de contenido de los diez escaneos etiquetados son artículos, titulares y anuncios, ya que no aparecen fotografías, una rareza en este período. La mAP de la detección de líneas es de 86.20.

También descomponemos la CER global en errores debidos al OCR y errores debidos a la detección de las líneas y de la disposición. Cuando el modelo de disposición no detecta regiones de texto, las clasifica erróneamente en otra categoría que no se procesa con OCR, como los anuncios, o cuando la detección de líneas omite o recorta líneas, la CER aumenta. La CER debida a errores de detección de las líneas y de la disposición es de 0.012.

Evaluación de la clasificación de legibilidad: Queremos evitar clasificar textos legibles como ilegibles y viceversa; la clase dudosa existe para abarcar la zona gris

entre estas dos categorías. En una muestra aleatoria de textos etiquetados, que contiene 81 textos legibles, ninguno de los textos legibles se clasifica erróneamente como ilegible. De 16 textos ilegibles, solo uno se clasifica erróneamente como legible. Para evaluar esto con mayor profundidad, procesamos con OCR todas las regiones de contenido de una muestra de un día por década. La tasa de no-palabras es más de tres veces mayor para el contenido clasificado como ilegible que para el clasificado como legible, y más del doble para el contenido clasificado como ilegible que para el contenido dudoso.

Evaluación del OCR: La tabla 2 informa la CER obtenida al ejecutar el OCR sobre disposiciones y líneas de referencia. Es de 0.043. Los materiales complementarios ofrecen un análisis mucho más detallado de la calidad del OCR. La evaluación en una muestra de un día por década muestra que la CER oscila entre el 8.9% (década de 1850) y el 1.8% (década de 1910), y que la mayor parte del contenido se concentra en el período posterior, en el que los escaneos presentan menos dificultades. Los materiales complementarios también documentan que EffOCR [3] es el que mejor cumple nuestros requisitos de precisión y costo, mediante una comparación con diversos motores de OCR de código abierto y propietarios.

Evaluación de la asociación de contenido: Logramos un F1 de 97 en la asociación de titulares con artículos en nuestro conjunto de datos de evaluación etiquetado. Asociamos correctamente todas las líneas de autoría.

6 Aplicaciones

Modelado del lenguaje: American Stories proporciona una cantidad enorme de texto que puede utilizarse para continuar el preentrenamiento de grandes modelos de lenguaje basados en transformers, ayudando a un modelo de lenguaje a desarrollar una mejor comprensión del inglés del siglo XIX y de comienzos del siglo XX y un mayor conocimiento del mundo sobre el pasado. Además, un modelo de lenguaje aumentado por recuperación (por ejemplo, [12]), combinado con ventanas de contexto más largas, podría proporcionar una herramienta valiosa para recuperar y resumir información vasta, ya se trate de perspectivas sobre acontecimientos históricos que cambiaron paradigmas o de detalles minuciosos de la vida cotidiana de los antepasados de las personas. American Stories también proporciona abundante contenido para estudiar el cambio semántico.

Clasificación multimodal: Las disposiciones y los textos de American Stories conforman un rico conjunto de datos multimodal, que proporciona una gran

cantidad de datos de calidad plata que podrían utilizarse para desarrollar métodos novedosos de análisis multimodal de la disposición o de clasificación multimodal; por ejemplo, con pares de imagen y pie de imagen.

Clasificación temática: La clasificación temática de textos de periódicos históricos es una aplicación habitual en las ciencias sociales, y la literatura recurre de forma abrumadora a búsquedas por palabras clave para medir los temas [9]. Para evaluar en qué medida American Stories puede facilitar la clasificación temática, en comparación con el OCR existente de Chronicling America a nivel de página, utilizamos métodos neuronales y dispersos para clasificar si un conjunto de contenido seleccionado aleatoriamente trata sobre política, un tema cubierto con frecuencia. Utilizamos un clasificador RoBERTa large [20], aplicado a los artículos de American Stories y a fragmentos de Chronicling America (el OCR de la página es significativamente más largo que la ventana de contexto). Los datos de entrenamiento se muestrearon aleatoriamente a nivel de artículo y contienen 2418 artículos. El conjunto de desarrollo contiene 15 escaneos completos seleccionados aleatoriamente (498 artículos) y el conjunto de prueba contiene 62 escaneos seleccionados aleatoriamente (1473 artículos). También consideramos palabras clave, con dos enfoques distintos para seleccionarlas: la minería de palabras clave en el conjunto de entrenamiento y la consulta a ChatGPT, con instrucciones cuidadosamente formuladas. Todos los métodos se describen en los materiales complementarios.

American Stories admite la clasificación a nivel de artículo, mientras que Chronicling America solo admite la clasificación a nivel de página. Una página es un ejemplo positivo en la verdad de referencia si alguno de sus artículos trata el tema, y las predicciones de artículos o fragmentos pueden agregarse en predicciones a nivel de página con la misma definición. La recuperación a nivel de escaneo tiende a recuperar mucho contenido ajeno, ya que por lo general solo una parte de la página contiene artículos sobre política.

Sobre textos de artículos estructurados, los métodos neuronales superan ampliamente a los métodos de palabras clave (F1 de 83.6 frente a 58.1). Todos los métodos funcionan mejor a nivel de página, ya que la probabilidad de falsos negativos es mucho menor, y el mejor desempeño, por amplio margen, se obtiene al aplicar métodos neuronales al corpus de American Stories.

Redes de difusión de contenido: El contenido reproducido es de considerable interés para los científicos sociales [7], pero detectarlo puede ser difícil debido al

ruido del OCR y a las versiones abreviadas. Evaluamos esta tarea en una muestra de un día completo de portadas etiquetadas del 1 de marzo de 1916, un día aleatorio que comprende 113 artículos reproducidos (la mediana de reproducción por artículo es de dos veces) así como 1994 artículos únicos.

	Clasificación temática			Contenido reproducido	
	Neuronal	Disperso		Neuronal	Disperso
	F1	Minería	GPT	ARI	Viral Texts
	(1)	(2)	(3)	(4)	(5)
American Stories a nivel de artículo	83.6	56.4	58.1	75.1	32.3
American Stories a nivel de página	96.0	82.8	79.6	86.2	74.6
Chronicling America	83.3	83.7	79.6	-	71.4

Tabla 3: Comparación de American Stories con Chronicling America de la Biblioteca del Congreso.

Para detectar contenido reproducido a nivel de artículo con American Stories, implementamos el modelo neuronal preentrenado de [28]. Sus autores ajustaron de forma contrastiva un modelo Sentence BERT [26, 32] con una muestra grande, anotada a mano, de pares de artículos reproducidos de un período posterior. En el momento de la inferencia, las representaciones de los artículos se agrupan mediante agrupamiento de enlace simple para detectar el contenido reproducido. Para que el resultado de American Stories sea comparable con Chronicling America, agregamos las predicciones a nivel de página. Un par de páginas se considera positivo si las páginas tienen algún artículo en común, lo que facilita la tarea.

Para detectar contenido reproducido con los escaneos de página completa de Chronicling America, en los que carecemos de los textos de los artículos que requiere el método neuronal, implementamos los métodos dispersos de Viral Texts [30]. Viral Texts se diseñó específicamente para detectar textos reproducidos en el OCR ruidoso a nivel de página de Chronicling America, buscando tramos de

n-gramas superpuestos. También aplicamos Viral Texts a American Stories a nivel de artículo y de página. La tabla 3 informa el índice de Rand ajustado (ARI) de estas especificaciones. El método de Viral Texts da resultados ligeramente mejores en American Stories, pero la verdadera ventaja de American Stories es que la estructura de artículos permite usar un método neuronal, que supera al método disperso por casi 12 puntos porcentuales a nivel de página.

Agrupamiento de noticias: La naturaleza estructurada de American Stories permite, además, agrupar el contenido a nivel de artículo. Como demostración de ello, mostramos cómo los artículos pueden agruparse en noticias, de modo que los distintos artículos que forman parte de una misma noticia en desarrollo queden agrupados juntos. Esta predicción no es posible con el contenido de página no estructurado de Chronicling America.

Año	Noticia más importante	Año	Noticia más importante
1885	Muerte del general Grant	1903	Tratado del Canal de Panamá
1886	Huelga ferroviaria del Suroeste	1904	Guerra ruso-japonesa
1887	El Vaticano apoya a los Caballeros del Trabajo	1905	Proceso de paz ruso-japonés
1888	Huelgas ferroviarias	1906	Ley Hepburn sobre tarifas ferroviarias
1889	Crisis de Samoa	1907	Accidentes mineros
1890	Planificación de la Feria Mundial de 1893	1908	Victoria presidencial de Taft
1891	Linchamientos de Nueva Orleans	1909	Carrera hacia el Polo Norte
1892	Huelga del acero de Homestead	1910	Huelgas ferroviarias
1893	Feria Mundial, Chicago	1911	Proyecto de ley de reciprocidad con Canadá
1894	Ley arancelaria Wilson-Gorman	1912	Convención Nacional

			Republicana (Taft contra Roosevelt)
1895	Ocupación británica de Corinto, Nicaragua	1913	Ley arancelaria Underwood-Simmons
1896	Movimiento bimetalista	1914	Primera Guerra Mundial
1897	Huelga de los mineros del carbón	1915	Primera Guerra Mundial
1898	Guerra de Independencia de Cuba	1916	Expedición contra Pancho Villa
1899	Guerra filipino-estadounidense	1917	Primera Guerra Mundial
1900	Guerra anglo-bóer	1918	Primera Guerra Mundial
1901	Huelga por el reconocimiento sindical en U.S. Steel	1919	Tratado de Versalles
1902	Huelga del carbón de antracita	1920	Huelgas ferroviarias

Tabla 4: Noticia más importante de cada año, 1885-1920.

Para crear estos grupos, ajustamos un bicodificador (biencoder) contrastivo con textos periodísticos modernos, extraídos de allsides.com, un sitio web que reúne distintas representaciones de una misma noticia procedentes de distintos medios. Los detalles completos de los datos, el modelo y el entrenamiento se ofrecen en los materiales complementarios. Ejecutamos este modelo sobre todos los artículos de portada deduplicados de 1885-1920. Leímos 20 artículos aleatorios del grupo más grande de cada año y nombramos la noticia a la que se refieren los artículos del grupo. La tabla 4 muestra el grupo de noticias más grande por año.

Esta aplicación demuestra una de las muchas formas en que los textos de artículos estructurados de American Stories pueden utilizarse para abrir nuevas vías de estudio de cuestiones históricas y sociales.

Además de estas tareas, los pares de imagen y pie de imagen obtenidos del análisis de la disposición podrían utilizarse para entrenar y evaluar modelos de

generación de descripciones de imágenes, modelos de respuesta a preguntas visuales, modelos de recuperación intermodal, modelos de recuperación de imágenes y modelos de comprensión multimodal (por ejemplo, de aprendizaje de representaciones). American Stories también podría aprovecharse para reducir sustancialmente los costos de crear nuevos conjuntos de datos de referencia (benchmarks) para otras tareas habituales de aprendizaje automático (ML), por ejemplo, la clasificación de imágenes y textos, la recuperación de imágenes y el reconocimiento de entidades nombradas.

7 Limitaciones y uso recomendado

American Stories contiene lenguaje histórico, que refleja la semántica y los sesgos culturales de la época. Este es un rasgo distintivo, central para muchas aplicaciones potenciales. No filtramos los textos que usan términos arcaicos o que pueden considerarse ofensivos, ya que esto invalidaría el uso del conjunto de datos para estudiar el cambio semántico y los contextos históricos. Al mismo tiempo, esto hace que American Stories sea menos adecuado para tareas que requieren textos plenamente conformes con las normas culturales o semánticas actuales. Por estas razones, desaconsejamos el uso de American Stories para entrenar modelos generativos. Si bien el OCR es de alta calidad, American Stories tampoco es adecuado para tareas que requieren textos completamente limpios. Más bien, American Stories puede utilizarse para una amplia variedad de aplicaciones, que van desde esclarecer cuestiones de las ciencias sociales hasta entrenar un modelo de lenguaje con orientación histórica o explorar la historia mundial y familiar. También ofrece un flujo de procesamiento modular que puede personalizarse para otras colecciones de documentos y escalarse a bajo costo, lo que brinda un modelo para liberar corpus de textos históricos a gran escala.

Materiales complementarios

Detalles de los modelos

American Stories implementa un flujo de procesamiento modular para digitalizar periódicos históricos. Esta sección ofrece detalles de cada componente del flujo de procesamiento.

Detección de la disposición

Para detectar artículos, titulares, anuncios y otras regiones de contenido en un escaneo de periódico, implementamos YOLOv8 (Medium) [34], inicializado a partir del punto de control preentrenado YOLOv8m publicado oficialmente. Entrenamos durante 100 épocas con 2202 escaneos de periódicos etiquetados, con un total de 48 874 objetos de disposición, utilizando los hiperparámetros predeterminados de YOLOv8 salvo: {imgsz: 1280, iou: 0.2, max_det: 500}. El modelo final alcanzó una mAP50:95 de 0.91 en los recuadros delimitadores de artículos y de 0.84 en los recuadros delimitadores de titulares. Redujimos el umbral de confianza a 0.1 para aumentar la exhaustividad (recall) en artículos y titulares.

Clasificación de legibilidad

Los recuadros delimitadores de imágenes de texto se clasifican como legibles, dudosos o ilegibles mediante MobileNetV3 (Small) [10], inicializado a partir del punto de control preentrenado de PyTorch Image Models ("timm") [35]. Entrenamos durante 50 épocas con 979 ejemplos etiquetados de artículos, titulares y pies de imagen. De los ejemplos etiquetados, 678 eran legibles, 192 dudosos y 109 ilegibles. El modelo se entrenó con una pérdida de entropía cruzada ponderada: pesos [2.0, 1.0, 1.0] para las clases legible, dudosa e ilegible, respectivamente. Se utilizaron las siguientes especificaciones: {resolution: 256, learning rate: 2e-3}. La tasa de aprendizaje se multiplicó por 0.1 cada veinte épocas.

Detección de líneas de texto

Los recuadros delimitadores de las líneas se detectan mediante YOLOv8 (Small) [34], inicializado a partir del punto de control preentrenado oficial YOLOv8s. Entrenamos primero durante 100 épocas con 4000 artículos generados sintéticamente, con los hiperparámetros predeterminados de YOLOv8. Después del entrenamiento sintético, el modelo se entrenó adicionalmente durante 50 épocas con 373 recortes de artículos y titulares anotados a mano, con los hiperparámetros predeterminados de YOLOv8 salvo los siguientes: {resolution: 640, initial learning rate: 0.02, final learning rate: 0.002}.

Localización de palabras y caracteres

Las palabras y los caracteres se detectan mediante YOLOv8 (Small) [34], inicializado a partir del punto de control preentrenado oficial YOLOv8s. Entrenamos primero durante 100 épocas con 8000 líneas de texto generadas sintéticamente, con los hiperparámetros predeterminados de YOLOv8. Después del entrenamiento sintético, el modelo se entrenó adicionalmente durante 100 épocas con 684 imágenes de líneas de texto anotadas a mano, con los hiperparámetros predeterminados salvo los siguientes: {resolution: 640, initial learning rate: 0.02, final learning rate: 0.001}. Cada imagen de línea anotada a mano se replicó tres veces con aumentos aleatorios a lo largo de tres ejes: rotación aleatoria entre -1° y 1°, variación aleatoria del brillo de la imagen de -30 a 30% y desenfoque aplicado aleatoriamente en un nivel de 0-4px. En promedio, los ejemplos de líneas de texto contenían 4.3 palabras y 23.6 caracteres.

Reconocimiento de palabras

Sobre la base de la arquitectura de [3], entrenamos el reconocimiento de palabras como un problema de recuperación de imágenes por vecino más cercano. Como se describe en el texto principal, el conjunto de datos de entrenamiento del modelo consta de renderizaciones digitales de palabras creadas con 43 tipografías, de datos de calidad plata del conjunto de datos objetivo, creados aplicando el modelo EffOCR-C (Small) de [3] a una muestra aleatoria de días, y de una pequeña cantidad de recortes de palabras etiquetados a mano y seleccionados aleatoriamente. Limitamos a 20 la cantidad de recortes con etiquetas generadas por el modelo, de modo que cada palabra puede tener entre 0 y 20 recortes de calidad plata según su frecuencia de aparición en nuestra muestra aleatoria. Este límite resulta restrictivo para las palabras comunes, por ejemplo, "the".

El reconocedor se entrena con la función de pérdida Supervised Contrastive ("SupCon") [13], una generalización de la pérdida InfoNCE [24] que admite múltiples pares positivos y negativos para un ancla dada. En particular, trabajamos con la formulación "outside" [exterior] de la pérdida SupCon

$$L^{sup_out} = \Sigma_{i \in I} L^{sup_out,i} = \Sigma_{i \in I} (-1/|P(i)|) \Sigma_{p \in P(i)} \log [\exp(z_i \cdot z_p / \tau) / \Sigma_{a \in A(i)} \exp(z_i \cdot z_a / \tau)]$$

tal como está implementada en PyTorch Metric Learning [22], donde τ es un parámetro de temperatura, i indexa una muestra en un lote "multiviewed" [de múltiples vistas] (en este caso, múltiples tipografías o aumentos de la misma palabra), P(i) es el conjunto de índices de todos los positivos del lote de múltiples vistas que son distintos de i, A(i) es el conjunto de todos los índices excepto i, y z es la representación vectorial de una muestra del lote [13].

Para crear los lotes de entrenamiento del reconocedor, utilizamos un algoritmo personalizado de muestreo de m elementos por clase sin reposición, adaptado del repositorio de PyTorch Metric Learning [22]. Las m variantes de palabra para cada clase (palabra) se extraen tanto de los documentos objetivo como de tipografías digitales aumentadas. Seleccionamos m = 4 y un tamaño de lote de 1024, lo que significa que en cada lote aparecen 4 estilos de cada una de 256 palabras distintas. Para el entrenamiento sin negativos difíciles, definimos una época como el hecho de que el modelo vea cada palabra (distinguiendo mayúsculas y minúsculas) exactamente m = 4 veces. El muestreo de cada clase se realiza sin reposición hasta agotar todas las variantes.

Para converger más rápido con un cómputo limitado, implementamos además minería de negativos difíciles fuera de línea, agrupando en lotes negativos similares junto con sus anclas positivas correspondientes, lo que hace que los contrastes entre los pares positivos y negativos dentro de un lote sean especialmente informativos. Para crear los conjuntos de negativos difíciles, renderizamos cada palabra con una tipografía de referencia (Noto-Serif Regular) y la incrustamos para crear un índice de referencia. Encontramos k = 8 vecinos más cercanos para cada palabra con este índice y con el modelo entrenado sin negativos difíciles, lo que produce conjuntos de 8 palabras que tienen un aspecto similar cuando se renderizan con la tipografía de referencia. Usamos solo la tipografía de referencia para crear estos conjuntos porque usar los recortes correspondientes a las 43 tipografías para cada palabra es computacionalmente costoso y genera más conjuntos de negativos difíciles de los que podemos usar en el entrenamiento. También usamos cada recorte de palabra del conjunto de datos objetivo (tanto las anotaciones de calidad plata generadas con predicciones del modelo como las anotaciones humanas de calidad oro) para crear conjuntos de negativos difíciles. Por lo tanto, el número total de conjuntos de negativos difíciles es igual al número de palabras de nuestro diccionario (generadas con la tipografía de referencia) más el número de recortes de palabras de los datos periodísticos del conjunto de entrenamiento.

Cada conjunto de negativos difíciles contiene 8 palabras, con m = 4 vistas por palabra, lo que significa que podemos incluir 32 conjuntos de negativos difíciles muestreados aleatoriamente en cada lote. Una época se define como ver cada conjunto de negativos difíciles una vez. Dado que el número de vistas sintéticas de una imagen es mucho mayor que el número de recortes de periódicos objetivo, siempre que hay recortes de periódicos disponibles forzamos que las m vistas de una palabra contengan el mismo número de recortes sintéticos y objetivo.

Utilizamos un codificador MobileNetV3 (Small) preentrenado en ImageNet1k, obtenido de la biblioteca timm [35]; más concretamente, el modelo mobilenetv3_small_050. Usamos 0.1 como temperatura para la pérdida SupCon y AdamW como optimizador, con los valores predeterminados de Pytorch [25] para todos los parámetros salvo el decaimiento de pesos (5e-4) y la tasa de aprendizaje. Utilizamos Cosine Annealing with Warm Restarts como planificador de la tasa de aprendizaje, con una tasa de aprendizaje máxima de 2e - 3, una tasa de aprendizaje mínima de 0, el tiempo hasta el primer reinicio (T0) igual al número de lotes de una época y un factor de reinicio Tmult de 2, mediante la implementación proporcionada en Pytorch.

Si bien las tipografías y los recortes de periódicos de cada palabra actúan como un aumento sobre el esqueleto de la palabra, añadimos también más transformaciones a nivel de imagen para mejorar la generalización. Entre ellas se incluyen la transformación afín (solo se permiten una ligera traslación y un ligero escalado), Random Color Jitter, Random Autocontrast, Random Gaussian Blurring, Random Grayscale, Random Solarize, Random Sharpness, Random Invert, Random Equalize, Random Posterize y el borrado aleatorio de una pequeña cantidad de píxeles de la imagen. Además, rellenamos la palabra para que la imagen sea cuadrada, preservando la relación de aspecto de la renderización de la palabra. No utilizamos aumentos habituales como Random Cropping o Center Cropping, para evitar destruir demasiada información.

El modelo entrenado sin negativos difíciles se entrenó durante 50 épocas y, con negativos difíciles, durante 40 épocas. Para seleccionar el mejor punto de control, utilizamos 1-CER (tasa de error de caracteres del OCR) como métrica de validación sobre el conjunto de validación de [3]. Elegimos el modelo que obtuvo el mejor desempeño en términos de CER al detectar solo palabras en el conjunto de validación. Esto significa que, si una palabra está fuera de nuestro diccionario, se

empareja forzosamente con su vecino más cercano en el diccionario. El mejor modelo alcanzó una CER del 4.9% con reconocimiento solo de palabras.

En el momento de la inferencia, las palabras se reconocen recuperando su vecino más cercano en el índice de representaciones vectoriales fuera de línea creado con la tipografía de referencia, mediante un backend Facebook Artificial Intelligence Similarity Search [11]. El código para entrenar el modelo y generar los datos de entrenamiento, así como los puntos de control del modelo, están disponibles en nuestro repositorio de GitHub. 4

Reconocimiento de caracteres

Cuando el vecino más cercano de un recorte de palabra incrustado en el índice de representaciones vectoriales de palabras fuera de línea queda por debajo de un umbral de similitud del coseno de 0.82, recurrimos por defecto al reconocimiento a nivel de carácter. Para el reconocimiento de caracteres utilizamos el modelo EffOCRC (Small) desarrollado en [3].

Asociación de contenido

Este paso asocia titulares, líneas de autoría y recuadros delimitadores de artículos. Utilizamos métodos basados en reglas que aprovechan la posición de los recuadros delimitadores de artículos y de líneas de autoría respecto de los titulares. En concreto, asociamos un recuadro delimitador de titular con un recuadro delimitador de artículo si se superponen verticalmente en más del 1% del ancho de la página, y si la parte inferior del titular no está más de un 10% de la altura de la página por encima de la parte superior del artículo ni más de un 2% de la altura de la página por debajo de la parte superior del artículo. Si varios recuadros delimitadores de artículo cumplen estas reglas para un titular dado, tomamos el más alto. Las mismas reglas se utilizan para asociar las líneas de autoría.

Evaluación del flujo de procesamiento

Como se analiza en el artículo principal, evaluamos el flujo de procesamiento de datos de extremo a extremo y evaluamos también secciones individuales, en particular el OCR. Aquí ofrecemos detalles adicionales sobre esas evaluaciones.

Evaluación del OCR

Procesar 20 millones de escaneos requería una solución de OCR rentable, y las tareas posteriores requieren un OCR muy preciso. Comparamos soluciones de OCR personalizadas, de código abierto y comerciales en cuanto a precisión, velocidad y costo para determinar nuestra arquitectura final. Las mediciones de la tasa de error de caracteres se realizaron en dos conjuntos de datos de validación distintos:

- CER [3] Tasa de error en un conjunto de datos de 64 líneas de texto de Chronicling America seleccionadas aleatoriamente, muestreadas de toda la colección. Las líneas de texto se muestrearon aleatoriamente de escaneos aleatorios y luego se recortaron y transcribieron. Este conjunto de datos y su construcción se describen en detalle en [3].
- CER Day-Per-Decade [un día por década] Tasa de error en una muestra de 225 líneas de texto en total, muestreadas de todos los escaneos de la colección Chronicling America publicados el 1 de marzo de los años terminados en "6", de 1856 a 1926. A diferencia de la muestra anterior de [3], esta muestra está equilibrada entre los períodos que predominan en la colección Chronicling America. Se muestrearon aleatoriamente 25 líneas de texto de páginas aleatorias publicadas en cada uno de esos días. En la figura S-1 se muestra una selección de líneas de texto de esta colección, junto con sus transcripciones de EffOCR. Este conjunto de datos está diseñado para ser mucho más difícil que el primero, ya que otorga más peso a los escaneos más antiguos y difíciles de leer, pese a su relativa escasez en la colección Chronicling America.

Las comparaciones se presentan en la tabla S-1. Los procedimientos de entrenamiento de EffOCR-Word se describen más arriba. Véase [3] para los procedimientos de entrenamiento, los puntos de control de inicialización y detalles adicionales sobre el entrenamiento y la evaluación de los modelos de comparación.

De las opciones que examinamos, EffOCR-Word (Small) fue claramente la mejor, ya que ofreció una tasa de error de caracteres inferior al 5% en el conjunto de evaluación más difícil y, a la vez, el menor costo por línea en una instancia Microsoft Azure Fs4v2.

4 https://github.com/dell-research-harvard/AmericanStories.

Model	¿Seq2S	¿Trans	Preent	Parám	CER	CER	Líneas	Costo

o/ Motor	eq?	former?	renamiento	etros	[3]	Day-Per-Decade	por segundo	por 10K líneas
EffOCR-C (Base)	×	×	desde cero	112.5 M	0.023	0.062	0.27	$1.77
EffOCR-C (Small)	×	×	desde cero	9.3 M	0.028	0.080	7.28	$0.06
EffOCR-T (Base)	×	√	desde cero	101.8 M	0.022	0.059	0.17	$2.80
EffOCR-Word (Small)	×	×	desde cero	10.6M	0.015	0.043	11.60	$0.04
Google Cloud Vision OCR	?	?	listo para usar	?	0.005	0.019	?	$15.00
Tesseract OCR (Best)	√	×	listo para usar	1.4 M	0.106	0.170	2.43	$0.19
EasyOCR CRNN	√	×	listo para usar ajustado desde cero	3.8 M	0.170 0.036 0.131	0.274 0.157 -	10.75	$0.04
PaddleOCR SVTR	×	×	listo para usar ajustado desde cero	11 M	0.304 0.103 0.104		7.36	$0.06
TrOCR (Base)	√	√	listo para usar ajusta	334 M	0.015 0.013 0.809	0.038 0.027 -	0.23	$2.02

			do desde cero					
TrOCR (Small)	✓	✓	listo para usar ajusta do desde cero	62 M	0.039 0.075 0.773	0.121 0.091 -	0.53	$0.90

Tabla S-1: Resultados y comparaciones en Chronicling America. Esta tabla informa el desempeño de distintas arquitecturas de OCR: listas para usar (off-the-shelf, sin ajuste fino con los datos objetivo), ajustadas (fine-tuned) con el conjunto de entrenamiento de Chronicling America a partir de la inicialización con el mejor punto de control de OCR público y preentrenado, y preentrenadas desde cero (from scratch) con un conjunto coherente y estandarizado de líneas de texto sintéticas y luego ajustadas con el conjunto de entrenamiento de Chronicling America. "?" indica que el dato se desconoce debido al carácter propietario de la arquitectura. Las velocidades de inferencia se basan en una extrapolación de las velocidades de inferencia medidas para EffOCR-Word (Small) al digitalizar toda la colección Chronicling America con cómputo en la nube.

WASHINGTON,April 1-Ambas-	WASHINGTON, April 1 Ambas-
FORT WORTH JITNEYS QUIT	FORT WORTH JITNEYS OUIT
General Plan 5-4-31	General Plan 5-4-31
State of Tennessee,	State of Tennessee
A non-Federl project to furnish free home assistance	A non-Federal project to furnish free home assistance
SEED DISTRIBUTION	SEED DISTRIBUTION
Iron. Steel and Tin Workers	Iron, Steel and Tin Workers
ADVERSE REPORTS ON DEMENT'S NOMINATION.	ADVERSE REPORTS ON DEMENTS NOMINATION
IMPROVEMENT IS SHOWN	IMPROVEMENT IS SHOWN

Figura S-1: Ejemplos de líneas de texto del conjunto de evaluación Day-Per-Decade. A la izquierda se muestran los recortes de imagen y a la derecha sus transcripciones de EffOCR correspondientes (con el conjunto de modelos final utilizado en el flujo de procesamiento de American Stories).

Legibilidad

La clasificación de legibilidad se probó en un conjunto de 100 recortes de imagen (50 artículos y 50 titulares) muestreados aleatoriamente del conjunto de entrenamiento de legibilidad de 1094 imágenes. Todas las imágenes de legibilidad se etiquetaron por duplicado. Como el objetivo era ser cautelosos al clasificar imágenes como ilegibles, cuando los anotadores discrepaban se utilizó la más legible de las dos etiquetas.

Se indicó a los anotadores que utilizaran las siguientes definiciones para el etiquetado de legibilidad:

- Legible: Más del 95% de las palabras de una imagen pueden leerse sin el contexto de las palabras adyacentes.
- Dudoso: Entre el 50 y el 95% de las palabras de una imagen pueden leerse sin el contexto de las palabras adyacentes.
- Ilegible: Menos del 50% de las palabras de una imagen pueden leerse sin el contexto de las palabras adyacentes.

El acuerdo entre anotadores fue del 91% entre los dos anotadores. En la figura S-2 se presenta una muestra de las discrepancias entre anotadores

(a) Legible/Dudoso

Al persons laterested in the Nerthern Faciãe should be among ite subscribers.

Persops Jooiag for homes in the West, capecially in the Red Rirer and Miodouri valleya, or at any poel e ore newspeper.

Bismarok is stusted at the present termiaus of the Nortbera Paciße, on the Missouri river, in a prairie re r Misouri in ceanection with the Northern Pacifc to Carroll, 800 miles above Biamarck, and to Fort Bentom, 1800 miles above, while the Yellowstone river is navigable for 800 mallos, giving. Bismarck 1800 mliea of navigable rivers above it, directly tributary tu it,

H e r best outlet and inlet to she New Biderado-not onby heshortent bat the mafest aaul best route.

(b) Dudoso/Ilegible

Figura S-2: Ejemplos de desacuerdo entre anotadores en el etiquetado de legibilidad. Las imágenes llevan la etiqueta "Class 1"/"Class 2" [Clase 1/Clase 2]

para mostrar las dos clases asignadas. En los casos de desacuerdo, se utilizó la más legible de las dos etiquetas para el entrenamiento y la evaluación.

Aplicaciones

El artículo presenta múltiples aplicaciones que el conjunto de datos American Stories puede facilitar. Esta sección ofrece detalles de cada una de ellas.

Clasificación temática

Para evaluar la clasificación temática, nos centramos en el tema de la política. Como evaluamos tanto a nivel de escaneo como de artículo, para los conjuntos de desarrollo y de prueba muestreamos escaneos completos (todos los artículos del mismo escaneo). Tomamos una muestra aleatoria de hasta tres escaneos de portada de cada año electoral de nuestra muestra. Estos escaneos fueron etiquetados por duplicado por estudiantes asistentes de investigación, y las incongruencias se discutieron y resolvieron. Asignamos el 20% de ellos (15 escaneos, 498 artículos) a un conjunto de desarrollo y los 62 escaneos restantes (1473 artículos) al conjunto de prueba. Los datos de entrenamiento se muestrearon a nivel de artículo, y no de escaneo, de la misma población de artículos de portada de años electorales. Los datos de entrenamiento fueron etiquetados una sola vez por los mismos asistentes de investigación. Una muestra se etiquetó por duplicado para comprobar la coherencia, y hubo acuerdo en el etiquetado en el 93% de los casos.

Para evaluar los métodos neuronales, ajustamos RoBERTa large [20] con el conjunto de entrenamiento durante diez épocas, con un tamaño de lote de 16 y una tasa de aprendizaje de 2e-6.

Para la evaluación de los métodos dispersos, utilizamos dos métodos distintos para seleccionar palabras clave. En primer lugar, usamos los conjuntos de prueba y de evaluación para extraer palabras clave. Usamos TF-IDF para obtener las palabras y los bigramas que aparecen con mayor frecuencia en los artículos del conjunto de entrenamiento sobre política, pero no en los artículos que no tratan el tema. Tomamos las 40 palabras y bigramas principales y luego elegimos secuencialmente los que maximizan el F1 en el conjunto de evaluación, hasta que no queda ninguna palabra clave que aumente el F1. Con esta técnica, las palabras clave extraídas fueron: vote, election, republican, committee, united, party,

president, congress [voto, elección, republicano, comité, unido, partido, presidente, congreso].

En segundo lugar, pedimos a Chat-GPT que produjera palabras clave. Utilizamos la instrucción (prompt): "You have a large number of 19th century US newspaper articles. You wish to classify these on whether they are about politics or not. The only way that you can do this is by checking whether they match any of a list of keywords or keyphrases. You can search for these keywords or phrases in each article, and if it matches any of them it will be classified as about politics, but if it does not match any, it will not. Please provide a list of keywords and phrases that will correctly classify as many of the articles that are about politics as possible, with a minimal number of off-topic articles classified as on topic" [Tienes una gran cantidad de artículos de periódicos estadounidenses del siglo XIX. Deseas clasificarlos según traten o no sobre política. La única manera de hacerlo es comprobar si coinciden con alguna de una lista de palabras clave o frases clave. Puedes buscar estas palabras o frases clave en cada artículo y, si coincide con alguna de ellas, se clasificará como sobre política; si no coincide con ninguna, no. Proporciona una lista de palabras clave y frases que clasifique correctamente la mayor cantidad posible de artículos sobre política, con un número mínimo de artículos ajenos al tema clasificados como pertinentes] y recibimos las siguientes palabras clave: President, Congress, Election, Senator, Representative, Governor, Democratic Party, Whig Party, Republican Party, Suffrage, Legislation, Lawmakers, Government, Policy, Bill, Campaign, Debate, Vote, Political Convention, Public Office, Political Reform, Impeachment [Presidente, Congreso, Elección, Senador, Representante, Gobernador, Partido Demócrata, Partido Whig, Partido Republicano, Sufragio, Legislación, Legisladores, Gobierno, Política pública, Proyecto de ley, Campaña, Debate, Voto, Convención política, Cargo público, Reforma política, Juicio político].

Con estas listas de palabras clave, consideramos que se predice que un artículo trata el tema si contiene cualquiera de estas palabras clave. No distinguimos entre mayúsculas y minúsculas.

Los datos estructurados de American Stories nos permiten clasificar a nivel de artículo, lo que constituye una ventaja significativa. Sin embargo, para compararlos con Chronicling America, evaluamos también los mismos métodos a nivel de escaneo. Un escaneo se considera pertinente al tema si algún artículo de esa página lo es. Para los métodos neuronales sobre Chronicling America,

dividimos el texto en pasajes de 256 tokens, ya que el OCR de la página es significativamente más largo que la ventana de contexto.

Redes de difusión de contenido

Para detectar contenido reproducido, comparamos también métodos neuronales y dispersos. En este caso, los métodos neuronales solo son posibles con American Stories, mientras que los métodos dispersos son posibles tanto con American Stories como con Chronicling America.

Evaluamos estos métodos en todas las portadas del 1 de marzo de 1916, un día seleccionado aleatoriamente. Se elige un solo día porque el contenido reproducido tiende a publicarse aproximadamente al mismo tiempo, de modo que un solo día tendrá un número mucho mayor de artículos reproducidos que una selección aleatoria de portadas a lo largo del tiempo. En ese día, American Stories contiene 114 escaneos, con 2354 artículos. De ellos, 1994 no fueron reproducidos, mientras que 360 sí lo fueron. Estos 360 comprenden 113 artículos distintos, y la mediana de reimpresión por artículo reproducido es de 2 veces.

Para el método neuronal, utilizamos el modelo neuronal preentrenado de [28]. Se trata de un bicodificador entrenado de forma contrastiva, ajustado a partir del modelo MPNet Sentence BERT [26, 32] con una muestra grande, anotada a mano, de pares de artículos de periódicos históricos reproducidos. [28] encuentran que este bicodificador mejora marginalmente al ejecutar un codificador cruzado sobre sus salidas, pero no reproducimos estos resultados porque el codificador cruzado es computacionalmente costoso para una pequeña ganancia de desempeño. También encuentran que este modelo bicodificador ajustado supera a modelos más genéricos de similitud textual semántica (p. ej., [26] por hasta 20 puntos porcentuales. Por lo tanto, el modelo se elige para maximizar la precisión, dentro de un presupuesto de cómputo razonable. En el momento de la inferencia, las representaciones de los artículos se agrupan mediante agrupamiento de enlace simple para detectar el contenido reproducido, y los enlaces espurios se podan mediante detección de comunidades. Utilizamos el mismo umbral de distancia que en [28].

Para permitir una comparación con Chronicling America, donde el contenido solo está disponible a nivel de página, agregamos estos resultados por página. Un par de páginas se considera positivo si tienen algún artículo en común. No obstante, la evaluación a nivel de página del método neuronal requiere que los datos estén

divididos en artículos. No puede ejecutarse sobre el texto no estructurado de Chronicling America.

Por lo tanto, para detectar contenido reproducido en Chronicling America, donde no disponemos de los textos de los artículos, implementamos los métodos dispersos de Viral Texts [30]. Viral Texts se diseñó específicamente para detectar textos reproducidos en el OCR ruidoso a nivel de página de Chronicling America, buscando tramos de n-gramas superpuestos. Para comparar este método entre American Stories y Chronicling America, lo ejecutamos también sobre los artículos de American Stories y luego agregamos estos resultados a nivel de página.

Por último, implementamos la especificación de hashing sensible a la localidad (LSH) de [28] para evaluar el desempeño de los métodos dispersos en American Stories, con los mismos parámetros. Lo hacemos, en particular, porque el método de Viral Texts no está diseñado para ejecutarse a nivel de artículo. Como era de esperar, encontramos que LSH funciona mejor que Viral Texts a nivel de artículo, pero ambos métodos tienen un desempeño significativamente peor que los métodos neuronales, en consonancia con los hallazgos de [28].

Agrupamiento de noticias

Por último, demostramos que el contenido de American Stories puede agruparse en noticias, siguiendo la misma noticia entre periódicos y a lo largo del tiempo. Para crear grupos de noticias, utilizamos un bicodificador entrenado de forma contrastiva.

Entrenamos este bicodificador con datos de allsides.com, un sitio web de noticias moderno que muestra cómo distintos periódicos redactan una misma noticia. Los artículos de allsides.com están truncados. Los grupos de artículos sobre la misma noticia en allsides.com se utilizaron para crear pares positivos. Para los negativos, aprovechamos que cada artículo está etiquetado con diversas etiquetas temáticas y que sabemos de qué medio proviene cada artículo. Para cada artículo, tomamos el artículo del mismo medio, con etiquetas temáticas distintas, que tenía la mayor similitud del coseno, usando el bicodificador antes del ajuste fino. En los casos en que no había artículos con etiquetas distintas del mismo medio, usamos artículos de un medio catalogado con la misma orientación política. La condición de que un artículo tenga etiquetas distintas es importante para asegurar que los artículos sean negativos reales.

En total, esto dio 26 194 artículos únicos, con 18 382 pares positivos y 18 445 pares negativos. Representamos los datos con el formato "headline [sep] article" [titular (sep) artículo] y ajustamos el bicodificador de [28], ya que en los experimentos encontramos que esto superaba al ajuste directo de un modelo MPNet Sentence BERT [26, 32]. Optimizamos los hiperparámetros mediante hyperband [17]. El mejor modelo se entrenó durante 9 épocas, en una sola GPU, con un tamaño de lote de 32 y un porcentaje de calentamiento (warm up) de 0.392. Optimizamos la pérdida contrastiva en línea [8], con un margen de pérdida de 0.497.

En el momento de la inferencia, agrupamos mediante agrupamiento de enlace simple, con un umbral de similitud del coseno de 0.92. Controlamos el tamaño de los grupos mediante la detección de comunidades de Leiden [33]. Deduplicamos el contenido con el método descrito en la sección anterior. Tomamos todos los artículos que se reimprimen al menos cinco veces y ejecutamos el agrupamiento por noticia sobre un año por vez.

Detalles del conjunto de datos

URL del conjunto de datos

El conjunto de datos se encuentra en https://huggingface.co/datasets/dell-research-harvard/ AmericanStories.

Este conjunto de datos tiene metadatos estructurados según schema.org y es fácilmente localizable. 5

Las etiquetas de entrenamiento de los modelos individuales detallados en este artículo también están disponibles y se encuentran en https://huggingface.co/datasets/dell-research-harvard/ AmericanStoriesTraining.

DOI

El DOI de este conjunto de datos es: 10.57967/hf/0757.

5 Véase https://search.google.com/test/rich-results/result?id=esZkoGgfOsLlnkrvwx9nSQ para los metadatos completos.

Licencia

El conjunto de datos tiene una licencia Creative Commons CC-BY.

Uso del conjunto de datos

El conjunto de datos está alojado en Hugging Face. Cada año del conjunto de datos se divide en un archivo distinto. El conjunto de datos puede descargarse fácilmente con la biblioteca datasets:

Como el conjunto de datos es muy grande, pueden descargarse los archivos de años específicos indicándolos, o bien los usuarios pueden descargar todos los datos de todos los años. Además, ofrecemos dos opciones para el tipo de salida. La primera contiene datos a nivel de artículo, con atributos como el nombre del periódico, el número de página, la edición, la fecha, el titular, la línea de autoría y el texto del artículo. La segunda contiene datos a nivel de escaneo. Incluye información como los metadatos del escaneo; todas las regiones de contenido detectadas, como artículos, fotografías y anuncios; información de legibilidad y las coordenadas de los recuadros delimitadores.

```
from datasets import load_dataset # Download data for the year 1809 at the associated article level (Default) dataset = load_dataset("dell-research-harvard/AmericanStories", "subset_years", year_list=["1809", "1810"] ) # Download and process data for all years at the article level dataset = load_dataset("dell-research-harvard/AmericanStories", "all_years" ) # Download and process data for 1809 at the scan level dataset = load_dataset("dell-research-harvard/AmericanStories", "subset_years_content_regions", year_list=["1809"] ) # Download ad process data for all years at the scan level dataset = load_dataset("dell-research-harvard/AmericanStories", "all_years_content_regions")
```

Los usuarios pueden encontrar más información sobre el acceso al conjunto de datos en la ficha del conjunto de datos (dataset card) en Hugging Face.

Declaración de los autores

Asumimos toda la responsabilidad en caso de vulneración de derechos.

Plan de mantenimiento

Hemos optado por alojar el conjunto de datos en huggingface, ya que esto garantiza el acceso y la preservación a largo plazo del conjunto de datos.

Documentación del conjunto de datos y usos previstos

Seguimos la plantilla de fichas técnicas para conjuntos de datos (datasheets for datasets) [6]. Además, hemos completado la ficha del conjunto de datos en Hugging Face, a la que se puede acceder mediante el enlace al conjunto de datos en el Hugging Face Hub 6

Reproducibilidad

Además, hemos incluido nuestras respuestas a The Machine Learning Reproducibility Checklist [Lista de verificación de reproducibilidad del aprendizaje automático], tal como se presenta en la tabla S-2.

6 https://huggingface.co/datasets/dell-research-harvard/AmericanStories

Motivación

¿Con qué propósito se creó el conjunto de datos? ¿Se tenía en mente una tarea específica? ¿Había un vacío específico que era necesario cubrir? Proporcione una descripción.

El conjunto de datos se creó para proporcionar a los investigadores un corpus grande y de alta calidad de textos estructurados y transcritos de artículos de periódicos locales históricos estadounidenses. Estos textos constituyen un enorme repositorio de información sobre temas que van desde la polarización política hasta la construcción de identidades nacionales y culturales y los detalles minuciosos de la vida cotidiana de los antepasados de las personas. El conjunto de datos será útil para una amplia variedad de investigadores, entre ellos historiadores, otros científicos sociales y profesionales del PLN.

¿Quién creó este conjunto de datos (por ejemplo, qué equipo o grupo de investigación) y en nombre de qué entidad (por ejemplo, empresa, institución, organización)?

El conjunto de datos fue creado por un equipo de investigadores de Harvard University, New York University, Northwestern Kellogg School, MIT y Princeton University, dirigido por Melissa Dell.

¿Quién financió la creación del conjunto de datos? Si existe una subvención asociada, indique el nombre de la entidad otorgante y el nombre y número de la subvención.

La financiación provino de la Harvard Data Science Initiative, de créditos de cómputo que Microsoft Azure otorgó a la Harvard Data Science Initiative, de Harvard Catalyst y del Ken Griffin Fund for Research on Development Economics and Political Economy del Harvard Economics Department.

¿Algún otro comentario?

Ninguno.

Composición

¿Qué representan las instancias que componen el conjunto de datos (por ejemplo, documentos, fotos, personas, países)? ¿Hay múltiples tipos de instancias (por ejemplo, películas, usuarios y valoraciones; personas e interacciones entre ellas; nodos y aristas)? Proporcione una descripción.

Las instancias del conjunto de datos son regiones de contenido detectadas en escaneos de páginas de periódicos de la colección Chronicling America de la Biblioteca del Congreso. En el caso de las regiones de artículo, titular, pie de imagen y línea de autoría, se incluye una transcripción del texto si la página está escrita en inglés.

¿Cuántas instancias hay en total (de cada tipo, si corresponde)?

La versión 0.1.0 de American Stories contiene 402 millones de regiones de contenido, de las cuales 294 millones incluyen una transcripción de texto.

¿El conjunto de datos contiene todas las instancias posibles o es una muestra (no necesariamente aleatoria) de instancias de un conjunto mayor? Si el conjunto de datos es una muestra, ¿cuál es el conjunto mayor? ¿Es la muestra representativa del conjunto mayor (por ejemplo, en cobertura geográfica)? Si es así, describa cómo se validó o verificó esta representatividad. Si no es representativa del conjunto mayor, describa por qué no (por ejemplo, para abarcar una gama más diversa de instancias, porque se retuvieron instancias o no estaban disponibles).

La versión 1.0 del conjunto de datos contendrá todas las instancias posibles. La versión 0.1.0 contiene aproximadamente el 40% de todas las instancias al 6/7/23.

¿En qué consisten los datos de cada instancia? ¿Datos "en bruto" (por ejemplo, texto o imágenes sin procesar) o atributos? En cualquier caso, proporcione una descripción.

Cada instancia incluye: un identificador único de la región de contenido, su clase detectada (ARTICLE, HEADLINE, CAPTION, BYLINE, IMAGE, AD, TABLE, HEADER, PAGE NUMBER o MASTHEAD) y las coordenadas en píxeles del recuadro delimitador de la región identificada en la página del periódico. Si la región de contenido se clasifica como ARTICLE, HEADLINE, CAPTION o BYLINE, también se proporciona el texto transcrito.

¿Hay una etiqueta o un objetivo asociado a cada instancia? Si es así, proporcione una descripción.

Las regiones de contenido se etiquetan con la clase predicha por el modelo. Las transcripciones de los textos de los artículos no tienen etiqueta.

¿Falta información en alguna de las instancias individuales? Si es así, proporcione una descripción y explique por qué falta esa información (por ejemplo, porque no estaba disponible). Esto no incluye la información eliminada intencionalmente, pero podría incluir, por ejemplo, texto censurado.

No.

¿Las relaciones entre instancias individuales se hacen explícitas (por ejemplo, las valoraciones de películas de los usuarios, los vínculos en redes sociales)? Si es así, describa cómo se hacen explícitas estas relaciones.

Todos los artículos y las demás regiones de contenido incluyen metadatos que permiten determinar de manera definitiva sus relaciones con otras regiones de contenido. Por ejemplo, dos artículos con el mismo lccn (identificador del periódico), la misma edición y el mismo número de página provienen del mismo escaneo de página de periódico.

¿Hay particiones de datos recomendadas (por ejemplo, entrenamiento, desarrollo/validación, prueba)? Si es así, proporcione una descripción de estas particiones y explique la lógica que las sustenta.

No hay particiones recomendadas.

¿Hay errores, fuentes de ruido o redundancias en el conjunto de datos? Si es así, proporcione una descripción.

La detección de la disposición, el OCR y la asociación de artículos introducen ruido.

¿El conjunto de datos es autocontenido, o enlaza con recursos externos o depende de ellos de algún otro modo (por ejemplo, sitios web, tuits, otros conjuntos de datos)? Si enlaza con recursos externos o depende de ellos, a) ¿hay garantías de que existirán y se mantendrán constantes a lo largo del tiempo?; b) ¿hay versiones oficiales archivadas del conjunto de datos completo (es decir, incluidos los recursos externos tal como existían en el momento en que se creó el conjunto de datos)?; c) ¿hay restricciones (por ejemplo, licencias, tarifas) asociadas a alguno de los recursos externos que pudieran aplicarse a un usuario futuro? Proporcione descripciones de todos los recursos externos y de las restricciones asociadas a ellos, así como enlaces u otros puntos de acceso, según corresponda.

Los datos textuales proporcionados son autocontenidos. Algunas aplicaciones podrían requerir la descarga de los escaneos originales, que se encuentran en https://chroniclingamerica.loc.gov/. Todos los escaneos están disponibles gratuitamente y son de dominio público.

¿El conjunto de datos contiene datos que podrían considerarse confidenciales (por ejemplo, datos protegidos por el secreto profesional o por la confidencialidad médico-paciente, datos que incluyen el contenido de comunicaciones no públicas de personas)? Si es así, proporcione una descripción.

El conjunto de datos procede en su totalidad de imágenes escaneadas de dominio público que pueden descargarse gratuitamente del sitio web de la Biblioteca del Congreso.

¿El conjunto de datos contiene datos que, vistos directamente, podrían resultar ofensivos, insultantes o amenazantes, o podrían causar ansiedad de algún otro modo? Si es así, describa por qué.

Los textos del conjunto de datos reflejan las actitudes y los valores de un grupo grande y diverso de editores y redactores de periódicos del período en que fueron escritos (1790-1960) e incluyen contenido que puede considerarse ofensivo por diversas razones.

¿El conjunto de datos se refiere a personas? Si no es así, puede omitir las preguntas restantes de esta sección.

Sí. El conjunto de datos contiene noticias sobre personas.

¿El conjunto de datos identifica alguna subpoblación (por ejemplo, por edad o género)? Si es así, describa cómo se identifican estas subpoblaciones y proporcione una descripción de sus respectivas distribuciones dentro del conjunto de datos. Podría ser posible inferir ciertas características de las personas que aparecieron históricamente en las noticias a partir de

los datos. Los autores del conjunto de datos no identifican ninguna subpoblación.

¿Es posible identificar a individuos (es decir, a una o más personas físicas), directa o indirectamente (es decir, en combinación con otros datos), a partir del conjunto de datos? Si es así, describa cómo.

Si una persona apareció en las noticias durante este período, los textos pueden contener su nombre y otra información. En algunos casos, podría ser posible vincular a las personas con información de sitios web de genealogía o de Wikipedia (en el caso de figuras históricas destacadas). En este artículo no intentamos hacerlo.

¿El conjunto de datos contiene datos que podrían considerarse sensibles en algún sentido (por ejemplo, datos que revelan el origen racial o étnico, la orientación sexual, las creencias religiosas, las opiniones políticas o la afiliación sindical, o ubicaciones; datos financieros o de salud; datos biométricos o genéticos; formas

de identificación gubernamental, como números de seguridad social; antecedentes penales)? Si es así, proporcione una descripción.

Los datos proceden en su totalidad de escaneos de periódicos de dominio público.

¿Algún otro comentario?

Ninguno.

Proceso de recopilación

¿Cómo se obtuvieron los datos asociados a cada instancia? ¿Los datos eran directamente observables (por ejemplo, texto sin procesar, valoraciones de películas), fueron informados por los sujetos (por ejemplo, respuestas a encuestas) o se infirieron o derivaron indirectamente de otros datos (por ejemplo, etiquetas de categoría gramatical, estimaciones de edad o idioma basadas en modelos)? Si los datos fueron informados por los sujetos o se infirieron o derivaron indirectamente de otros datos, ¿se validaron o verificaron? Si es así, describa cómo.

El flujo de procesamiento utilizado para crear las disposiciones y las transcripciones de los artículos a partir de las imágenes de las páginas se describe en detalle en el artículo. El conjunto de datos aquí descrito es el resultado de ese flujo de procesamiento.

¿Qué mecanismos o procedimientos se utilizaron para recopilar los datos (por ejemplo, aparatos de hardware o sensores, curaduría humana manual, programas de software, API de software)? ¿Cómo se validaron estos mecanismos o procedimientos?

El flujo de extracción de datos se describe y evalúa en el texto principal del artículo.

Si el conjunto de datos es una muestra de un conjunto mayor, ¿cuál fue la estrategia de muestreo (por ejemplo, determinista, probabilística con probabilidades de muestreo específicas)?

La versión 1.0 incluirá todo el contenido de la colección de escaneos de Chronicling America.

¿Quiénes participaron en el proceso de recopilación de datos (por ejemplo, estudiantes, trabajadores de crowdsourcing, contratistas) y cómo se los remuneró (por ejemplo, cuánto se pagó a los trabajadores de crowdsourcing)?

Un grupo numeroso de profesores, asistentes de investigación y estudiantes colaboró en todos los aspectos del proceso de recopilación de datos, incluidos el etiquetado de los datos de entrenamiento, el entrenamiento y la validación de los modelos, la ingeniería de datos y el diseño conceptual. Todos fueron remunerados por su trabajo, de acuerdo con la normativa de Harvard University y New York University.

¿En qué período se recopilaron los datos? ¿Este período coincide con el período de creación de los datos asociados a las instancias (por ejemplo, un rastreo reciente de artículos de noticias antiguos)? Si no es así, describa el período en el que se crearon los datos asociados a las instancias.

Los escaneos de Chronicling America se procesaron entre el 6/1/23 y el 6/7/23. Los datos asociados a las instancias se crearon entre 1780 y 1963, cuando se publicaron en periódicos locales.

¿Se llevó a cabo algún proceso de revisión ética (por ejemplo, por parte de un comité de ética institucional)? Si es así, proporcione una descripción de estos procesos de revisión, incluidos sus resultados, así como un enlace u otro punto de acceso a la documentación de respaldo.

Los datos son íntegramente de dominio público y, por lo tanto, no están bajo la jurisdicción de los comités de ética institucionales de las universidades.

¿El conjunto de datos se refiere a personas? Si no es así, puede omitir las preguntas restantes de esta sección.

Sí, los artículos del conjunto de datos hablan de personas.

¿Recopilaron los datos directamente de las personas en cuestión u obtuvieron los datos a través de terceros u otras fuentes (por ejemplo, sitios web)?

Recopilamos estos datos de un tercero, la Biblioteca del Congreso, que ha verificado que todos los datos son de dominio público.

¿Se notificó a las personas en cuestión sobre la recopilación de datos? Si es así, describa (o muestre con capturas de pantalla u otra información) cómo se realizó la notificación y proporcione un enlace u otro punto de acceso al texto exacto de la notificación, o reprodúzcalo de otro modo.

Los datos son de dominio público y abarcan a muchos millones de personas, la mayoría de las cuales han fallecido.

¿Las personas en cuestión dieron su consentimiento para la recopilación y el uso de sus datos? Si es así, describa (o muestre con capturas de pantalla u otra información) cómo se solicitó y se otorgó el consentimiento, y proporcione un enlace u otro punto de acceso al texto exacto al que las personas dieron su consentimiento, o reprodúzcalo de otro modo.

Los datos son de dominio público y abarcan a muchos millones de personas, la mayoría de las cuales han fallecido.

Si se obtuvo el consentimiento, ¿se proporcionó a las personas que lo otorgaron un mecanismo para revocarlo en el futuro o para determinados usos? Si es así, proporcione una descripción, así como un enlace u otro punto de acceso al mecanismo (si corresponde).

No corresponde.

¿Se ha realizado un análisis del impacto potencial del conjunto de datos y de su uso sobre los titulares de los datos (por ejemplo, una evaluación de impacto relativa a la protección de datos)? Si es así, proporcione una descripción de este análisis, incluidos sus resultados, así como un enlace u otro punto de acceso a la documentación de respaldo.

No se ha realizado ningún análisis de ese tipo.

¿Algún otro comentario?

Ninguno.

Preprocesamiento/limpieza/etiquetado

¿Se realizó algún preprocesamiento, limpieza o etiquetado de los datos (por ejemplo, discretización o agrupamiento en intervalos, tokenización, etiquetado de categorías gramaticales, extracción de características SIFT, eliminación de

instancias, tratamiento de valores faltantes)? Si es así, proporcione una descripción. Si no es así, puede omitir el resto de las preguntas de esta sección.

No se realizó ningún preprocesamiento.

Usos

¿Se ha utilizado ya el conjunto de datos para alguna tarea? Si es así, proporcione una descripción.

En el texto principal se detallan usos de ejemplo.

¿Existe un repositorio que enlace con alguno o todos los artículos o sistemas que utilizan el conjunto de datos? Si es así, proporcione un enlace u otro punto de acceso.

Actualmente no existe un repositorio de ese tipo.

¿Para qué (otras) tareas podría utilizarse el conjunto de datos?

Existe una gran cantidad de usos potenciales en las ciencias sociales, las humanidades digitales y la investigación en aprendizaje profundo, que se analizan con más detalle en el texto principal.

¿Hay algo en la composición del conjunto de datos o en la forma en que se recopiló y se preprocesó, limpió o etiquetó que pueda afectar a usos futuros? Por ejemplo, ¿hay algo que un usuario futuro deba saber para evitar usos que podrían dar lugar a un trato injusto de personas o grupos (por ejemplo, estereotipos, problemas de calidad del servicio) u otros daños indeseables (por ejemplo, daños financieros, riesgos legales)? Si es así, proporcione una descripción. ¿Hay algo que un usuario futuro pueda hacer para mitigar estos daños indeseables?

Este conjunto de datos contiene contenido sin filtrar redactado por editores de periódicos, columnistas y otras fuentes. Refleja sus sesgos y los errores fácticos que cometieron.

¿Hay tareas para las que no debería utilizarse el conjunto de datos? Si es así, proporcione una descripción.

Recomendamos cautela al utilizar los datos para entrenar modelos de lenguaje generativos (sin un filtrado adicional), ya que contienen contenido que muchos considerarían tóxico.

¿Algún otro comentario?

Ninguno.

Distribución

¿Se distribuirá el conjunto de datos a terceros ajenos a la entidad (por ejemplo, empresa, institución, organización) en cuyo nombre se creó? Si es así, proporcione una descripción.

Sí. El conjunto de datos está disponible para uso público.

¿Cómo se distribuirá el conjunto de datos (por ejemplo, un archivo tarball en un sitio web, una API, GitHub)? ¿El conjunto de datos tiene un identificador de objeto digital (DOI)?

El conjunto de datos está disponible a través de HuggingFace. La descarga y las instrucciones se encuentran en https: //huggingface.co/datasets/dell-research-harvard/AmericanStories. El DOI del conjunto de datos es: https://doi.org/10.57967/hf/0757

¿Cuándo se distribuirá el conjunto de datos?

El conjunto de datos ya está disponible.

¿Se distribuirá el conjunto de datos bajo una licencia de derechos de autor u otra licencia de propiedad intelectual (PI), o bajo condiciones de uso (CdU) aplicables? Si es así, describa esta licencia o estas CdU y proporcione un enlace u otro punto de acceso a los términos de licencia o CdU pertinentes, o reprodúzcalos de otro modo, así como las tarifas asociadas a estas restricciones.

El conjunto de datos se distribuye bajo una licencia Creative Commons CC-BY. Los términos de esta licencia pueden consultarse en https://creativecommons.org/licenses/by/2.0/

¿Algún tercero ha impuesto restricciones basadas en la propiedad intelectual o de otro tipo sobre los datos asociados a las instancias? Si es así, describa estas restricciones y proporcione un enlace u otro punto de acceso a los términos de

licencia pertinentes, o reprodúzcalos de otro modo, así como las tarifas asociadas a estas restricciones.

No hay restricciones de terceros basadas en la propiedad intelectual ni de otro tipo sobre los datos.

¿Se aplican controles de exportación u otras restricciones regulatorias al conjunto de datos o a instancias individuales? Si es así, describa estas restricciones y proporcione un enlace u otro punto de acceso a la documentación de respaldo, o reprodúzcala de otro modo.

No se aplican controles de exportación ni otras restricciones regulatorias al conjunto de datos ni a instancias individuales.

¿Algún otro comentario?

Ninguno.

Mantenimiento

¿Quién dará soporte, alojará o mantendrá el conjunto de datos?

HuggingFace seguirá alojando el conjunto de datos. Los autores proporcionarán soporte, actualizaciones y mantenimiento.

¿Cómo se puede contactar al propietario, curador o administrador del conjunto de datos (por ejemplo, dirección de correo electrónico)?

Se puede contactar a Melissa Dell por correo electrónico en melissadell@fas.harvard.edu

¿Hay una fe de erratas? Si es así, proporcione un enlace u otro punto de acceso.

No hay fe de erratas.

¿Se actualizará el conjunto de datos (por ejemplo, para corregir errores de etiquetado, añadir nuevas instancias, eliminar instancias)? Si es así, describa con qué frecuencia, quién lo hará y cómo se comunicarán las actualizaciones a los usuarios (por ejemplo, lista de correo, GitHub).

El conjunto de datos se seguirá actualizando a medida que se procesen nuevos escaneos. Las nuevas versiones se añadirán a HuggingFace. Cualquier persona puede suscribirse a las notificaciones sobre el conjunto de datos a través de HuggingFace.

Si el conjunto de datos se refiere a personas, ¿existen límites aplicables a la conservación de los datos asociados a las instancias (por ejemplo, se informó a las personas en cuestión de que sus datos se conservarían durante un período determinado y luego se eliminarían)? Si es así, describa estos límites y explique cómo se harán cumplir.

Todos los datos son de dominio público.

¿Se seguirá dando soporte a las versiones anteriores del conjunto de datos, o se seguirán alojando o manteniendo? Si es así, describa cómo. Si no es así, describa cómo se comunicará su obsolescencia a los usuarios.

Las versiones anteriores del conjunto de datos seguirán siendo visibles a través del repositorio de HuggingFace.

Si otras personas desean ampliar, aumentar, desarrollar o contribuir al conjunto de datos, ¿existe un mecanismo para hacerlo? Si es así, proporcione una descripción. ¿Se validarán o verificarán estas contribuciones? Si es así, describa cómo. Si no es así, ¿por qué no? ¿Existe un proceso para comunicar o distribuir estas contribuciones a otros usuarios? Si es así, proporcione una descripción. El conjunto de datos se crea y se mantiene de forma privada. Actualmente no está previsto admitir contribuciones de código abierto.

para comunicar o distribuir estas contribuciones a otros usuarios? Si es así, proporcione una
descripción.
El conjunto de datos se crea y se mantiene de forma privada. Actualmente no está previsto admitir contribuciones de código
abierto.

¿Algún otro comentario?
Ninguno.

Ítem	Respuesta	Comentario
Para todos los modelos y algoritmos presentados, verifique si incluye:		
Una descripción clara del marco matemático, del algoritmo o del modelo.	Sí	
Una explicación clara de todos los supuestos.	Sí	
Un análisis de la complejidad (tiempo, espacio, tamaño de la muestra) de todos los algoritmos.	NA	La complejidad puede depender de la arquitectura y los métodos específicos de cada aplicación. Utilizamos modelos basados en transformers dentro de nuestro marco y hemos informado el perfil temporal y otros detalles relacionados
Para toda afirmación teórica, verifique si incluye:		
Un enunciado claro de la afirmación.	Sí	
Una demostración completa de la afirmación.	Sí	
Para todos los conjuntos de datos utilizados, verifique si incluye:		
Las estadísticas pertinentes, como el número de ejemplos	Sí	
Los detalles de las particiones de entrenamiento / validación / prueba	Sí	
Una explicación de todos los datos excluidos y de todos los pasos de preprocesamiento.	Sí	

Un enlace a una versión descargable del conjunto de datos o del entorno de simulación	Sí	Se proporciona un enlace al repositorio del Hugging Face Hub
Para los datos nuevos recopilados, una descripción completa del proceso de recopilación de datos, como las instrucciones a los anotadores y los métodos de control de calidad.	Sí	
Para todo el código compartido relacionado con este trabajo, verifique si		incluye:
Especificación de las dependencias.	Sí	
Código de entrenamiento.	Sí	
Códigos de evaluación	Sí	
Modelo(s) (pre)entrenado(s).	Sí	Disponible(s) en HuggingFace
Un archivo README que incluye una tabla de resultados acompañada del comando preciso que debe ejecutarse para producir esos resultados	Sí	
Para todos los resultados experimentales informados, verifique si incluye:		
El rango de hiperparámetros considerados, el método para seleccionar la mejor configuración de hiperparámetros y la especificación de todos los hiperparámetros utilizados para generar	Sí	

los resultados		
El número exacto de ejecuciones de entrenamiento y evaluación.	Sí	
Una definición clara de la medida o los estadísticos específicos utilizados para informar los resultados.	Sí	

Tabla S-2: Lista de verificación de reproducibilidad

Continúa en la página siguiente

Una descripción de los resultados con tendencia central (por ejemplo, media) y variación (por ejemplo, barras de error).	NA	
El tiempo de ejecución promedio de cada resultado, o el costo energético estimado.	Sí	Se han informado los tiempos tanto de entrenamiento como de inferencia
Una descripción de la infraestructura de cómputo utilizada	Sí	

Tabla S-2: Lista de verificación de reproducibilidad (continuación)

Referencias

- ALI, A., TOUVRON, H., CARON, M., BOJANOWSKI, P., DOUZE, M., JOULIN, A., LAPTEV, I., NEVEROVA, N., SYNNAEVE, G., VERBEEK, J., ET AL. Xcit: Cross-covariance image transformers. Advances in neural information processing systems 34 (2021).
- CAI, Z., AND VASCONCELOS, N. Cascade r-cnn: Delving into high quality object detection. Proceedings of the IEEE conference on computer vision and pattern recognition (2018), 61546162.
- CARLSON, J., BRYAN, T., AND DELL, M. Efficient ocr for building a diverse digital history. arXiv preprint arXiv:2304.02737 (2023).

- DOSOVITSKIY, A., BEYER, L., KOLESNIKOV, A., WEISSENBORN, D., ZHAI, X., UNTERTHINER, T., DEHGHANI, M., MINDERER, M., HEIGOLD, G., GELLY, S., ET AL. An image is worth 16x16 words: Transformers for image recognition at scale. arXiv preprint arXiv:2010.11929 (2020).
- GARBE, W. SymSpell, June 2012.
- GEBRU, T., MORGENSTERN, J., VECCHIONE, B., VAUGHAN, J. W., WALLACH, H., AU2, H. D. I., AND CRAWFORD, K. Datasheets for datasets, 2021.
- GUARNERI, J. Newsprint Metropolis. University of Chicago Press, 2017.
- HADSELL, R., CHOPRA, S., AND LECUN, Y. Dimensionality reduction by learning an invariant mapping. In 2006 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'06) (2006), vol. 2, IEEE, pp. 1735-1742.
- HANLON, W. W., AND BEACH, B. Historical newspaper data: A researcher's guide and toolkit, 2022.
- HOWARD, A., SANDLER, M., CHU, G., CHEN, L.-C., CHEN, B., TAN, M., WANG, W., ZHU, Y., PANG, R., VASUDEVAN, V., ET AL. Searching for mobilenetv3. Proceedings of the IEEE/CVF international conference on computer vision (2019), 1314-1324.
- JOHNSON, J., DOUZE, M., AND JÉGOU, H. Billion-scale similarity search with gpus. IEEE Transactions on Big Data 7, 3 (2019), 535-547.
- KHATTAB, O., SANTHANAM, K., LI, X. L., HALL, D., LIANG, P., POTTS, C., AND ZAHARIA, M. Demonstrate-search-predict: Composing retrieval and language models for knowledge-intensive nlp. arXiv preprint arXiv:2212.14024 (2022).
- KHOSLA, P., TETERWAK, P., WANG, C., SARNA, A., TIAN, Y., ISOLA, P., MASCHINOT, A., LIU, C., AND KRISHNAN, D. Supervised contrastive learning. arXiv preprint arXiv:2004.11362 (2020).
- KIRILLOV, A., MINTUN, E., RAVI, N., MAO, H., ROLLAND, C., GUSTAFSON, L., XIAO, T., WHITEHEAD, S., BERG, A. C., LO, W.-Y., ET AL. Segment anything. arXiv preprint arXiv:2304.02643 (2023).
- LEE, B. C. G., MEARS, J., JAKEWAY, E., FERRITER, M., ADAMS, C., YARASAVAGE, N., THOMAS, D., ZWAARD, K., AND WELD, D. S. The newspaper navigator dataset: extracting headlines and visual content from 16 million historic newspaper pages in chronicling america. In Proceedings of the 29th ACM International Conference on Information & Knowledge Management (2020), pp. 3055-3062.

- LEVENSHTEIN, V. I., ET AL. Binary codes capable of correcting deletions, insertions, and reversals. In Soviet physics doklady (1966), vol. 10, Soviet Union, pp. 707-710.
- LI, L., JAMIESON, K., DESALVO, G., ROSTAMIZADEH, A., AND TALWALKAR, A. Hyperband: A novel bandit-based approach to hyperparameter optimization, 2018.
- LI, M., LV, T., CUI, L., LU, Y., FLORENCIO, D., ZHANG, C., LI, Z., AND WEI, F. Trocr: Transformer-based optical character recognition with pre-trained models. arXiv preprint arXiv:2109.10282 (2021).
- LIBRARY OF CONGRESS. Chronicling America: Historic American Newspapers, 2022.
- LIU, Y., OTT, M., GOYAL, N., DU, J., JOSHI, M., CHEN, D., LEVY, O., LEWIS, M., ZETTLEMOYER, L., AND STOYANOV, V. Roberta: A robustly optimized bert pretraining approach. arXiv preprint arXiv:1907.11692 (2019).
- LIU, Z., LIN, Y., CAO, Y., HU, H., WEI, Y., ZHANG, Z., LIN, S., AND GUO, B. Swin transformer: Hierarchical vision transformer using shifted windows. arXiv preprint arXiv:2103.14030 (2021).
- MUSGRAVE, K., BELONGIE, S., AND LIM, S.-N. Pytorch metric learning, 2020.
- OCKERBLOOM, J. M. Newspaper copyrights, notices, and renewals, 2019.
- OORD, A. V. D., LI, Y., AND VINYALS, O. Representation learning with contrastive predictive coding. arXiv preprint arXiv:1807.03748 (2018).
- PASZKE, A., GROSS, S., MASSA, F., LERER, A., BRADBURY, J., CHANAN, G., KILLEEN, T., LIN, Z., GIMELSHEIN, N., ANTIGA, L., DESMAISON, A., KOPF, A., YANG, E., DEVITO, Z., RAISON, M., TEJANI, A., CHILAMKURTHY, S., STEINER, B., FANG, L., BAI, J., AND CHINTALA, S. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In Advances in Neural Information Processing Systems 32 (2019), H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché Buc, E. Fox, and R. Garnett, Eds., Curran Associates, Inc., pp. 8024-8035.
- REIMERS, N., AND GUREVYCH, I. Sentence-bert: Sentence embeddings using siamese bertnetworks. arXiv preprint arXiv:1908.10084 (2019).
- SHEN, Z., ZHAO, J., DELL, M., YU, Y., AND LI, W. Olala: Object-level active learning for efficient document layout annotation. arXiv preprint arXiv:2010.01762 (2020).
- SILCOCK, E., D'AMICO-WONG, L., YANG, J., AND DELL, M. Noise-robust de-duplication at scale. International Conference on Learning Representations (2023).

- SILCOCK, E., AND DELL, M. Amassive scale semantic similarity dataset of historical english,
- 2023.
- SMITH, D. A., CORDELL, R., AND MULLEN, A. Computational methods for uncovering reprinted texts in antebellum newspapers. American Literary History 27, 3 (2015), E1-E15.
- SONG, G., LIU, Y., AND WANG, X. Revisiting the sibling head in object detector. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (2020), 11563-11572.
- SONG, K., TAN, X., QIN, T., LU, J., AND LIU, T.-Y. Mpnet: Masked and permuted pretraining for language understanding. Advances in Neural Information Processing Systems 33 (2020), 16857-16867.
- TRAAG, V. A., WALTMAN, L., AND VAN ECK, N. J. From Louvain to Leiden: guaranteeing well-connected communities. Scientific Reports 9, 1 (Mar. 2019), 5233. Number: 1 Publisher: Nature Publishing Group.
- ULTALYTICS. Yolo v8 github repository. https://github.com/ultralytics/ ultralytics, 2023.
- WIGHTMAN, R. Pytorch image models. https://github.com/rwightman/ pytorch-image-models, 2019.