El conjunto de datos Newspaper Navigator: extracción y análisis del contenido visual de 16 millones de páginas de periódicos históricos de Chronicling America

Benjamin Lee*

University of Washington Library of Congress

bcgl@cs.washington.edu

Meghan Ferriter LC Labs

Library of Congress

Deborah Thomas

National Digital Newspaper Program Library of Congress

RESUMEN

Chronicling America es un producto del National Digital Newspaper Program, una alianza entre la Biblioteca del Congreso y el National Endowment for the Humanities para digitalizar periódicos históricos. Hasta la fecha se han digitalizado para Chronicling America más de 16 millones de páginas de periódicos históricos estadounidenses, con imágenes de alta resolución y OCR METS/ALTO legible por máquina. A los usuarios de Chronicling America les interesa considerablemente disponer de un corpus semantizado, que incluya el contenido visual y los titulares extraídos. Para lograrlo, presentamos un modelo de reconocimiento de contenido visual entrenado con anotaciones de cuadros delimitadores de fotografías, ilustraciones, mapas, historietas y caricaturas editoriales recopiladas en el marco de Beyond Words, la iniciativa de colaboración abierta (crowdsourcing) de la Biblioteca del Congreso, y complementadas con anotaciones adicionales, entre ellas las de titulares y anuncios publicitarios. Describimos nuestro flujo de procesamiento (pipeline), que utiliza este modelo de aprendizaje profundo para extraer 7 clases de contenido visual —titulares, fotografías, ilustraciones, mapas, historietas, caricaturas editoriales y anuncios publicitarios—, junto con contenido textual,

como los epígrafes derivados del OCR METS/ALTO, así como incrustaciones de imagen (image embeddings) para realizar consultas rápidas

*Trabajo realizado durante su estancia como Innovator-in-Residence [innovador residente] en la Biblioteca del Congreso y como estudiante de doctorado en la Paul G. Allen School for Computer Science and Engineering de la University of Washington.

Jaime Mears LC Labs Library of Congress Eileen Jakeway LC Labs Library of Congress

Chris Adams

IT Design & Development Library of Congress

Kate Zwaard Digital Strategy & LC Labs

Library of Congress

por similitud de imagen. Informamos los resultados de ejecutar el flujo de procesamiento sobre 16,3 millones de páginas del corpus de Chronicling America y describimos el conjunto de datos resultante, Newspaper Navigator, el mayor conjunto de datos de contenido visual extraído de periódicos históricos jamás producido. El conjunto de datos Newspaper Navigator, el modelo de reconocimiento de contenido visual ajustado y todo el código fuente se ponen en el dominio público para su reutilización sin restricciones.

INTRODUCCIÓN

Chronicling America, una iniciativa del National Digital Newspaper Program —a su vez una alianza entre la Biblioteca del Congreso y el National Endowment for the Humanities—, es un recurso invaluable para que historiadores académicos, locales y públicos; docentes y estudiantes; genealogistas; periodistas y el público en general exploren la historia estadounidense a través del contenido singularmente rico que se conserva en los periódicos locales históricos. Más de 16 millones de páginas de periódicos publicados entre 1789 y 1963 están disponibles públicamente en línea mediante un portal de búsqueda, así como a través de una API pública. Entre los datos de cada página figuran imágenes de 400 DPI y OCR METS/ALTO, un estándar mantenido por la Biblioteca del Congreso que incluye la localización del texto [2].

Las 16,3 millones de páginas de Chronicling America incluidas en Newspaper Navigator abarcan 174 años de historia estadounidense, e incluyen 47 estados, Washington, D.C. y Puerto Rico. En la Figura 1 mostramos mapas coropléticos con la cobertura geográfica de las 16,3 millones de páginas de periódicos de Chronicling America incluidas en el conjunto de datos Newspaper Navigator. En la Figura 2 mostramos la cobertura temporal de estas páginas. La cobertura refleja el proceso de selección con el que se determina qué periódicos se incluyen en Chronicling America; para un examen en profundidad,

Nathan Yarasavage

National Digital Newspaper Program Library of Congress

Daniel Weld

University of Washington

véanse [26, 55]. El proceso de selección debe tenerse en cuenta en la metodología de cualquier investigación realizada con el conjunto de datos Newspaper Navigator.

Si bien las imágenes y el OCR de Chronicling America ofrecen una gran cantidad de información, los usuarios interesados en el contenido visual extraído, incluidos los titulares, están actualmente limitados a búsquedas generales por palabras clave o a búsquedas manuales en páginas individuales de Chronicling America. Por ejemplo, el personal de la Biblioteca del Congreso ha elaborado hasta la fecha una colección de mapas de la Guerra Civil en periódicos históricos, pero la colección dista mucho de estar completa debido a la dificultad de buscar manualmente entre los cientos de miles de páginas de Chronicling America de 1861 a 1865 [7]. Un conjunto de datos completo sería de inmenso valor para los historiadores de la Guerra Civil. Del mismo modo, reunir todas las tiras cómicas de los periódicos publicados a principios del siglo XX proporcionaría a los investigadores de la historieta un corpus de una escala sin precedentes. Además, los usuarios no disponen actualmente de ningún método fiable para determinar qué artículos desambiguados aparecen en cada página, lo que plantea dificultades para los enfoques de procesamiento del lenguaje natural (PLN) en el estudio del corpus. Un conjunto de datos de titulares extraídos no solo ofrece a los investigadores información sobre los artículos individuales que aparecen en cada página, sino que también permite a los usuarios plantear preguntas como "¿Qué temas noticiosos aparecieron en la mitad superior de la portada y cuáles en la

mitad inferior, y en qué periódicos?". De hecho, abundan las preguntas de humanidades digitales que podrían plantearse con un conjunto de datos así. Y, sin embargo, las posibilidades van más allá de las humanidades digitales e incluyen la historia pública, la computación creativa, el uso educativo en el aula y la participación del público en las colecciones de la Biblioteca del Congreso.

Para empezar a construir conjuntos de datos más amplios del contenido visual de Chronicling America y para involucrar al público estadounidense, Library of Congress Labs lanzó en 2017 una iniciativa de colaboración abierta llamada Beyond Words 1. En esta iniciativa se pidió a voluntarios que trazaran cuadros delimitadores alrededor de fotografías, ilustraciones, historietas, caricaturas editoriales y mapas en periódicos de Chronicling America de la época de la Primera Guerra Mundial; también se les pidió que transcribieran los epígrafes corrigiendo el OCR dentro de cada anotación de cuadro delimitador, y que registraran al creador del contenido. Hasta la fecha se han reunido aproximadamente 10.000 anotaciones verificadas de Beyond Words.

Nuestra investigación se basa en las anotaciones de Beyond Words obtenidas mediante colaboración abierta: utilizamos los cuadros delimitadores trazados alrededor de fotografías, ilustraciones, historietas, caricaturas editoriales y mapas, así como anotaciones adicionales, entre ellas las que marcan titulares y anuncios publicitarios, para ajustar (fine-tuning) una implementación preentrenada de FasterRCNN del Model Zoo de Detectron2 [58, 76]. Nuestro modelo de reconocimiento de contenido visual predice cuadros delimitadores alrededor de estas 7 clases distintas de contenido visual en periódicos históricos. Este artículo presenta nuestro trabajo de entrenamiento de este modelo de reconocimiento de contenido visual y de construcción de un flujo de procesamiento para automatizar la identificación de este contenido visual en páginas de periódicos de Chronicling America. Inspirándonos en el flujo de trabajo de Beyond Words, extraemos el contenido textual correspondiente, como titulares y epígrafes, identificando el texto del OCR METS/ALTO que queda dentro de cada cuadro delimitador predicho. Este método es eficaz para obtener epígrafes porque a los voluntarios de Beyond Words se les pidió que incluyeran los epígrafes y el contenido textual pertinente dentro de sus anotaciones de cuadros delimitadores. Por último, para permitir consultas rápidas por similitud en tareas de búsqueda y recomendación, generamos incrustaciones de imagen para el contenido visual extraído mediante modelos ResNet-18 y ResNet-50 preentrenados en ImageNet. El conjunto de datos resultante, al que llamamos

conjunto de datos Newspaper Navigator, es la mayor colección de contenido visual extraído de periódicos históricos jamás producida.

1 https://labs.loc.gov/work/experiments/beyond-words/

Nuestras contribuciones son las siguientes:

- Presentamos un flujo de procesamiento de acceso público para extraer contenido visual y textual de páginas de periódicos históricos, diseñado para ejecutarse a gran escala sobre terabytes de datos de imagen. Las categorías de contenido visual incluyen titulares, fotografías, ilustraciones, mapas, historietas, caricaturas editoriales y anuncios publicitarios.
- Liberamos en el dominio público un modelo Faster-RCNN ajustado para esta tarea, que alcanza una precisión media promedio (mAP) 2 de cuadros delimitadores del 63,4% en un conjunto de validación de páginas de Chronicling America de la época de la Primera Guerra Mundial.
- Presentamos el conjunto de datos Newswpaper Navigator, un nuevo conjunto de datos público de titulares y contenido visual extraídos, junto con el contenido textual correspondiente, como títulos y epígrafes, producido al ejecutar el flujo de procesamiento sobre 16,3 millones de páginas de periódicos históricos de Chronicling America. Este corpus constituye el mayor conjunto de datos de su tipo jamás producido.

TRABAJOS RELACIONADOS

Corpus y conjuntos de datos

En los últimos 15 años, los esfuerzos realizados en todo el mundo para digitalizar periódicos históricos han tenido un éxito notable [52]. Además de Chronicling America, entre los grandes repositorios de periódicos digitalizados se cuentan Trove [23], Europeana [54, 75], Delpher [3], The British Newspaper Archive [6], OurDigitalWorld [12], Papers Past [13], NewspaperSG [22], newspapers.com [5] y Google Newspaper Search [24]. La disponibilidad de periódicos a la escala de millones de páginas digitalizadas ha impulsado la construcción de conjuntos de datos para tareas de aprendizaje supervisado relacionadas con los periódicos digitalizados. Además de Beyond Words, entre los conjuntos de datos para el reconocimiento de periódicos históricos figuran los conjuntos de datos de periódicos históricos de la Biblioteca Nacional de Luxemburgo [8], que incluyen

artículos y anuncios publicitarios segmentados; CHRONIC, un conjunto de datos de 452.543 imágenes de periódicos históricos neerlandeses [67]; y SIAMESET, de Europeana, un conjunto de datos de 426.777 anuncios publicitarios de periódicos históricos neerlandeses [73]. Entre los conjuntos de datos para tareas de aprendizaje automático con documentos históricos figuran READ-BAD [33] y DIVA-HisDB [61]. Sin embargo, todos estos conjuntos de datos están diseñados para servir como conjuntos de entrenamiento y no como conjuntos de datos exhaustivos del contenido extraído de corpus completos. Nuestro trabajo, en cambio, busca utilizar el conjunto de datos de Beyond Words para entrenar un modelo de reconocimiento de contenido visual con el fin de procesar el contenido visual del corpus de Chronicling America, que comprende más de 16 millones de páginas de periódicos históricos.

2 La precisión media promedio es la métrica estándar utilizada para evaluar comparativamente los modelos de detección de objetos; incorpora la intersección sobre la unión para valorar la precisión y la exhaustividad (recall). Describimos la métrica con más detalle en la sección 6.

Figura 1: Mapas coropléticos a nivel de estado y de condado que muestran la cobertura geográfica de las 16,3 millones de páginas de periódicos históricos de Chronicling America incluidas en el conjunto de datos Newspaper Navigator. El color amarillo indica que ninguna página cubre la región correspondiente. Puerto Rico aparece en la esquina inferior derecha de cada mapa.

Año

Figura 2: Histograma que muestra la cobertura temporal de las 16,3 millones de páginas de periódicos históricos de Chronicling America incluidas en el conjunto de datos Newspaper Navigator. Hasta 2016 se aplicó un límite temporal de 1922 para la digitalización de periódicos de Chronicling America, lo que explica la correspondiente caída de la cobertura temporal.

Extracción de contenido visual

Otros investigadores han construido herramientas y flujos de procesamiento para extraer y analizar, mediante aprendizaje profundo, el contenido visual de documentos históricos, entre ellos periódicos. 3 PageNet utiliza una red totalmente convolucional (Fully Convolutional Network) para extraer, píxel a píxel, los límites de página de documentos históricos [70]. dhSegment es un marco

de aprendizaje profundo para el procesamiento de documentos históricos que incluye tareas de segmentación y extracción píxel a píxel [19]. Liebl y Burghardt evaluaron comparativamente 11 redes troncales (backbones) de aprendizaje profundo distintas para la segmentación píxel a píxel de periódicos históricos, incluida la separación de elementos de maquetación como texto y tablas [41]. La colaboración AIDA de la University of Nebraska-Lincoln ha aplicado técnicas de aprendizaje profundo a corpus periodísticos, entre ellos Chronicling America y la Burney Collection of British Newspapers [44, 45, 46], para tareas como el reconocimiento de contenido poético [47, 68], así como el reconocimiento de contenido visual mediante dhSegment [48]. En lugar de un enfoque píxel a píxel, nosotros utilizamos cuadros delimitadores, lo que da como resultado un mejor rendimiento. Además, nuestro flujo de procesamiento reconoce 7 clases distintas de contenido visual (titulares, fotografías, ilustraciones, mapas, historietas, caricaturas editoriales y anuncios publicitarios), extrae el OCR correspondiente y genera incrustaciones de imagen. Por último, desplegamos nuestro flujo de procesamiento de reconocimiento de contenido visual a gran escala.

3 Para enfoques de clasificación de documentos históricos que no utilizan aprendizaje profundo, véase, por ejemplo, [40].

Desambiguación de artículos

La desambiguación de artículos en páginas de periódicos históricos interesa desde hace tiempo a los investigadores. Entre los grupos que han estudiado esta tarea figuran el proyecto IMPRESSO [56], el proyecto NewsEye [57] y Google Newspaper Search [24]. 4 Merece especial mención el enfoque adoptado por Google Newspaper Search, que extraía bloques de titulares usando como rasgos el tamaño de fuente del OCR y la razón área-perímetro, y utilizaba los titulares extraídos para segmentar cada página en artículos individuales [24]. 5 Nosotros también nos centramos en la extracción de titulares, porque constituye en sí misma una forma de desambiguación de artículos. Sin embargo, a diferencia de enfoques anteriores, tratamos la extracción de titulares como una tarea visual en el nivel de la imagen, y no como una tarea textual en el nivel del OCR. Nuestro enfoque novedoso consiste en aprovechar el carácter visualmente distintivo de los titulares en las páginas de los periódicos y entrenar un clasificador para predecir cuadros delimitadores alrededor de los titulares de la página. A continuación, el texto del titular contenido en cada cuadro delimitador se extrae del OCR METS/ALTO subyacente.

4 Trabajos relacionados se han centrado en la segmentación de contenido en libros [49].

5 Hasta donde sabemos, la extracción y clasificación de contenido visual quedaba fuera del alcance del proyecto.

Por último, cabe señalar que una desambiguación de artículos adecuada requiere la capacidad de filtrar el texto de los anuncios publicitarios, dada su omnipresencia. Al igual que con los titulares, tratamos la identificación de anuncios publicitarios como una tarea visual y no textual, porque los anuncios se identifican de manera muy natural por sus rasgos visuales. Dado que nuestro modelo de reconocimiento de contenido visual identifica los anuncios publicitarios de forma robusta, podemos distinguir el texto periodístico del texto publicitario.

Incrustaciones de imagen para colecciones de patrimonio cultural

En los últimos años, los investigadores han utilizado incrustaciones de imagen para visualizar y explorar el contenido visual de colecciones de patrimonio cultural. La interfaz PixPlot del Yale Digital Humanities Lab [31] y el proyecto National Neighbors [43] utilizan incrustaciones de Inception v3 [69]. El t-SNE Map de Google Arts & Culture utiliza incrustaciones producidas por el flujo de procesamiento de búsqueda de Google [29]. El proyecto Principal Components del Museo Nacional de Noruega [34] utiliza incrustaciones de imagen de Caffe ajustadas [36]. Olivia Vane utiliza incrustaciones de VGG-16 para visualizar la Royal Photographic Society Collection [72]. Del mismo modo, Brian Foo ha creado una visualización de la colección de imágenes del American Museum of Natural History [32] utilizando incrustaciones de VGG-16 [62]. Refik Anadol utiliza incrustaciones para visualizar la colección SALT Research [18]. En lo que respecta específicamente al contenido visual de periódicos históricos, Wevers y Smits han utilizado incrustaciones de Inception v3 para realizar un análisis a gran escala de los conjuntos de datos CHRONIC y SIAMESET, derivados de periódicos históricos neerlandeses [74]. Su trabajo incluye el despliegue de SIAMESE, un sistema de recomendación de anuncios publicitarios en periódicos históricos, así como un análisis del entrenamiento de una nueva capa de clasificación sobre las incrustaciones de Inception para predecir según categorías personalizadas [74].

De hecho, además de permitir visualizaciones de espacios latentes que capturan la similitud semántica, las incrustaciones de imagen son deseables para tareas de búsqueda visual y de recomendación porque permiten realizar con ellas consultas rápidas por similitud. Mediante modelos ResNet-18 y ResNet-50 [35] preentrenados en ImageNet, generamos incrustaciones de imagen para el contenido visual extraído; estas se incluyen en el conjunto de datos Newspaper Navigator con el fin de facilitar una variedad de tareas de búsqueda visual y de recomendación para el corpus de Chronicling America.

CÓDIGO

Todo el código analizado en este artículo se encuentra en el repositorio público de GitHub https://github.com/LibraryOfCongress/ newspaper-navigator y es de código abierto, puesto en el dominio público para su reutilización sin restricciones. Además, el repositorio incluye el modelo de reconocimiento de contenido visual ajustado, el conjunto de entrenamiento con el que se ajustó el modelo, un cuaderno de Jupyter para experimentar con el modelo de reconocimiento de contenido visual y una presentación de diapositivas con predicciones.

CONSTRUCCIÓN DEL CONJUNTO DE ENTRENAMIENTO

Reutilización de las anotaciones de Beyond Words

Para crear un conjunto de entrenamiento para nuestro modelo de reconocimiento de contenido visual, reutilizamos las anotaciones públicas de fotografías, ilustraciones, mapas, historietas y caricaturas editoriales procedentes de Beyond Words, una iniciativa de colaboración abierta lanzada por la Biblioteca del Congreso para que el público estadounidense se involucrara con el contenido visual de los periódicos de Chronicling America de la época de la Primera Guerra Mundial. La propia plataforma Beyond Words se construyó con Scribe [14]. El flujo de trabajo de colaboración abierta constaba de tres tareas distintas que los voluntarios podían elegir realizar:

- Mark [Marcar], en la que se pedía a los usuarios que "draw a rectangle around each unmarked illustration or photograph excluding those in advertisements [and] enclose any caption or text describing the picture and the illustrator or photographer" [trazaran un rectángulo alrededor de cada ilustración o fotografía no marcada, excluidas las que aparecen en anuncios publicitarios,

(e) incluyeran cualquier epígrafe o texto que describiera la imagen y al ilustrador o fotógrafo] [37].

- Transcribe [Transcribir], en la que se pedía a los usuarios que corrigieran el OCR del epígrafe de cada ilustración o fotografía marcada, transcribieran el nombre del autor y anotaran la categoría ("Editorial Cartoon," [caricatura editorial] "Comics/Cartoon," [historietas/viñeta] "Illustration," [ilustración] "Photograph," [fotografía] o "Map" [mapa]) [38].
- Verify [Verificar], en la que se pedía a los usuarios que seleccionaran la transcripción de otro voluntario que más se ajustara al epígrafe impreso. Los usuarios también podían descartar regiones defectuosas o aportar sus propias transcripciones en caso de que ninguna de las transcripciones fuera de buena calidad [39].

Hasta 6 personas distintas pueden haber intervenido en cada anotación durante este proceso. La anotación requería alcanzar al menos un 51% de acuerdo entre los voluntarios en los pasos Transcribe y Verify.

Para ajustar el modelo de reconocimiento de contenido visual, primero fue necesario convertir las anotaciones de Beyond Words obtenidas por colaboración abierta a un formato de datos adecuado para entrenar un modelo de aprendizaje profundo. Elegimos el formato del conjunto de datos Common Objects in Context (COCO) [42], un formato de datos estándar para tareas de detección de objetos, segmentación y generación de epígrafes, adoptado por Detectron2, la plataforma de aprendizaje profundo para la detección de objetos de Facebook AI Research [76].

Las anotaciones verificadas de Beyond Words utilizadas como datos de entrenamiento se descargaron del sitio web público de Beyond Words el 1 de diciembre de 2019. Para convertir el archivo JSON disponible para descarga en un conjunto de entrenamiento de aprendizaje profundo, escribimos un script de Python que descarga las imágenes de periódicos de Chronicling America utilizadas por Beyond Words y da formato a las anotaciones según el estándar COCO. El script está disponible en el repositorio de GitHub de Newspaper Navigator.

Reiteramos que las instrucciones del paso "Mark" [Marcar] pedían a los usuarios que "enclose any caption or text describing the picture and the illustrator or photographer" [incluyeran cualquier epígrafe o texto que describiera la imagen y al ilustrador o fotógrafo] [37]; por lo tanto, un modelo entrenado con estas

anotaciones aprende a incluir el texto pertinente dentro de los cuadros delimitadores del contenido visual, texto que luego puede extraerse de manera automatizada del OCR METS/ALTO correspondiente.

Incorporación de anotaciones

Como los titulares y los anuncios publicitarios no estaban incluidos en el flujo de trabajo de Beyond Words, añadimos anotaciones de titulares y anuncios publicitarios para todas las imágenes del conjunto de datos. Estas anotaciones no están verificadas, ya que cada página fue anotada por una sola persona. Además, debido al escaso número de mapas

Estadísticas del conjunto de entrenamiento/validación

Categoría	Recuento
Fotografía	4,254
Ilustración	1,048
Mapa	215
Historieta/Viñeta	1,150
Caricatura editorial	293
Titular	27,868
Anuncio publicitario	13,581
Total	48,409

Tabla 1: Tabla con el desglose del contenido de las 7 clases distintas del conjunto de datos de entrenamiento/validación producido a partir de las anotaciones de cuadros delimitadores de Beyond Words, complementadas con anotaciones adicionales.

anotados en los datos de Beyond Words (79 en total), añadimos anotaciones de 122 páginas que contenían mapas, obtenidas mediante una búsqueda por la palabra clave "map" [mapa] en el portal de búsqueda de Chronicling America restringida a los años 1914-1918. A continuación descargamos las páginas en las que identificamos mapas y anotamos las 7 categorías de contenido visual en cada página. Al igual que las anotaciones de titulares y anuncios publicitarios, estas anotaciones no están verificadas.

Estadísticas del conjunto de entrenamiento

El conjunto de datos de Beyond Words ampliado, en formato COCO, se encuentra en el repositorio de Newspaper Navigator y está disponible en el dominio público

para su reutilización sin restricciones. El conjunto de datos contiene 3.559 páginas de Chronicling America de la época de la Primera Guerra Mundial con 48.409 anotaciones en total. El desglose de las anotaciones por categoría figura en la Tabla 1.

ENTRENAMIENTO DEL MODELO DE RECONOCIMIENTO DE CONTENIDO VISUAL

Para entrenar un modelo de reconocimiento de contenido visual que identificara las 7 clases de contenido periodístico, optamos por ajustar un modelo preentrenado de detección de objetos Faster-RCNN del Model Zoo de Detectron2 mediante Detectron2 [76] y PyTorch [53]. Como la inferencia del modelo era el cuello de botella del tiempo de ejecución de nuestro flujo de procesamiento, elegimos la red troncal Faster-RCNN R50-FPN, la más rápida de su tipo en tiempo de inferencia. Aunque podríamos haber utilizado la red troncal Faster-RCNN de mayor rendimiento, que alcanzaba aproximadamente un 5% más de precisión media promedio en la tarea de preentrenamiento COCO [42] a costa de 2,5 veces el tiempo de inferencia, la evaluación cualitativa de las predicciones con la red troncal R50-FPN ajustada indicó que el modelo tenía un rendimiento suficiente para nuestros fines. Además, conjeturamos que el rendimiento de nuestro modelo de reconocimiento de contenido visual está limitado por el ruido de los datos de entrenamiento, y no por la arquitectura y la selección del modelo, por dos razones. En primer lugar, las etiquetas de referencia (ground truth) de Beyond Words no estaban completas, porque a los voluntarios solo se les exigía trazar un cuadro delimitador por página (aunque podían añadir más). En segundo lugar, hubo un desacuerdo no trivial entre los anotadores de Beyond Words en la tarea de marcado de cuadros delimitadores, debido a

Rendimiento (validación)

Categoría	AP	N.º en conj. val.
Fotografía	61.6%	879
Ilustración	30.9%	206
Mapa	69.5%	34
Historieta/Viñeta	65.6%	211
Caricatura editorial	63.0%	54
Titular	74.3%	5,689
Anuncio publicitario	78.7%	2,858

Promedio (mAP)	63.4%	N/A
Clase única	75.1%	9,931

Tabla 2: Tabla con la precisión promedio (AP) en los datos de validación del modelo de reconocimiento de contenido visual ajustado para las distintas categorías de contenido, así como el número de instancias de cada categoría en el conjunto de validación. La fila Promedio incluye la precisión media promedio de las 7 clases. La fila Clase única se calcula combinando todo el contenido visual en una sola clase y calculando la precisión promedio con esa clase única. Esto refleja cuánto error introduce la detección del contenido visual frente a su clasificación.

la heterogeneidad de las disposiciones del contenido visual y las ambigüedades que de ello resultaban en la tarea de anotación. 6

Todo el ajuste se realizó con PyTorch [53] en una instancia g4dn.2xlarge de Amazon EC2 con una sola GPU NVIDIA T4. El ajuste de la red troncal R50-FPN se evaluó en un conjunto de validación reservado según una partición 80%-20%; los archivos JSON con las particiones de entrenamiento y validación pueden descargarse junto con el repositorio de GitHub. Utilizamos los siguientes hiperparámetros: una tasa de aprendizaje base de 0,00025, un tamaño de lote de 8 y 64 propuestas por imagen. Como técnicas de aumento de datos se utilizaron RESIZE_SHORTEST_EDGE y RANDOM_FLIP. 7 Con detención temprana, el modelo se ajustó durante 77 épocas, lo que requirió 17 horas de ejecución en la GPU NVIDIA T4. El archivo de pesos del modelo es público y se encuentra en el repositorio de GitHub de este proyecto.

Informamos una precisión media promedio en el conjunto de validación del 63,4%; la precisión promedio de cada categoría, así como el número de instancias de validación de cada categoría, figuran en la Tabla 2. Elegimos la precisión promedio como métrica de evaluación porque es la métrica estándar utilizada en la comunidad de visión por computadora para evaluar comparativamente las tareas de detección de objetos. Dado un umbral fijo de intersección sobre la unión (IoU) para evaluar si una predicción es correcta, la precisión promedio se calcula ordenando todas las clasificaciones según su puntuación de predicción, generando la curva de precisión-exhaustividad correspondiente y modificándola mediante el trazado de la curva de menor área que la contiene y que además es monótonamente decreciente. Según el estándar

6 En cuanto a la exactitud de las anotaciones, cabe señalar que Beyond Words se lanzó como un experimento; en consecuencia, no hubo intervenciones en el flujo

de trabajo ni en la gestión de la comunidad después de su lanzamiento, y la exactitud de las anotaciones resultantes debe valorarse en consecuencia.

7 Son los dos únicos métodos de aumento de datos que Detectron2 admite actualmente.

Figura 3: Diagrama que muestra los pasos de nuestro flujo de procesamiento.

COCO, la precisión promedio se calcula luego promediando la precisión interpolada sobre 101 valores distintos de exhaustividad y 10 umbrales de IoU, del 50% al 95%. Para nuestros cálculos, utilizamos todas las predicciones con puntuaciones de confianza superiores a 0,05 y descartamos las predicciones con puntuaciones de confianza por debajo de este umbral. 8

EL FLUJO DE PROCESAMIENTO

Construcción del manifiesto

Para crear un índice completo de las páginas digitalizadas que el flujo de procesamiento debía procesar, utilizamos una bifurcación (fork) del repositorio chronam-get-images de la colaboración AIDA 9 para generar, para cada lote de periódicos, un manifiesto compuesto por las rutas de archivo de cada página del lote. 10 El 17 de marzo de 2020 se compilaron en total manifiestos que comprendían 16.368.424 páginas de Chronicling America.

Pasos del flujo de procesamiento

En la Figura 3 presentamos un diagrama del funcionamiento del flujo de procesamiento. Nuestro flujo de procesamiento procesó cada manifiesto en serie. El código del flujo de procesamiento consta de seis pasos distintos:

8 Una puntuación de confianza de 0,05 es el umbral de corte predeterminado para conservar predicciones en Detectron2.

9 https://github.com/bcglee/chronam-get-images

10 Puede encontrarse más información sobre los lotes en https://chroniclingamerica.loc.gov/batches.

- Descarga de la imagen y del XML METS/ALTO de cada página, y submuestreo de la imagen por un factor de 6 para producir un JPEG de menor resolución. El submuestreo se realizó para reducir la entrada/salida (E/S) y el consumo de memoria, así como para evitar la sobrecarga que introduciría el submuestreo que Detectron2 tendría que realizar antes de cada pasada hacia adelante durante la inferencia del modelo. Este paso se ejecutó en paralelo en los 48 núcleos de CPU de cada instancia de EC2. Los archivos se descargaron directamente de los buckets públicos de AWS S3 de la Biblioteca del Congreso.
- Ejecución de la inferencia del modelo de reconocimiento de contenido visual sobre cada imagen para producir predicciones de cuadros delimitadores con coordenadas, clases predichas y puntuaciones de confianza. Este paso se ejecutó en paralelo en las 4 GPU de cada instancia de EC2. Se guardaron las predicciones con puntuaciones de confianza superiores a 0,05. Optamos por guardar predicciones con puntuaciones de confianza bajas para permitir que cada usuario seleccione un umbral de corte según el equilibrio entre precisión y exhaustividad que considere ideal.
- Extracción del OCR contenido en cada cuadro delimitador predicho. Este paso requirió analizar sintácticamente el XML METS/ALTO y se ejecutó en paralelo en los 48 núcleos de CPU de cada instancia de EC2.
- Recorte y guardado del contenido visual extraído como JPEG submuestreados (para todas las clases salvo los titulares). Este paso se ejecutó en paralelo en los 48 núcleos de CPU de cada instancia de EC2.
- Generación de incrustaciones de ResNet-18 y ResNet-50 para las imágenes recortadas y guardadas con puntuaciones de confianza mayores

Estadísticas del conjunto de datos Newspaper Navigator

Categoría	Recuento ≥ Puntuación de confianza		
	≥ 0.9	≥ 0.7	≥ 0.5
Fotografía	1.59 ×10 6	2.63 ×10 6	3.29 ×10 6
Ilustración	8.15 ×10 5	2.52 ×10 6	4.36 ×10 6
Mapa	2.07 ×10 5	4.59 ×10 5	7.54 ×10 5
Historieta/Viñeta	5.35 ×10 5	1.23 ×10 6	2.06 ×10 6
Caricatura editorial	2.09 ×10 5	6.67 ×10 5	1.27 ×10 6
Titular	3.44 ×10 7	5.37 ×10 7	6.95 ×10 7
Anuncio	6.42 ×10 7	9.48 ×10 7	1.17 ×10 8

publicitario			
Total	1.02 ×10 8	1.56 ×10 8	1.98 ×10 8

Tabla 3: Tabla con el desglose del contenido extraído en el conjunto de datos Newspaper Navigator. Se presentan tres cortes distintos de la puntuación de confianza para mostrar el efecto de la elección del corte en el conjunto de datos resultante cuando se favorece la precisión o la exhaustividad.

o iguales a 0,5. Este paso se implementó con una bifurcación (fork) de img2vec 11 [59]. Este paso se ejecutó en paralelo en las 4 GPU de cada instancia de EC2. Las incrustaciones de ResNet-18 y ResNet-50 se extrajeron de la penúltima capa de cada arquitectura tras su entrenamiento en ImageNet (los modelos se descargaron de torchvision.models en PyTorch [53]). Se eligieron las incrustaciones de ResNet-50, de 2.048 dimensiones, por el alto rendimiento y el rápido tiempo de inferencia de ResNet-50 en comparación con otros modelos de reconocimiento de imágenes [21]. También se generaron las incrustaciones de ResNet-18, de 512 dimensiones, por su menor dimensionalidad, que permite un cálculo más rápido en tareas de búsqueda y recomendación.

- Guardado de los metadatos extraídos y de las imágenes recortadas. El formato de los metadatos guardados se describe en la sección siguiente.

Ejecución del flujo de procesamiento a gran escala

Todo el procesamiento se realizó en 2 instancias g4dn.12xlarge de Amazon AWS EC2, cada una con 48 vCPU Intel Cascade Lake y 4 GPU NVIDIA T4. Todo el código del flujo de procesamiento se escribió en Python 3. En total, el flujo de procesamiento procesó con éxito 16.368.041 páginas (99,998%) en 19 días de tiempo real transcurrido. Los manifiestos de las páginas procesadas con éxito, así como de las 383 páginas que fallaron, se encuentran en el repositorio de GitHub de Newspaper Navigator.

EL CONJUNTO DE DATOS NEWSPAPER NAVIGATOR

Estadísticas y visualizaciones

En la Tabla 3 se presenta un desglose estadístico del contenido extraído en el conjunto de datos Newspaper Navigator. Como la elección del umbral de corte de la puntuación de confianza afecta a la cantidad resultante de contenido visual en

el conjunto de datos Newspaper Navigator, incluimos estadísticas para tres umbrales de corte distintos: 0,5, 0,7 y 0,9.

11 https://github.com/bcglee/img2vec

En la Figura 4 mostramos visualizaciones del número de fotografías, ilustraciones, mapas, historietas, caricaturas editoriales, titulares y anuncios publicitarios del conjunto de datos Newspaper Navigator según el año de publicación. Estas visualizaciones muestran el número medio de apariciones por página de cada una de las siete clases a lo largo del tiempo, así como la fracción media de la página cubierta por cada una de las siete clases a lo largo del tiempo. Como en la Tabla 3, mostramos tres cortes distintos. Con estas visualizaciones podemos observar tendencias como el auge de las fotografías a comienzos del siglo XX y el aumento gradual del espacio de página ocupado por los titulares entre 1880 y 1920.

Para ilustrar preguntas que podemos empezar a responder con el conjunto de datos Newspaper Navigator, hemos incluido la Figura 5, una visualización que muestra los mapas de la Guerra Civil identificados al buscar en el contenido visual de las 278.094 páginas del conjunto de datos publicadas entre 1861 y 1865. 12 Solo a partir de esta colección, los investigadores pueden estudiar las batallas de la Guerra Civil, la historia de la cartografía, las diferencias en las tendencias de impresión entre los periódicos del Norte y los del Sur, y los patrones de reproducción de mapas ("viralidad").

Acceso al conjunto de datos y formato

Se puede acceder al conjunto de datos Newspaper Navigator a través del repositorio de GitHub de Newspaper Navigator. A continuación presentamos el formato de los datos, pero en la página web se encuentran instrucciones de uso más detalladas. Para cada página procesada, un archivo JSON asociado contiene los siguientes metadatos:

- filepath [str]: la ruta a la imagen, relativa a la estructura de archivos de Chronicling America. 13
- pub_date [str]: la fecha de publicación de la página, en el formato AAAA-MM-DD.
- boxes [list:list]: una lista que contiene las coordenadas normalizadas de los cuadros predichos, indexadas según [x1, y1, x2, y2], donde (x1,y1) es la esquina

superior izquierda del cuadro respecto del origen estándar de la imagen y (x2,y2) es la esquina inferior derecha.

- scores [list:float]: una lista que contiene la puntuación de confianza asociada a cada cuadro (solo se conservaron los cuadros predichos con una puntuación de confianza ≥ 0.5).
- pred_classes [list:int]: una lista que contiene la clase predicha para cada cuadro, según la siguiente correspondencia entre enteros y clases:
- 0→Photograph [Fotografía]
- 1→ Illustration [Ilustración]
- 2→Map [Mapa]
- 3→Comics/Cartoon [Historietas/Viñeta]
- 4→Editorial Cartoon [Caricatura editorial]
- 5→Headline [Titular]
- 6→Advertisement [Anuncio publicitario]
- ocr [list:str]: una lista que contiene el OCR de las cadenas separadas por espacios en blanco identificadas dentro de cada cuadro.

12 La visualización se creó con [16].

13 Véase, por ejemplo, https://chroniclingamerica.loc.gov/data/ batches/.

(a) Gráfico que muestra el número medio de apariciones por página de cada una de las siete clases de contenido visual, de 1850 a 1950. (b) Gráfico que muestra la fracción media de cada página cubierta por cada una de las siete clases de contenido visual, de 1850 a 1950.

Figura 4: Gráficos de varios paneles que visualizan el número de fotografías, ilustraciones, mapas, historietas, caricaturas editoriales, titulares y anuncios publicitarios del conjunto de datos Newspaper Navigator, derivado de 16,3 millones de páginas de periódicos históricos de Chronicling America. En cada gráfico, la línea central corresponde a un corte de 0,7 en la puntuación de confianza, y los límites superior e inferior del intervalo de confianza en azul claro corresponden a cortes de 0,5 y 0,9, respectivamente. Obsérvese que las escalas del eje y varían según la categoría en ambos gráficos. Se incluye la fracción cubierta de cada página porque es una métrica más coherente para disposiciones complejas de contenido visual (como los fotomontajes y los anuncios clasificados): el número de cuadros delimitadores predichos puede variar mucho aunque sigan siendo correctos y, en conjunto, cubran las mismas regiones.

- visual_content_filepaths [list:str]: una lista que contiene la ruta de archivo de cada imagen recortada (salvo los titulares, que no se recortaron ni guardaron).

Otro archivo JSON con el mismo nombre de archivo y el sufijo "_embeddings" incluye las incrustaciones de imagen en el formato siguiente; ninguna predicción con una puntuación de confianza inferior a 0,5 tiene una incrustación correspondiente:

- filepath [str]
- resnet_50_embeddings [list:list]: una lista que contiene la incrustación de ResNet-50, de 2.048 dimensiones, de cada imagen (salvo los titulares, para los que no se generaron incrustaciones).
- resnet_18_embeddings [list:list]: una lista que contiene la incrustación de ResNet-18, de 512 dimensiones, de cada imagen (salvo los titulares, para los que no se generaron incrustaciones).
- visual_content_filepaths [list:list]

Conjuntos de datos preempaquetados

Para que el conjunto de datos Newspaper Navigator sea accesible a quienes no tienen experiencia en programación, también hemos empaquetado conjuntos de datos más pequeños derivados del conjunto de datos Newspaper Navigator, que pueden descargarse en bloque desde nuestro repositorio de GitHub. Estos conjuntos de datos derivados están agrupados geográfica y temporalmente y abarcan tanto contenido visual como contenido textual (titulares legibles por máquina, epígrafes del contenido visual, Tabla 4: Tabla con la precisión promedio (AP) en conjuntos de prueba de 500 páginas anotadas de 1850 a 1875 y 500 páginas anotadas de 1875 a 1900. Debido a la escasez de las demás clases en los datos etiquetados, solo se incluyen titulares, anuncios publicitarios e ilustraciones. Como en la Tabla 2, Clase única se refiere a la precisión promedio al combinar todo el contenido visual en una sola clase, con el fin de reflejar cuánto error introduce la detección del contenido visual frente a su clasificación.

Categoría	AP (1850-1875)	AP (1875-1900)
Titular	21.2%	51.6%
Anuncio publicitario	7.3%	44.7%
Ilustración	N/A	36.4%
Clase única	12.1%	48.1%

Rendimiento en páginas de periódicos del siglo XIX

etc.). Un ejemplo de ello es la colección de mapas de la Guerra Civil que se muestra en la Figura 5. Seguiremos añadiendo conjuntos de datos derivados a medida que Newspaper Navigator evolucione.

DISCUSIÓN

Generalización a páginas de periódicos del siglo XIX

Dado que el modelo de reconocimiento de contenido visual se entrenó con periódicos de la época de la Primera Guerra Mundial, es natural preguntarse por la capacidad de generalización del modelo a los periódicos del siglo XIX. Aunque la Figura 4 revela tendencias coherentes con la intuición, como la aparición de fotografías en los periódicos históricos a comienzos del siglo XX, sigue valiendo la pena cuantificar la generalización. Para ello, seleccionamos al azar 500 páginas de periódicos de 1850 a 1875 y 500 páginas de periódicos de 1875 a 1900, y anotamos esas páginas. En la Tabla 4 presentamos la precisión promedio para titulares, anuncios publicitarios e ilustraciones en los conjuntos de prueba, tomando nuestras anotaciones como verdad de referencia (las demás clases se omitieron debido a su escasez en las páginas anotadas). Al comparar los resultados de la Tabla 4 con los resultados en los datos de validación de la 2, observamos una caída moderada del rendimiento para las páginas publicadas entre 1875 y 1900, así como una caída más pronunciada para las páginas publicadas entre 1850 y 1875. No obstante, el contenido visual extraído de las páginas anteriores a 1875 del conjunto de datos Newspaper Navigator sigue teniendo calidad suficiente para posibilitar análisis novedosos, como lo demuestra la colección extraída de mapas de la Guerra Civil que se muestra en la Figura 5.

Alianzas con iniciativas de colaboración abierta de voluntarios

Nuestro trabajo es también un estudio de caso sobre la asociación de proyectos de aprendizaje automático con iniciativas de colaboración abierta de voluntarios, un paradigma prometedor en el que los anotadores son voluntarios que aprenden sobre un tema nuevo al participar. Con el creciente impulso de iniciativas de colaboración abierta en el ámbito del patrimonio cultural, como By the People [1] de la Biblioteca del Congreso, Digital Volunteers [15] del Smithsonian, History Unfolded [9] del United States Holocaust Memorial Museum, Zooniverse [63],

Emigrant City [4] de la New York Public Library, LibCrowds [10] de The British Library, el proyecto Living with Machines [11] y la iniciativa de colaboración abierta sobre periódicos de Trove [20], hay más oportunidades que nunca de utilizar datos obtenidos por colaboración abierta para tareas de aprendizaje automático relevantes para el patrimonio cultural, desde el reconocimiento de escritura manuscrita hasta la clasificación taxonómica botánica [60]. Estas alianzas también pueden aportar conocimientos sobre el diseño de los proyectos, las decisiones, los flujos de trabajo y el contexto de los materiales para los que se solicitan contribuciones de colaboración abierta. Junto con el trabajo de Dielemann et al. [30], que entrenaron una red neuronal para clasificar galaxias con datos de colaboración abierta de GalaxyZoo, esperamos que nuestro proyecto anime a más investigadores en aprendizaje automático a asociarse con proyectos de colaboración abierta de voluntarios, especialmente para estudiar temas pertinentes al patrimonio cultural.

CONCLUSIÓN

En este artículo hemos descrito nuestro flujo de procesamiento para extraer, categorizar y dotar de epígrafes al contenido visual de periódicos históricos, incluidos titulares, fotografías, ilustraciones, mapas, historietas, caricaturas editoriales y anuncios publicitarios. Presentamos el conjunto de datos Newspaper Navigator, un conjunto de datos de estos 7 tipos de contenido visual extraído de 16,3 millones de páginas de Chronicling America. Es el mayor conjunto de datos de su tipo jamás producido. Además de publicar el conjunto de datos Newspaper Navigator, hemos publicado nuestro modelo de reconocimiento de contenido visual para periódicos históricos, así como un nuevo conjunto de datos de entrenamiento para esta tarea basado en las anotaciones de Beyond Words, la iniciativa de colaboración abierta de Library of Congress Labs para anotar y dotar de epígrafes al contenido visual de los periódicos de Chronicling America de la época de la Primera Guerra Mundial. Todo el código se ha puesto en el dominio público para su reutilización sin restricciones.

TRABAJO FUTURO

El trabajo futuro sobre el propio flujo de procesamiento incluye mejorar la capacidad de generalización del modelo de reconocimiento de contenido visual a las páginas de periódicos anteriores al siglo XX, especialmente para el 10,4% de las páginas del conjunto de datos Newspaper Navigator publicadas antes de 1875.

Esto podría lograrse ajustando el modelo con un conjunto de entrenamiento más diverso, que podría construirse en alianza con otra iniciativa de colaboración abierta de voluntarios, como el proyecto Living with Machines [11]. También cabría imaginar el entrenamiento de un conjunto (ensemble) de modelos de reconocimiento de contenido visual sobre distintos rangos de fechas. Dado que solo el 10,4% de las páginas del conjunto de datos Newspaper Navigator se publicó antes de 1875, es sencillo volver a ejecutar el flujo de procesamiento sobre esas páginas con un modelo de reconocimiento de contenido visual mejorado. 14

Para mejorar el contenido textual extraído del OCR, el trabajo futuro incluye entrenar un flujo de procesamiento de PLN que corrija los errores sistemáticos del OCR. En el segundo paso del flujo de Beyond Words, se pidió a los voluntarios que corrigieran o introdujeran el OCR que aparece sobre cada cuadro delimitador marcado, lo que ha dado como resultado hasta la fecha aproximadamente 10.000 anotaciones textuales corregidas. Es sencillo construir pares de entrada y salida para entrenar un modelo supervisado que corrija el OCR. Otros enfoques del posprocesamiento del OCR incluyen el uso de flujos existentes de corrección de OCR a posteriori [17, 50, 51, 71], todos los cuales podrían evaluarse comparativamente con los pares de entrenamiento de Beyond Words antes mencionados.

14 Esto solo requiere sustituir el archivo de pesos del modelo y filtrar por rango de fechas las páginas que se procesarán.

Figura 5: Visualización de los mapas de la Guerra Civil del conjunto de datos Newspaper Navigator, filtrados a partir de 278.094 páginas publicadas entre 1861 y 1865. Obsérvese que ciertos mapas aparecen varias veces, lo que indica que fueron reimpresos. Solo una pequeña fracción de las imágenes incluidas son falsos positivos, lo que sugiere el alto rendimiento del modelo de reconocimiento de contenido visual del flujo de procesamiento. Esta colección de mapas de la Guerra Civil está disponible como conjunto de datos preempaquetado.

El trabajo futuro que más nos entusiasma, sin embargo, consiste en las numerosas formas en que puede utilizarse el conjunto de datos Newspaper Navigator. Nuestro trabajo futuro inmediato consiste en construir una nueva interfaz de usuario de búsqueda llamada Newspaper Navigator, que se someterá a pruebas con usuarios para evaluar nuevos métodos de búsqueda exploratoria. No obstante, el trabajo futuro también incluye investigar una variedad de preguntas de humanidades digitales. Por ejemplo, los proyectos Viral Texts [25, 28, 65, 64, 66,

77] y Oceanic Exchanges [27] han estudiado los patrones de reproducción de textos en los periódicos del siglo XIX, incluidos periódicos de Chronicling America; el conjunto de datos Newspaper Navigator nos permite estudiar la reproducción de fotografías en los periódicos del siglo XX. Además, utilizando los titulares de Newspaper Navigator, podemos estudiar qué ciclos noticiosos aparecieron en distintas regiones de los Estados Unidos en distintos momentos. Estos ejemplos son solo algunos de los muchos que esperamos que se examinen con el conjunto de datos Newspaper Navigator. Esperamos inspirar una amplia variedad de proyectos de humanidades digitales, humanidades públicas y computación creativa.

AGRADECIMIENTOS

Los autores desean agradecer a Laurie Allen, Leah Weinryb Grohsgal, Abbey Potter, Robin Butterhof, Tong Wang, Mark Sweeney y a todo el personal del National Digital Newspaper Program de la Biblioteca del Congreso; a Molly Hardy, del National Endowment for the Humanities; a Stephen Portillo, Daniel Gordon y Tim Dettmers, de la University of Washington; a Michael Haley Goldman, Eric Schmalz y Elliott Wrenn, del United States Holocaust Memorial Museum; y a Gabriel Pizzorno, de la Harvard University, sus inestimables consejos para este proyecto. Por último, los autores desean agradecer a todas las personas que han contribuido a Chronicling America y Beyond Words, sin las cuales nada de este trabajo habría sido posible.

Este material se basa en trabajo financiado por la National Science Foundation Graduate Research Fellowship mediante la subvención DGE-1762114, el puesto de Innovator-in-Residence [innovador residente] de la Biblioteca del Congreso y la WRF/Cable Professorship.

REFERENCIAS

- N/A. About By the People. https://crowd.loc.gov/about/. (N/A).
- N/A. About Chronicling America. (N/A). https://chroniclingamerica.loc.gov/about/
- N/A. About Delpher. (N/A). https://www.delpher.nl/nl/platform/pages/helpitems?title=wat+is+delpher
- N/A. About Emigrant City. http://emigrantcity.nypl.org/#/about. (N/A).

- N/A. About Newspapers.com. (N/A). http://www.newspapers.com/about/ Library Catalog: www.newspapers.com.
- N/A. About The British Newspaper Archive. (N/A). https://www.britishnewspaperarchive.co.uk/help/about
- N/A. Civil War Maps - Newspaper and Current Periodical Reading Room (Serial and Government Publications Division, Library of Congress). (N/A). https://www.loc.gov/rr/news/topics/civilwarmaps.html
- N/A. Historical Newspapers â ˇA¸S BnL Open Data. (N/A). https://data.bnl.lu/data/historical-newspapers/
- N/A. History Unfolded: US Newspapers and the Holocaust. https://newspapers.ushmm.org/about/project. (N/A).
- N/A. LibCrowds Documentation. https://docs.libcrowds.com/. (N/A).
- N/A. Living with Machines: About Us. https://livingwithmachines.ac.uk/about/. (N/A).
- N/A. OurDigitalWorld: Digital Newspapers. (N/A). https: //ourdigitalworld.net/what-we-do/digital-newspapers/
- N/A. Papers Past. https://natlib.govt.nz/collections/a-z/papers-past. (N/A).
- N/A. Scribe: Document Transcription, Crowdsourced. https://scribeproject.github.io/. (N/A).
- N/A. Smithsonian Digital Volunteers: Transcription Center: About. https://transcription.si.edu/about. (N/A).
- Dmitry Alimov. 2017. Collage Maker. (2017). https://github.com/delimitry/collage_maker
- Chantal Amrhein and Simon Clematide. 2018. Supervised OCR Error Detection and Correction Using Statistical and Neural Machine Translation Methods. Journal for Language Technology and Computational Linguistics (JLCL) 33, 1 (2018), 49-76. https://doi.org/10.5167/uzh-162394
- Refik Anadol. 2020. Archive Dreaming. http://refikanadol.com/works/archive-dreaming/. (2020).
- Sofia Ares Oliveira, Benoit Seguin, and Frederic Kaplan. 2018. dhSegment: A generic deep-learning approach for document segmentation. In Frontiers in Handwriting Recognition (ICFHR), 2018 16th International Conference on. IEEE, 7-12.
- Marie-Louise Ayres. 2013. 'Singing for their supper': Trove, Australian newspapers, and the crowd. In IFLA WLIC 2013.
- Simone Bianco, Remi Cadene, Luigi Celona, and Paolo Napoletano. 2018. Benchmark Analysis of Representative Deep Neural Network Architectures.

IEEE Access 6 (2018), 64270-64277. DOI: http://dx.doi.org/10.1109/ACCESS.2018.2877890

- Mazelan bin Anuar, Cally Law, and Soh Wai Yee. 2012. Challenges of Digitizing Vernacular Newspapers & Preliminary Study of User Behaviour on NewspaperSG's Multilingual UI. In IFLA 2012 Pre-Conference: "The Electronic Re-evolution - News Media in the Digital Age". Mikkeli, Finland.
- Steve Cassidy. 2016. Publishing the Trove Newspaper Corpus. In Proceedings of the Tenth International Conference on Language Resources and Evaluation (LREC'16). European Language Resources Association (ELRA), Portorož, Slovenia, 4520-4525. https://www.aclweb.org/anthology/L16-1715
- Krishnendu Chaudhury, Ankur Jain, Sriram Thirthala, Vivek Sahasranaman, Shobhit Saxena, and Selvam Mahalingam. 2009. Google Newspaper Search – Image Processing and Analysis Pipeline. In 2009 10th International Conference on Document Analysis and Recognition. IEEE, Barcelona, Spain, 621-625. DOI: http://dx.doi.org/10.1109/ICDAR.2009.272
- Ryan Cordell. 2015. Reprinting, Circulation, and the Network Author in Antebellum Newspapers1. American Literary History 27, 3 (2015), 417-445. DOI: http://dx.doi.org/10.1093/alh/ajv028
- Ryan Cordell. 2017. "Q i-jtb the Raven": Taking Dirty OCR Seriously. Book History 20 (2017), 188 - 225.
- Ryan Cordell, M. H Beals, Isabel G Russell, Julianne Nyhan, Ernesto Priani, Marc Priewe, Hannu Salmi, Jaap Verheul, Raquel Alegre, Tessa Hauswedell, and et al. 2019. Oceanic Exchanges. (Oct 2019). DOI: http://dx.doi.org/10.17605/OSF.IO/WA94S
- Ryan Cordell and Abby Mullen. 2017. â ˇAIJFugitive Versesâ ˇA ̇I: The Circulation of Poems in Nineteenth-Century American Newspapers. American Periodicals: A Journal of History & Criticism 27 (2017), 29 - 52.
- Cyril Diagne, Nicolas Barradeau, and Simon Doury. 2018. t-SNEMap. https://experiments.withgoogle.com/t-sne-map. (2018).
- Sander Dieleman, Kyle W. Willett, and Joni Dambre. 2015. Rotation-invariant convolutional neural networks for galaxy morphology prediction. Monthly Notices of the Royal Astronomical Society 450, 2 (04 2015), 1441-1459. DOI:

http://dx.doi.org/10.1093/mnras/stv632

- Douglas Duhaime. 2020. PixPlot. https://github.com/YaleDHLab/pix-plot. (2020).
- Brian Foo. 2020. Visualizing AMNH Image Collection with Machine Learning. https://github.com/amnh-sciviz/image-collection. (2020).

- T. GrÃijning, R. Labahn, M. Diem, F. Kleber, and S. Fiel. 2018. READ-BAD: A New Dataset and Evaluation Scheme for Baseline Detection in Archival Documents. In 2018 13th IAPR International Workshop on Document Analysis Systems (DAS). 351-356. DOI: http://dx.doi.org/10.1109/DAS.2018.38
- Francoise Hanssen-Bauer, Magnus Bognerud, Dag Hensten, Gro Benedikte Pedersen, Even Westvang, and Audun Mathias ÃŸygard. 2018. t-SNEMap. https:
- //www.nasjonalmuseet.no/en/about-the-national-museum/ collection-management---behind-the-scenes/digitalcollection-management/project-principal-components/. (2018).
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2015. Deep Residual Learning for Image Recognition. arXiv preprint arXiv:1512.03385 (2015).
- Yangqing Jia, Evan Shelhamer, Jeff Donahue, Sergey Karayev, Jonathan Long, Ross Girshick, Sergio Guadarrama, and Trevor Darrell. 2014. Caffe: Convolutional Architecture for Fast Feature Embedding. arXiv preprint arXiv:1408.5093 (2014).
- LC Labs. 2017a. BeyondWords ("Mark"). (2017). http://beyondwords.labs.loc.gov/#/mark
- LC Labs. 2017b. Beyond Words ("Transcribe"). (2017). http://beyondwords.labs.loc.gov/#/transcribe
- LC Labs. 2017c. BeyondWords ("Verify"). (2017). http://beyondwords.labs.loc.gov/#/verify
- Benjamin Charles Germain Lee. 2018. Machine learning, template matching, and the International Tracing Service digital archive: Automating the retrieval of death certificate reference cards from 40 million document scans. Digital Scholarship in the Humanities 34, 3 (11 2018), 513-535. DOI: http://dx.doi.org/10.1093/llc/fqy063
- Bernhard Liebl and Manuel Burghardt. 2020. An Evaluation of DNN Architectures for Page Segmentation of Historical Newspapers. (2020).
- Tsung-Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C. Lawrence Zitnick. 2014. Microsoft COCO: Common Objects in Context. In Computer Vision - ECCV 2014, David Fleet, Tomas Pajdla, Bernt Schiele, and Tinne Tuytelaars (Eds.). Springer International Publishing, Cham, 740-755.
- Matthew Lincoln, Golan Levin, Sarah Reiff Conell, and Lingdong Huang. 2019. National Neighbors: Distant Viewing the National Gallery of Art's Collection of Collections. https://nga-neighbors.library.cmu.edu. (2019).

- Elizabeth Lorang. 2018. Patterns, Collaboration, Practice: Algorithms as Editing for Historic Periodicals. (2018), 14.
- Elizabeth Lorang and Leen-Kiat Soh. 2019a. Application of the Image Analysis for Archival Discovery Teamâ ˘A ´Zs First- Generation Methods and Software to the Burney Collection of British Newspapers. (2019), 21.
- Elizabeth Lorang and Leen-Kiat Soh. 2019b. Using Chronicling Americaâ ˘A´Zs Images to Explore Digitized Historic Newspapers & Imagine Alternative Futures. (2019), 19.
- Elizabeth Lorang, Leen-Kiat Soh, Maanas Varma Datla, and Spencer Kulwicki. 2015. Developing an Image-Based Classifier for Detecting Poetic Content in Historic Newspaper Collections. D-Lib Mag. 21 (2015).
- Elizabeth Lorang, Leen-Kiat Soh, Yi Liu, and Chulwoo Pack. 2020. Digital Libraries, Intelligent Data Analytics, and Augmented Description: A Demonstration Project. (2020). https://labs.loc.gov/static/labs/work/reports/UNL-final-report.pdf
- Lara McConnaughey, Jennifer Dai, and David Bamman. 2017. The Labeled Segmentation of Printed Books. In Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing. Association for Computational Linguistics, Copenhagen, Denmark, 737-747. DOI:http://dx.doi.org/10.18653/v1/D17-1077
- Quoc-Dung Nguyen, Duc-Anh Le, and Ivan Zelinka. 2019. OCR Error Correction for Unconstrained Vietnamese Handwritten Text. In Proceedings of the Tenth International Symposium on Information and Communication Technology (SoICT 2019). Association for Computing Machinery, New York, NY, USA, 132â ˘A¸S138. DOI: http://dx.doi.org/10.1145/3368926.3369686
- T. Nguyen, A. Jatowt, M. Coustaty, N. Nguyen, and A. Doucet. 2019. Deep Statistical Analysis of OCR Errors for Effective Post-OCR Processing. In 2019 ACM/IEEE Joint Conference on Digital Libraries (JCDL). 29-38. DOI:http://dx.doi.org/10.1109/JCDL.2019.00015
- Bob Nicholson. 2013. THE DIGITAL TURN: Exploring the methodological possibilities of digital newspaper archives. Media History: Special Issue: Journalism and History: Dialogues 19, 1 (2013), 59-73. http://www.tandfonline.com/doi/abs/10.1080/ 13688804.2012.752963
- Adam Paszke, Sam Gross, Francisco Massa, Adam Lerer, James Bradbury, Gregory Chanan, Trevor Killeen, Zeming Lin, Natalia Gimelshein, Luca Antiga, Alban Desmaison, Andreas Kopf, Edward Yang, Zachary DeVito, Martin Raison, Alykhan Tejani, Sasank Chilamkurthy, Benoit Steiner, Lu Fang, Junjie Bai, and

Soumith Chintala. 2019. PyTorch: An Imperative Style, High-Performance Deep Learning Library. In Advances in Neural Information Processing Systems 32, H. Wallach, H. Larochelle, A. Beygelzimer, F. d'Alché-Buc, E. Fox, and R. Garnett (Eds.). Curran Associates, Inc., 8024-8035. http://papers.neurips.cc/paper/9015-pytorch-an-imperativestyle-high-performance-deep-learning-library.pdf

- AleÅ ¸ a PekÃ ¸ arek and Marieke Willems. 2012. The Europeana Newspapers â ˇA¸S A Gateway to European Newspapers Online. In Progress in Cultural Heritage Preservation, Marinos Ioannides, Dieter Fritsch, Johanna Leissner, Rob Davies, Fabio Remondino, and Rossella Caffo (Eds.). Springer Berlin Heidelberg, Berlin, Heidelberg, 654-659.
- National Digital Newspaper Program. 2020. Chronicling America Guidelines & Resources. (2020). http://www.loc.gov/ndnp/guidelines/
- Impresso Project. 2017. Impresso Project Overview. (2017). https://impresso-project.ch/project/overview/
- Juha Rautiainen. 2019. Opening Digitized Newspapers for Different User Groups - Successes and Challenges. In IFLA WLIC 2019 - Athens, Greece - Libraries: Dialogue for Change.
- Shaoqing Ren, Kaiming He, Ross Girshick, and Jian Sun. 2015. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks. In Advances in Neural Information Processing Systems 28, C. Cortes, N. D. Lawrence, D. D. Lee, M. Sugiyama, and R. Garnett (Eds.). Curran Associates, Inc., 91-99. http://papers.nips.cc/paper/5638-faster-r-cnntowards-real-time-object-detection-with-regionproposal-networks.pdf
- Christian Safka. 2019. img2vec. (Nov. 2019). https://github.com/christiansafka/img2vec original-date: 2017-09-21T08:19:17Z.
- Eric Schuettpelz, Paul B.Â˘aFrandsen, Rebecca B.Â˘aDikow, Abel Brown, Sylvia Orli, Melinda Peters, Adam Metallo, Vicki A.Â˘aFunk, and Laurence J.Â˘aDorr. 2017. Applications of deep convolutional neural networks to digitized natural history collections. Biodiversity Data Journal 5 (2017). DOI: http://dx.doi.org/10.3897/BDJ.5.e21139
- Foteini Simistira, Mathias Seuret, Nicole Eichenberger, Angelika Garz, Marcus Liwicki, and Rolf Ingold. 2016. DIVA-HisDB: A Precisely Annotated Large Dataset of Challenging Medieval Manuscripts. In 2016 15th International Conference on Frontiers in Handwriting Recognition (ICFHR). IEEE, Shenzhen, China, 471-476. DOI:http://dx.doi.org/10.1109/ICFHR.2016.0093

- Karen Simonyan and Andrew Zisserman. 2015. Very Deep Convolutional Networks for Large-Scale Image Recognition. In International Conference on Learning Representations.
- Robert J. Simpson, Kevin R. Page, and David De Roure. 2014. Zooniverse: observing the world's largest citizen science platform. In WWW '14 Companion.
- D. A. Smith, R. Cordell, and E. M. Dillon. 2013. Infectious texts: Modeling text reuse in nineteenth-century newspapers. In 2013 IEEE International Conference on Big Data. 86-94. DOI: http://dx.doi.org/10.1109/BigData.2013.6691675
- D. A. Smith, R. Cordell, E. M. Dillon, N. Stramp, and J. Wilkerson. 2014. Detecting and modeling local text reuse. In IEEE/ACM Joint Conference on Digital Libraries. 183-192. DOI: http://dx.doi.org/10.1109/JCDL.2014.6970166
- David A. Smith, Ryan Cordell, and Abby Mullen. 2015. Computational Methods for Uncovering Reprinted Texts in Antebellum Newspapers. American Literary History 27, 3 (06 2015), E1-E15. DOI: http://dx.doi.org/10.1093/alh/ajv029
- T. Smits and W.J. Faber. 2018. CHRONIC (Classified Historical Newspaper Images). http://lab.kb.nl/dataset/chronic-classifiedhistorical-newspaper-images
- Leen-Kiat Soh, Elizabeth Lorang, and Yi Liu. 2018. Aida: Intelligent Image Analysis to Automatically Detect Poems in Digital Archives of Historic Newspapers. In Proceedings of the Thirty-Second AAAI Conference on Artificial Intelligence, (AAAI-18), the 30th innovative Applications of Artificial Intelligence (IAAI-18), and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence (EAAI-18), New Orleans, Louisiana, USA, February 2-7, 2018, Sheila A. McIlraith and Kilian Q. Weinberger (Eds.). AAAI Press, 7837-7842. https://www.aaai.org/ocs/index.php/AAAI/ AAAI18/paper/view/16880
- Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens, and Zbigniew Wojna. 2016. Rethinking the Inception Architecture for Computer Vision. In Proceedings of IEEE Conference on Computer Vision and Pattern Recognition,. http://arxiv.org/abs/1512.00567
- Chris Tensmeyer, Brian Davis, Curtis Wigington, Iain Lee, and Bill Barrett. 2017. PageNet: Page Boundary Extraction in Historical Handwritten Documents. In Proceedings of the 4th International Workshop on Historical Document Imaging and Processing (HIP2017). ACM, New York, NY, USA, 59-64. DOI: http://dx.doi.org/10.1145/3151509.3151522
- T. Underwood. 2017. Data Munging. https://github.com/tedunderwood/DataMunging. (2017).

- Olivia Vane. 2018. Visualising the Royal Photographic Society collection: Part 2. https://www.vam.ac.uk/blog/digital/visualising-theroyal-photographic-society-collection-part-2. (2018).
- M. Wevers and J. Lonij. 2017. SIAMESET. http://lab.kb.nl/dataset/siameset
- Melvin Wevers and Thomas Smits. 2019. The visual digital turn: Using neural networks to study historical images. Digital Scholarship in the Humanities 35, 1 (01 2019), 194-207. DOI: http://dx.doi.org/10.1093/llc/fqy085
- Marieke Willems and Rossitza Atanassova. 2015. Europeana Newspapers: searching digitized historical newspapers from 23 European countries. Insights 28, 1 (March 2015), 51-56. DOI: http://dx.doi.org/10.1629/uksg.218 Number: 1 Publisher: UKSG in association with Ubiquity Press.
- Yuxin Wu, Alexander Kirillov, Francisco Massa, Wan-Yen Lo, and Ross Girshick. 2019. Detectron2. https://github.com/facebookresearch/detectron2. (2019).
- Shaobin Xu, David Smith, Abigail Mullen, and Ryan Cordell. 2014. Detecting and Evaluating Local Text Reuse in Social Networks. In Proceedings of the Joint Workshop on Social Dynamics and Personal Attributes in Social Media. Association for Computational Linguistics, Baltimore, Maryland, 50-57. DOI: http://dx.doi.org/10.3115/v1/W14-2707