Los datos importan: en busca de corpus de alta calidad para construir modelos robustos y fiables para humanistas

Jaione Macicior-Mitxelena, Ana Garcia-Serrano

Universidad Pública de Navarra (UPNA), ETSI Informática (UNED)

jaione.macicior@unavarra.es, agarcia@lsi.uned.es

Resumen

La digitalización de periódicos históricos españoles plantea desafíos importantes debido a la baja calidad de los escaneos, la diversidad tipográfica, las disposiciones de página complejas y la variación lingüística respecto del español contemporáneo. Si bien los avances en el reconocimiento óptico de caracteres (OCR, por sus siglas en inglés) y en los modelos sensibles a la disposición de página ofrecen resultados prometedores, su eficacia depende en gran medida de la calidad y la coherencia de los corpus de entrenamiento subyacentes. Este trabajo se centra en la construcción y la evaluación de corpus para el procesamiento de documentos históricos. Se llevaron a cabo dos experimentos. En el primero se utilizó el corpus los101, un subcorpus curado manualmente y anotado estructuralmente, derivado de periódicos históricos españoles y diseñado para garantizar una verdad de referencia coherente en condiciones reales heterogéneas. Este corpus permite una experimentación sistemática en las tareas de OCR y de análisis de la disposición de los documentos. En una segunda fase experimental, aplicamos un corpus adicional centrado en la disposición de página, caracterizado por la regularidad estructural y una organización de página coherente, lo que nos permite aislar el efecto de la homogeneidad de la disposición sobre el rendimiento de la segmentación. Se evalúan modelos de OCR de vanguardia y un modelo de detección de la disposición como instrumentos de validación para valorar la adecuación de los corpus, y no como contribuciones principales. Los análisis cuantitativos y cualitativos basados en (1) la relación entre la calidad de la anotación, (2) la variabilidad estructural y (3) el comportamiento de los modelos muestran que los corpus heterogéneos ponen a prueba la estabilidad tanto de la transcripción como de la segmentación, mientras

que los datos con una disposición coherente mejoran significativamente la fiabilidad de la detección estructural.

Palabras clave: humanidades digitales, construcción de corpus, OCR, análisis de la disposición de página, periódicos históricos

1. Introducción

Antes de la era digital, la investigación sobre periódicos históricos requería acceso físico a archivos y colecciones impresas, lo que daba lugar a flujos de trabajo laboriosos y limitados geográficamente (Tworek, 2024). Desde comienzos de la década de 2000, las iniciativas sistemáticas de digitalización, como las impulsadas por instituciones como la Biblioteca Nacional de España (BNE), han permitido el acceso remoto a grandes repositorios de prensa y han facilitado el análisis computacional. Paralelamente, los avances en inteligencia artificial y en procesamiento del lenguaje natural han ampliado las posibilidades de investigación en humanidades digitales: los grandes modelos de lenguaje respaldan el procesamiento a gran escala de textos históricos no estructurados y hacen posibles aplicaciones como las interfaces conversacionales sobre el patrimonio (Sergeev et al., 2025), el análisis de sentimiento (Jaber et al., 2025) y la descripción automática de imágenes (Garcia-Arias y Garcia-Serrano, 2025), según se analiza en trabajos recientes (Simons et al., 2025; Lastra-Díaz et al., 2021).

Sin embargo, la eficacia de estas tecnologías depende fundamentalmente de la calidad y la coherencia de los corpus subyacentes. Los periódicos históricos españoles presentan desafíos específicos: escaneos degradados, variación tipográfica, ortografía no normalizada, disposiciones en varias columnas, anuncios, notas marginales y estructuras de página irregulares. En estos contextos, el rendimiento de los modelos suele verse limitado no sólo por el diseño de la arquitectura, sino también por la fiabilidad y la coherencia interna de los datos anotados que se utilizan para el entrenamiento y la evaluación.

El objetivo principal de este trabajo es examinar cómo el diseño del corpus, en particular la variabilidad de la disposición de página, afecta al rendimiento de los sistemas de OCR y de análisis de la disposición en periódicos históricos. Con este fin, llevamos a cabo dos fases experimentales: primero, utilizando un corpus heterogéneo curado manualmente (los101) para la experimentación conjunta de OCR y de disposición; y, segundo, introduciendo un corpus estructuralmente homogéneo dedicado al análisis de la disposición, con el fin de aislar el efecto de

la regularidad de la disposición sobre el rendimiento de la segmentación. los101 (Miguez Lamanuzzi et al. (2025)) es un corpus curado manualmente según criterios de anotación filológicos y estructurales para garantizar la coherencia y la reproducibilidad de la verdad de referencia (Torterolo-Orta et al., 2025). En lugar de priorizar la comparación entre modelos, las arquitecturas de OCR y de disposición se emplean como instrumentos de diagnóstico para examinar cómo el diseño del corpus, la coherencia de la anotación y la variabilidad de la disposición afectan al rendimiento computacional. Se analizan sistemáticamente los factores clave que influyen en el comportamiento de los sistemas. Además, la adaptación al dominio está limitada por el tamaño modesto del conjunto de datos anotado, la heterogeneidad tipográfica y la calidad variable de los escaneos. En conjunto, ambos corpus proporcionan condiciones experimentales complementarias que nos permiten analizar la relación entre la calidad de la anotación, la variabilidad estructural y el comportamiento de los modelos.

El resto del trabajo se organiza de la siguiente manera. La sección 2 revisa trabajos previos sobre OCR y análisis de la disposición para el procesamiento de documentos históricos. La sección 3 detalla la motivación y la construcción de los corpus. La sección 4 describe la configuración experimental y los modelos utilizados, y las subsecciones siguientes presentan las estrategias de preprocesamiento y las métricas de evaluación, mientras que la sección 5 analiza los resultados experimentales. La sección 6 concluye con las implicaciones para el diseño de corpus y las futuras líneas de investigación.

2. Trabajos relacionados

El reconocimiento óptico de caracteres (OCR) convierte imágenes escaneadas en texto legible por máquina y permite el acceso a archivos digitales con fines de investigación y recuperación (Benavent et al., 2010). La precisión del OCR repercute en los resultados de investigaciones como la atribución de autoría (Hill y Hengchen, 2019; Garcia Serrano y Menta Garuz, 2022) y en la satisfacción de los usuarios en la búsqueda de documentos históricos (Kettunen et al., 2022). Los enfoques neuronales recientes han mejorado la calidad de la transcripción mediante la corrección y la normalización automáticas (Fleischhacker et al., 2025). Herramientas colaborativas como OCR4all e Impresso contribuyen además a ello al permitir la interacción entre humanos y máquinas para el refinamiento (Düring et al., 2024). Las arquitecturas transformer, como TrOCR, han revolucionado el OCR al ofrecer una transcripción de extremo a extremo con un

codificador visual y un decodificador textual, y han alcanzado resultados de vanguardia en diversos conjuntos de datos (Li et al., 2023; Moreno-Sandoval et al., 2024; Bengio et al., 2013).

La digitalización de periódicos históricos españoles plantea desafíos particulares debido a la calidad variable de los escaneos, la diversidad tipográfica y las disposiciones de página complejas (Sánchez-Salido et al., 2023; Liebl y Burghardt, 2021). Mientras que el OCR tradicional tiene dificultades con estos problemas, el aprendizaje profundo (CNN, RNN) ha aumentado la robustez al aprender patrones visuales, aunque estas redes presentan limitaciones con las secuencias largas y la computación en paralelo (Vaswani et al., 2017; Cho, 2014).

Junto con el OCR, el análisis de la disposición de página garantiza un orden de lectura correcto y la coherencia semántica mediante la segmentación de elementos como columnas y títulos (Rezanezhad et al., 2023). Los primeros métodos mejoraron la precisión al preservar la estructura de la página (Chen et al., 2017; Alberti et al., 2017; Zhu et al., 2022). Más recientemente, los marcos de detección de objetos como YOLO, en concreto los modelos DocLayoutYOLO, tratan las regiones estructurales como objetos visuales, en particular en las disposiciones complejas de los periódicos (Zhao et al., 2024; Santos Júnior et al., 2025; Shen et al., 2021).

Varias cadenas institucionales de digitalización han adoptado una estrategia de segmentación previa, en la que las cajas de la disposición se detectan y normalizan antes de la transcripción por OCR. Por ejemplo, el proyecto Esperanto Newspaper Excerpts de Austrian National Library Labs implementa un flujo de trabajo en el que primero se identifican las regiones del documento mediante modelos de detección de objetos y después se aplica el reconocimiento de texto, lo que pone de relieve la importancia del preprocesamiento estructural para los periódicos históricos (Austrian National Library Labs, 2024).

Estos avances muestran una convergencia entre el modelado visual y el lingüístico en la digitalización de documentos. Sin embargo, su eficacia depende de corpus anotados de alta calidad, que escasean para los materiales históricos en español, lo que motivó la creación del corpus los101 para los experimentos de este estudio.

No obstante, si bien numerosos estudios evalúan modelos de OCR y de disposición de página, son menos los trabajos que analizan explícitamente cómo la

variabilidad estructural del corpus condiciona el comportamiento de los modelos en las distintas tareas. Este vacío motiva el diseño experimental en dos fases utilizado en este estudio.

3. La necesidad de un corpus de calidad

La experimentación se organiza en dos fases, tal como se presentan en los párrafos siguientes.

Fase 1: experimentos de OCR y de disposición con un corpus heterogéneo. La primera fase de este estudio se centró en evaluar sistemas de OCR sobre periódicos históricos españoles, mediante un enfoque clásico con Tesseract, un motor de OCR de código abierto mantenido por Google. Los experimentos se realizaron en el marco de la tarea compartida PastReader 2025 (IberLEF) 1 , que abordó la transcripción automática de periódicos históricos. El corpus PastReader Montejo-Ráez et al. (2025) consta de más de 12.000 páginas escaneadas de ocho publicaciones heterogéneas que abarcan géneros culturales, científicos, satíricos y literarios. Estos materiales presentan tipografías, disposiciones y estados de conservación diversos, lo que constituye un banco de pruebas exigente para los sistemas de OCR (véase la figura 1).

Figura 1: Páginas de muestra del corpus PastReader.

Se evaluaron dos configuraciones de Tesseract:

- Modelo de base (spa): el modelo predeterminado para el español (spa v5.3), utilizado como referencia

1 https://sites.google.com/view/ pastreader2025

sin ajustes adicionales.

- Modelo ajustado (los101): adaptado al conjunto de entrenamiento de PastReader mediante la utilidad tesstrain. El ajuste fino sigue la cadena de procesamiento de Tesseract basada en LSTM, que requiere pares alineados de imágenes de líneas de texto y sus transcripciones correspondientes en UTF-8. Cada muestra de entrenamiento se segmentó línea por línea, lo que significa que cada línea debe definirse mediante sus coordenadas.

La evaluación empleó métricas estándar de OCR, entre ellas la tasa de error de caracteres (CER, por sus siglas en inglés), la tasa de error de palabras (WER) y

medidas semánticas (BLEU y ROUGE-L) (algunos detalles en la subsección 4.1). Los resultados mostraron que el ajuste fino no mejoró el rendimiento: la CER aumentó ligeramente de 0.36 a 0.38 y la puntuación BLEU disminuyó marginalmente. El análisis de errores reveló que las anotaciones heterogéneas y las disposiciones complejas en varias columnas dificultaron la convergencia, sobre todo en las páginas con tipografía irregular o con incoherencias en la segmentación de líneas.

Para superar estas limitaciones, se creó un subcorpus específico con anotaciones coherentes y una verdad de referencia controlada, lo que garantizó datos de alta calidad para los experimentos posteriores. Del conjunto de datos PastReader se seleccionaron cuidadosamente 101 documentos a partir de análisis cualitativos, que se transcribieron manualmente con la plataforma Transkribus, la cual admite tanto la transcripción textual como el marcado estructural mediante regiones, etiquetas y relaciones entre regiones. El corpus (los101) se dividió en conjuntos de entrenamiento (80 %), validación (10 %) y prueba (10 %) Miguez Lamanuzzi et al. (2025).

Las anotaciones siguieron una guía de transcripción unificada con un enfoque literal modernizado, que preserva la ortografía y omite los rasgos puramente paleográficos (Miguez Lamanuzzi y García Serrano, 2026). En otras palabras, la normalización se dirige a la variabilidad gráfica sin alterar el contenido lingüístico subyacente. Las pautas abarcaron el texto ilegible, las notas marginales, las notas al pie y la segmentación estructural en párrafos, encabezados y otras cajas. Se incluyeron relaciones entre regiones, como la vinculación de títulos con cuerpos de texto o de imágenes con sus pies, para captar el orden de lectura y la disposición del documento, en apoyo de los modelos de OCR multimodales (Miguez Lamanuzzi et al., 2026).

Fase 2: análisis de la disposición con un corpus homogéneo. A pesar de la alta calidad de sus anotaciones, los101 presenta una considerable heterogeneidad en la disposición de página, que incluye variaciones en la estructura de columnas, la tipografía, el espaciado y la organización visual general.

Para investigar el efecto de la regularidad de la disposición, se construyó un segundo corpus (layout-homogeneous) específicamente para el análisis de la disposición. Este corpus consta de páginas digitalizadas de nueve periódicos diferentes, que abarcan estilos editoriales diversos (véase la figura 2). Se diseñó para presentar estructuras de página más homogéneas, con configuraciones de columnas y patrones de disposición más coherentes entre las muestras Obispo et

al. (2026). Contiene únicamente anotaciones de disposición, ya que su propósito es aislar el efecto de la coherencia estructural sobre el rendimiento de la segmentación, y no evaluar la calidad del OCR.

Figura 2: Páginas de muestra del corpus. Cada imagen procede de un periódico distinto incluido en el conjunto de datos.

4. Banco de pruebas para las tareas de OCR y de disposición

Para evaluar la adecuación de los corpus construidos, se emplearon modelos representativos de OCR y de disposición como herramientas de diagnóstico, y no como contribuciones principales de la investigación. Los sistemas seleccionados, Tesseract, TrOCR, Granite y DocLayoutYOLO, abarcan el OCR clásico, el reconocimiento basado en transformers, la transcripción multimodal y la segmentación de la disposición basada en la detección de objetos. Esta diversidad nos permite observar cómo las características del corpus influyen en el rendimiento en distintos paradigmas arquitectónicos.

Los experimentos se llevaron a cabo en dos fases que reflejan el diseño de los corpus:

- Fase 1: experimentos de OCR y de disposición sobre el

corpus heterogéneo los101, que contiene anotaciones tanto textuales como estructurales.

- Fase 2: experimentos de segmentación de la disposición realizados de forma independiente sobre ambos corpus, con una configuración de entrenamiento especializada centrada exclusivamente en la detección de la disposición, para aislar el efecto de la regularidad estructural sobre el rendimiento de la segmentación.

Cada modelo requiere una cadena de preprocesamiento adaptada a sus supuestos arquitectónicos y a sus restricciones de entrada. Tesseract, como motor de OCR clásico, opera sobre imágenes TIFF emparejadas con anotaciones a nivel de carácter y genera internamente representaciones intermedias de entrenamiento. TrOCR, un modelo de OCR basado en transformers, procesa imágenes JPEG alineadas con sus transcripciones textuales correspondientes, según un paradigma de aprendizaje de secuencia a secuencia. Granite, concebido como un sistema de OCR multimodal, requiere que las imágenes se redimensionen

proporcionalmente y se inserten en un lienzo de tamaño fijo para preservar la relación de aspecto y garantizar dimensiones de entrada uniformes. En cambio, DocLayoutYOLO aborda la segmentación de la disposición y, por lo tanto, procesa las imágenes de los documentos junto con anotaciones estructurales en formato YOLO que codifican las coordenadas de los cuadros delimitadores y las clases de región.

Aunque estos flujos de preprocesamiento difieren según el diseño arquitectónico, todos los modelos se integran en un marco experimental unificado para garantizar la coherencia metodológica y una comparación equitativa.

4.1. Métricas de evaluación

Para valorar el comportamiento de los modelos, consideramos varias métricas de evaluación adecuadas a cada tarea. En (Macicior Mitxelena, 2025) se exploró un conjunto más amplio de medidas, y el código se publicó en GitHub (Jaione Macicior Mitxelena y Ana Garcia-Serrano., 2026)); sin embargo, en aras de la claridad y la concisión, este artículo presenta y analiza únicamente las más representativas.

En cuanto a las métricas de la subtarea de OCR, se utiliza la tasa de error de caracteres (CER) (cuanto más baja, mejor), complementada con métricas semánticas (BLEU y ROUGE-L). Las métricas empleadas para la subtarea de análisis de la disposición deben tener en cuenta la precisión de la segmentación y la de la clasificación. La precisión de la segmentación se mide mediante la intersección sobre la unión (IoU, por sus siglas en inglés), que cuantifica el solapamiento entre los cuadros delimitadores predichos y los de la verdad de referencia:

IoU = Área de la intersección / Área de la unión

El rendimiento de la clasificación se evalúa mediante la precisión (precision) y la exhaustividad (recall), con el fin de obtener su media armónica (puntuación F1), calculada por tipo de región.

Además, se consideran la precisión media promedio con un umbral de IoU de 0.5 (mAP@0.5) y la mAP@0.5:0.95, que promedia el rendimiento en múltiples umbrales de IoU (0.5-0.95). Estas métricas proporcionan un marco estándar de evaluación de la detección de regiones que capta conjuntamente la calidad de la localización y de la clasificación en distintos niveles.

Por último, para equilibrar explícitamente la precisión espacial y la categorial, definimos una nueva métrica, la puntuación compuesta de disposición:

$$\text{Score}_{\text{layout}} = \alpha \cdot \text{IoU} + (1 - \alpha) \cdot \text{F1-score},$$

donde $\alpha \in [0, 1]$ controla el peso relativo de la localización frente a la clasificación. En este estudio, $\alpha = 0.75$, lo que prioriza una ubicación espacial precisa sin dejar de tener en cuenta el etiquetado correcto de las regiones.

4.2. Fase 1: evaluación de la adaptación al corpus

Para garantizar la coherencia metodológica, se aplicó el mismo protocolo experimental a los tres modelos de OCR (Tesseract, TrOCR y Granite). Siguiendo los procedimientos de preprocesamiento descritos, cada modelo de base se ajustó con la partición de entrenamiento del corpus los101. A continuación, se evaluó el rendimiento en los conjuntos correspondientes de entrenamiento, validación y prueba, y los resultados de los modelos ajustados se compararon sistemáticamente con los de sus respectivos modelos de base.

Esta configuración controlada nos permite aislar y medir el efecto específico de las características del corpus sobre el rendimiento de la transcripción. Al mantener idénticas las particiones de entrenamiento y de evaluación en todos los modelos, cualquier variación observada entre las configuraciones de base y las ajustadas puede atribuirse a la influencia del corpus construido y no a diferencias en el diseño experimental. Esta comparación funciona como un mecanismo de diagnóstico para valorar en qué medida el corpus favorece la adaptación en distintas arquitecturas de OCR, incluidos el OCR clásico (Tesseract), el reconocimiento de secuencia a secuencia basado en transformers (TrOCR) y la transcripción multimodal (Granite).

Los experimentos iniciales de detección de la disposición y de clasificación de cajas se llevaron a cabo sobre el corpus heterogéneo los101 y utilizaron una configuración conjunta que combinaba la detección de la disposición y la clasificación de cajas. (véase la tabla 2).

El ajuste fino del modelo DocLayoutYOLO se realizó con una configuración mínima: 30 épocas, tamaño de lote de 2, sin aumento de datos explícito, sin congelación de capas y sin regularización más allá de los parámetros de optimización predeterminados. La precisión mixta estaba desactivada y la

validación activada, pero el régimen de entrenamiento no incluyó ningún tipo de aumento de datos ni estrategias de convergencia controlada.

Con esta configuración, el modelo se optimizó conjuntamente para la detección de la disposición y la clasificación de cajas, lo que aumentó la complejidad de la tarea al operar sobre un corpus estructuralmente heterogéneo. Es probable que el número limitado de épocas y la ausencia de mecanismos de regularización agravaran la inestabilidad, en particular ante estructuras de página incoherentes.

4.3. Fase 2: evaluación de la segmentación de la disposición

Como se comentó anteriormente, en la segunda fase se aplicó por separado una estrategia de ajuste fino controlado del modelo DocLayoutYOLO a ambos corpus, los101 y layout-homogeneous, con lo que se obtuvieron los modelos los101_augment y per_augment, respectivamente.

Para mejorar la robustez del modelo frente a los artefactos de digitalización, se aplicó una estrategia de aumento geométrico de datos que simula la variabilidad de los documentos reales. Esta incluyó pequeñas rotaciones (±2.0◦) y cizallamiento lateral (2.0◦) para reproducir la inclinación de la página y la curvatura causada por la encuadernación, junto con traslación (0.1) y escalado (0.3) para dar cuenta de márgenes irregulares. Aunque se utilizó el aumento en mosaico para mejorar la extracción de características de la imagen a múltiples escalas, se desactivó deliberadamente durante las últimas 15 épocas. Esta fase de desaumento permitió al modelo afinar la precisión de los cuadros delimitadores sobre la distribución original de los documentos, de modo que los pesos finales quedaran optimizados para las disposiciones sin distorsión de los corpus objetivo.

La configuración se adaptó explícitamente a regímenes de pocos datos y para aislar el efecto de la estructura del corpus: el entrenamiento se restringió únicamente a la detección de la disposición (se eliminó la clasificación de cajas), se congelaron las primeras 10 capas de la red troncal (backbone) para preservar los conocimientos previos visuales de bajo nivel, se desactivaron la distorsión de perspectiva y los volteos, y se activó el aumento en mosaico (Mosaic Augmentation) durante la mayoría de las épocas. También se emplearon dropout (0.15), una tasa de aprendizaje de 0.001 con un calentamiento de 3 épocas y parada temprana (paciencia = 20).

La parada temprana se determinó a partir de las métricas de detección mAP@0.5 (precisión media promedio con un umbral de IoU de 0.5) y mAP@0.5:0.95 (mAP promedio en múltiples umbrales de IoU de 0.5 a 0.95 en pasos de 0.05). Estas métricas reflejan la precisión de detección y la exactitud de localización del modelo: mAP@0.5 privilegia la detección correcta de objetos con un solapamiento moderado, mientras que mAP@0.5:0.95 ofrece una evaluación más estricta al promediar el rendimiento en umbrales de IoU cada vez más exigentes. Incorporar ambas métricas garantiza que el modelo equilibre una ubicación precisa de los cuadros con una confianza de detección fiable.

Pese al máximo inicialmente configurado de 300 épocas de entrenamiento, la parada temprana (paciencia = 20) se activó de forma independiente para cada corpus, lo que indica que no se observaron mejoras adicionales del rendimiento a partir de cierto número de épocas. Este comportamiento de la parada sugiere la convergencia del proceso de optimización y la estabilización del rendimiento de detección. Para los101, el entrenamiento se detuvo en la época 138, con el mejor rendimiento en la época 66: mAP@0.5 = 0.832, mAP@0.5 : 0.95 = 0.424, mientras que para el segundo corpus, el homogéneo, el entrenamiento se detuvo en la época 138, con el mejor rendimiento en la época 118: mAP@0.5 = 0.768, mAP@0.5 : 0.95 = 0.469.

5. Resultados

A continuación se describen los resultados del análisis.

5.1. Resultados de la fase 1

La tabla 1 resume los resultados de los experimentos de OCR sobre el corpus heterogéneo los101. Los resultados ponen de relieve la interacción entre las propiedades del corpus, la arquitectura del modelo y las estrategias de ajuste fino. Tesseract obtiene las tasas de error de base más bajas (CER = 0.108), lo que confirma su robustez en escenarios sin ajustes previos. Curiosamente, el ajuste fino de Tesseract con los101 provoca un deterioro sustancial del rendimiento: la CER aumenta a más del doble. Este efecto negativo refleja la influencia de la heterogeneidad del corpus de entrenamiento: la segmentación de líneas incoherente, las fuentes variables y las disposiciones en varias columnas introducen ruido que perturba el proceso de entrenamiento de la LSTM. Estos resultados subrayan que los motores de OCR clásicos dependen en gran medida

de anotaciones coherentes y que su rendimiento puede degradarse cuando se exponen a datos históricos heterogéneos, aun cuando el corpus sea relativamente grande.

TrOCR, basado en transformers, se comporta de otro modo. Su rendimiento de base es comparativamente pobre, dada su elevada tasa de error (CER = 0.996), debido en gran parte al pequeño tamaño del corpus de entrenamiento en relación con la capacidad del modelo. El ajuste fino con los101 reduce la CER a 0.906, lo que demuestra que la adaptación al dominio puede compensar parcialmente la falta inicial de especialización. Aunque las tasas de error absolutas siguen siendo altas, la variación positiva muestra que los modelos basados en transformers se benefician de la exposición a muestras específicas del dominio, siempre que estén anotadas de forma limpia. Esto indica que la flexibilidad arquitectónica permite la adaptación a la variabilidad de los documentos históricos, aunque limitada por el tamaño del conjunto de datos.

Granite, el modelo de OCR multimodal, mantiene tasas de error intermedias (CER $\approx$ 0.29-0.30) tanto en la versión de base como en la ajustada. El ajuste fino aumenta ligeramente la CER, lo que sugiere un leve sobreajuste al pequeño conjunto de entrenamiento. No obstante, Granite muestra una estabilidad relativa en comparación con Tesseract y TrOCR, probablemente gracias a su capacidad para combinar indicios visuales y textuales, lo que lo hace más resistente a la variación tipográfica y de la disposición.

Modelo	Enfoque	CER	ΔCER	BLEU	ROUGE-L
Tesseract	spa	0.1080	-	0.5998	0.8696
	los101	0.2454	-127%	0.0505	0.4364
TrOCR	base	0.9961	-	0.0000	0.0017
	los101	0.9060	+9.0%	0.0000	0.0437
Granite	base	0.2897	-	0.2577	0.6557
	los101	0.3033	-4.7%	0.2495	0.6390

Tabla 1: Rendimiento del OCR en la primera fase con el corpus los101 (conjunto de prueba). Las variaciones relativas (Δ) indican el cambio de rendimiento tras el ajuste fino.

Configuración	IoU	F1	Compuesta
Base	0.3099	0.0000	0.2324
Ajustado	0.0000	0.0000	0.0000

Tabla 2: Resultados de la segmentación de la disposición y de la clasificación de cajas en la fase 1 sobre el corpus los101, en el conjunto de prueba, con el modelo DocLayoutYOLO.

En conjunto, los resultados de la tabla 1 ponen de relieve que la heterogeneidad del corpus afecta fuertemente al rendimiento del OCR. Los motores clásicos son muy sensibles a las anotaciones incoherentes, mientras que los modelos basados en transformers sólo se benefician del ajuste fino cuando se dispone de suficientes datos limpios. Las métricas semánticas (BLEU y ROUGE-L) reflejan las mismas tendencias: Tesseract cae bruscamente tras el ajuste fino, TrOCR muestra mejoras modestas y Granite se mantiene relativamente estable, lo que demuestra su resistencia a la variabilidad tipográfica y de la disposición. En resumen, el propio corpus los101 limita la calidad del OCR, lo que subraya la necesidad de anotaciones coherentes y de disposiciones controladas. Esto motiva el segundo experimento, que utiliza un nuevo corpus de páginas con características más homogéneas.

En lo que respecta a la subtarea de segmentación de la disposición, el modelo no logró converger hacia representaciones espaciales estables (véase la tabla 2). Las puntuaciones de intersección sobre la unión (IoU) y F1 se desplomaron durante la validación y la prueba, en algunos casos hasta acercarse a cero. En lugar de mejorar la calidad de la segmentación, el ajuste fino amplificó la inestabilidad, lo que sugiere que la variabilidad estructural, los múltiples formatos editoriales, las estructuras de columnas incoherentes y las organizaciones heterogéneas de las cajas introdujeron un ruido excesivo en el proceso de optimización. Estos resultados indican que la interacción entre la heterogeneidad del corpus y el entrenamiento multitarea limita un aprendizaje fiable de la disposición.

Para complementar la evaluación cuantitativa, se realizó un análisis cualitativo sobre el conjunto de validación, centrado en los archivos que se situaban sistemáticamente entre los de peor rendimiento según múltiples métricas. Los resultados muestran que los errores no obedecen a un único factor dominante, sino que se correlacionan con varias características recurrentes de los documentos. En particular, el rendimiento se degrada en los escaneos de baja calidad (p. ej., con poco contraste), en disposiciones no estándar como los diagramas y en las páginas que contienen elementos tipográficos decorativos o complejos, todos los cuales interfieren con la segmentación y el reconocimiento del texto. Además, las páginas con poco o ningún contenido textual tienden a

producir resultados inestables. Estos factores suelen darse a la vez, lo que hace que la atribución de los errores no sea trivial. Aunque tanto el modelo de base como el ajustado se ven afectados, el modelo ajustado muestra una mayor sensibilidad a las entradas visualmente complejas. En general, estos hallazgos indican que el rendimiento del OCR está fuertemente condicionado por la variabilidad visual y estructural, que las métricas de evaluación agregadas no captan.

5.2. Resultados de la fase 2

La evaluación de la fase 2 pone de relieve el efecto de las estrategias de aumento de datos (relacionadas con el preprocesamiento de imágenes) sobre el rendimiento de la detección de la disposición en los dos corpus. Los modelos los101_augment y per_augment se obtuvieron mediante el ajuste fino del modelo de base con el corpus los101 y con el corpus layout-homogeneous, respectivamente.

Para el corpus los101 (tabla 3), los101_augment obtiene sistemáticamente la IoU media más alta en todas las particiones, lo que indica una mejor alineación espacial de las cajas predichas con la verdad de referencia. También alcanza los mejores valores de mAP50 y mAP50:95 en la mayoría de las particiones, lo que sugiere que los aumentos específicos del corpus ayudan al modelo a detectar y localizar mejor los elementos de la disposición con mayor precisión. El modelo per_augment muestra una mejora moderada respecto del modelo de base en las métricas de detección, pero su IoU media sigue siendo algo inferior, lo que implica que las estrategias de aumento diseñadas para disposiciones generales pueden no captar plenamente los patrones estructurales específicos del corpus. El modelo de base mantiene un solapamiento espacial razonable, pero adolece de una menor precisión y exhaustividad de detección, como reflejan sus valores más bajos de mAP50 y mAP50:95.

Para el corpus layout-homogeneous (tabla 4), per_augment supera claramente a los demás modelos en todas las particiones y métricas, y alcanza los valores más altos de IoU media, mAP50 y mAP50:95. Este resultado demuestra que los aumentos sensibles a la disposición manejan eficazmente las estructuras de página heterogéneas y complejas de los periódicos, y mejoran tanto la localización de las cajas como la confianza de la detección. El modelo los101_augment tiene un buen desempeño, pero queda ligeramente por detrás de per_augment, en

particular en mAP50:95, lo que sugiere que los aumentos optimizados para los101 no se generalizan perfectamente a otros formatos editoriales. El modelo de base sigue siendo el más débil en todas las métricas, lo que pone de manifiesto la necesidad del aumento de datos para un aprendizaje robusto de la disposición en corpus muy variables.

	Entrenamiento			Validación			Prueba		
Modelo	IoU media	mAP50	mAP50:95	IoU media	mAP50	mAP50:95	IoU media	mAP50	mAP50:95
base	0.773	0.231	0.134	0.788	0.162	0.105	0.773	0.270	0.171
per_augment	0.720	0.293	0.136	0.722	0.283	0.130	0.726	0.362	0.172
los101_augment	0.799	0.696	0.464	0.745	0.596	0.361	0.747	0.545	0.305

Tabla 3: Métricas de evaluación de la fase 2 para el corpus los101.

	Entrenamiento			Validación			Prueba		
Modelo	IoU media	mAP50	mAP50:95	IoU media	mAP50	mAP50:95	IoU media	mAP50	mAP50:95
base	0.730	0.182	0.098	0.740	0.170	0.097	0.734	0.196	0.106
per_augment	0.841	0.755	0.560	0.810	0.652	0.436	0.804	0.554	0.370
los101_augment	0.749	0.589	0.331	0.769	0.447	0.261	0.741	0.592	0.324

Tabla 4: Métricas de evaluación de la fase 2 para el corpus layout-homogeneous.

Para complementar la evaluación cuantitativa, visualizamos las predicciones de los modelos en las figuras 3 y 4. Los cuadros delimitadores se colorean según la confianza de la detección, lo que permite valorar rápidamente la certeza del modelo: el verde indica predicciones de alta confianza (conf > 0.9), el naranja

representa una confianza moderadamente alta ($0.75 < \text{conf} \leq 0.9$), el amarillo corresponde a una confianza media ($0.5 < \text{conf} \leq 0.75$) y el rojo señala las predicciones de baja confianza ($0.2 < \text{conf} \leq 0.5$). Esta codificación visual facilita la inspección tanto de la alineación espacial como de la certeza del modelo en los distintos corpus y estrategias de aumento.

Puede observarse que el modelo de base suele producir menos cajas con una menor variación de confianza, que a menudo aparecen predominantemente en verde, lo que refleja un comportamiento de detección más conservador pero coherente. En cambio, los modelos ajustados (per_augment y los101_augment muestran una mejor cobertura de detección y alineación espacial, pero sus predicciones incluyen una mayor proporción de cajas naranjas, amarillas y rojas. Esto indica que, si bien los modelos ajustados no son intrínsecamente peores, su confianza está más distribuida, lo que refleja una mayor sensibilidad a la diversidad de estructuras de página y a la presencia de elementos de disposición más difíciles.

(a) Original

(b) baseline

- (c) per_augment

(d) los101_augment

Figura 3: Visualización de los resultados de la detección de la disposición en un ejemplo del corpus los101.

5.3. Discusión sobre la adaptación al corpus

De la evaluación en ambos corpus surgen varias tendencias clave, que ponen de relieve el efecto del aumento de datos y los matices del rendimiento de la detección. En primer lugar, el uso de estrategias de aumento conduce a mejoras significativas tanto en la IoU media como en las métricas mAP. Esto demuestra que dichas técnicas son muy eficaces para estabilizar el aprendizaje de la disposición, probablemente porque proporcionan al modelo un conjunto más

(a) Original

- (b) baseline
- (c) per_augment

- (d) los101_augment

Figura 4: Visualización de los resultados de la detección de la disposición en un ejemplo del nuevo corpus.

diverso y robusto de variaciones espaciales durante el entrenamiento.

Los resultados revelan también un compromiso entre especialización y generalización. Los modelos optimizados para un corpus específico, como los101_augment para el conjunto de datos los101, alcanzan sistemáticamente el mayor rendimiento sobre sus datos de origen. Sin embargo, estas mejoras no siempre se trasladan a otros corpus, lo que sugiere que, si bien la optimización específica del corpus maximiza la precisión local, puede limitar la capacidad del modelo para generalizar a distintos estilos de disposición.

Además, la diferencia de rendimiento entre mAP50 y mAP50:95 ilustra la complejidad de la localización precisa. Los valores de mAP50:95 son sistemáticamente más bajos en todas las pruebas, lo que refleja la mayor dificultad de mantener una alta precisión con umbrales de solapamiento más estrictos. Al evaluar tanto la alineación espacial mediante la IoU media como la precisión de la detección mediante las métricas mAP, se obtiene una visión más completa del rendimiento de los modelos. Este enfoque combinado revela con éxito los compromisos inherentes entre lograr una ubicación precisa de las cajas y mantener una alta precisión global de detección.

6. Conclusiones y trabajo futuro

En este estudio sobre el procesamiento de documentos históricos, la calidad y la regularidad estructural del corpus subyacente resultan tan decisivas como la elección de la arquitectura del modelo. Nuestros experimentos con los101 revelan que las anotaciones de alta calidad curadas manualmente no bastan por sí solas para superar una heterogeneidad extrema de la disposición en motores de OCR clásicos como Tesseract, que sufrió una caída de rendimiento de más del 120 % en la CER tras el ajuste fino.

Por el contrario, los resultados de la segunda fase indican que la homogeneidad estructural estabiliza significativamente el análisis de la disposición. Al utilizar un corpus con patrones de columnas coherentes y estrategias de aumento refinadas, logramos una mejora notable en la localización espacial (IoU media) y en la precisión de la detección (mAP50). Para el investigador humanista, esto implica

que un conjunto de datos más pequeño y estructuralmente coherente puede ser más valioso para el entrenamiento de modelos que una colección más grande, más ruidosa y muy variable. Por último, nuestros resultados sugieren que los modelos multimodales como Granite ofrecen un término medio más resistente, al equilibrar indicios visuales y textuales para sortear el "ruido" de las digitalizaciones históricas.

La investigación futura seguirá tres direcciones principales. En primer lugar, nos proponemos explorar regímenes de entrenamiento híbridos que combinen la regularidad estructural de nuestro segundo corpus con la riqueza lingüística de los101, comenzando por disposiciones sencillas e introduciendo gradualmente la complejidad. En segundo lugar, pretendemos implementar técnicas automatizadas de normalización de la disposición como paso de preprocesamiento para reducir el "ruido visual" antes de que llegue al motor de OCR.

Por último, prevemos ampliar el corpus los101 para incluir una gama más amplia de revistas científicas del siglo XIX, a fin de poner a prueba la generalizabilidad de nuestro enfoque de transcripción 'literal modernizado". Esto supondrá también evaluar el efecto de los errores de OCR en tareas posteriores de PLN, como el reconocimiento de entidades nombradas (NER, por sus siglas en inglés) y el modelado de tópicos, para cuantificar con exactitud cuánto "importa la anotación" para el análisis histórico final.

7. Agradecimientos

Este trabajo cuenta con el apoyo parcial del Ministerio de Ciencia e Innovación/AEI, en el marco del proyecto nacional coordinado español GRESEL UNED (PID2023-151280OB-C22).

8. Referencias bibliográficas

Michele Alberti, Mathias Seuret, Vinaychandran Pondenkandath, Rolf Ingold, and Marcus Liwicki. 2017. Historical document image segmentation with lda-initialized deep neural networks. In Proceedings of the 4th international workshop on historical document imaging and processing, pages 95-100.

Austrian National Library Labs. 2024. Esperanto newspaper excerpts. GitLab repository. Accessed 2026-02-25.

Joan Benavent, Xaro Benavent, Esther de Ves, Ruben Granados, and Ana García-Serrano. 2010. Experiences at imageclef 2010 using CBIR and TBIR mixing information approaches. In CLEF 2010 LABs and Workshops, Notebook Papers, 22-23 September 2010, Padua, Italy, volume 1176 of CEUR Workshop Proceedings. CEUR-WS.org.

Yoshua Bengio, Aaron Courville, and Pascal Vincent. 2013. Representation learning: A review and new perspectives. IEEE transactions on pattern analysis and machine intelligence, 35(8):1798-1828.

Kai Chen, Mathias Seuret, Jean Hennebert, and Rolf Ingold. 2017. Convolutional neural networks for page segmentation of historical document images. In 2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR), volume 1, pages 965-970. IEEE.

Kyunghyun Cho. 2014. On the properties of neural machine translation: Encoder-decoder approaches. arXiv preprint arXiv:1409.1259.

Marten Düring, Estelle Bunout, and Daniele Guido. 2024. Transparent generosity. introducing the impresso interface for the exploration of semantically enriched historical newspapers. Historical Methods: A Journal of Quantitative and Interdisciplinary History, 57(1):20-40.

David Fleischhacker, Roman Kern, and Wolfgang Göderle. 2025. Enhancing ocr in historical documents with complex layouts through machine learning. International Journal on Digital Libraries, 26(1):3.

Enrique Garcia-Arias and Ana Garcia-Serrano. 2025. Creación de un modelo de descripciones de imágenes especializado en arqueología griega (pending edit). Procesamiento del Lenguaje Natural, 75(0).

Ana Garcia Serrano and Antonio Menta Garuz. 2022. La inteligencia artificial en las humanidades digitales: dos experiencias con corpus digitales. Revista de Humanidades Digitales, 7:19-39.

Mark J Hill and Simon Hengchen. 2019. Quantifying the impact of dirty ocr on historical text analysis: Eighteenth century collections online as a case study. Digital Scholarship in the Humanities, 34(4):825-843.

Areej Jaber, Israa Bahati, and Paloma Martínez. 2025. Leveraging pre-trained embeddings in an ensemble machine learning approach for arabic sentiment analysis. Frontiers in Artificial Intelligence, Volume 8 - 2025.

Jaione Macicior Mitxelena and Ana Garcia-Serrano. 2026. From Paper To Pixel: Experimental Framework for Access to Historical Spanish Documents. https://github.com/jaionemacicior/ from-paper-to-pixel. Software/Code.

Kimmo Kettunen, Heikki Keskustalo, Sanna Kumpulainen, Tuula Pääkkönen, and Juha Rautiainen. 2022. Ocr quality affects perceived usefulness of historical newspaper clippings-a user study. arXiv preprint arXiv:2203.03557.

Juan J. Lastra-Díaz, Josu Goikoetxea, Mohamed Ali Hadj Taieb, Ana Garcia-Serrano, Mohamed Ben Aouicha, Eneko Agirre, and David Sánchez. 2021. A large reproducible benchmark of ontology-based methods and word embeddings for word similarity. Information Systems, 96:101636.

Minghao Li, Tengchao Lv, Jingye Chen, Lei Cui, Yijuan Lu, Dinei Florencio, Cha Zhang, Zhoujun Li, and Furu Wei. 2023. Trocr: Transformer-based optical character recognition with pre-trained models. In Proceedings of the AAAI conference on artificial intelligence, volume 37, pages 13094-13102.

Bernhard Liebl and Manuel Burghardt. 2021. An evaluation of dnn architectures for page segmentation of historical newspapers. In 2020 25th International Conference on Pattern Recognition (ICPR), pages 5153-5160. IEEE.

Jaione Macicior Mitxelena. 2025. Del papel al pixel: Experimentos para la digitalización de documentos históricos españoles. Master's thesis, UNED: Universidad Nacional de Educación a Distancia, Madrid, Spain, September. Directed by Ana Garcia-Serrano. Máster en Tecnologías del Lenguaje. Grade: Sobresaliente (9).

- Miguez Lamanuzzi and A. García Serrano. 2026. Annotation of historical texts for automatic processing in the gresel-uned project. In Congreso Internacional de Lingüística de Corpus (CILC 2026), Madrid. UAM. Aceptada.
- Miguez Lamanuzzi, J. Macicior Mitxelena, Y. Torterolo, R. Ortuño Casanova, and A. García Serrano. 2026. Guía de transcripción y anotación para prensa histórica. https://doi. org/10.5281/zenodo.19187624.

Antonio Moreno-Sandoval, Leonardo CampillosLlanos, and Ana García-Serrano. 2024. Language resources in spanish for automatic text simplification across domains.

Vahid Rezanezhad, Konstantin Baierer, Mike Gerber, Kai Labusch, and Clemens Neudecker. 2023. Document layout analysis with deep learning and heuristics. In Proceedings of the 7th International Workshop on Historical Document Imaging and Processing, pages 73-78.

Eva Sánchez-Salido, Antonio Menta, and Ana García-Serrano. 2023. Seeking information in spanish historical newspapers: The case of diario de madrid (18th and 19th centuries). DHQ: Digital Humanities Quarterly, (4).

Eder Silva dos Santos Júnior, Thuanne Paixão, and Ana Beatriz Alvarez. 2025. Comparative performance of yolov8, yolov9, yolov10, and yolov11 for layout analysis of historical documents images. Applied Sciences, 15(6):3164.

Alexander Sergeev, Valeriya Goloviznina, Mikhail Melnichenko, and Evgeny Kotelnikov. 2025. Talking to data: Designing smart assistants for humanities databases.

Zejiang Shen, Ruochen Zhang, Melissa Dell, Benjamin Charles Germain Lee, Jacob Carlson, and Weining Li. 2021. Layoutparser: A unified toolkit for deep learning based document image analysis. arXiv preprint arXiv:2103.15348.

Arno Simons, Michael Zichert, and Adrian Wüthrich. 2025. Large language models for history, philosophy, and sociology of science: Interpretive uses, methodological challenges, and critical perspectives.

Yanco Amor Torterolo-Orta, Jaione MaciciorMitxelena, Marina Miguez-Lamanuzzi, and Ana García-Serrano. 2025. Transcribing spanish texts from the past: Experiments with transkribus, tesseract and granite.

Heidi JS Tworek. 2024. Digitized newspapers and the hidden transformation of history. The American Historical Review, 129(1):143-147.

Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. In Advances in Neural Information Processing Systems, volume 30.

Zhiyuan Zhao, Hengrui Kang, Bin Wang, and Conghui He. 2024. Doclayout-yolo: Enhancing document layout analysis through diverse synthetic data and global-to-local adaptive perception. arXiv preprint arXiv:2410.12628.

Wenzhen Zhu, Negin Sokhandan, Guang Yang, Sujitha Martin, and Suchitra Sathyanarayana. 2022. Docbed: A multi-stage ocr solution for documents with complex layouts. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 36, pages 12643-12649.

9. Referencias de recursos lingüísticos

- Miguez Lamanuzzi, A. García Serrano, Jaione Macicior Mitxelena, and Yanco Torterolo. 2025. Los101. [Data set].
- Montejo-Ráez, E. Sánchez Nogales, G. Expósito Álvarez, A. Ureña López, M. T. MartínValdivia, J. Collado-Montañez, I. Cabrera de Castro, M. V. Cantero Romero, A. García Serrano, R. Ortuño Casanova, and Y. A. Torterolo Orta. 2025. Pastreader 2025. https://doi.org/ 10.5281/zenodo.15084265. [Data set].
- Obispo, R. Ortuño Casanova, L. Garçon, Y. Seyeux, E. Sinardet, D. Villanueva Romero, and E. Vivó Capdevila. 2026. Corpus de prensa histórica con el layout marcado en pagexml. https://doi.org/10.5281/zenodo. 18774961. [Data set].