Layout y OCR en EntropIA Lite

Procesamiento, exploración y análisis de fuentes históricas

Agustín Nieto · INHUS-CEHis, UNMdP-CONICET

SICSS Uruguay · 4 de noviembre de 2026

Recorrido

01

I · Las herramientas como instrumentos

Instrumento y medición, teoría infraestructurada, valores por defecto, «sesgo» u «orientación».

02

II · Digitalización crítica en EntropIA

La cadena archivo → imagen → texto → corpus, eslabón por eslabón.

De dónde venimos

> *Encuentro 1.* El layout define la **unidad documental**: qué es una noticia, un aviso, una columna. Segmentar es interpretar.

> *Encuentro 2.* El OCR produce un **texto nuevo**, con errores que no se distribuyen al azar. Fluidez no es fidelidad.

> *Hoy.* ¿Qué pasa cuando esos dos pasos quedan **dentro de una aplicación** que los ejecuta con un clic?

Piensen en la última base de datos de prensa o de archivo que usaron.

¿Sabían qué OCR tenía, cuándo se hizo, quién lo hizo y si alguien lo corrigió?
¿Les importó?

Los supuestos con que recibimos una herramienta

01 La hicieron profesionales.

02 Fue diseñada para gente como yo.

03 Su popularidad la valida.

04 Alguien la mantiene.

05 Va a perdurar.

06 «Cada una de estas cosas **dista mucho de cumplirse siempre**».

Lo que una herramienta muestra y lo que oculta

«Para hacer visibles cosas nuevas, la herramienta oculta otras; al facilitar algunos caminos metodológicos, dificulta comparativamente otros; y, en última instancia, la herramienta cambia sus objetivos».

Jacomy et al. (2026), cap. 20, p. 5

I. Las herramientas como instrumentos científicos

Qué tienen en común un telescopio, una balanza y una aplicación de OCR.

Herramienta e instrumento

Las herramientas digitales pertenecen a la familia de los **instrumentos científicos**: telescopios, microscopios, balanzas. A diferencia de un martillo, un instrumento sirve para **medir** (pp. 5–6).

Doble filiación (fig. 20.1): son a la vez **infraestructura**, un objeto técnico que hay que mantener, y **método**, algo que da forma a lo que producimos.

Un método implementado en un algoritmo «puede ser ejecutado por cualquiera (aunque no necesariamente comprendido o interpretado por cualquiera)» (p. 7). Cuando EntropIA hace OCR, ejecuta un método que no diseñaron: además de saber si funciona, hay que saber **qué mide y cómo**.

> «Necesitamos poder nombrar y discutir nuestros instrumentos científicos porque tienen una carga metodológica».
>
> JACOMY ET AL. (2026), CAP. 20, PP. 6–7

«Todo CSV es una expresión de poder, toda API es un argumento»

> *Un CSV es una tabla.* Quien la arma decide qué columnas existen. **Lo que no tiene columna no se puede contar, filtrar ni comparar.**

> *Una API es la vía por la que un servicio entrega sus datos.* Decide qué se puede pedir y en qué forma llega la respuesta. Al hacerlo, **sostiene una idea de qué datos importan**.

> *En EntropIA.* La pestaña Layout agrupa las regiones en Títulos, Texto, Tablas, Figuras y Notas: **«aviso» no es una categoría posible**.

El software de investigación «codifica consideraciones metodológicas y epistemológicas»: influye en «cómo se seleccionan y operacionalizan las variables, qué análisis pueden llevarse a cabo y cómo se interpretan y presentan los resultados».

JACOMY ET AL. (2026), CAP. 20, P. 14

Teoría infraestructurada

> No existe la herramienta ateórica: sería «inútil e impotente, porque no podría marcar ninguna diferencia en nada» (p. 14).

> En la herramienta, la teoría pierde propiedades del texto (es **«menos explícita, menos discutible»**) y gana *affordances*: maneras materiales de guiar al usuario sin justificarse (p. 15).

> «Las teorías infraestructuradas **no se leen, sino que se ponen en acto y se experimentan**» (p. 15).

«Incluso decisiones de diseño aparentemente menores —como las estructuras de las bases de datos, los parámetros por defecto o el orden en que se presentan las opciones— pueden tener efectos significativos en la investigación».

JACOMY ET AL. (2026), CAP. 20, P. 16

Construir cosas como forma de conocer

> En historia, la «teoría» no predice, explica. Decir que el software es teoría es decir que **transmite conocimiento** en ese sentido.

> El problema es la **opacidad**: las herramientas de uso diario se vuelven transparentes y sólo se notan cuando se rompen. Sus supuestos hay que **inferirlos usándolas**; abrir el código no alcanza, porque pocos leen el código ajeno.

«Un prototipo es una teoría. Dejen de disculparse por sus prototipos».

«a prototype is a theory. Stop apologizing for your prototypes.»

MANOVICH, CITADO EN RAMSAY Y ROCKWELL (2012)

«¿Qué pasa cuando construir ocupa el lugar de escribir?»

«What happens when building takes the place of writing?»

RAMSAY Y ROCKWELL (2012)

¿Sesgo u orientación?

> Rieder, Peeters y Borra proponen reservar «sesgo» para su sentido estadístico y hablar de **orientación** o **sustancia** de la herramienta.

> Hablar de sesgo en todo supone que podría existir un software sin limitaciones, compromisos ni idiosincrasias, **«lo que es difícil de imaginar»** (p. 220).

> Reemplacen «tuits» por **«páginas de prensa»**: ¿la exportación conserva el vínculo con la imagen original?

«Incluso un simple archivo CSV con tuits es el producto de decisiones de diseño sobre qué datos incluir, qué transformaciones agregar […], si conectarlo de vuelta con la plataforma (por ejemplo, con enlaces a la fuente original)».

«Even a simple CSV file containing tweets is the product of design decisions on what data to include, which transformations to add […], whether to connect back into the platform (e.g. providing links to the original source)»

RIEDER, PEETERS Y BORRA (2024), P. 219

Del texto al string

> Para la computadora, un texto es un *string*, una secuencia de caracteres. No hay ahí, de por sí, palabras, cursivas ni párrafos: hay que definir una manera formal de representarlos (p. 28).

> *Puente con el encuentro 2.* El OCR es el punto exacto donde una página (columnas, tipografías, jerarquías) **se convierte en** *string*.

> Lo que el *string* no representa (el cuerpo de letra, la ubicación en la página, el filete que separa un aviso de una noticia) **hay que guardarlo aparte**, por ejemplo en el layout, o se pierde.

«En el desfase entre nuestra noción literaria de un texto y el procesamiento literal de la computadora están la decepción y la posibilidad del análisis de textos».

«In the slippage between our literary notion of a text and the computer's literal processing lie the disappointment and the possibility of text analysis»

ROCKWELL Y SINCLAIR (2016), CAP. 2, P. 26

Elijan una herramienta que usen siempre.

Nombren un valor por defecto que tenga y un efecto que ese valor tenga en lo que encuentran o escriben.

Ejemplos: el orden de los resultados por «relevancia» · la búsqueda que ignora acentos (o no) · el idioma por defecto del OCR · la cantidad de resultados por página.

II. Digitalización crítica: la cadena dentro de EntropIA

En cada eslabón, tres preguntas: qué decide la aplicación, qué se gana y qué se pierde.

Archivo → imagen → texto → corpus

01

Archivo

1. Colección
2. Importación

02

Imagen

3. Documento y página
4. Edición de la imagen

03

Texto

5. Texto nativo u OCR
6. OCR remoto
7. Layout
8. Un texto por página
9. Corrección con IA

04

Corpus

10. Búsqueda
11. Exportación y respaldo

1–2 · Colección e importación

> Lo que se decide aquí: **cómo se agrupan las fuentes** y **qué se sabe de cada una** en el momento en que entra al corpus.

Eslabón	Qué hace EntropIA Lite	Decisión incorporada	Qué discutir
1. Colección	Un espacio que agrupa documentos. No hay forma de mover documentos entre colecciones.	La colección es la primera unidad de organización y es rígida.	¿Refleja el fondo de archivo, el proyecto o el tema? ¿Y una fuente que pertenece a dos?
2. Importación	Guarda una copia; el original no cambia. El título sale del nombre del archivo. Registra nombre original, ruta, fecha de importación, tamaño y fechas del archivo.	Guarda la historia del archivo en la computadora, no la de la fuente.	Una ruta como C:\Users\…\Descargas\scan0034.jpg no es una cita archivística. ¿Quién completa el resto?

3–4 · Página e imagen

> Lo que se decide aquí: **cuál es la unidad que se procesa** y **si la imagen de la fuente puede cambiar**.

Eslabón	Qué hace EntropIA Lite	Decisión incorporada	Qué discutir
3. Documento y página	Un PDF se divide en páginas y cada página se procesa por separado.	La página es la unidad de procesamiento, no el artículo ni la noticia.	Encuentro 1: una noticia que sigue en otra página queda partida en dos unidades que la aplicación trata por separado.
4. Edición de la imagen	El visor permite recortar, rotar y «Borrar región (relleno blanco)». El manual recomienda duplicar antes de editar.	La aplicación permite alterar la fuente.	¿Es legítimo borrar un sello o una mancha para que el OCR funcione mejor? ¿Cómo queda documentado?

5–7 · Texto nativo, OCR remoto y layout

> Lo que se decide aquí: **de dónde sale el texto** y **quién define las regiones** de la página.

Eslabón	Qué hace EntropIA Lite	Decisión incorporada	Qué discutir
5. Texto nativo u OCR	En un PDF, primero intenta usar el texto digital que ya trae el archivo. Con unos 40 caracteres alfanuméricos por página (y según la proporción de imagen), no hace OCR.	Puede quedarse con el OCR de otra institución en lugar de reconocer la imagen.	Encuentro 2 (Cordell, Milligan): el OCR de las bases comerciales puede entrar al corpus sin que lo notemos.
6. OCR remoto	El OCR (OCRH) se pide a GLM-OCR por Internet, con una clave de API. Lite no tiene OCR local.	La fuente sale hacia un servicio externo (z.ai); el resultado depende de un modelo que no controlamos.	¿Qué fuentes se pueden enviar a un servicio externo (privacidad, derechos, archivos con restricciones)?
7. Layout	El layout llega de la misma llamada al OCR: regiones con etiqueta y coordenadas. Se filtran Títulos, Texto, Tablas, Figuras y Notas. No se edita.	La tipología de regiones la define el modelo.	Comparar con las clases de DocLayout-YOLO del encuentro 1.

9–11 · Corrección, búsqueda y exportación

> Lo que se decide aquí: **si se corrige el texto y cómo**, **cómo se lo busca** y **qué sale de la aplicación**.

Eslabón	Qué hace EntropIA Lite	Decisión incorporada	Qué discutir
9. Corrección con IA	OCRC reemplaza el texto sin pedir aceptación previa; «Restaurar OCR original» vuelve atrás. El respaldo se descarta si se rehace el OCR.	Prioriza la legibilidad.	Boros (encuentro 2): una corrección fluida puede normalizar grafías, nombres y cifras.
10. Búsqueda	Texto completo con variantes próximas («Aproximado») y búsqueda semántica por embeddings.	Compensa errores de OCR, pero trae coincidencias falsas.	Puente con el bloque III y con el encuentro 4 (RAG).
11. Exportación y respaldo	«Exportar JSON» guarda textos y análisis, no las imágenes, y no reconstruye la colección; la copia de seguridad guarda todo.	Sale el texto sin la imagen.	Rieder et al.: ¿se conserva el vínculo con la fuente original?

Qué muestran estos once eslabones

Los parámetros por defecto no son abstractos. El umbral de 40 caracteres, «una página, un texto», «OCRC aplica sin preguntar» o la lista de etiquetas del layout son **decisiones de diseño** con consecuencias para lo que el historiador puede ver.

La facilidad de uso tiene un costo. Un botón OCRH **esconde la elección de modelo, la segmentación y el orden de lectura**.

«La facilidad de uso puede ser contraproducente cuando permite al usuario obtener resultados que dependen de decisiones que no puede tomar por sí mismo, porque no ve lo que implican las elecciones o, peor aún, porque ni siquiera es consciente de que esas decisiones existen».

JACOMY ET AL. (2026), CAP. 22, P. 36

Preparar los datos también es investigar

> Given y Willson muestran que los humanistas dedican mucho trabajo a preparar, limpiar y organizar sus materiales, y proponen la preparación de datos como **una práctica de investigación de segundo nivel**.

> Usan los **metadatos para conservar el contexto** en corpus grandes: una herramienta que no los admite es un impedimento.

«Prefiero que sean lo menos parecidas posible a una caja negra. […] Quiero poder ver los pasos intermedios».

«I prefer them to be as un-black-box-like as possible. […] I want to be able to see the intermediate steps.»

PARTICIPANTE DEL ESTUDIO DE GIVEN Y WILLSON (2018)

III. Procedencia y trazabilidad

Cómo pasar de la crítica de fuentes a la crítica de herramientas, y cómo comprobar lo que devuelve una búsqueda.

De la crítica de fuentes a la crítica de herramientas

CRÍTICA DE FUENTES (FICKERS)

Cinco preguntas clásicas

¿Quién? ¿Qué tipo de documento? ¿Dónde? ¿Cuándo? ¿Por qué?
Lo digital agrega una sexta: **¿cómo se hizo esta versión de la fuente?**

CRÍTICA DE HERRAMIENTAS (KOOLEN ET AL.)

Las mismas preguntas, sobre la herramienta

¿Quién hizo la herramienta? ¿Qué tipo de herramienta es? ¿Cuándo se hizo? ¿Por qué se hizo?
Y, sobre todo: **¿cómo funciona?**

Qué hacer con una herramienta

Analizarla **en el nivel de las transformaciones de los datos**: cómo difiere lo que entra de lo que sale.

Integrar crítica de fuentes, crítica de herramientas y crítica de datos.

Documentar los rodeos (*workarounds*) que inventamos ante sus limitaciones.

A los creadores: una página **«Acerca de»** que explique cómo cada función selecciona, filtra y transforma los datos.

La crítica de herramientas busca «entender el impacto de cualquier limitación de la herramienta en el objetivo específico, no mejorar el rendimiento de la herramienta».

«understand the impact of any limitation of the tool on the specific goal, not to improve a tool's performance»

KOOLEN ET AL. (2019), P. 20

La crítica de herramientas como práctica

No es un juicio distante, sino **reflexión en la acción** (Schön): «interacción continua más que el ejercicio de un juicio distanciado» (párr. 14).

Las herramientas fáciles de usar **«parecen transparentes y neutrales»** (párr. 41), y la transparencia no alcanza si no entendemos lo que vemos.

Berry y Fagerjord proponen una *ralentización productiva* (párr. 27): el trabajo crítico demora el proyecto, y esa demora **no tiene por qué vivirse como algo negativo**. En los talleres de Van Es, los equipos recién vieron cómo la herramienta había encuadrado sus opciones al preparar la presentación final.

¿Para quién (no) se hizo? ¿Qué impacto tienen los distintos ajustes y parámetros? ¿Cómo cambiarían ciertas decisiones la interpretación de los datos? ¿Cuáles son mis propios supuestos y valores?

«For who (not)? […] What is the impact of different settings and parameters? […] How would certain decisions change how we interpret the underlying data? […] What are my own assumptions and values?»

VAN ES (2023), PÁRR. 40

Qué registra y qué no registra EntropIA Lite

> El registro de procedencia es **en parte automático y en parte responsabilidad del investigador**: lo que figura en la columna derecha hay que anotarlo a mano.

Se registra	No se registra (o se pierde)
Nombre original, ruta de origen, fecha de importación, tamaño y fechas del archivo	Repositorio, signatura, publicación, fecha, número y página de la fuente (hay que cargarlos a mano)
Una copia del archivo importado	Las ediciones de la imagen se guardan, pero sin una ficha de qué se modificó y por qué
Método de extracción de cada página (texto nativo u OCR remoto) y su fecha	El historial de OCR: cada OCR nuevo reemplaza al anterior
Nombre del modelo de layout y coordenadas de cada región	La versión del modelo de OCR que procesó cada página
El texto previo a una corrección automática (OCRC), hasta que se hace un nuevo OCR	Quién corrigió a mano, qué cambió y cuándo
Notas y tópicos ligados al documento o a la página	Un registro unificado de las operaciones (una bitácora) por documento

Una definición de trazabilidad

«Datos de la mejor calidad, cuya procedencia esté asegurada y cuya estructura e historia puedan investigarse y ponerse a prueba».

Prescott (2025), pp. 24–25 · «the best quality data whose provenance is assured and whose structure and history can be investigated and tested»

Falsos positivos

La búsqueda aproximada que **compensa errores de OCR** también produce coincidencias espurias.

Con suficientes datos siempre aparece algo con el mismo perfil: es el **equivalente maquínico de la apofenia**, la tendencia a ver patrones en todo (p. 132).

No se puede volver a leer todo, pero hay que **desarrollar maneras de poner a prueba los resultados** aunque no se puedan comprobar leyendo (Jockers, pp. 133–134).

«Cuanto más sucio el dato, más falsos resultados».

«The messier the data, the more false hits you get»

ROCKWELL Y SINCLAIR (2016), CAP. 7, P. 131

«Tener 87.000 resultados no es lo mismo que comprender la literatura del siglo XIX».

«having 87,000 results isn't the same as understanding nineteenth-century literature»

ROCKWELL Y SINCLAIR (2016), CAP. 7, PP. 135–136

Registrar la procedencia permite comprobar un hallazgo

Cuando una búsqueda devuelve algo sorprendente, hay que poder volver a la imagen y ver si el resultado viene del documento o de un error del OCR.

IV. Crear herramientas es hacer ciencia por otros medios

Quién hace las herramientas, para quién, y qué pasa cuando cambian.

Las herramientas no se crean para sus usuarios

> Muchas nacen para resolver un problema de **quien las hace** y se comparten después. Rockwell sobre Voyant: «Íbamos a construir la herramienta que queríamos» (p. 7).

> Unas necesidades quedan cubiertas por muchas herramientas y otras **por ninguna** (p. 9).

> Muchas se vuelven populares **porque se enseñan** (p. 10). Las comunidades de usuarios «no son neutrales ni universales, sino situadas» (p. 11).

«La herramienta desarrolla al usuario, al presentar y encuadrar enfoques particulares de investigación».

«the tool develops the user, by presenting and framing particular approaches to research»

RIEDER, PEETERS Y BORRA (2024), P. 225

Facilidad de uso y aprender jugando

> Las herramientas de ciencias sociales y humanidades «están pensadas para aportar **comprensiones interpretativas**, no sólo para producir resultados» (p. 36). Por eso a veces los creadores exponen decisiones a propósito.

> Ramsay y su «hermenéutica de **andar perdiendo el tiempo**» (*screwing around*) frente a la búsqueda: curiosear también es un método, y «puede sacar a la luz cosas de las que ni siquiera el creador de herramientas es consciente» (p. 38).

> «Los humanistas no investigan todos los días de la semana […] Necesitan herramientas que puedan adoptar rápidamente, usar intensamente, dejar de lado y luego no usar durante seis meses».
>
> ROCKWELL, EN JACOMY ET AL. (2026), CAP. 22, P. 35

Cuando la herramienta depende de un servicio ajeno

> Netvizz permitía descargar datos de Facebook para investigar. Funcionó más de diez años, hasta que **Facebook cerró su API**: la herramienta dejó de servir aunque su código siguiera intacto (cap. 20, pp. 8–9).

> EntropIA Lite depende de algo parecido: no reconoce el texto en la computadora, sino que **envía la imagen a GLM-OCR**. Si el proveedor cambia el modelo o las condiciones, o cierra el servicio, cambia o se detiene el OCR de la aplicación.

> «El software se pudre con el tiempo. No porque el código en sí se deteriore, sino porque el entorno en el que se ejecuta cambia inevitablemente».
>
> RIEDER ET AL., CITADO EN JACOMY ET AL. (2026), CAP. 23, P. 53

Mantenimiento y ciclo de vida

El código abierto **no garantiza la sostenibilidad** (pp. 58–59): su propósito debería ser permitir el escrutinio metodológico, la reproducibilidad y el código como bien común.

Rockwell sospecha que «los días de Voyant pueden estar llegando a su fin», reemplazado por **«la línea de prompt»** (p. 57).

Como la aplicación y el servicio cambian, conviene **anotar la versión de EntropIA, el servicio de OCR y la fecha** en cada procesamiento: la misma página procesada dentro de un año puede dar otro texto.

> «Todo prototipo es una herramienta; y toda herramienta es un prototipo».
>
> JACOMY ET AL. (2026), CAP. 23, P. 48

Los investigadores tienen más poder del que suponen

Readaptar las herramientas y hacer tutoriales: usar una herramienta de otra manera ya es crear herramientas (cap. 22, p. 41).

Presupuestar funcionalidades: incluir en un proyecto financiado una partida para que los creadores agreguen la función que la investigación necesita. Rockwell lo hace con Voyant: figura en la solicitud y recibe fondos para, por ejemplo, agregar etiquetado gramatical (pp. 70–71).

Cooperar con los creadores, por ejemplo con un *issue* en GitHub en lugar de un correo (cap. 21, p. 28).

Involucrarse con el software y, eventualmente, crear herramientas.

«La propiedad de la herramienta conlleva responsabilidad metodológica».

JACOMY ET AL. (2026), CAP. 25, P. 75

¿Usabilidad o decisión epistemológica?

USABILIDAD

Se resuelve con mejor diseño

Un problema de usabilidad se arregla mejorando la interfaz **sin cambiar lo que puedo conocer**.
Ejemplo: un botón difícil de encontrar.

DECISIÓN EPISTEMOLÓGICA

Cambia qué cuenta como dato

Cambia **qué cuenta como dato, qué se conserva o qué se puede comparar**.
Ejemplos: una página, un texto; las etiquetas del layout; el OCR heredado del PDF.
Muchos casos son las dos cosas a la vez: decirlo también vale.

Tres conclusiones

01

Conocer el instrumento

Antes de usar el texto que produce EntropIA, saber cómo se produjo: de dónde salió, con qué modelo y qué regiones se detectaron.

02

Buscar los valores por defecto

Las decisiones de la herramienta no están en el manual sino en su funcionamiento, y se descubren usándola.

03

Registrar lo que falta

La procedencia archivística, las ediciones de la imagen, las correcciones y la versión del servicio: lo que la aplicación no guarda, lo anotamos nosotros.