Layout: estructura de la página

Detección de regiones, orden de lectura y unidades documentales

Agustín Nieto · CONICET / UNMdP

SICSS Uruguay · 30 de octubre de 2026



Centro Gallego, Montevideo, 28/10/1917, n.º 2, p. 6. Galiciana / Wikimedia Commons.

Propósitos de la clase

01 Conocer distintos enfoques de Layout

02 Describir la organización de una página y distinguir sus unidades.

03 Comprender qué devuelve un detector y qué requiere otro procedimiento.

04 Evaluar omisiones, fusiones, fragmentaciones y errores de clasificación.

Primera lectura: reconocer unidades



CENTRO GALLEGO

ECOS DE GALICIA

CORUÑA

El vapor "Barcelo" trajo para este puerto unas 58 bocoyadas de vaga general, entre la cual figuran, entre otras, 1.800 pacales 800 sacos de cemento, 45 cajas con fi- ores, 194 fardos con fi- jidos y gran cantidad de cacharrería y piezas de maquinaria.

Han terminado los conciertos musicales en el paseo de Méndez Núñez.

La banda de música del regimiento de Isabel la Católica ha cumplido su compromiso, mostrándose, como siempre, galante y obsequiosa con el pueblo de La Coruña.

Reflejando el agrado con que fueron escuchados por este los conciertos de referencia, en los cuales dicha banda demostró una vez más que posee un selecto repertorio y ejecuta con una gran afinación y gusto, dirigirá hoy el alcalde una comunicación al coronel del regimiento de Isabel la Católica, a fin de que le dé a conocer al maestro Quiroga, que con tanto acierto dirige la colectividad y a esta toda.

También la banda de música del Hospicio que dirige con mucho entusiasmo el señor Prado, dió en este verano una serie simpatiquísimas y agradable, amenizando los paseos vespertinos en Riazor con la mayor complacencia del público que concurría todos los días al balneario.

Y asimismo expresará el alcalde a la Comisión provincial la satisfacción que La Coruña advierte en los progresos de la banda citada que honra al establecimiento y al director señor Prado.

Ha dado una conferencia en el local de la Exposición de Arte Gallego instalada en la Alameda, el distinguido escritor don Ramón María Tenreiro.

Habló el señor Tenreiro sobre "La representación y la realidad de Galicia" y "Galicia vista al través de sus pintores", siendo muy aplaudido.

El acreditado balneario de Arteijo hace visita concurridísima en la actual temporada, por numerosas y distinguidas familias de La Coruña, Lago, Santiago, Ferrol, Betanzos y Puentedeume.

Tomó posesión de su cargo en La Coruña el nuevo alcalde don Carlos Pinal Pequeño. Le dió posesión el gobernador civil señor Garrido.

El noventa enviado desde La Coruña a Madrid estuvo en la capital de España a los siguientes precios:

Bezugos, de 1'50 a 1'75 pesetas kilo.
Calmarzos, de 1'75 a 2'25 id.
Congros, de 2'00 a 2'25 id.
Lenguados, de 3'00 a 4'50 id.
Merluza, de 1'80 a 2'75 id.
Mero, de 1'50 a 2'00 id.
Pescadillas, a 1'40 id.
Sardinas, a 1'20 id.

Salió para Madrid la colonia veraniega que aquel Ayuntamiento envía al Sanatorio de Oza a pasar una temporada de alta mesa.

A despedida asistieron el gobernador civil, alcalde, director del establecimiento, señor Paz Varela, y los profesores.

También acudieron los niños de la colonia veraniega de la Lagoa (Sada), con sus profesores. Los pequeñuelos van encantados de su estancia en Oza.

Los catedráticos n- asociados de la Universidad de Santiago han dirigido una circular a sus compañeros de toda España rogándoles que en lo sucesivo el nombramiento de profesor auxiliar interino recaiga en persona de verdadero prestigio científico, procurando que no intervenga en su propuesta ni la política ni el favoritismo.

Han sido en Ferrol desmantelados del submarino "B-23" todos los mecanismos. También se le quitaron los tubos. Saldrán para Vigo, donde están fondeados, el capitán Lederer y el doctor Stein, pertenecientes al ejército del Cantábrico, que llegaron hace días a El Ferrol para saludar al comandante del sumergible y visitar éste.

Las fiestas de Betanzos se celebrarán en el presente año limitadas al vecindario de Betanzos, y sin embargo no han decaído el bullicio y la animación que son tradicionales. La Coruña no ha dado el contingente de otros años, debido a las circunstancias excepcionales que la población atravesaba en aquellos días.

Pero restablecida la normalidad vendrán a la histórica y simpática ciudad de Betanzos muchísimas personas, que gustan de las delicias de los Cantones y no quieren dejar de asistir a la exaltación que se prepara galantemente en obsequio de los forasteros.

A las pintorescas márgenes del Mandeo, a aquellos sotos llenos de encanto y de poesía, propios en atractivos, acudirán centenares de personas de nuestra vecindad para las cuales una jira anual a los Cantones es cosa de igual, como cumplimiento de un voto.

Sarracos la ruseda ria numerosas embarcaciones.

Hubo como siempre, baile, merienda, bullicio, llenando la hermosa campiña brigantina notas de belleza y de alegría.

Una excursión, en fin, que bizo honor a una tradición que no muere, porque se basa en los naturales encantos de aquel paisaje del cual bien se puede decir en metáfora que es trasunto de la gloria.

Se declaró un violento incendio en el establecimiento de ultramarinos que en a casa número 51 de la calle de Santa Isabel, tiene establecida don José Sánchez Villar.

Fué advertido el fuego por los vecinos de la casa, donde también habita el señor Sánchez, y a cuyo y a la rapidez con que acudieron dichos vecinos y algunos guardias y transeuntes a sofocarlo, se debe que el incendio se extinguiese pronto.

Cuando llegó a Santa Lucía el retén de bomberos del Camino Nuevo, ya el fuego estaba apagado.

Los trabajos de extinción fueron activísimos, y a ellos aportaron su trabajo, no sólo los inquilinos de los pisos altos de la casa incendiada, sino los de las viviendas vecinas.

Otro incendio. Varios vecinos de la calle de San Roque advirtieron que salía humo por la ventana de la bohardilla de la casa número 17 de aquella vía.

El inquilino de la casa número 19, Fernando Lago, subió hasta la citada bohardilla, y golpeó fuertemente a la puerta.

Como nadie le contestase, y convencido de que allí había fuego, dió voces avisando a los vecinos del resto de la casa, y se dispuso a abrir a hachazos la puerta de entrada a dicha vivienda.

Entre las personas que allí se reunieron, estaba el obrero electricista José Suevras, quien ayudó a Lago a abrir la puerta de la bohardilla. Ya franqueada la entrada, se vió que el humo invadía la vivienda.

El citado José Suevras, con verdadera exposición de su vida, ya que estuvo a punto de perecer asfixiado, penetró en la bohardilla, y—tendido, cuando que el humo no permitía—logró sacar de una alcoba, donde, en una [illegible] Laban tres criaturitas, de cinco, tres y uno medio años, respectivamente, que hubieran muerto de haberse unos momentos más en aquel a- sivarias.

Estaban casi asfixiadas.

El citado convecino José Sacáras, fu- extrajo de la bohardilla, una a una, y las entregó a las demás personas que se hallaban a la entrada de aquella, quienes las condujeron a la Casa de Socorro.

Luego de asistidas por los médicos de este establecimiento, de las tres criaturitas se hizo cargo su madre, María Amado.

Tiene ésta a su esposo, Luis López en la Habana.

LUGO

Nota de los precios del mercado celebrado últimamente en Lugo:

Centeno fertado, pesetas 3,75; trigo ídem, 4,50; cebada ídem, 3,35; maíz ídem 4,75; patatas quintal, 7,00; huevos docena, 1,40; manteca kilo, 3,50; tocino ídem, 3,50.

Reina gran entusiasmo entre toda la gente política de la provincia ante la visita que en el corriente mes de Septiembre hará el señor González Besada a esta capital. Sábese que vendrán a ella con el indicado motivo muchos representantes en Cortes, entre ellos el de La Coruña, señor Maral, y el de Puente Caldelas, señor Villaverde, hijo del ilustre hacendista. Sábese que el señor Sot- Reguera, acompañando a éste. Además vendrán también varios diputados y senadores que se encuentran veraneando actualmente en la capital penitenciaria. Puede darse ya como absolutamente seguro que el señor González Besada llegará a Lugo el día 18 de Septiembre y que será obsequiado con el banquete popular—banquete verdaderamente monstruo—el día siguiente.

Continúan las gestiones para la creación de una escuela en la parroquia de Santa Cruz del Valle de Oro. Si de gran necesidad este centro y sin duda el lugar más a propósito para su instalación es la parroquia dicha, tanto por su situación respecto a las demás del Valle, como en relación con las aldeas vecinas. La ciudad de la Habana "Hijos del Valle de Oro", pone a disposición de este Ayuntamiento 1.000 pesetas para el mobiliario de la futura escuela. De aplaudir es la conducta de estos hijos del Valle que tan oportunamente se acuerdan de su país.

Ha tenido plena confirmación el rumor de haber aprovado en sumo del Mitin el cadáver del joven abogado don Juan Pardo Ballda, fiscal municipal del Cargo.

PHILIPS ARGA
TIPO 2 WATT
PHILIPS "ARGA"
la mejor lámpara.
Oscar Pintos y Cía.
Avda. 18 DE JULIO, 1100

Ha sido nombrado Auxiliar agente ejecutivo para la cobranza de las contribuciones en el Ayuntamiento de Castro de Rey, don Severino Rivas vecino de Loseñía, en dicho municipio.

Llama justamente la atención de cuantos la admiran, la magnífica bandera que para la tropa de explosadores de Sarria, ha donado su madrina la excelentísima señora doña Josefa Díaz de Quiroga Ruplo. Hállase expuesta al público en uno de los escaparates de cerrero de la calle Mayor.

El Registrador de la propiedad de Vivero don Román Iglesias, ha sido destinado en comisión a Madrid.

Señalándose los días 8, 9 y 10 de Septiembre corriente para las ferias de los Remedios, en Mondoñedo.

Se ha constituído en Mondoñedo una sociedad titulada "Agrupación Mondoñedana", que tendrá por objeto la constante y activa gestión de cuantos asuntos puedan ser convenientes a aquella ciudad.

Con objeto de reanudar los ensayos de- rción, cesdalla y sesión de declamación, celebró junta general la sinfónica colectividad coral "Orfeón Verga", que dirige don José Castelao Jurado.

Proyectan dar una velada y rendir póstumos homenajes al inmortal Virgo, autor de la Alborada.

Por la autoridad competente, ha sido suspendida la popular y tradicional fiesta que en honor de Conde Santa, se venía efectuando anualmente en Villanueva de Lorenzana. En la creencia de que estos festejos serían, como de costumbre, celebrados, acudió regular número de personas, improvisando un pasco. Por ambos desmontarán, se efectuaron algunas detenciones.

Fué designado el sobrestante de obras públicas don Victoriano Prado Erria, para las operaciones de tipación y valoración de las fincas que se han de expropiar en el término municipal de Friol, con motivo de las obras de ensanchamiento de la carretera de Lago a la provincial de Villalba a las Pías, trozo 4.o y 5.o

Por el Gobierno civil de la provincia se reclama a los alcaldes de Sarriás y Meira certificaciones acreditativas de no haberse presentado reclamación al-

· Centro Gallego, n.º 2, p. 6, 28/10/1917. Galiciana / Commons.
Fuente del ejemplo

LECTURA DE LA PÁGINA

Una página reúne títulos, bloques de texto, figuras y avisos. Determinar dónde empieza y termina una noticia exige criterios explícitos, y esos criterios pueden variar entre lectores.

Sin layout, la página se lee como un único texto

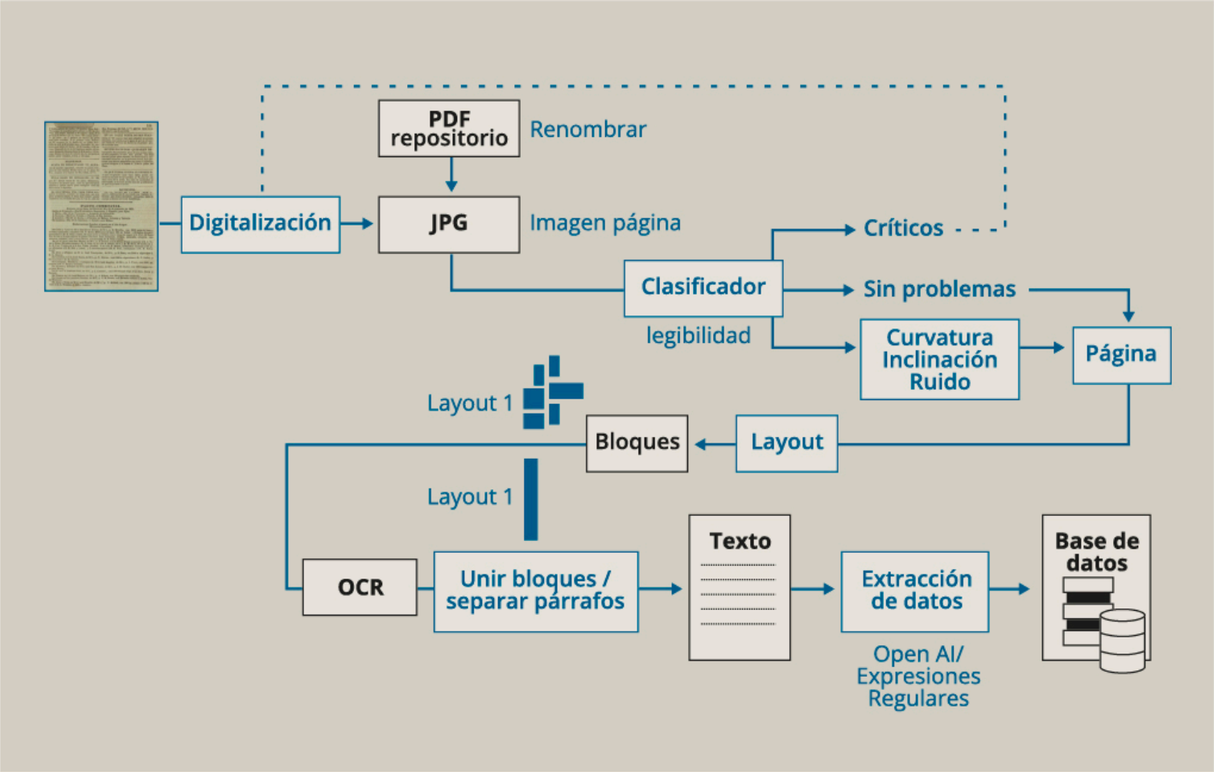
> El OCR por página de Chronicling America mezcla titulares, artículos, avisos y pies de imagen.

> Sin regiones, el reconocimiento puede leer fuera de orden, duplicar o fragmentar el texto.

> En American Stories, un modelo que clasificaba artículos completos identificó las noticias sobre política mejor que una búsqueda por palabras clave.

> Separar la página en regiones no siempre mejora el texto reconocido: en otro estudio, al procesar la página completa, una mayor proporción de las palabras obtenidas figuraba en un diccionario. Eso no demuestra que el texto sea fiel al original.

Dónde se ubica el layout: el flujo de PortADa



· Proyecto PortADa, flujo de construcción de la base de datos.

FLUJO DE TRABAJO

Antes del layout, la página se renombra, se clasifica por legibilidad y se corrige (curvatura, inclinación, ruido); las críticas vuelven a digitalizarse. Después vienen el OCR por bloques, la unión de bloques y la extracción de datos.

Qué llamamos layout

> La disposición espacial de los elementos de una página: posiciones, tamaños, alineaciones y separaciones.

> El análisis documental identifica regiones y, según el método, les asigna funciones y relaciones.

> Columna, párrafo, artículo y sección describen unidades diferentes. No deben intercambiarse.

Estructura física y estructura editorial

01

Física

Columnas, líneas, márgenes, filetes y recuadros. Se describen mediante posiciones y formas.

02

Editorial

Títulos, noticias, avisos, secciones y continuaciones. Su identificación puede requerir lectura del contenido.

La disposición también comunica

> El tamaño y la posición de un título orientan la atención: señalan qué contenido se presenta como destacado.

> Los espacios, las líneas y los recuadros ayudan a distinguir dónde termina una noticia y empieza otra.

> La cercanía entre un título, un texto y una imagen puede sugerir que pertenecen a la misma noticia; hay que comprobar esa relación al leer.

> Si guardamos solo las palabras, perdemos estas pistas sobre la importancia de cada contenido y su relación con los demás.

La página como espacio de expresión política

> La prensa de la comunidad afroestadounidense del siglo XIX publicaba noticias, debates y reclamos de derechos de una población históricamente excluida.

> Beyene y Dancy mencionan The North Star y The Weekly Anglo-African: sus editores usaban la disposición de la página para destacar mensajes, fortalecer vínculos comunitarios y afirmar una posición política.

> Estudiar esa prensa exige preguntar no solo qué se decía, sino cómo se presentaba: ¿qué se destacaba?, ¿qué contenidos se agrupaban?, ¿qué relaciones se proponían al lector?

> Una transcripción permite leer las palabras. Conservar también la página permite investigar esas decisiones editoriales.

Las mismas palabras, dos lecturas posibles

01

Como titular de una noticia

«Se convoca a una asamblea» aparece en letras grandes, encima de un texto que explica quién convoca y qué se debatirá. La disposición invita a leer la frase como título de ese texto.

02

Como aviso independiente

«Se convoca a una asamblea» aparece en un recuadro separado de las noticias, con lugar y horario. La disposición ayuda a reconocer una convocatoria independiente, no el título de la noticia vecina.

Cuatro tareas del análisis documental

01

Detectar

Localizar regiones y delimitar su extensión.

02

Clasificar

Asignar una categoría a cada región.

03

Ordenar

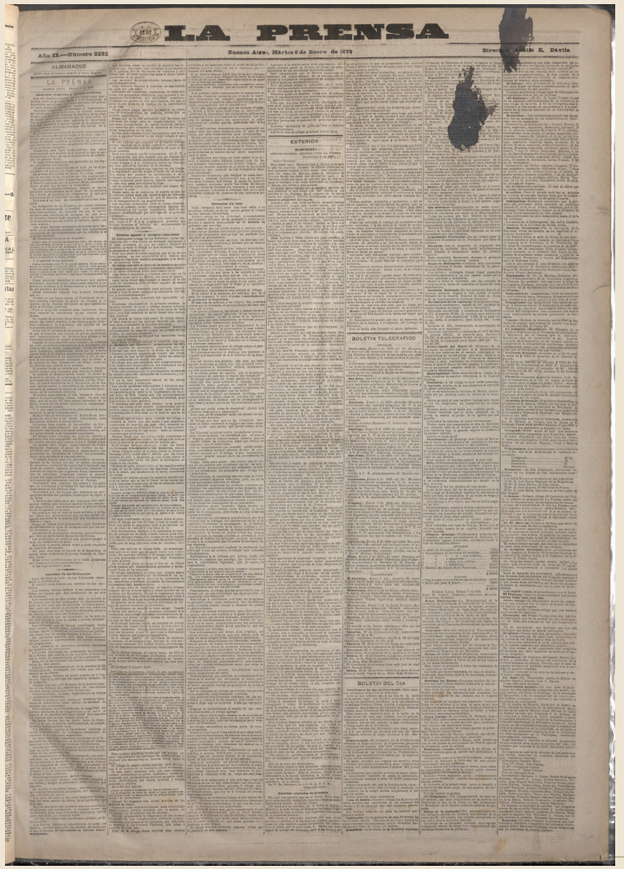
Establecer la secuencia de lectura.

04

Relacionar

Agrupar regiones de una misma unidad editorial.

Las columnas muy juntas dificultan su detección



· La Prensa (Buenos Aires).

LECTURA DE LA PÁGINA

Cuando hay poco espacio entre columnas, el detector puede unir bloques que deberían quedar separados. Los separadores y los cambios tipográficos ayudan a reconocer los límites. Una columna puede contener varias noticias; una noticia puede ocupar varias columnas.

Qué se pierde al recortar

> Perdemos la ubicación y el contexto. Una noticia recortada ya no permite ver si estaba en la portada, al pie de la página o junto a un anuncio.

> Podemos perder pistas sobre qué se destacaba y qué iba junto. Si el recorte deja fuera el título grande o la foto con su pie, cuesta reconstruir cómo se presentaba la noticia.

> Sin la página completa, no podemos revisar qué quedó fuera. Si un recorte termina a mitad de una frase, necesitamos el original para comprobar si el texto seguía en la columna de al lado.

De la imagen al documento estructurado

01

Imagen

Conservar original, procedencia y dimensiones.

02

Regiones

Delimitar y clasificar; revisar límites.

03

Texto

Transcribir regiones y comprobar omisiones.

04

Relaciones

Ordenar y asociar bloques; registrar continuaciones.

La imagen ya viene mediada

> En Burney, la imagen digital se obtuvo de un microfilm, no directamente del periódico. Si una letra ya era ilegible en esa copia, escanearla no garantiza recuperarla.

> Al microfilmar, los operadores debían decidir a qué número pertenecía cada página. Esa identificación pasó a las copias posteriores; no era una propiedad automática de la imagen.

> Algunas tomas incluían una página y otras, dos páginas enfrentadas. Antes de detectar columnas y noticias, hay que comprobar si el archivo contiene una página o una doble página.

> Después se aplicó OCR para obtener texto buscable. El texto reconocido es otra representación: una palabra visible en la imagen puede estar mal transcrita y no aparecer en la búsqueda.

La iluminación cambia lo que podemos ver

> Una fotografía con luz uniforme puede mostrar bien la tinta y ocultar pequeños surcos del papel. Una luz dirigida desde un costado produce sombras que ayudan a verlos.

> Prescott y Hughes describen marcas hechas con una punta sin tinta en el Benedictional de san Æthelwold. Esas marcas ayudaban a organizar el manuscrito y se distinguen con luz lateral.

> En Beowulf, las fotografías con luz ultravioleta permiten estudiar trazos que no se distinguen igual bajo luz normal. Si solo consultamos la vista normal, podemos pasar por alto esa evidencia.

> No ver una marca en una imagen no demuestra que el original no la tenga. Antes de concluir que falta, hay que preguntar cómo se hizo la fotografía y qué otras vistas existen.

Prescott y Hughes (2018), §§ 24–29

Registrar cómo se obtuvo la imagen permite revisar sus límites

> Identificar el documento y la copia utilizada: periódico, fecha, página, institución y enlace o identificador. Por ejemplo, indicar si el archivo proviene de un microfilm o de una fotografía del original.

> Anotar qué muestra la toma: una página, dos páginas enfrentadas o un recorte. Si solo tenemos un recorte, no podemos usarlo para afirmar que el resto de la página estaba vacío.

> Registrar los cambios realizados. Por ejemplo: «giré la imagen», «recorté los márgenes» o «aumenté el contraste». Conservar también el archivo recibido para poder comparar.

> Indicar lo que no sabemos. Si la institución no informa cómo obtuvo la imagen, escribir «procedimiento de captura no informado», en lugar de suponer que fue una fotografía directa.

A partir de Prescott (2018) y Prescott y Hughes (2018)

Reconocer texto no resuelve todas las relaciones

01

OCR

Reconoce caracteres o secuencias de texto. Un sistema completo puede incorporar detección y ordenación.

02

Reconstrucción documental

Asocia titulares, cuerpos, pies y continuaciones. Un OCR correcto por bloque no garantiza artículos completos.

Definir una pauta de anotación

Anotar es marcar regiones de la página y asignarles categorías. La pauta indica cómo hacerlo para que las personas no usen criterios distintos sin advertirlo.

Elegir qué se quiere identificar. Si buscamos noticias, tres párrafos de una misma noticia no deben contarse como tres noticias; si buscamos párrafos, sí deben marcarse por separado.

Definir las categorías con ejemplos: una oferta de venta como aviso y una crónica de un hecho como noticia. Acordar también cómo tratar casos dudosos, como un anuncio redactado con apariencia de noticia.

Acordar los límites del recorte. Por ejemplo, decidir si una foto incluye su pie o si se marcan por separado. Esas decisiones orientan el aprendizaje del modelo, aunque no garantizan que siempre las respete.

Revisar los desacuerdos antes de evaluar el modelo

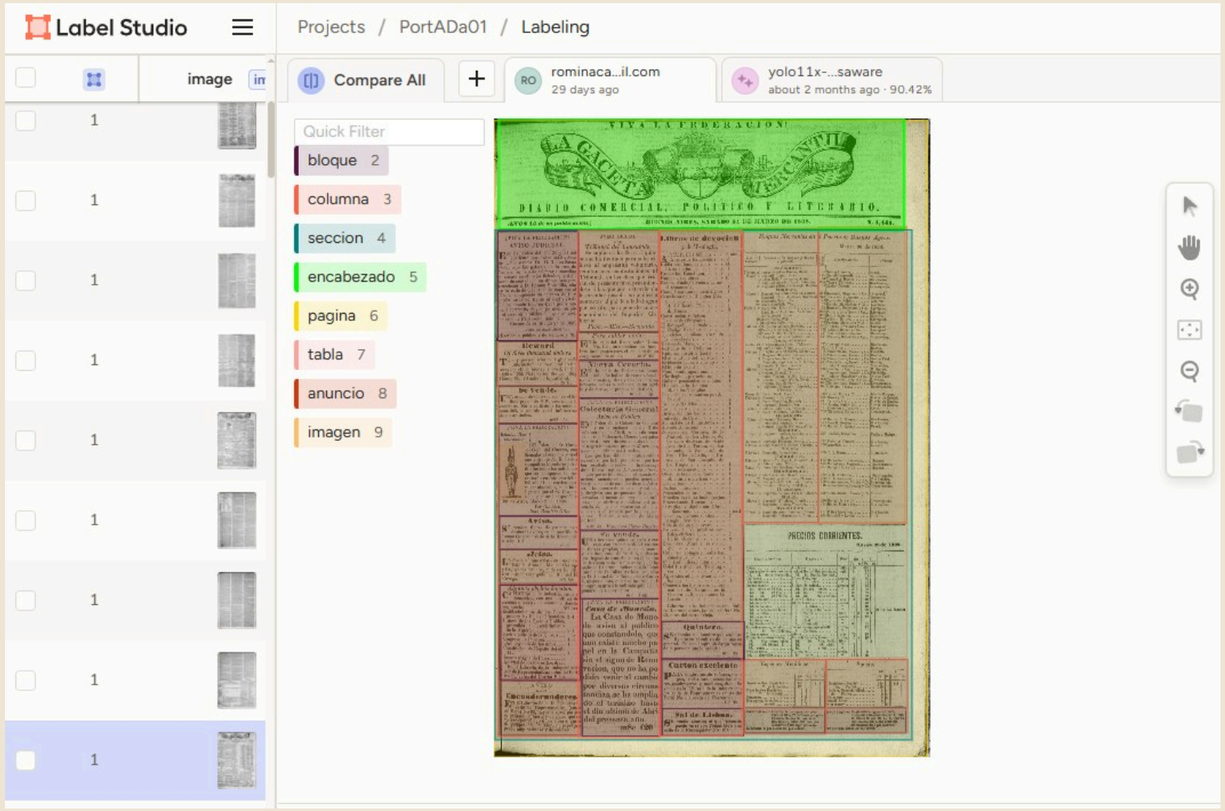
> Dos personas pueden marcar distinto el mismo aviso: una encierra texto, marco e imagen; otra marca cada parte. Comparar ambas versiones permite detectar una regla que falta en la pauta.

> Registrar el desacuerdo y acordar cómo resolverlo. Añadir ese caso como ejemplo y revisar las páginas ya marcadas que puedan tener el mismo problema.

> La referencia de evaluación es un conjunto de páginas revisadas con el que contrastamos la salida del modelo. No debe confundirse con los ejemplos usados para entrenarlo.

> Guardar por separado lo marcado por las personas y lo propuesto por el modelo. Si aceptamos sus recortes sin revisarlos y luego los usamos como referencia, sus errores pueden pasar por aciertos.

Anotación manual de regiones



· Captura de Label Studio.

LECTURA DE LA PÁGINA

La persona delimita y etiqueta. La herramienta permite registrar decisiones; no determina qué debe contar como noticia o aviso.

Cajas y máscaras

01

Caja delimitadora

Rectángulo definido por dos esquinas. Es la salida de un detector de objetos; puede incluir fondo o contenido contiguo.

02

Máscara o polígono

Representación más ajustada a la forma de la región. Exige otro tipo de anotación y una salida compatible del modelo.

Coordenadas y vínculo con el original

- Una caja puede expresarse como (x1, y1, x2, y2), en píxeles y desde la esquina superior izquierda.
- Registrar ancho y alto de la imagen: al reescalarla también cambian las coordenadas.
- Conservar identificador de página, identificador de región y ruta del recorte.
- No confundir coordenadas en píxeles con coordenadas normalizadas.

Reglas geométricas y modelos aprendidos

01

Reglas

La persona escribe el criterio. Por ejemplo: buscar una franja vertical sin tinta y usarla como límite entre columnas. Si un titular cruza esa franja o las columnas están muy juntas, la regla puede fallar y hay que revisarla.

02

Aprendizaje supervisado

La persona marca regiones y categorías en páginas de ejemplo. Durante el entrenamiento, el modelo compara sus propuestas con esas marcas y se ajusta para reducir las diferencias. Después propone recortes en páginas nuevas; hay que revisarlos, sobre todo si cambia el diseño.

Las reglas buscan señales visibles para separar regiones

> Espacios en blanco: buscar una franja vacía entre dos columnas. Si están casi pegadas, esa pista puede ser demasiado estrecha para separarlas.

> Proyecciones: contar los píxeles oscuros en cada fila o columna de la imagen. Una zona con pocos puede señalar un espacio entre líneas de texto o entre columnas.

> Componentes conectados: agrupar los píxeles oscuros que se tocan y después reunir esas formas por cercanía. Una mancha puede unir letras que deberían quedar separadas.

> Separadores: buscar líneas impresas o marcos que dividen contenidos. Si una línea está cortada o desgastada, el sistema puede no reconocer ese límite.

YOLO aplicado a documentos

YOLO reúne modelos que localizan elementos en una imagen. Aplicados a documentos, pueden buscar regiones de texto, títulos, imágenes o tablas, según las categorías con las que fueron entrenados.

Para cada región, un detector propone una caja: un rectángulo que indica dónde está y cuánto espacio ocupa. Por ejemplo, puede encerrar un bloque de texto de una columna.

También propone una categoría y una puntuación. Por ejemplo, «texto» indica cómo clasifica ese bloque; la puntuación sirve para filtrar propuestas, no demuestra que el recorte sea correcto.

Las variantes no hacen todas lo mismo: unas devuelven cajas; las de segmentación también pueden delimitar el contorno de cada región. Hay que comprobar qué modelo se está usando y qué aprendió a reconocer.

Detectar los bloques no basta para reconstruir una noticia

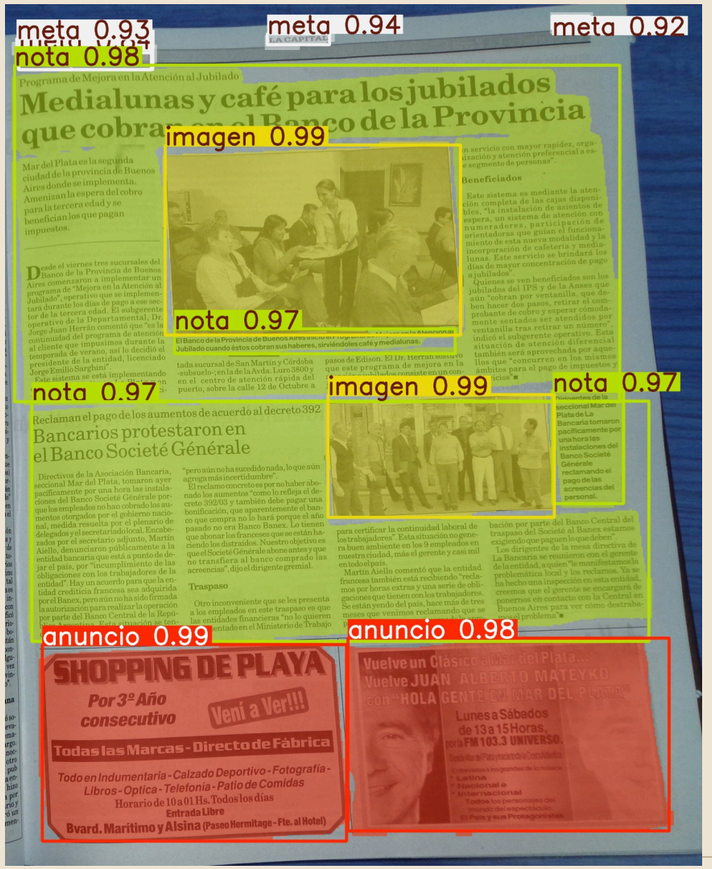
> Transcribir: una caja alrededor de un párrafo indica dónde está, pero no qué dice. Para convertir la imagen de las letras en texto hace falta OCR u otro procedimiento de transcripción.

> Ordenar: varias cajas no indican cuál se lee primero. En una página con dos columnas, hay que comprobar si se termina la columna izquierda antes de pasar a la derecha.

> Relacionar: detectar un titular y dos bloques de texto no demuestra que formen una misma noticia. Hay que revisar el contenido, la posición y las posibles continuaciones.

> Un sistema completo puede combinar estas tareas. Al comparar herramientas, distinguir lo que produce el detector de lo que añaden los demás componentes.

Segmentación de instancias: máscaras además de cajas



· La Capital (Mar del Plata). Salida de YOLO-seg.

LECTURA DE LA PÁGINA

Un modelo YOLO de segmentación (variantes -seg) predice, para cada región, una caja y una máscara que sigue su contorno. Las clases nota, imagen, anuncio y meta provienen de un entrenamiento propio. La visualización permite inspeccionar límites y etiquetas, pero no mide por sí sola su calidad.

DocLayout-YOLO

> DocLayout-YOLO está preparado para localizar partes de una página, como títulos, bloques de texto, imágenes y tablas. Propone recortes y categorías; no transcribe el contenido.

> Aprendió con ejemplos de documentos, incluidas páginas creadas por computadora que combinan textos e imágenes en distintas posiciones. Esas páginas amplían los ejemplos disponibles, pero no son periódicos históricos reales.

> No todas las versiones aprendieron con los mismos ejemplos. También cambia el resultado si se le muestra la página con más o menos detalle o si se aceptan propuestas que el modelo considera menos seguras.

> Hay que anotar qué versión y ajustes se usaron. Antes de confiar en los recortes, compararlos con páginas de nuestra colección: ¿faltan noticias?, ¿se mezclan columnas?, ¿se confunden avisos con texto?

Repositorio del modelo

Clases del modelo y categorías de investigación

01

Clases disponibles

title, plain text, figure, table y otras categorías documentales. La etiqueta abandon agrupa elementos considerados descartables por el esquema.

02

Categorías que necesitamos

Noticia, aviso, sección, firma o continuación. American Stories usa artículo, titular, firma, pie, aviso, tabla y mancheta. No aparecen por traducir etiquetas.

El corpus importa tanto como el modelo

> El corpus es el conjunto de documentos con el que se trabaja. Aprender con artículos científicos y documentos de oficina no prepara al modelo para todos los diseños de la prensa histórica.

> Un detector que aprendió con prensa de la Primera Guerra Mundial localizó peor las regiones en periódicos de 1850–1875. Incluso dentro de la prensa, cambiar de época puede afectar el resultado.

> En otro estudio, entrenar con páginas muy diversas no produjo resultados estables; con páginas más parecidas, mejoró la localización. Agregar variedad no garantiza por sí solo una mejora.

> Probar el modelo en páginas de distintas épocas y cabeceras, reservadas fuera del entrenamiento. Comparar con el original qué omite, qué mezcla y qué divide mal.

La confianza no equivale a exactitud

> El modelo asigna una puntuación a cada región propuesta. Una puntuación alta no demuestra que el recorte o su categoría sean correctos.

> El umbral es la puntuación mínima que aceptamos. Bajarlo permite encontrar regiones antes omitidas, pero también aceptar recortes incorrectos.

> Subir ese mínimo puede quitar recortes incorrectos, pero también dejar fuera regiones que sí interesan.

> Comparar los recortes aceptados y descartados con la página original. Conservar las salidas para poder revisar la decisión.

Lee et al. (2020), Newspaper Navigator

Orden geométrico y orden de lectura

01

Orden geométrico

Las cajas se numeran por coordenada vertical y luego horizontal. Los números identifican regiones; no establecen cómo se lee el periódico.

02

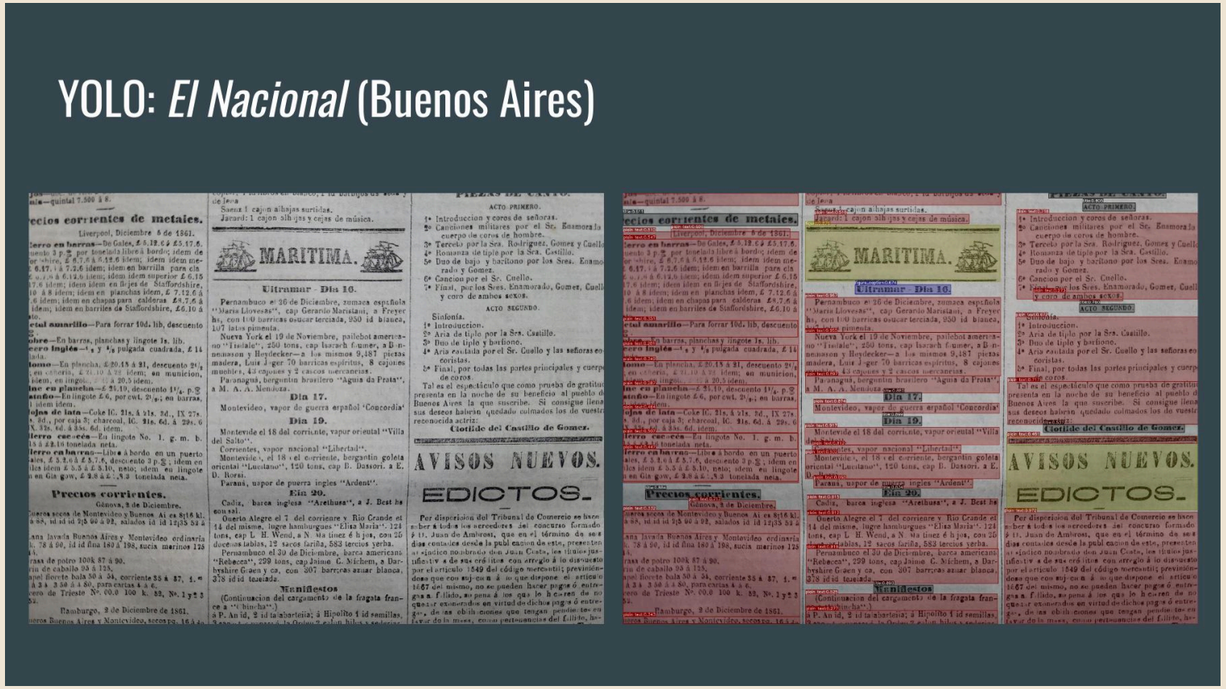
Orden documental

Puede exigir completar una columna antes de pasar a otra, saltar un aviso o enlazar una continuación. Hay que comprobarlo en la fuente.

Reconstruir un artículo

- Relacionar título, cuerpo, imágenes y pies que pertenezcan a una misma unidad.
- Combinar geometría con indicios textuales: continuidad sintáctica, encabezados y referencias de continuación.
- Una regla explícita también es un criterio: American Stories asocia titular y artículo si se solapan en vertical y la distancia no supera el 10 % del alto de página.
- Los modelos multimodales pueden usar imagen y texto; la arquitectura por sí sola no garantiza asociaciones correctas.
- Registrar por separado relaciones propuestas y relaciones revisadas.

Caso portuario: El Nacional

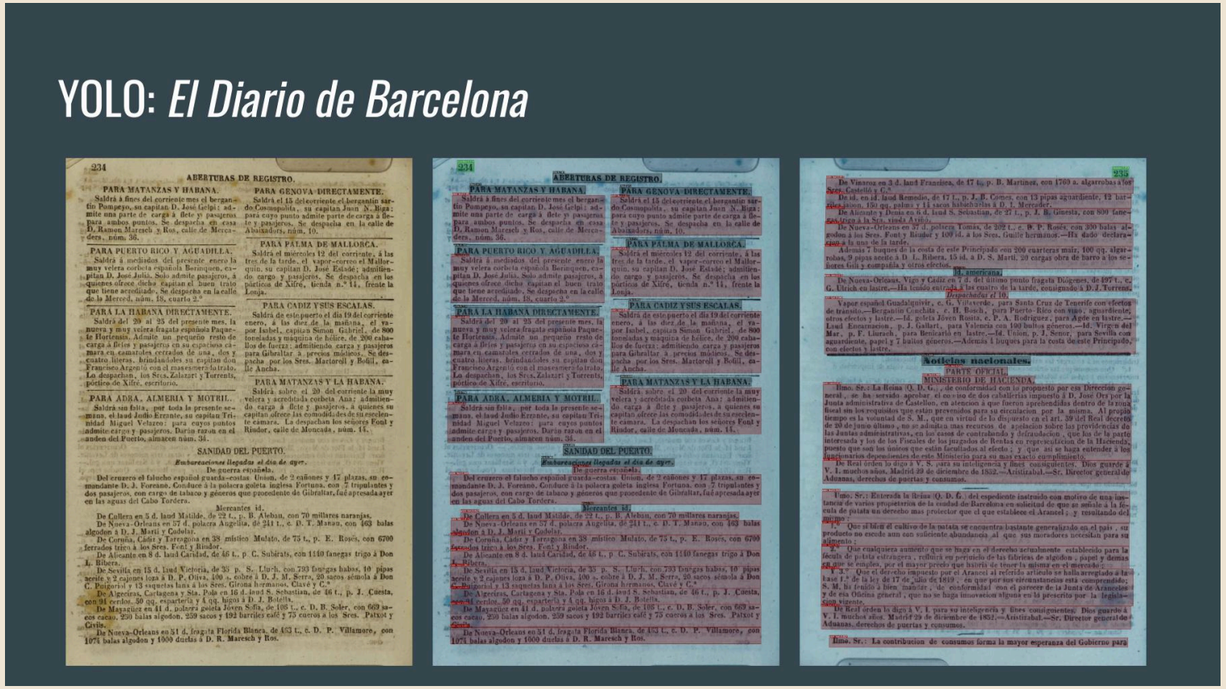


· El Nacional.

LECTURA DE LA PÁGINA

La fuente distingue imagen, detecciones y regiones. Pregunta de revisión: ¿cada recorte permite identificar una entrada portuaria completa?

Comparación entre cabeceras



· El Diario de Barcelona.

LECTURA DE LA PÁGINA

El Diario de Barcelona. Comparar densidad, separaciones y extensión de las regiones con El Nacional. Las imágenes ilustran un procedimiento, no una evaluación comparable.

Secciones y registros portuarios

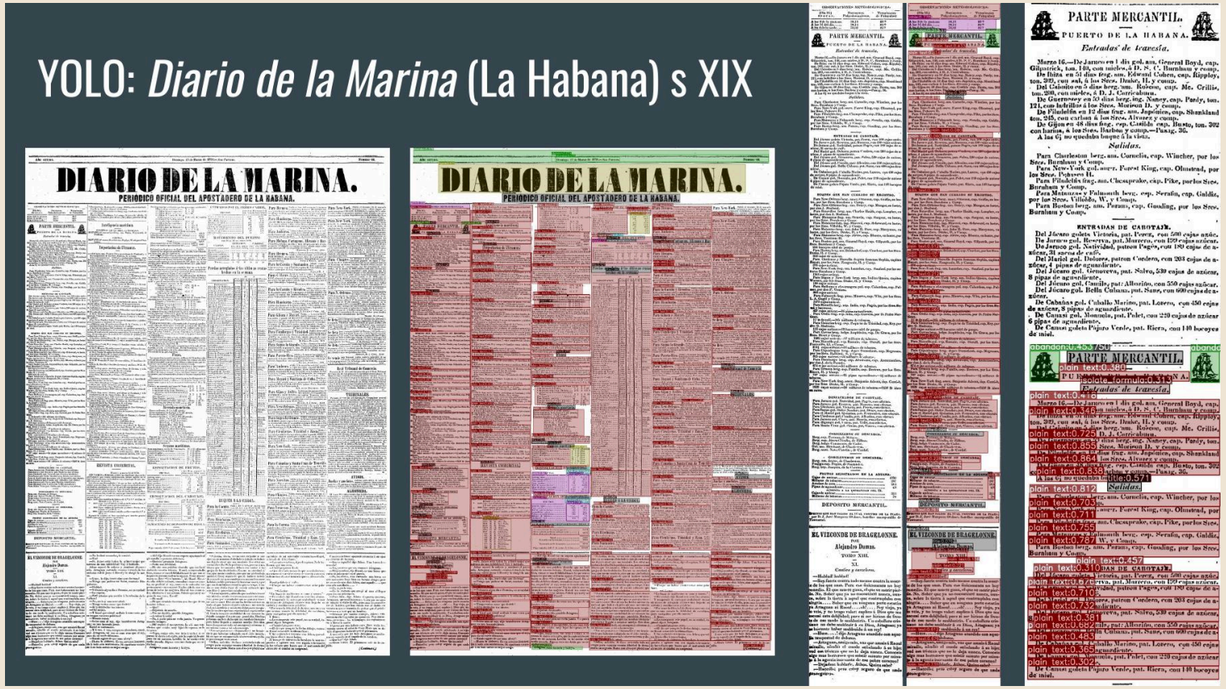


· Le Sémaphore de Marseille.

LECTURA DE LA PÁGINA

Le Sémaphore de Marseille. Distinguir página, sección y entrada. Una unidad útil para OCR puede contener varios registros o solo una parte de uno.

Revisar el contexto del recorte



· Diario de la Marina, La Habana.

LECTURA DE LA PÁGINA

Diario de la Marina, La Habana. Localizar encabezados que aporten fechas o categorías a varias entradas. Conservar esas relaciones al extraer registros.

Herramientas: comparar funciones concretas

01

Detección y procesamiento abierto

DocLayout-YOLO detecta regiones. Eynollah trabaja con análisis de layout y salida PAGE-XML. Verificar clases, formatos y revisión disponibles.

02

Plataformas documentales

Arcanum y Transkribus ofrecen flujos de procesamiento documental. Evaluar exportación, edición, costos y acceso a los originales; no comparar solo demostraciones.

Modelos de visión y lenguaje

> Estos modelos trabajan con la imagen de una página y con instrucciones escritas. Pueden usar tanto las letras como su posición y el aspecto de la página para producir una respuesta.

> Podemos pedir una transcripción o que organicen la información. Por ejemplo, devolver por separado el nombre, la fecha y el lugar que aparecen en un aviso, en vez de un único párrafo.

> Que entreguen una respuesta ordenada no demuestra que sea fiel al documento. Hay que comprobar si cada dato aparece en la imagen y si quedó contenido sin recuperar.

Un texto fácil de leer puede estar incompleto o alterado

> Omitir: en la prueba de una carta de Cullen, GLM-OCR devolvió solo el encabezamiento y dejó fuera el cuerpo sin avisar. El fragmento legible podía confundirse con una transcripción completa.

> Duplicar o cambiar: en otras pruebas hubo frases repetidas y palabras sustituidas. PaddleOCR-VL leyó «Represión» donde el manuscrito decía «Representante»: ambas son palabras reales, pero no dicen lo mismo.

> Revisar contra la imagen: ¿están todos los bloques?, ¿aparecen una sola vez?, ¿se conservaron nombres y fechas? Un texto fluido no responde esas preguntas por sí solo.

> Probar con nuestros documentos y nuestra tarea. Una imagen donde no se distinguen las letras ofrece menos pistas; tampoco es lo mismo leer un aviso que transcribir una página completa o un manuscrito.

Evaluación previa de herramientas, §§ 2–4

Errores que debemos distinguir

01 Omite: una unidad visible no tiene región correspondiente.

02 Fragmenta: divide en varios recortes una unidad que debía mantenerse completa.

03 Fusiona: reúne unidades que debían mantenerse separadas.

04 Clase errónea: localiza la región, pero le asigna otra función.

05 Límite incorrecto: corta contenido o incorpora una región vecina.

Evaluación geométrica y evaluación documental

01

Detección

Comparar cada recorte con una región marcada a mano: ¿coinciden sus límites?, ¿la categoría es correcta? Contar por separado los recortes correctos, los incorrectos y las regiones que faltan.

02

Uso histórico

Comprobar si cada noticia está completa, si conserva sus relaciones y si puede leerse en orden. Un recorte puede coincidir casi por completo con la región marcada y aun así cortar una palabra o perder una fecha.

Descomponer el error

> Localizar y clasificar son tareas distintas. En Newspaper Navigator, el detector obtuvo mejores resultados cuando solo debía localizar regiones, sin distinguir sus categorías.

> No todos los errores del texto vienen de confundir letras: en American Stories, una parte se debía a regiones o líneas mal delimitadas.

> La comparación entre modelos puede cambiar si exigimos recortes más ajustados al original. Explicar qué coincidencia de límites se considera aceptable.

> Comprobar cuántos ejemplos se evaluaron por categoría. Un buen resultado con solo dos imágenes no basta para saber si el modelo funcionará en otras páginas.

La comparación mezcla cobertura y problemas de búsqueda

> Helen McGuffie revisó prensa y revistas para reunir noticias sobre el escritor Samuel Johnson. Prescott comparó esa lista manual con una búsqueda de «Johnson» en la colección digital Burney.

> No se buscaba en las mismas publicaciones: de los 78 títulos usados para la lista, solo 36 estaban en Burney. Una noticia de una publicación ausente no podía aparecer, aunque el OCR fuera perfecto.

> Por eso los porcentajes siguientes no son una medida de calidad del OCR: comparan lo encontrado en una colección parcial con toda la lista manual.

> Pero había otro problema: en 1766, 39 noticias de la lista pertenecían a títulos incluidos en Burney y la búsqueda no recuperó ninguna. La diferencia no se explica solo por publicaciones ausentes.

Prescott (2018), Searching for Dr. Johnson, pp. 64–67

Qué parte de la lista apareció en una colección de cobertura parcial

2,4 %

1765 · encontró 3 de 122 noticias de la lista

0 %

1766 · encontró 0 de 59 noticias de la lista

5,2 %

1773 · encontró 10 de 190 noticias de la lista

1,5 %

1782 · encontró 3 de 195 noticias de la lista

Prescott (2018), Searching for Dr. Johnson

El modelo no decide qué información nos importa

> En una prueba con una página de Centro Gallego, de Montevideo, DocLayout-YOLO localizó texto e imágenes, pero marcó la cabecera, el número de página y un sello como elementos «descartables».

> Esa categoría responde al modo en que se preparó el modelo. No significa que esos elementos carezcan de valor para nuestra investigación ni que el programa los haya borrado.

> La cabecera permite identificar la publicación y el número de página ayuda a citarla. Un sello puede aportar información sobre la institución que conservó el ejemplar.

> Si eliminamos automáticamente lo marcado como descartable, podemos perder esas pistas. Revisar las categorías antes de filtrar y conservar la página original para comprobar el contexto.

Un modelo puede fallar al cambiar el tipo de documento

01

Qué se necesitaba

En cinco imágenes de documentos escritos a mano se buscaban bloques de texto para trabajarlos por separado. Un modelo que detecta texto impreso no necesariamente reconoce la escritura manuscrita como la misma clase de elemento.

02

Qué ocurrió en la prueba

DocLayout-YOLO marcó cada página completa como una sola imagen, sin separar sus bloques de texto. Para ese objetivo, la salida no servía. Antes de aplicarlo a otra clase de documentos, hay que comprobar si reconoce lo que necesitamos.

Las omisiones pueden cambiar lo que estudiamos

> Burney reúne prensa histórica de la Biblioteca Británica, principalmente de los siglos XVII y XVIII. Su versión digital permite ver páginas y buscar en el texto reconocido.

> Según Hitchcock, más de la mitad de ese texto no se recupera mediante búsquedas. Influyen la tipografía, la disposición de la página y la tinta del reverso que se transparenta.

> Omitir una tabla o un bloque deja datos fuera. Si ocurre más en ciertas épocas o cabeceras, el corpus representará unas partes de la colección mejor que otras.

> Prescott encontró que en Burney se recuperaban mejor los avisos que las noticias. Más resultados no prueban que se publicaran más avisos: también pueden reflejar un procesamiento más eficaz.