El OCR en la investigación histórica

Digitalización de prensa histórica, sistemas de reconocimiento de texto y evaluación de doce modelos

Agustín Nieto · INHUS-CEHis, UNMdP-CONICET · PortADa

Recorrido

01

I · El OCR como problema historiográfico

Cómo el estado del papel, el microfilm, la digitalización y los buscadores condicionan qué fuentes encontramos.

02

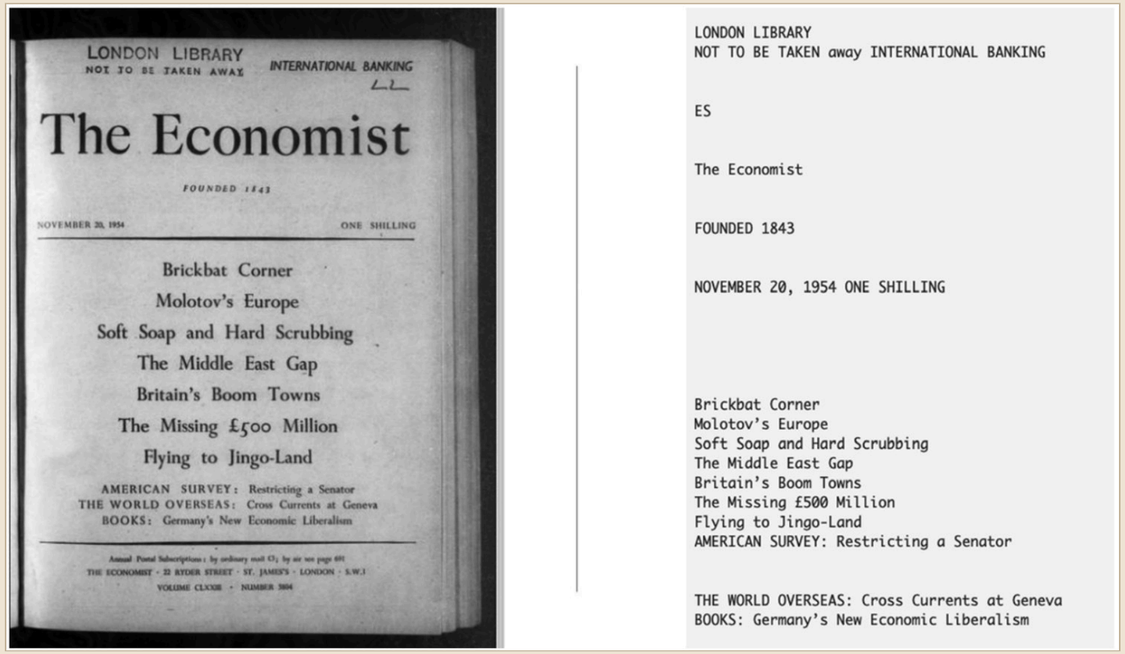
II · Modelos y métricas

Cómo funcionan los programas que leen texto, quién los ofrece y cómo se mide cuánto se equivocan.

I. El OCR como problema historiográfico

Antes de usar una fuente digitalizada conviene preguntarse cómo llegó hasta la pantalla.

Qué es el OCR



The Economist, 20-XI-1954: imagen y texto OCR del Internet Archive · Milligan (2022), fig. 2, p. 28

IMAGEN Y TEXTO

OCR es la sigla en inglés de **reconocimiento óptico de caracteres**. Es un programa que mira la fotografía de una página y la convierte en letras que una computadora puede buscar, contar y copiar. La imagen escaneada sigue siendo una fotografía; **el texto que permite buscar palabras es un producto nuevo**, fabricado por el programa a partir de esa fotografía, y puede tener errores.

El ejemplo es un caso fácil: la portada de una revista británica de 1954, limpia, con letra regular y una sola columna. Aun así, el programa copió como texto el sello de la biblioteca y agregó una línea («ES») que no está en la página. En la prensa histórica, con papel gastado y columnas apretadas, **los errores son mucho más frecuentes, y quien busca no los ve**.

Del impreso a la búsqueda digital

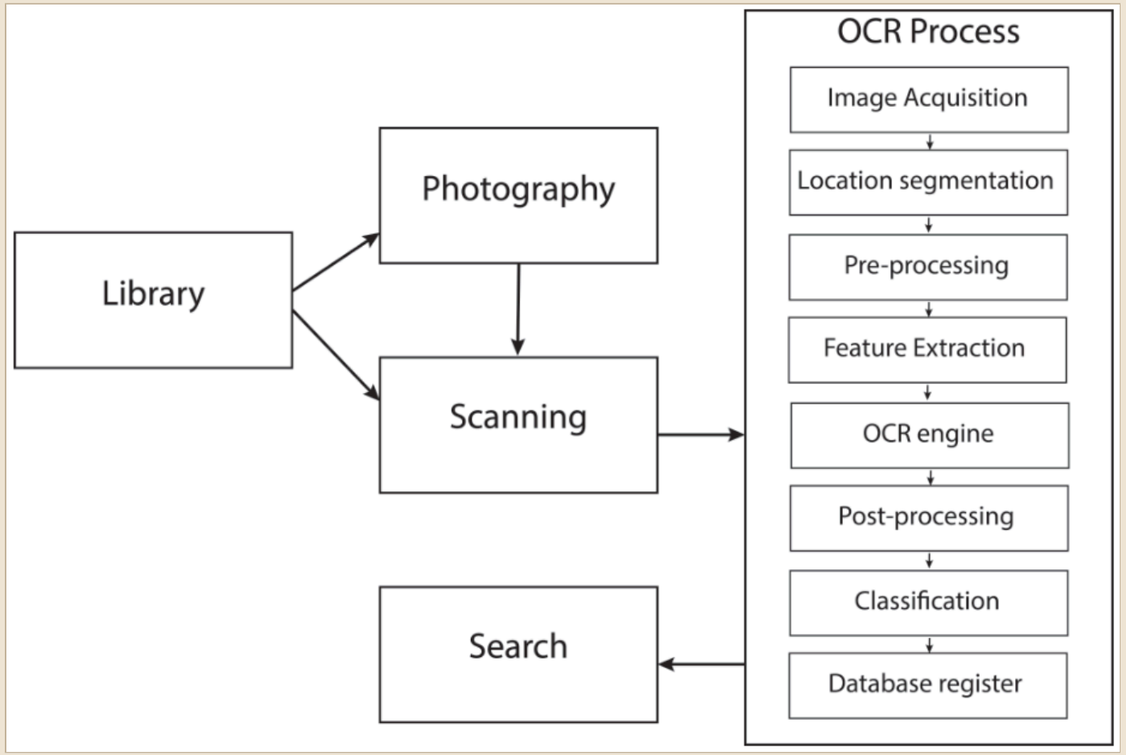


Fig. 5: etapas del proceso de OCR · Burchardt (2023), p. 45

BURCHARDT (2023)

Entre el diario impreso y el resultado que aparece en la pantalla hay varios pasos. Una biblioteca conserva los ejemplares y elige cuáles digitalizar. Luego se fotografía o escanea cada página, muchas veces a partir de un microfilm, es decir, de una copia fotográfica del diario en película. Después el programa de OCR divide la página en zonas, limpia la imagen, reconoce las letras, intenta corregirlas y guarda el resultado en una base de datos donde podemos buscar.

En cada paso alguien toma decisiones que quien consulta no ve: qué diarios se incluyen, con qué calidad se fotografiaron, qué programa se usó y si alguien revisó el resultado. Por eso el texto digital es el producto de toda esa cadena, y **conviene tratarlo como una copia más del documento, con su propia historia**.

El papel de la prensa del siglo XIX



UN POCO MAS DE LUZ EN LOS OMNIBUS

No es la primera vez que, a parte de otras deficiencias, llamamos la atención sobre la escasa luz que muchos ómnibus tienen en el interior.

Unas veces son las lamparillas que no se encienden, otras veces es la deficiente luz de todas las lamparillas; el caso es que de continuo se encuentra uno realizando viajes en una semi-tinieblа poco grata.

Creemos que es asunto fácil de remediar, en cuanto los señores autobuseros pongan un poco de buena voluntad.

porcionalmente quieta a la lista "Universidad".

La lista "Enseñanza" que en el primer escrutinio contó con número inferior de votos a las otras dos, cifra la posibilidad de lograr su primer candidato en el segundo cociente, que le publica su número.

Quiere decir, pues, que hasta el día de hoy continúa la incertidumbre referente a la integración definitiva, por el escaso margen que separa a las dos listas más votadas y la situación especial en que se coloca la tercera para el segundo escrutinio.

EL TIEMPO

CIELO: Cubierto y semicubierto. Lluvias parciales.

VIENTO: Noroeste Suroeste fuertes.

TEMPERATURA: En descenso.

el caso de esos pobres náufragos de la política (Gran ova. ción). Pensad que la tentación es muy grande. Ver la perspectiva de una provincia de la que se marchan los votos y tener en la mano el presupuesto de Obras Públicas o el de Instrucción Pública con el de poder verter unos chorritos de influencia para ver si con ellos se ganan unos cuantos votos que se estaban perdiendo, es una tentación tan fuerte y yo todo lo comprendo y todo lo explico. Quien no tiene votos es natural que pretenda comprarlos con obras públicas de última hora; para quien no tiene la voluntad del pueblo, los pequeños favores consultados a la providencia de todos aquellos desgraciados que no tienen otra ilusión alguna."

en cierta ma justificarse. que el Estado de toda esa — policía y e vaguarda el que poseen nos.

No hay dud uno crea probl dos aquellos incremento derancia en actividad: pro tria, comercio menos cierto sólo poco har sía en forma dades en mu alidades podera su lado, explo te a ese elem nalidades.

Esos dos son hoy el cón cerio.

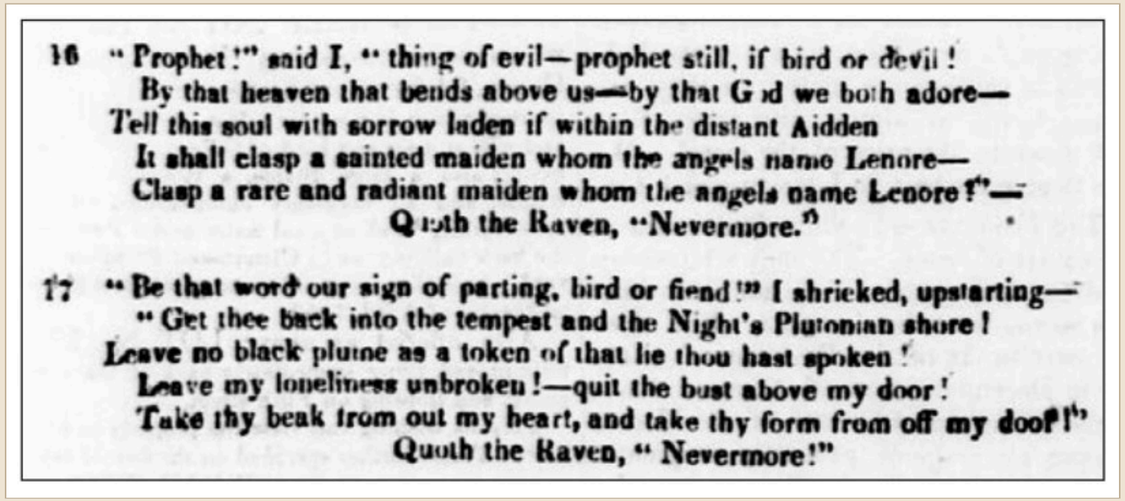
El Bien Público (Montevideo), 14-II-1936 · Biblioteca Nacional de Uruguay · Comesaña y Vilches-Blázquez (2019), fig. 1

EL PROBLEMA DEL PAPEL

Desde mediados del siglo XIX los diarios se imprimieron en **papel hecho con pulpa de madera**, barato y fabricado a máquina. Ese papel contiene sustancias que con el tiempo lo vuelven amarillo y ácido: se pone quebradizo y se rompe al manipularlo. Desde la década de 1930, los estudios sobre su conservación advirtieron que duraría pocas décadas y recomendaron copiar la prensa en microfilm antes de que se perdiera.

Esa decisión explica que **gran parte de la prensa digitalizada hoy provenga del microfilm y no del diario original**. En muchos casos, el programa de OCR lee la fotografía de una copia fotográfica de un papel que ya estaba manchado, roto o descolorido, como esta página de un diario montevideano de 1936.

Microfilm y escaneo



16 "Prophet!" said I, "thing of evil—prophet still, if bird or devil!
By that heaven that bends above us—by that God we both adore—
Tell this soul with sorrow laden if within the distant Aidden
It shall clasp a sainted maiden whom the angels name Lenore—
Clasp a rare and radiant maiden whom the angels name Lenore?"—
Quoth the Raven, "Nevermore."

17 "Be that word our sign of parting, bird or fiend!" I shrieked, upstarting—
"Get thee back into the tempest and the Night's Plutonian shore!
Leave no black plume as a token of that lie thou hast spoken!
Leave my loneliness unbroken!—quit the bust above my door!
Take thy beak from out my heart, and take thy form from off my door!"
Quoth the Raven, "Nevermore!"

Fig. 4: «The Raven» en el Lewisburg Chronicle (1849), imagen de archivo de Chronicling America · Cordell (2017), p. 206

HOLLEY (2009) · CORDELL (2017)

Quienes digitalizaron la prensa histórica de Australia describieron qué afecta la calidad del OCR: **el estado del diario original, la calidad del microfilm**, el nivel de detalle con que se escanea la imagen, el contraste entre la tinta y el papel, y la capacidad del programa para reconocer las letras. Recomendaban escanear el original cuando fuera posible y, si no, usar el microfilm más reciente y la copia más cercana al original.

Este detalle de un poema impreso en 1849 muestra el problema: al escanear el microfilm con mucho contraste, las letras mal entintadas del diario se cortan o se empastan. En síntesis, **la calidad del texto suele depender más del estado de los materiales que del programa que lo leyó**.

Calidad del OCR según el período

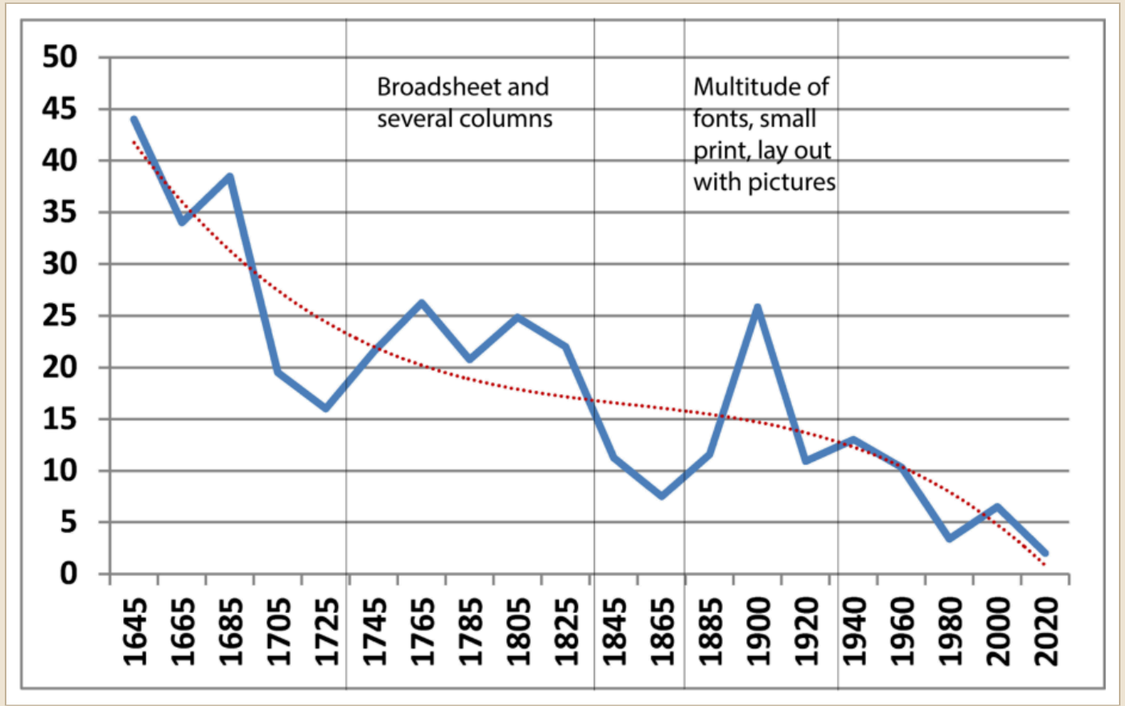


Fig. 3: porcentaje de palabras mal leídas por período · Burchardt (2023), p. 41

BURCHARDT (2023)

Un estudio revisó once archivos digitales de prensa de Europa y Estados Unidos. De cada uno tomó un gran diario y, cada diez a veinte años, un fragmento de unas cien palabras, y contó cuántas estaban mal leídas. En promedio, **casi una de cada cinco palabras (18 %) tenía errores**.

El gráfico muestra que la calidad mejora con los siglos, pero no de forma pareja. Desde 1730, durante casi cien años, el error aumentó porque los diarios pasaron a formatos grandes con muchas columnas, que confunden al programa. Hacia 1885 volvió a subir con la mezcla de tipografías, las ilustraciones y la letra cada vez más chica. Por eso **un mismo término es más fácil de encontrar en algunos períodos que en otros**, por razones ajenas a la historia que se investiga.

Burchardt (2023), pp. 38–42

Avisos y búsqueda de frases

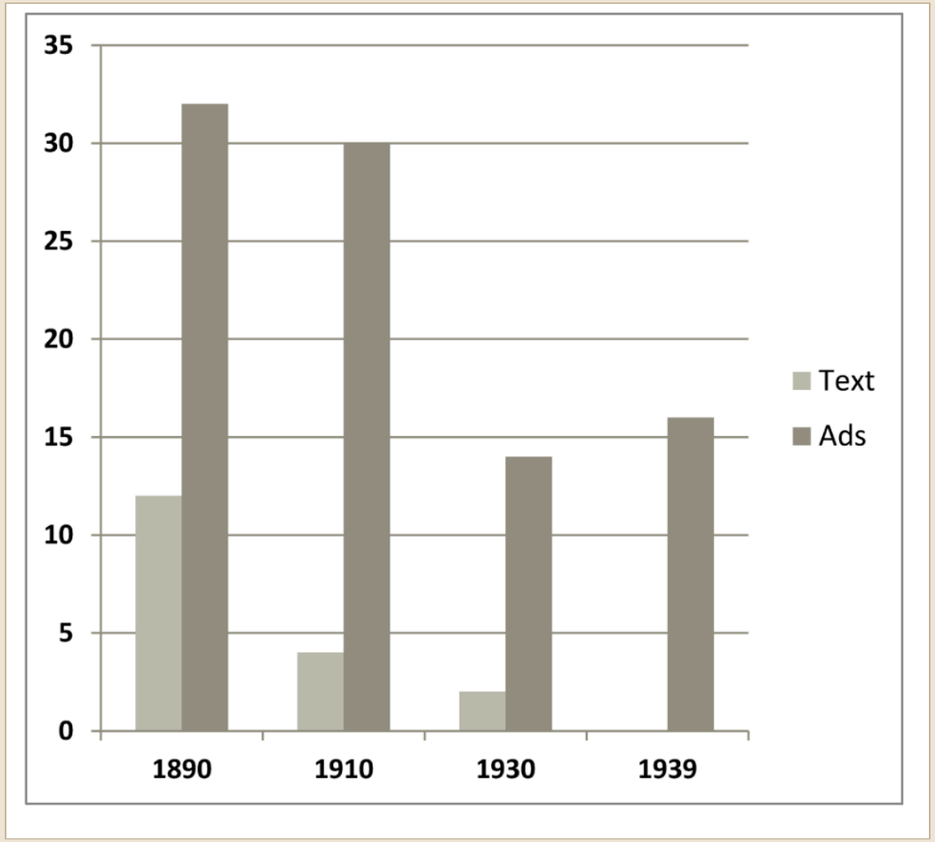


Fig. 4: errores en avisos (Ads) y en texto de noticias (Text), Päivälehti, 1890–1939 · Biblioteca Nacional de Finlandia · Burchardt (2023), p. 43

BURCHARDT (2023)

En un diario finlandés se compararon los avisos con el texto de las noticias: en todas las fechas, **los avisos tenían muchos más errores**. Mezclan letras de distintos tamaños y formas, y se ubican en recuadros que no siguen las columnas. Una historia del consumo, del trabajo o del comercio que se apoye en los avisos trabaja, entonces, con un texto más dañado.

El error también pesa más cuando se buscan frases. Si una de cada diez palabras está mal leída, una frase de siete palabras se encuentra en menos de la mitad de los casos; si es una de cada cinco, apenas en uno de cada cinco. Por eso, con estos archivos, **no se puede afirmar cuándo un hecho apareció «por primera vez» en la prensa**.

Burchardt (2023), pp. 42–43

Bases de datos en línea y citas

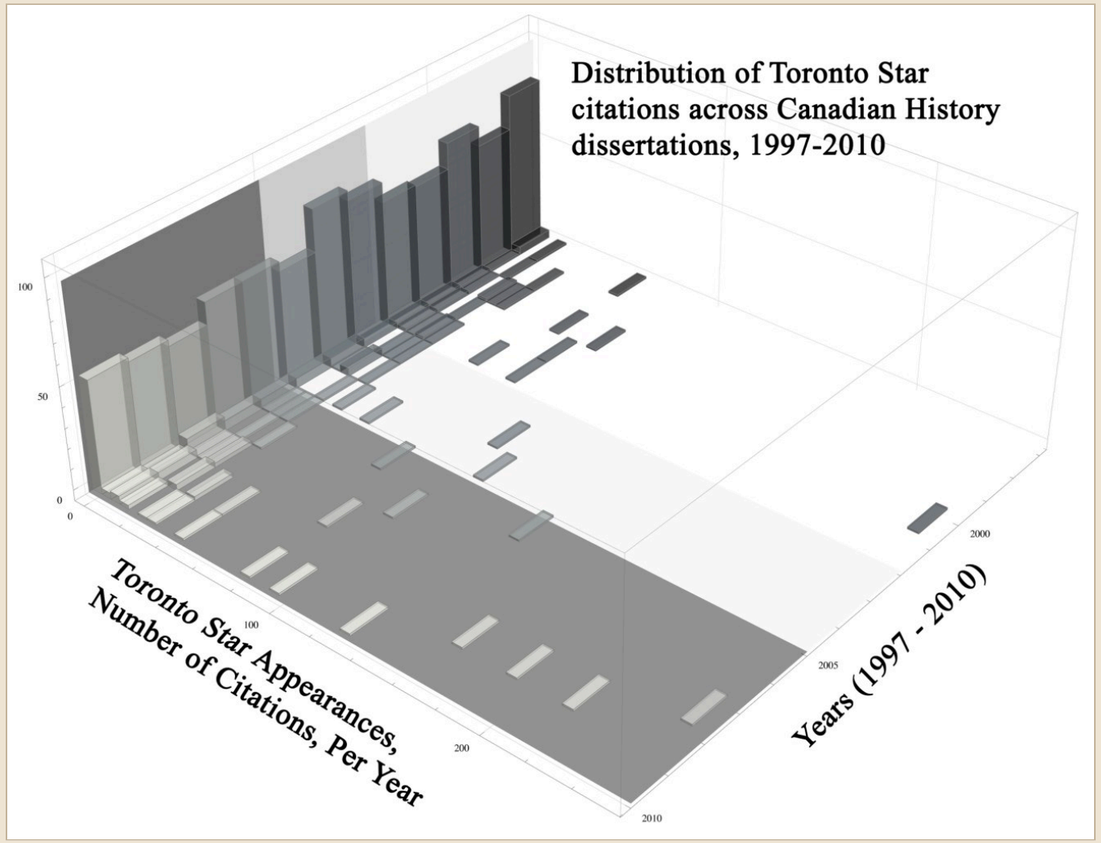


Fig. 4: citas del Toronto Star en tesis de historia canadiense, 1997–2010 · Milligan (2013), preprint, p. 10

MILLIGAN (2013)

Un estudio contó cuántas veces se citaban periódicos en tesis doctorales de historia de Canadá. En 1998, en 67 tesis, un gran diario de Toronto aparecía 74 veces; en 2010, en 69 tesis, **753 veces**. El cambio coincide con la publicación en línea del archivo de ese diario, mientras otros periódicos sin buscador digital perdían lugar. El gráfico muestra cómo crecen, desde mediados de la década de 2000, las tesis que lo citan muchas veces.

La conclusión es que **los buscadores en línea cambiaron qué fuentes usan los historiadores sin que nadie lo dijera**, y que hace falta entender el OCR para usarlos con cuidado. Cuando la búsqueda trae un artículo equivocado, lo descartamos al leerlo; **los artículos que la búsqueda no encuentra, en cambio, nunca llegan a nuestra vista**.

Búsqueda digital y contexto

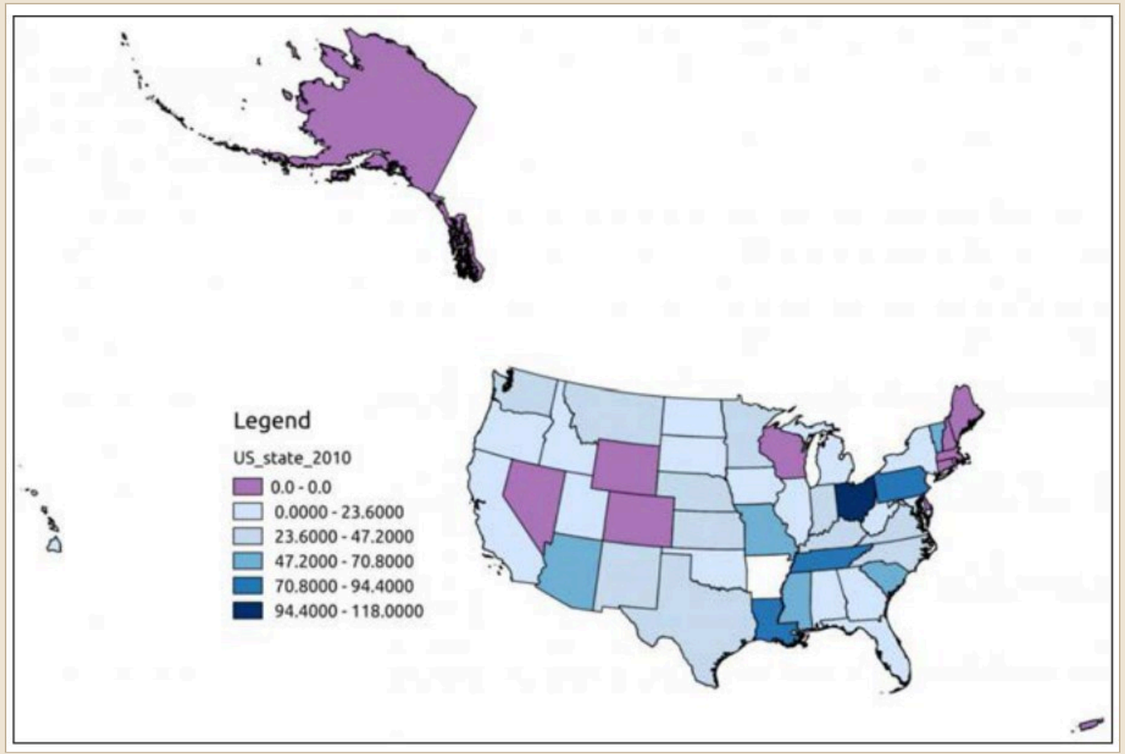


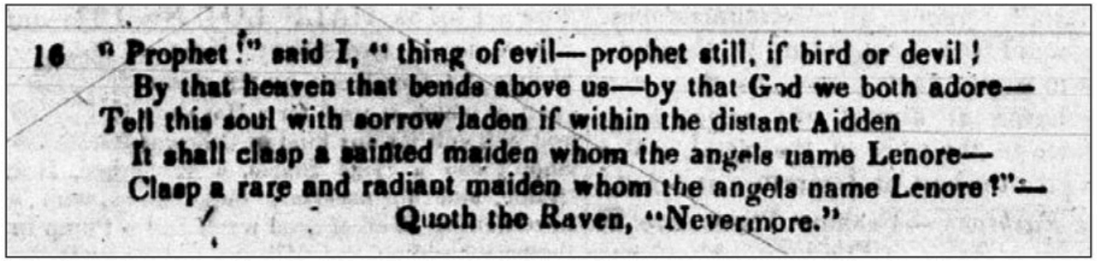
Fig. 6: diarios aportados por cada estado a Chronicling America, 2015 · Cordell (2017), p. 209

PUTNAM (2016)

El buscador permite, por primera vez, **encontrar documentos sin saber de antemano dónde buscarlos**. Eso facilitó seguir personas e ideas entre países, pero **separa el hallazgo del conocimiento del lugar**: llegamos a una mención sin hojear el diario completo, sin saber si el tema era raro o frecuente ni qué otras noticias ocupaban la página.

Además, **lo digitalizado no representa todo lo que se publicó**. La prensa en inglés fue la primera en digitalizarse, y aun dentro de un país la cobertura es desigual. El mapa muestra cuántos diarios aportó cada estado al archivo nacional de prensa digitalizada de Estados Unidos; varios no aportaban ninguno. Cabe preguntarse quiénes quedan en la sombra: la población rural, la que no sabía leer, la que no publicaba.

El texto OCR como objeto bibliográfico



16 " Prophet !" said I, " thing of evil—prophet still, if bird or devil !
By that heaven that bends above us—by that God we both adore—
Tell this soul with sorrow laden if within the distant Aidden
It shall clasp a sainted maiden whom the angels name Lenore—
Clasp a rare and radiant maiden whom the angels name Lenore?"—
Quoth the Raven, "Nevermore."

1 Prophet .'" said I, " thing of evil prophet still, if bird or devil !
By that heaven that bends above us -by that G id we both adore
Tell this soul with sorrow laden if within the distant Aidden
It shall clasp a sainted maiden whom the angels name Lenore
Clasp a rare and radiant maiden whom the angels name Lenore f
Q i-jtb the Raven, "Nevermore.
f 7 "Re that word-our sign of parting, bird or fiend !" I shrieked, upstarting
" Get thee back into the tempest and the Night's Plutonian shore 1
Leave no black- plume as a token of that lie thou hast spoken !
Leave my loneliness unbrokeu ! quit the bust above my door !
Take Ihy beak Irom out my heart, and take thy form from off my doof P'

Figs. 5 y 1: imagen del microfilm (arriba) y texto OCR (abajo) del mismo poema · Cordell (2017), pp. 189, 207

CORDELL (2017)

En 1849 un diario de Pensilvania reimprimió el poema «El cuervo». En el archivo digital, el verso «Quoth the Raven, ‹Nevermore›» aparece como **«Q i-jtb the Raven»**: la tinta irregular del original y el escaneo del microfilm transformaron «Quo» en signos sin sentido. Sin embargo, **los datos técnicos que acompañan al archivo estiman que el texto tiene un 98,2 % de palabras correctas**.

Por eso se propone **tratar estos textos digitales como ediciones nuevas, con su propia historia**: quién hizo el microfilm, quién lo escaneó, con qué programa y con qué criterios se eligieron los diarios. Así, un error de OCR también informa cómo se construyó la fuente que tenemos delante.

Representatividad de las colecciones digitales

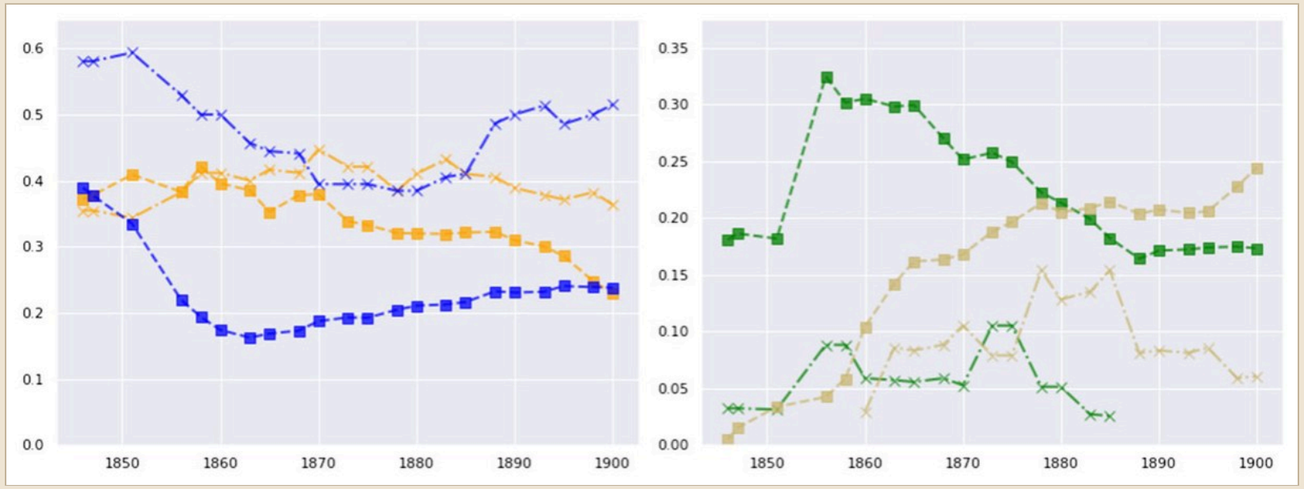


Fig. 6: proporción de diarios por orientación política, colección digital y anuarios de Mitchell · Beelen et al. (2023), p. 12

BEELEN ET AL. (2023)

Un equipo comparó una gran colección digital de diarios provinciales británicos con anuarios de prensa del siglo XIX, que describían cada periódico con su orientación política, su precio y su ciudad. En los gráficos, las cruces corresponden a la colección digital y los cuadrados a los anuarios: a la izquierda, diarios liberales y conservadores; a la derecha, neutrales e independientes.

Al comienzo del período los conservadores son **casi el 60 % de la colección digital, pero el 40 % de los anuarios**. Desde la década de 1860, neutrales e independientes suman cerca del 40 % de la prensa y **apenas el 10 % de lo digitalizado**. También faltan los diarios baratos de lectura masiva. **Este sesgo existe antes de cualquier OCR**: viene de la elección de qué diarios digitalizar.

Calidad del OCR y selección del corpus

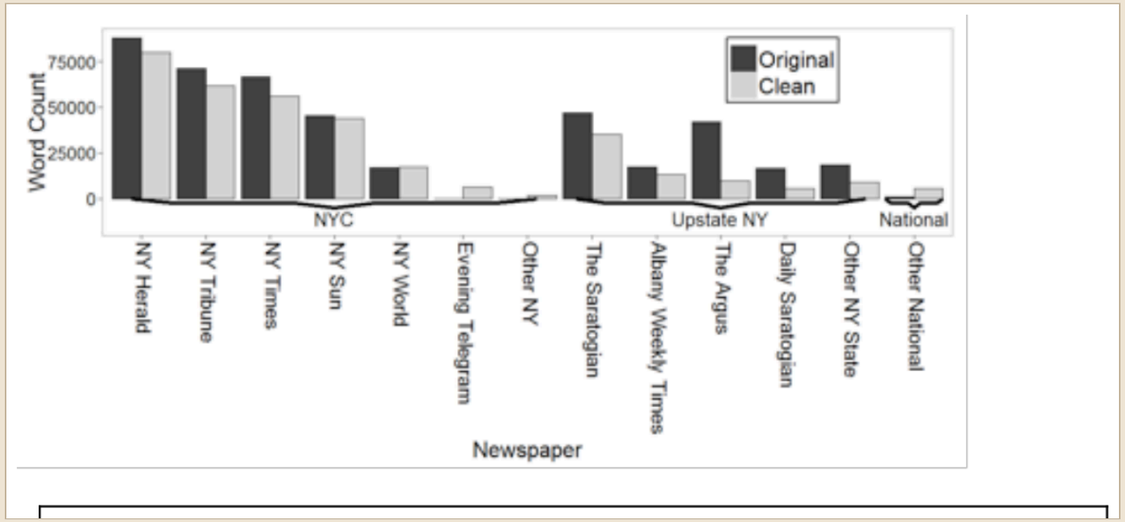


Fig. 2: palabras por diario, texto OCR original (izquierda) y corregido (derecha) · Strange et al. (2014), §§16–17

STRANGE ET AL. (2014)

Un equipo reunió las noticias de prensa sobre un asesinato ocurrido en Nueva York en 1873 para estudiar cómo se habló del caso. **La calidad del texto digital dependía del diario**: en un gran diario de la ciudad, el 94,5 % de las palabras estaba bien leído; en un diario regional, solo el 65 %.

Corregir a mano los textos más dañados exigía demasiado trabajo, así que, en general, **se dejaron afuera los artículos con menos del 80 % de palabras correctas**. Los más afectados fueron los diarios pequeños y regionales. El gráfico muestra cuántas palabras aportó cada diario antes de la corrección (izquierda) y después (derecha). **El corpus final quedó más limpio, pero inclinado hacia los grandes diarios**: un criterio técnico decidió qué voces entraban en el análisis.

Calidad del OCR y conteo de resultados



OCR from the ANNO platform (ÖNB) (*Neue Freie Presse*, 15 October 1938)	Improved OCR with Transkribus (*Neue Freie Presse*, 15 October 1938)
Rückkehr in die befreite Heimat ®onnerStag mittag trafen in IReidhcubcrg bie e r fte n in bie .§cimat zurückgekehrten f5tkrhi^iitgo ein. h®>^bclt sich 16 SJlänner auS bem Sereidt ber @91» ©nippe HUitte (ünagbeburg), bie währenb il)reS 9lufentholte§ unter bem ©d)uhe bcS 9lltreid)e§ oon ber ©ruppc '^»gemiä^ ausgebilbet, oollkommen eingekleibet unb je|t in ihre .^eimat Znrückgeleitet würben. ©mpfang oerfammelte sich bie gesamte ©eoöllterung auf bem iDlarktplah, Wo gegen Sllittag ftnrmweife bie SRäuner mit gepadrtem Tornister, Uoran bic f^ahnc, auf bem 9tbolf»,§itler»ißlah aufmarfdperten.	Rückkehr in die befreite Heimat Donnerstag mittag trafen in Reichenberg die ersten in die Heimat zurückgekehrten Flüchtlinge ein. Es handelt sich um 16 Männer aus dem Bereich der SA= Gruppe Mitte (Magdeburg), die während ihres Aufenthaltes unter dem Schutze des Altreiches von der Gruppe SA=gemäß ausgebildet, vollkommen eingekleidet und jetzt in ihre Heimat zurückgeleitet wurden. Zum Empfang versammelte sich die gesamte Bevölkerung auf dem Marktplatz, wo gegen Mittag sturmweise die Männer mit gepacktem Tornister, voran die Fahne, auf dem Adolf=Hitler=Platz aufmarschierten.

Fig. 6: Neue Freie Presse, 15-X-1938, texto del archivo ANNO y nueva lectura con Transkribus · Oberbichler y Pfanzelter (2022), p. 142

OBERBICHLER Y PFANZELTER (2022)

Un estudio rastreó cómo hablaba la prensa austríaca, entre 1850 y 1950, de las personas que volvían de emigrar, usando el archivo digital de la Biblioteca Nacional de Austria. **La calidad del texto cambiaba mucho entre años y entre diarios, y el buscador no lo advertía**. La figura compara el texto que ofrecía el archivo para un diario de 1938 (izquierda) con el que se obtuvo al leer de nuevo la imagen con otro programa (derecha).

También mostró que **contar resultados puede engañar**. El archivo tiene muchos más diarios de la Primera Guerra Mundial que de la Segunda, así que el tema parecía más frecuente en la primera. Al calcular la proporción sobre las páginas disponibles cada año, **el regreso de emigrantes aparece mucho más en la Segunda Guerra**.

Hemerotecas digitales latinoamericanas



J. Norton como á un instrumento
go del partido tory á que pertenece.
defensor encuentra la prueba de es-
en una multitud de circunstancias
precedieron al proceso, y particu-
mento en que el querellante ha esco-
o por abogado á uno de los gefes de
partido, Sir W. Follett, procurador
eral en el ministerio Peel-Welling.

El fiscal termina su elocuente defen-
que duró cerca de tres horas, anun-
ndo solemnemente en nombre de lord
lbourne que las relaciones de esto
la Sra. Norton no han tenido nada
trario á las buenas costumbres, y lo
rda que persuadido de la bondad de
causa, ha renunciado á hacer oir los
gos en su favor.

Minas, Septiembre 21 de 1836.

El que subscribe tiene el honor de poner en manos de V. E. la adjunta comunicacion del Sr. Cura Vicario de esta Parroquia, para que tenga á bien elevarla al Exmo. Gobierno del Estado, como el Sr. Vicario lo pide.

Dios guarde á V. E. muchos años.

Macedonio Larrosa.

Exmo. Sr. Ministro de Guerra y Marina.

Minas, Septiembre 23 de 1836.

El Cura Vicario de esta parroquia de Minas al fijarse en la nota oficial, que en estos momentos ha tenido el honor de recibir, del Sr. Capitan Comandante del primer Escuadron de la Guardia

grande y justa causa que sostiene el Gobierno de este Estado.

Suplica á V. E. se digne señalarlo una noche en los dias de la semana próxima, para representar una funcion escogida, cuyo producto íntegro se servirá V. E. destinarlo para socorro de las viudas y huerfanos de los dignos heroes: nombrando los sugetos que para dicha noche deban intervenir la recaudacion. En la inteligencia que los gastos que puedan ocurrirse en la espresada exhibicion, tendrá como todos los individuos de la espresada compañia, la grata satisfaccion de abonarlos.

Gracia que espera merecer de la acreditada bondad de V. E.

Juan Antonio Paso.

Defensor de las Leyes (Montevideo), 30-IX-1836 · Biblioteca Nacional de Uruguay · Comesaña y Vilches-Blázquez (2019), fig. 2

COMESAÑA Y VILCHES-BLÁZQUEZ (2019)

Un estudio buscó noticias sobre lluvias, tormentas y otros fenómenos del tiempo en las hemerotecas digitales de Colombia, Ecuador, México y Uruguay: más de 22.500 documentos, de los cuales más de 5.500 eran uruguayos. Al revisar a mano 2.775 noticias encontró que **más del 60 % estaba mal digitalizado** por el deterioro del papel y de la tinta, y que **muchos diarios se habían publicado solo como imagen, sin texto que se pudiera buscar**.

Señala además colecciones incompletas, títulos interrumpidos y, hasta mediados del siglo XIX, diarios sin secciones ni títulos que separen las noticias, como este diario montevideano de 1836. En estas condiciones **la búsqueda por palabra no alcanza**, y parte del trabajo debe hacerse leyendo página por página.

Preguntas para evaluar una colección digitalizada

01 **Qué se digitalizó y qué quedó afuera**: diarios, años, idiomas y regiones, comparados con lo que se publicaba en la época.

02 **De dónde se sacó la imagen**: del diario original o de un microfilm, y con qué calidad se escaneó.

03 **Quién produjo el texto**: con qué programa, en qué fecha y si alguien lo corrigió después.

04 **Cómo cambia la calidad**: según el período, el diario y la sección, incluidos avisos y tablas.

05 **Qué permite el buscador**: frases exactas o aproximadas, conteos en relación con el total, descarga del texto.

06 **Qué significa una búsqueda sin resultados**: qué podemos afirmar y cómo lo comprobamos mirando las imágenes.

Beelen et al. (2023); Burchardt (2023); Cordell (2017); Milligan (2013); Oberbichler y Pfanzelter (2022); Putnam (2016)

II. Modelos y métricas

Cómo funcionan los programas que leen texto, quién los ofrece y cómo se mide cuánto se equivocan.

Breve historia del OCR

01 1912–1913 · Se construye **el optófono**, un aparato que convierte letras impresas en sonidos para personas ciegas.

02 1950–1970 · Aparecen **máquinas lectoras para correos, bancos y oficinas**, preparadas para tipografías y formularios uniformes.

03 1976 · Una máquina lectora combina un escáner, **el reconocimiento de distintas tipografías** y una voz artificial que lee en voz alta.

04 1985–2005 · Se desarrolla **Tesseract**, que en 2005 se libera como programa gratuito y todavía se usa.

05 2006–2018 · Los programas aprenden a **leer renglones completos a partir de ejemplos**, y el método se aplica también a manuscritos.

06 2021–2026 · Llegan **los modelos de inteligencia artificial que miran la página completa** y escriben su transcripción.

Smith, «An Overview of the Tesseract OCR Engine» (2007) · Graves et al. (2006)

OCR tradicional

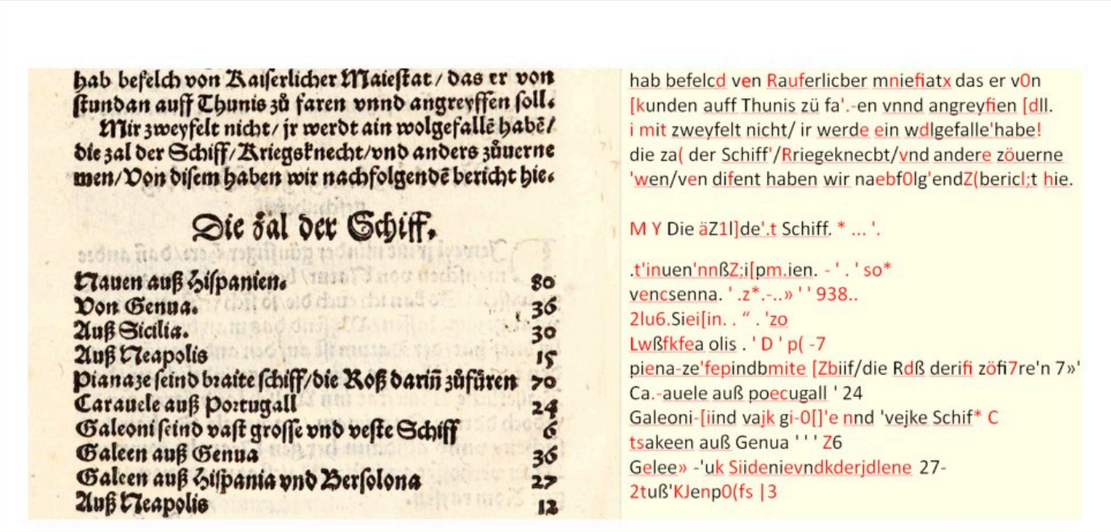


Fig. 1: Newe Zeytung (1535) y el texto producido por el OCR · Burchardt (2023), p. 39

RECONOCIMIENTO LETRA POR LETRA

Los primeros programas separan cada letra de la imagen y **la comparan con un catálogo de letras guardado en su memoria**. Algunos buscan la forma más parecida; otros descomponen la letra en rasgos, como líneas, curvas cerradas y cruces, y eligen la que mejor coincide. Después, un diccionario ayuda a elegir entre las palabras posibles.

Como dependen de separar bien cada letra, **fallan con letras rotas, tipografías poco comunes o columnas mal divididas**. La figura muestra una hoja impresa en 1535 en letra gótica y el texto que produjo el programa: cerca de tres de cada cuatro palabras están mal. **Estos errores suelen ser fáciles de ver**, porque producen palabras inexistentes o grupos de letras sin sentido que cualquier lector detecta.

Burchardt (2023), pp. 39–40

OCR por renglones

CÓMO FUNCIONA

Aprender de ejemplos

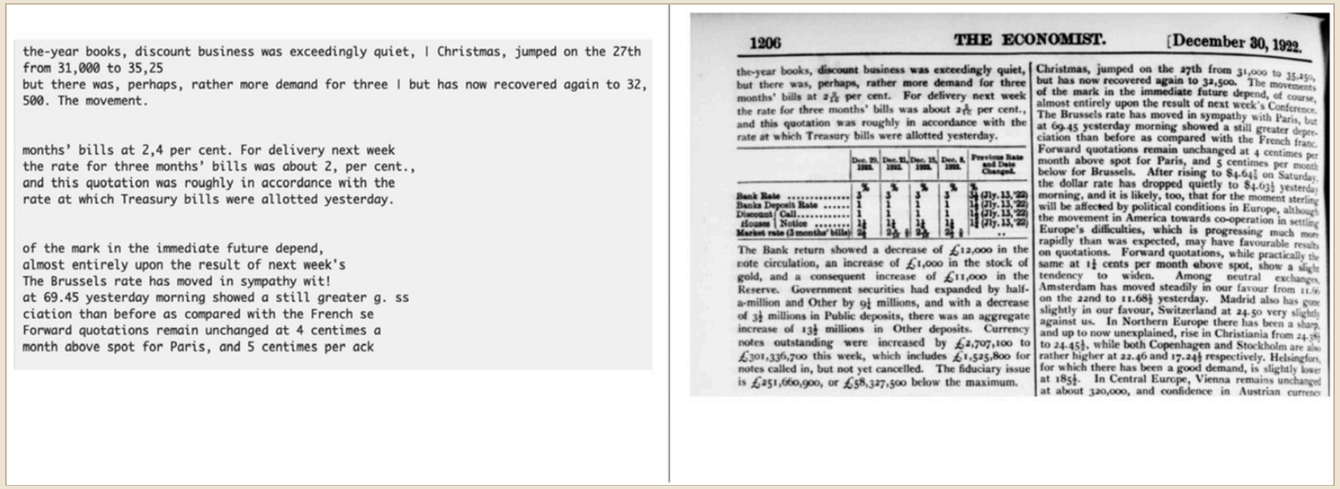
En lugar de separar letra por letra, el programa **mira el renglón entero** y lo lee de izquierda a derecha, como una secuencia. **Aprende a hacerlo a partir de miles de renglones ya transcritos por personas**. Así funcionan las versiones actuales de Tesseract y de Transkribus, este último muy usado para manuscritos.

QUÉ IMPLICA

Adaptable a cada archivo

Se lo puede entrenar con algunas decenas de páginas transcritas de un mismo fondo o de una misma letra para que lea mejor ese material. Funciona en una computadora común. Necesita que la página esté bien dividida en renglones y que haya ejemplos del idioma y de la época.

Análisis del diseño de la página



```
the-year books, discount business was exceedingly quiet, I Christmas, jumped on the 27th
from 31,000 to 35,25
but there was, perhaps, rather more demand for three I but has now recovered again to 32,
500. The movement.


months' bills at 2,4 per cent. For delivery next week
the rate for three months' bills was about 2, per cent.,
and this quotation was roughly in accordance with the
rate at which Treasury bills were allotted yesterday.


of the mark in the immediate future depend,
almost entirely upon the result of next week's
The Brussels rate has moved in sympathy wit!
at 69.45 yesterday morning showed a still greater g. ss
ciation than before as compared with the French se
Forward quotations remain unchanged at 4 centimes a
month above spot for Paris, and 5 centimes per ack
```


the-year books, discount business was exceedingly quiet, but there was, perhaps, rather more demand for three months' bills at 2⅛ per cent. For delivery next week the rate for three months' bills was about 2⅛ per cent., and this quotation was roughly in accordance with the rate at which Treasury bills were allotted yesterday.

	Dec. 29, 1922.	Dec. 22, 1922.	Dec. 15, 1922.	Dec. 8, 1922.	Previous Rate and Date Changed.
	%	%	%	%	%
Bank Rate	3	3	3	3	4 (Jly. 13, '22)
Banks Deposit Rate	1	1	1	1	½ (Jly. 13, '22)
Discount Call	1	1	1	1	½ (Jly. 13, '22)
House Notice	1¼	1¼	1¼	1¼	¾ (Jly. 13, '22)
Market rate (3 months' bills)	2⅛	2⅛	2⅛	2⅛	..

The Bank return showed a decrease of £12,000 in the note circulation, an increase of £1,000 in the stock of gold, and a consequent increase of £11,000 in the Reserve. Government securities had expanded by half-a-million and Other by 9¼ millions, and with a decrease of 3¼ millions in Public deposits, there was an aggregate increase of 13¾ millions in Other deposits. Currency notes outstanding were increased by £2,707,100 to £301,336,700 this week, which includes £1,525,800 for notes called in, but not yet cancelled. The fiduciary issue is £251,660,900, or £58,327,500 below the maximum.

Christmas, jumped on the 27th from 31,000 to 35,250, but has now recovered again to 32,500. The movements of the mark in the immediate future depend, of course, almost entirely upon the result of next week's Conference. The Brussels rate has moved in sympathy with Paris, but at 69.45 yesterday morning showed a still greater depreciation than before as compared with the French franc. Forward quotations remain unchanged at 4 centimes per month above spot for Paris, and 5 centimes per month below for Brussels. After rising to $4.64¼ on Saturday the dollar rate has dropped quietly to $4.63¾ yesterday morning, and it is likely, too, that for the moment sterling will be affected by political conditions in Europe, although the movement in America towards co-operation in settling Europe's difficulties, which is progressing much more rapidly than was expected, may have favourable results on quotations. Forward quotations, while practically the same at 1¼ cents per month above spot, show a slight tendency to widen. Among neutral exchanges, Amsterdam has moved steadily in our favour from 11.56 on the 22nd to 11.68½ yesterday. Madrid also has gone slightly in our favour, Switzerland at 24.50 very slightly against us. In Northern Europe there has been a sharp, and up to now unexplained, rise in Christiania from 24.36 to 24.45½, while both Copenhagen and Stockholm are also rather higher at 22.46 and 17.24½ respectively. Helsingfors, for which there has been a good demand, is slightly lower at 18.85. In Central Europe, Vienna remains unchanged at about 320,000, and confidence in Austrian currency

Fig. 3: texto OCR (izquierda) de The Economist, 30-XII-1922 (derecha) · Internet Archive · Milligan (2022), p. 29

EL DISEÑO DE LA PÁGINA

Antes de reconocer letras, el programa tiene que entender cómo está armada la página: dónde hay títulos, columnas, imágenes, tablas y avisos, y en qué orden se leen. A esta etapa se la llama análisis del diseño de la página (en inglés, layout). **Si falla, el programa puede reconocer bien cada letra y aun así producir un texto inservible**.

En el ejemplo, una página de una revista de 1922 a dos columnas se leyó como si cada renglón cruzara toda la página, y **el resultado mezcla frases de ambas columnas**. En la prensa histórica el problema es mayor: columnas angostas, avisos, tablas y notas que continúan en otra página. Por eso muchos proyectos **primero recortan la página en bloques y después leen el texto de cada uno**.

Modelos de visión y lenguaje

> Los modelos de visión y lenguaje son programas de inteligencia artificial, como Gemini, Claude o GPT, que reciben una imagen y escriben un texto. No reconocen letra por letra: **miran la página completa y escriben, palabra tras palabra, lo que les parece más probable**. Por eso leen mejor los textos difíciles, pero también **pueden completar, «corregir» o inventar texto que suena correcto**.

Rasgo	OCR tradicional	Modelo de visión y lenguaje
Cómo lee	Separa y compara letras o renglones	Mira la página entera y escribe el texto
Qué tiene en cuenta	La forma de cada letra y un diccionario	La imagen y el sentido de lo que va escribiendo
Error típico	Visible: letras sueltas o palabras sin sentido	Difícil de ver: palabras reales pero equivocadas, omisiones, repeticiones
Qué necesita	Una computadora común	Una computadora muy potente o un servicio pago por internet
Qué más puede hacer	Solo texto	Leer tablas, respetar la estructura y extraer datos

Tipos de sistemas

> Los sistemas se distinguen por cómo funcionan y por cómo se accede a ellos. Algunos son **servicios pagos de empresas**, a los que se envían las imágenes por internet; otros son **programas abiertos**, que se descargan gratis y se usan en una computadora propia.

Tipo	Ejemplos	Cómo se usa	Riesgo principal
OCR tradicional	Tesseract, docTR, EasyOCR, Kraken	Gratis, en cualquier computadora	Muchos errores, pero visibles
Servicios de OCR de empresas	Amazon Textract, Google Document AI	Pago por uso, por internet	No se sabe cómo funcionan; las imágenes salen del archivo
Plataformas para manuscritos	Transkribus	En línea, con créditos	Depende de que exista un modelo para esa letra
Modelos abiertos para documentos	olmOCR, dots.mocr, Chandra, LightOnOCR	Gratis, en una computadora potente	Repeticiones en tablas; palabras cambiadas
Modelos abiertos generales	Qwen2.5-VL, Qwen3-VL	Gratis, en una computadora potente	Modernizan la ortografía; repeticiones
Modelos para fuentes antiguas	Churro	Gratis, en una computadora potente	Rinde según lo que vio al entrenarse
Modelos comerciales generales	Gemini, Claude, GPT	Pago por uso, por internet	Errores creíbles; versiones que cambian

Servicios pagos y programas abiertos

SERVICIOS DE EMPRESAS

Se usan por internet

Hoy son, en general, los más precisos. Se paga por página, **hay que enviar las imágenes a la empresa** y el servicio puede cambiar sin aviso: un estudio procesó los mismos documentos durante siete días seguidos y obtuvo resultados distintos según el día. Si el archivo tiene datos personales o acceso restringido, **enviar las imágenes puede no estar permitido**.

PROGRAMAS ABIERTOS

Se usan en una computadora propia

Se descargan gratis y **funcionan sin enviar nada fuera de la institución**; además, la versión usada queda fija y puede citarse. A cambio, necesitan una computadora con una placa gráfica potente, alguien que los instale y supervisión. Su falla más común es **quedar «trabados» repitiendo la misma frase** en tablas o páginas muy dañadas.

CER y WER

CARACTERES

CER: tasa de error de caracteres

Se compara el texto del programa con una transcripción hecha por personas, que se toma como correcta: **la referencia**. Se cuentan **las letras cambiadas, faltantes o sobrantes** y se divide por el total de letras de la referencia. Ejemplo: «La casa roja» leído como «La cosa roja» tiene 1 letra mal en 12 caracteres (contando espacios): 8,3 %.

PALABRAS

WER: tasa de error de palabras

Es la misma cuenta hecha con palabras: **basta una letra mal para que la palabra entera cuente como error**. En el ejemplo, 1 palabra mal en 3: 33,3 %.
Antes de calcular hay que decidir cómo se tratan las mayúsculas, los acentos, la puntuación y las palabras cortadas al final del renglón.

Límites de las tasas de error



Fig. 1: tipos de error de dos programas sobre impresos del siglo XVIII · Vesalainen et al. (2026), p. 11

VESALAINEN ET AL. (2026)

Una tasa de error cuenta diferencias, pero **no dice cuáles importan**. Cambiar la fecha «30ABR84» por «20ABR84» cuenta como un solo carácter, igual que equivocar una letra de un adjetivo, aunque la consecuencia para la investigación sea mucho mayor. Un estudio comparó dos programas sobre libros ingleses del siglo XVIII y concluyó que **dos sistemas con el mismo puntaje pueden equivocarse de maneras muy distintas**.

Por eso conviene separar los errores que producen palabras inexistentes, fáciles de detectar, de los que producen palabras reales y pasan inadvertidos. También importa cómo se resume el error. **La mediana describe la página típica**: la que queda en el medio al ordenar todas de mejor a peor. **El error total** suma todos los errores sobre todas las letras y muestra, además, las páginas en que el programa fracasó por completo.

Transcripción diplomática y normalizada

id	
2759	Potatoes, au gratin
7176	Potatoes au Gratin
8373	Potatoes--Au gratin
35728	Potatoes: au gratin
44271	Au Gratin Potatoes
84510	Au Gratin (Potatoes)
94968	Potatoes, au Gratin,
97166	POTATOES:- Au gratin
185040	Au Gratin [potatoes]
313168	Au Gratin Potatoes
315697	(Potatoes) Au Gratin
325940	Au Gratin Potatoes
330420	au-Gratin Potatoes
353435	Potatoes: Au gratin
373639	Potatoes Au Gratin

Variantes de «Potatoes au gratin» en What’s on the Menu? · New York Public Library (menus.nypl.org)

RAWSON Y MUÑOZ (2019)

Para medir el error hace falta una transcripción de referencia, y esa transcripción sigue reglas. Una **transcripción diplomática** copia el documento tal como está, con su ortografía de época, sus abreviaturas y sus erratas. Una **transcripción normalizada** unifica mayúsculas, acentos o formas antiguas para facilitar la búsqueda. **Las dos son válidas, pero miden cosas distintas**, y el mismo programa puede salir mejor o peor según cuál se use.

Un proyecto sobre una colección de menús de restaurantes de Nueva York encontró un mismo plato escrito de decenas de maneras, como muestra la lista. **Unificarlas facilita contar, pero borra información** sobre quién escribía y cómo. Antes de medir o de limpiar un texto conviene decidir qué diferencias queremos conservar.

Clasificar los cambios por su efecto

> Un estudio reciente advierte que un texto corregido por inteligencia artificial **puede leerse bien y, sin embargo, decir otra cosa que la fuente**. Propone medir si el modelo cambia texto que estaba bien, si conserva la ortografía de época y si agrega contenido que no está en el documento. En la discusión del trabajo se sugirió clasificar cada cambio por su efecto, como en estos ejemplos en alemán antiguo.

> **Infiel**: conserva el sentido pero cambia la forma histórica. **Dañino**: cambia palabras, números o nombres, o agrega texto.

Tipo de cambio	Lectura del OCR	Texto original	Corrección del modelo	Efecto
Corrección	Laud	Land	Land	Mejora
Modernización	Thür, ſeyn	Thür, ſeyn	Tür, sein	Infiel
Paráfrasis	allwo er ſtarb	allwo er ſtarb	wo er starb	Infiel
Palabra real equivocada	Wcin	Wein	Bein	Dañino
Número cambiado	1o00	1000	100	Dañino
Nombre alterado	Schmidt	Schmidt	Schmitt	Dañino
Texto agregado	…der König von	…der König von	…der König von Preußen	Dañino

Alucinaciones

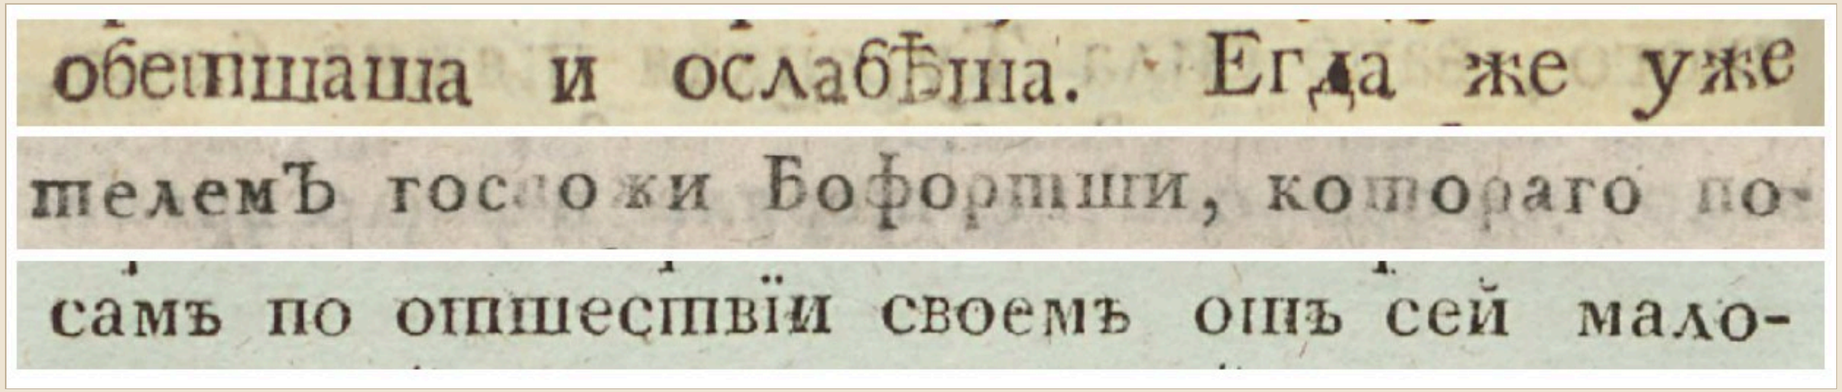


Fig. 4: libro ruso del siglo XVIII en tipografía civil · Levchenko (2025), p. 8

LEVCHENKO (2025)

Se llama **alucinación al texto que un modelo de inteligencia artificial escribe con seguridad aunque no esté en la fuente**. Un estudio probó doce de estos modelos sobre 1.029 páginas de libros rusos del siglo XVIII y creó dos medidas: cuántas letras propias de esa época conserva cada modelo, y cuántas letras todavía más antiguas, que ya no se usaban, agrega por su cuenta. Encontró que **los modelos «envejecían» el texto**: en lugar de modernizarlo, le ponían letras de siglos anteriores.

La imagen muestra por qué la tarea es difícil: en esa tipografía la letra ш a veces se parece a т. Otros estudios registran el problema inverso: los modelos **«corrigen» entre el 27 % y el 59 % de las erratas del original**, algo que los programas tradicionales no hacen. En los dos casos **el texto resultante deja de ser fiel al documento**.

Medidas de fidelidad

01 **Palabras exactas**: qué proporción de las palabras del documento quedó igual.

02 **Omisiones**: palabras legibles que el programa dejó afuera.

03 **Texto inventado**: frases que aparecen en el resultado pero no en la imagen.

04 **Números cambiados**: cifras y fechas alteradas, contadas aparte por su importancia.

05 **Palabras reemplazadas**: una palabra real cambiada por otra también real, el error más difícil de ver.

06 **Erratas corregidas**: errores del documento que el programa «arregló» sin que se lo pidieran.

07 **Nombres y cifras exactos**: personas, lugares, siglas y números sin ningún error.

08 **Fallas graves**: páginas en que el programa repitió la misma frase sin parar o erró más de la mitad del texto.

Boros (2026); Levchenko (2025); Vesalainen et al. (2026)

III. PortADa y pruebas con 12 modelos

Un proyecto de datos portuarios y una prueba propia sobre documentos mecanografiados, manuscritos, prensa e impresos.

El proyecto PortADa



Port of Buenos Ayres

ARRIVALS.

DECEMBER 5TH.

Constitucion, National steamer, S. Fidan- za, from Montevideo 4th inst., with 10 bar- rels brandy, 20 boxes wine, 25 stones, 50 bundles brooms, 42 do spades, 937 bags fariña, 15 boxes axes, 7 do, 196 packages and 1 barrel merchandise. Passengers 104.

Port of Buenos Ayres

ARRIVALS.

DECEMBER 5TH.

Constitucion, National steamer, S. Fidan- za, from Montevideo 4th inst., with 10 bar- rels brandy, 20 boxes wine, 25 stones, 50 bundles brooms, 42 do spades, 937 bags fariña, 15 boxes axes, 7 do, 196 packages and 1 barrel merchandise. Passengers 104.

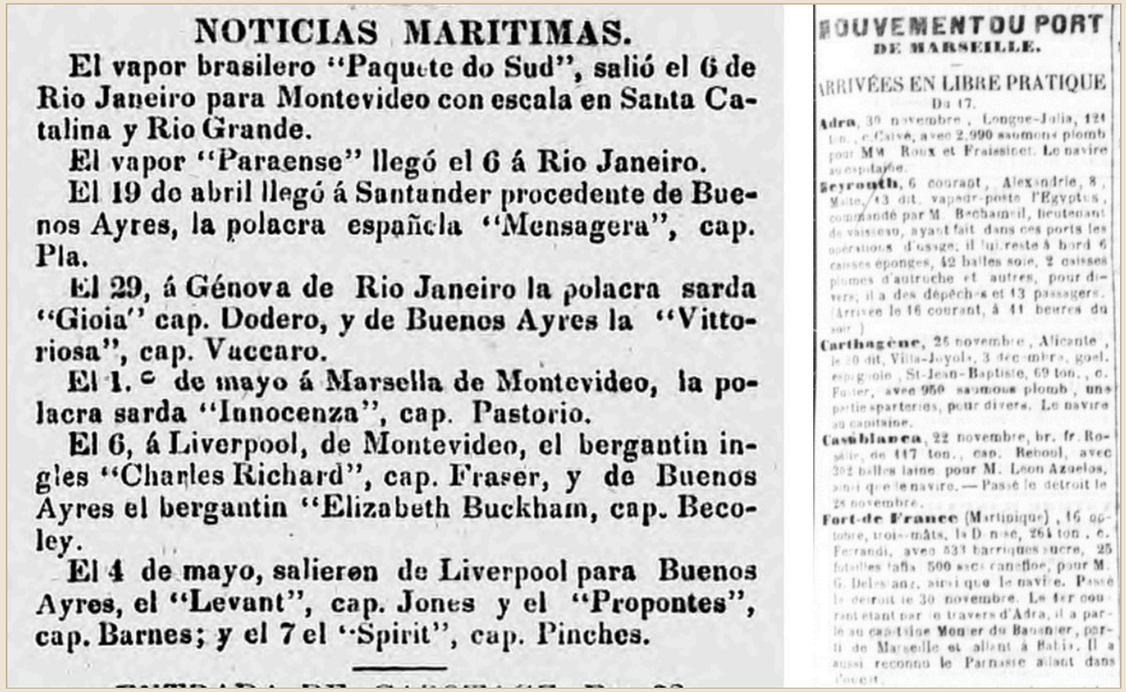
The British Packet, and Argentine News (Buenos Aires): «Port of Buenos Ayres. Arrivals» y su transcripción · Transcripción del equipo PortADa

PORT ARRIVALS DATA

PortADa es un proyecto financiado por la Unión Europea que trabaja con **las noticias diarias en que la prensa de grandes puertos informaba qué barcos habían llegado**. Con ellas busca reconstruir el tráfico marítimo del siglo XIX, cuando la navegación a vela fue reemplazada por el vapor. El objetivo es **pasar esas noticias a tablas con los mismos datos para todos los puertos**: fechas de salida y de llegada, origen y escalas, tipo, nombre, tamaño y bandera del barco, capitán, carga y motivo de la llegada.

Solo para Buenos Aires, entre 1850 y 1910, se calculan **unas 22.000 noticias**, una por día durante sesenta años, y el proyecto estima reunir **unos 350.000 registros**. Como la prensa argentina de ese período está poco y mal digitalizada, primero hubo que conseguir buenas imágenes y después leerlas con OCR.

Prueba de 2024



NOTICIAS MARITIMAS.

El vapor brasilero "Paquete do Sud", salió el 6 de Rio Janeiro para Montevideo con escala en Santa Catalina y Rio Grande.

El vapor "Paraense" llegó el 6 á Rio Janeiro.

El 19 de abril llegó á Santander procedente de Buenos Ayres, la polacra española "Mensagera", cap. Pla.

El 29, á Génova de Rio Janeiro la polacra sarda "Gioia" cap. Dodero, y de Buenos Ayres la "Vittoriosa", cap. Vaccaro.

El 1.º de mayo á Marsella de Montevideo, la polacra sarda "Innocenza", cap. Pastorio.

El 6, á Liverpool, de Montevideo, el bergantin ingles "Charles Richard", cap. Fraser, y de Buenos Ayres el bergantin "Elizabeth Buckham, cap. Becoley.

El 4 de mayo, salieron de Liverpool para Buenos Ayres, el "Levant", cap. Jones y el "Propontes", cap. Barnes; y el 7 el "Spirit", cap. Pinches.

MOUVEMENT DU PORT DE MARSEILLE.

ARRIVÉES EN LIBRE PRATIQUE Du 17.

Adra, 30 novembre, Longue-Julia, 124 ton., c. Caivé, avec 2,990 saumons plomb pour M.M. Roux et Fraissinet. Le navire au capitaine.

Beyrouth, 6 courant, Alexandrie, 8, Malte, 13 dit, vapeur-poste l'Egyptus, commandé par M. Bechameil, lieutenant de vaisseau, ayant fait dans ces ports les opérations d'usage; il lui reste à bord 6 caisses éponges, 42 balles soie, 2 caisses plumes d'autruche et autres, pour divers; il a des dépêches et 13 passagers. (Arrivée le 16 courant, à 11 heures du soir.)

Carthagène, 25 novembre, Alicante, le 30 dit, Villa-Joyosa, 3 décembre, goel. espagnole, St-Jean-Baptiste, 69 ton., c. Fortier, avec 950 saumons plomb, une partie sparteries, pour divers. Le navire au capitaine.

Casablanca, 22 novembre, br. fr. Rosalie, de 117 ton., cap. Reboul, avec 202 balles laine pour M. Léon Azuelos, ainsi que le navire. — Passé le détroit le 28 novembre.

Fort-de-France (Martinique), 16 octobre, trois-mâts, la Danoise, 264 ton., c. Ferrandi, avec 531 barriques sucre, 25 futailles taffia, 500 sacs cassonade, pour M. G. Delessart, ainsi que le navire. Passé le détroit le 30 novembre. Le fer courant étant par le travers d'Adra, il a parlé au capitaine Monnier du Baounier, parti de Marseille et allant à Bahia. Il a aussi reconnu le Parnasse allant dans l'ouest.

El Federal (Buenos Aires) y Le Sémaphore de Marseille, mediados del siglo XIX · Recorte del equipo PortADa

PRUEBA DE 2024

En 2024 el equipo comparó seis programas sobre dos noticias de puerto de mediados del siglo XIX, en dos idiomas: una de un diario de Buenos Aires, **completamente legible**, y otra de un diario de Marsella, **con una imagen muy borrosa**. Se probaron tres programas gratuitos (EasyOCR, Tesseract y Transkribus) y tres servicios de empresas (Amazon Textract, Google Document AI y el OCR de Google Drive).

Para cada recorte se preparó una transcripción correcta, revisando a mano el texto de uno de los programas, y se midió el error de cada uno. Era una prueba pequeña, pero mostró algo que se repitió después: **con una imagen de mala calidad, las diferencias entre programas se agrandan mucho**.

Resultados de la prueba de 2024

> Porcentaje de caracteres y de palabras mal leídos; cuanto menor, mejor. **Los servicios de empresas fueron los más precisos en los dos recortes**. Con la imagen borrosa, Transkribus pasó de 8 % a 63 % de caracteres mal leídos y EasyOCR casi no reconoció palabras. Como la transcripción correcta se armó a partir del texto de Google Document AI, la prueba puede favorecer a ese programa.

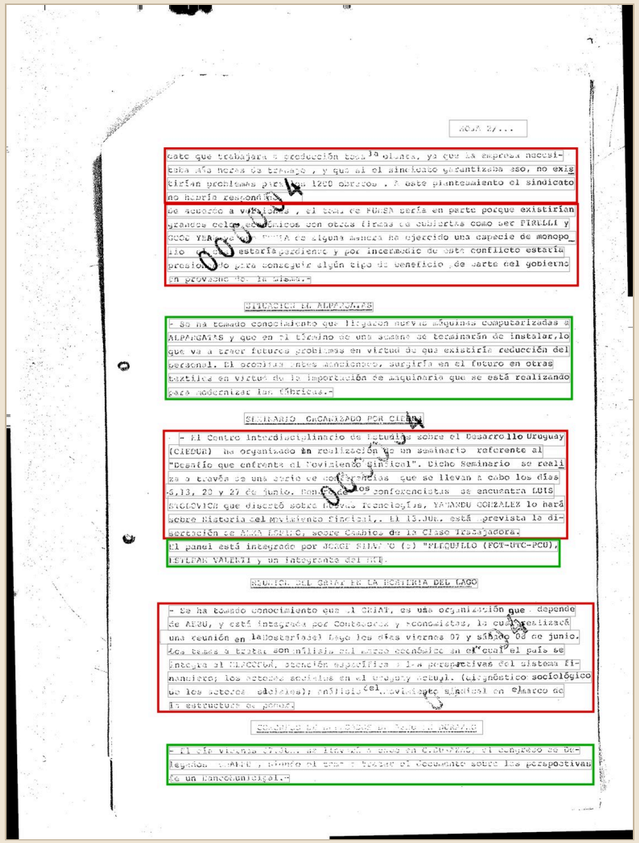
Programa	Recorte legible · caracteres	Recorte legible · palabras	Recorte borroso · caracteres	Recorte borroso · palabras
EasyOCR	9,23	24,11	72,77	96,46
Tesseract	7,61	14,18	19,35	52,21
Transkribus	8,23	12,77	62,84	82,74
Amazon Textract	0,87	3,55	12,58	34,51
Google Document AI	0,75	3,55	6,92	25,22
Google Drive	0,12	0,71	6,33	23,45

Diseño de la comparación de 2026

> En 2026 se hicieron **pruebas con 12 modelos sobre 151 fragmentos de cuatro tipos de documento**: tres servicios de empresas que se usan pagando por internet (Gemini, Claude y GPT), siete modelos abiertos instalados en una computadora propia y dos programas tradicionales (docTR y Tesseract). En cada caso se comparó el resultado con una transcripción hecha por personas.

Prueba	Cantidad	De dónde viene	Qué la hace difícil
Mecanografiados	55 párrafos de 10 páginas	Archivo Berrutti, copias de microfilm	Copias gastadas; nombres y fechas
Manuscritos	30 páginas	Colección pública de manuscritos en español, siglos XV a XIX	Letra a mano; abreviaturas
Prensa	46 recortes	PortADa, diarios de 1851 a 1910	Columnas angostas; tablas; letra gastada
Impresos	20 páginas de una columna	Colección pública de impresos en español, siglos XVI a XIX	Tipografías antiguas

Mecanografiados: archivo Berrutti



Página de baja calidad del conjunto Berrutti · OCR Berrutti Dataset v3 · licencia CC BY-NC-SA 4.0

PRUEBA 1

El conjunto de datos Berrutti reúne 175 páginas mecanografiadas de los años setenta y ochenta, del período de la dictadura uruguaya, conocidas a través de copias en microfilm y transcritas por completo. Para la prueba se eligieron 10 páginas de calidad alta, media y baja, divididas en 55 párrafos. En la imagen, los recuadros verdes marcan los párrafos usados y los rojos los descartados, porque tienen números o anotaciones a mano encima del texto.

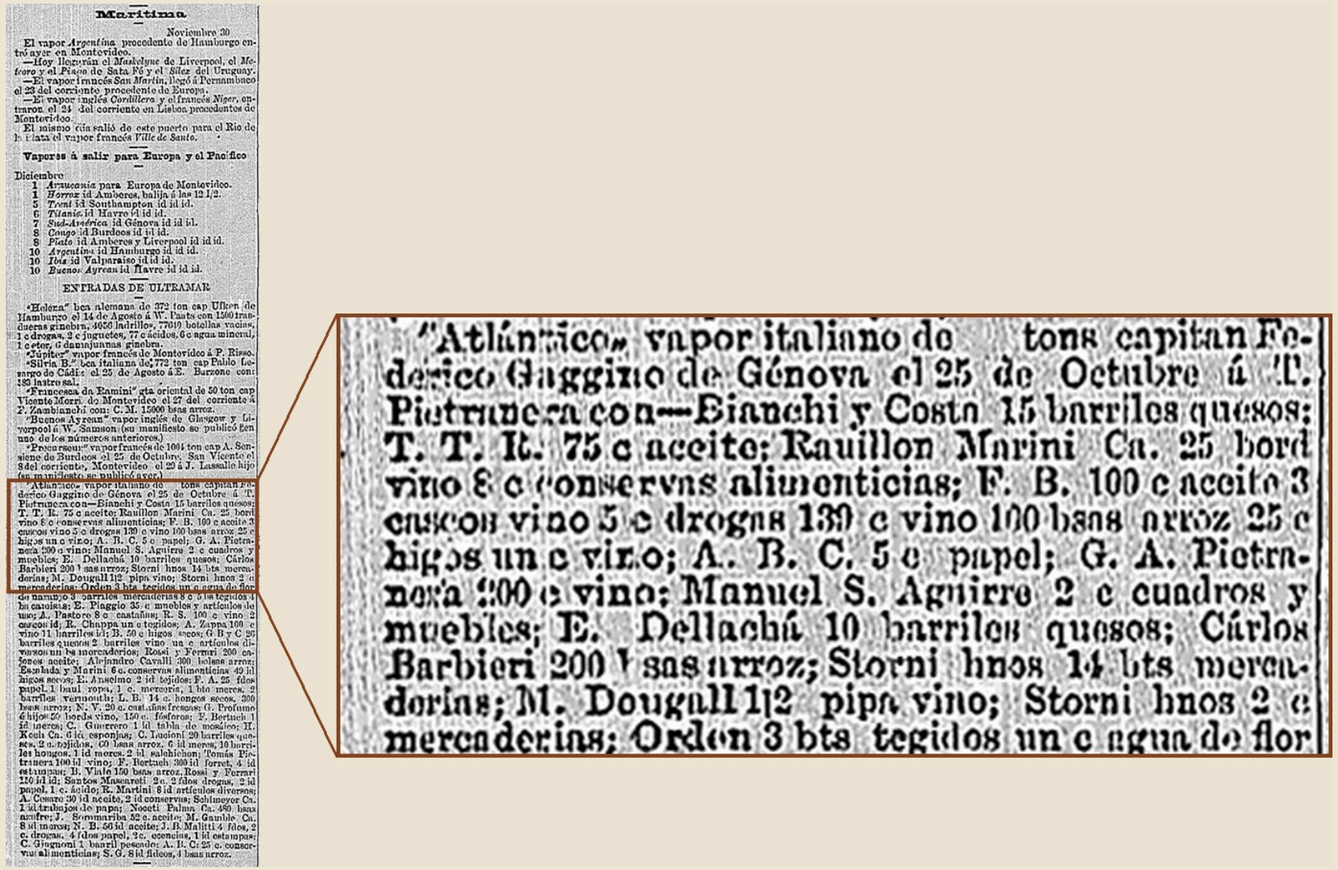
Los tres servicios de empresas se equivocaron **en menos de 6 de cada 1.000 letras**: Gemini, 0,15 %; Claude, 0,33 %; GPT, 0,57 %. Los mejores modelos abiertos quedaron cerca del 1 %, y los programas tradicionales, entre 7 % y 14 %. **Casi todo el error se concentra en las páginas más dañadas**: en las de buena calidad, los mejores sistemas no llegan a equivocarse en 1 de cada 1.000 letras.

Resultados generales

> Cada modelo recibió dos posiciones en cada prueba: una por su página típica y otra por su error total. **El puntaje es el promedio de esas ocho posiciones: cuanto más bajo, mejor**. Las columnas de cada prueba muestran el porcentaje de caracteres mal leídos. Fallas graves: páginas en que el modelo se trabó repitiendo texto o erró más de la mitad. El costo de los modelos abiertos incluye solo la electricidad.

#	Modelo	Tipo	Puntaje	Mecanogr.	Manuscr.	Prensa	Impresos	Fallas graves	US$ cada 1.000 págs.
1	Gemini 4 Argon	Empresa	1,1	0,15	5,8	0,37	0,75	1	6,29
2	Claude Opus 5.5	Empresa	2,0	0,33	6,2	0,44	0,67	1	20,27
3	GPT-6 Astra	Empresa	3,8	0,57	9,3	1,43	0,83	4	48,61
4	Churro-3B	Abierto · antiguo	5,6	2,14	8,9	1,50	0,92	3	0,13
5	LightOnOCR-3-4B	Abierto · documentos	5,9	0,99	13,8	1,75	1,23	4	0,07
6	Qwen3-VL-8B	Abierto · general	7,1	1,05	19,4	1,22	0,96	10	0,21
7	dots.mocr	Abierto · documentos	7,4	1,32	17,6	1,19	1,02	6	0,05
8	Chandra OCR 2	Abierto · documentos	7,6	1,14	19,8	1,44	2,34	4	0,12
9	Qwen2.5-VL-7B	Abierto · general	7,9	1,14	20,6	2,04	1,08	5	0,11
9	olmOCR 2	Abierto · documentos	7,9	1,23	17,8	1,60	1,46	5	0,08
11	docTR	Tradicional	10,4	7,39	63,1	9,82	5,68	30	0
12	Tesseract 5.5	Tradicional	11,4	14,37	77,0	17,08	8,27	41	0

Prensa: secciones marítimas



Marítima.

Noviembre 30

El vapor *Argentina* procedente de Hamburgo entró ayer en Montevideo.

—Hoy llegarán el *Maskelyne* de Liverpool, el *Motore* y el *Piata* de Sata Fé y el *Siler* del Uruguay.

—El vapor francés *San Martin*, llegó á Pernambuco el 23 del corriente procedente de Europa.

—El vapor inglés *Cordillera* y el francés *Niger*, entraron el 24 del corriente en Lisboa procedentes de Montevideo.

El mismo dia salió de este puerto para el Rio de la Plata el vapor francés *Ville de Santo*.

Vapores á salir para Europa y el Pacífico

Diciembre

1 *Araucania* para Europa de Montevideo.
1 *Horror* id Amberes, balija á las 12 1/2.
5 *Trent* id Southampton id id id.
6 *Titanic* id Havre id id id.
7 *Sud-America* id Génova id id id.
8 *Congo* id Burdeos id id id.
8 *Piata* id Amberes y Liverpool id id id.
10 *Argentina* id Hamburgo id id id.
10 *Ibis* id Valparaiso id id id.
10 *Buenos Ayreas* id Havre id id id.

ENTRADAS DE ULTRAMAR

"Holcza" bca alemana de 372 ton cap Ulken de Hamburgo el 14 de Agosto á W. Pants con 1560 trabuceros ginebra, 4656 ladrillos, 7709 botellas vacias, 1 c drogas, 2 c juguetes, 77 c ácidos, 6 c aguas mineral, 1 c eter, 6 damajuanas ginebra.

"Pirifor" vapor francés de Montevideo á P. Risso.

"Silvia B." bca italiana de, 772 ton cap Pablo Lesargo de Cádiz el 25 de Agosto á E. Barzone con 183 lastre sal.

"Francesca da Ramini" gta oriental de 50 ton cap Vicente Morri de Montevideo el 27 del corriente á P. Zambianchi con C. M. 15000 hoja arroz.

"Buenos Ayreas" vapor inglés de Glasgow y Liverpool á W. Samson (su manifiesto se publicó en uno de los números anteriores.)

"Presidente" vapor francés de 1064 ton cap A. Seniene de Burdeos el 25 de Octubre, San Vicente el 3del corriente, Montevideo el 29 á J. Lasalle hijo (su manifiesto se publicó ayer)

"Atlántico» vapor italiano de tons capitan Federico Gaggino de Génova el 25 de Octubre á T. Pietrnera con—Bianchi y Costa 15 barriles quesos; T. T. L. 75 c aceite; Rauillon Marini Ca. 25 bord vino 8 c conservas alimenticias; F. B. 100 c aceite 3 cascon vino 5 c drogas 139 c vino 100 bsas arroz 25 c higos un c vino; A. B. C. 5 c papel; G. A. Pietrnera 200 c vino; Manuel S. Aguirre 2 c cuadros y muebles; E. Dellachá 10 barriles quesos; Cárlos Barbieri 200 bsas arroz; Storni hnos 14 bts mercaderias; M. Dougall 1/2 pipa vino; Storni hnos 2 c mercaderias; Orden 3 bts tegidos un c agua de flor de naranjo 3 barrica mercaderias 8 c s/a tegidos 4 bs canelas; E. Piaggio 35 c muebles y articulos de uso; A. Pastoro 8 c castañas; R. S. 100 c vino 2 cascon id; R. Chappa un c tegidos; A. Zappa 108 c vino 11 barriles id; B. 50 c higos secos; G. B y C 20 barriles quesos 2 barriles vino un c articulos diversos un bs mercaderias; Rossi y Ferrari 200 cajones aceite; Alejandro Cavalli 200 bolsas arroz; Escalada y Marini 6 c conservas alimenticias 49 bl higos secos; L. Anselmo 2 id tejidos; F. A. 25 fdos papel, 1 baul ropa, 1 c. mercerie, 1 bto mueres, 2 barriles vermouth; L. B. 14 c. hongos secos, 200 bsas arroz; N. V. 20 c. esencias frenos; G. Profumo 6 bijo 50 botls vino, 150 c. fósforos; E. Bertsch 1 id muebles; C. Guerrero 1 id. tabla de mosáico; H. Keels Ca. 6 ic esponjas; C. Iusioni 20 barriles quesos 2 c. tejidos, 60 bsas arroz, 6 id muebles, 10 barriles hongos, 1 id muebles, 2 id. salchichon; Tomás Pietranera 100 bl vino; F. Bertsch 300 bl fornet, 4 id estampas; B. Viale 150 bsas arroz, Rossi y Ferrari 120 id id; Santos Masenreti 2 c. 2 fdos drogas, 2 id papel, 1 c. ácido; R. Martini 8 id artículos diversos; A. Cesare 20 id aceite, 2 id conservas; Schlumerer Ca. 1 id trabajos de papa; Nocetti Palma Ca. 480 bsas arroz; J. Soromariba 52 c. aceite; M. Gamba Ca. 8 id muebles; N. B. 60 id aceite; J. B. Mallitt 4 fdos, 2 c. drogas, 4 fdos papel, 2 c. esencias, 1 id estampas; C. Gigneni 1 barril posudo; A. H. C. 25 c. conservas id mentidas; S. G. 8 id fideos, 4 bsas arroz.

"Atlántico» vapor italiano de tons capitan Federico Gaggino de Génova el 25 de Octubre á T. Pietrnera con—Bianchi y Costa 15 barriles quesos; T. T. L. 75 c aceite; Rauillon Marini Ca. 25 bord vino 8 c conservas alimenticias; F. B. 100 c aceite 3 cascon vino 5 c drogas 139 c vino 100 bsas arroz 25 c higos un c vino; A. B. C. 5 c papel; G. A. Pietrnera 200 c vino; Manuel S. Aguirre 2 c cuadros y muebles; E. Dellachá 10 barriles quesos; Cárlos Barbieri 200 bsas arroz; Storni hnos 14 bts mercaderias; M. Dougall 1/2 pipa vino; Storni hnos 2 c mercaderias; Orden 3 bts tegidos un c agua de flor

La Nación (Buenos Aires), 1-XII-1880, p. 2, sección marítima: columna completa y párrafo ampliado · Recorte del equipo PortADa

PRUEBA 3

La prueba de prensa usó 46 recortes de las secciones marítimas de diarios de Buenos Aires, Montevideo y Barcelona publicados entre 1851 y 1910. En la página típica, **Gemini y Claude se equivocaron en menos de 5 de cada 1.000 letras**, entre tres y cuatro veces menos que el mejor modelo abierto.

A la izquierda, la columna completa de un diario porteño de 1880; a la derecha, un párrafo ampliado, donde se ven **letras rotas, manchas y un dato en blanco**. Las listas en forma de tabla de 1880 **fueron el punto débil de los modelos abiertos**: dos se trabaron repitiendo renglones, y en esta misma página uno de ellos escribió casi cuatro veces más texto que el original. Así, **la mayoría de las páginas sale bien, pero unas pocas fallan por completo**.

Corrección de la transcripción de referencia



¡Viva la Confederacion Argentina!
¡Mueran los salvages asquerosos unitarios!
¡Muera el loco traidor salvage unitario Urquiza!

Capitania del Puerto——

Relacion de los buques que han entrado al Puerto el dia de la fecha, con expresion de sus toneladas, cargamentos, procedencias y consignatarios.

NACIONALES.

Balandra Bella Sestrina, de 15 toneladas, patron B. Ragio, de Santa Fé el 20 del pasado, con 137 fanegas carbon; al patron.

Goleta San José Ytati, p. L. Soleci, de Goya el 15 del pasado y del Paraná el 8 del corriente, con 1,164 cueros vacunos secos, 8 chiguas lana, 200 quesos, 4,000 astas, 33 sacos cerda; á Llavallol é hijos.

Pailebot Ysico, de 9 tns., p. T. Vello, del Sauce ayer, en lastre; al patron.

Goleta 1.ª Santa Fecina, de 35 tns., p. B. Bruno, del Rosario el 6, con 750 cueros vacunos secos, 63 fardos lana, 80 suelas; á la órden.

Garandumba San José y Animas, de 20 tns., p. J. Bradon, del Monte el 8, con 30 carretadas leña; al patron.

Goleta Julia, de 54 tns., p. M. Carablanca, de Corrientes el 30 del pasado y del Paraná el 9 del presente, con 180 cueros vacunos, 181 tirantes, 23 chiguas cerda, 5,800 astas; á Llavallol é hijos.

Bergantin-goleta Rama Negra, de 122 tns., cpn. J. Avenente, de Patagones el 9 del presente; á B. Delfino: al mismo, 600 fanegas sal.

La Gaceta Mercantil (Buenos Aires), 17-I-1852: entradas al puerto · Recorte del equipo PortADa

PRUEBA 3

Para medir el error se necesita una transcripción correcta con la cual comparar. Al principio, Gemini y Claude coincidían mucho entre sí, pero ambos se alejaban de la transcripción del proyecto: **buena parte de las diferencias eran errores de esa transcripción**, armada a partir de un OCR que no se había revisado del todo. Se revisaron de nuevo las 46 páginas contra la imagen y se hicieron **746 cambios**, entre ellos 324 errores de lectura heredados, 26 renglones que sobraban y 24 textos que faltaban.

En este recorte de 1852, la transcripción incluía una palabra que no está impresa («dely») y lecturas como «carbton», «va cunos» o «Llavailol», donde el diario dice «carbon», «vacunos» y «Llavallol». Quedaron 198 lecturas dudosas. Como los textos de Gemini y Claude ayudaron a ubicar los errores, **parte de su ventaja puede deberse a esa revisión**.

Fidelidad en los mecanografiados

> Los programas tradicionales cometen **muchos errores, pero se ven**. Los modelos de inteligencia artificial cometen **pocos, pero creíbles**: escribieron «potencial hidroeléctrico» donde dice «petróleo», «Romero» donde dice «Ramiro», «20ABR84» donde dice «30ABR84» e «ISMAEL» donde dice «ESTEBAN». También corrigen el original: «profesional» donde el documento dice «profecional». Resultados sobre 3.105 palabras del archivo Berrutti.

Modelo	Palabras exactas	Palabras reemplazadas	Números cambiados	Erratas corregidas	Nombres y cifras exactos	Marcó «ilegible»
Gemini 4 Argon	99,7 %	3	0	1	98,9 %	0
Claude Opus 5.5	99,3 %	10	0	0	96,1 %	3
GPT-6 Astra	98,9 %	17	1	2	95,1 %	4
LightOnOCR-3-4B	98,1 %	30	0	8	93,7 %	0
Qwen3-VL-8B	98,0 %	29	1	6	93,0 %	1
Chandra OCR 2	97,6 %	35	1	9	92,3 %	0
Tesseract 5.5	78,8 %	140	4	1	72,6 %	—
docTR	75,2 %	131	2	6	71,2 %	—

Manuscritos

> Porcentaje de caracteres mal leídos en la página típica. Primero, comparando con una transcripción simplificada (sin acentos, abreviaturas ni ortografía antigua); entre paréntesis, con la copia literal. Ningún modelo había visto antes las páginas del grupo A; **Churro, en cambio, ya había visto las de B y C al entrenarse (*), por lo que esos resultados no son comparables**. Una página en letra de escribanía de 1590 superó el 48 % de error en todos los modelos.

Modelo	A · siglos XV a XIX	B · siglo XIX	C · década de 1890
Gemini 4 Argon	7,0 (14,8)	4,8 (7,2)	4,2 (6,5)
Claude Opus 5.5	7,4 (13,8)	6,1 (8,8)	5,9 (7,8)
GPT-6 Astra	11,2 (17,5)	7,6 (9,2)	7,4 (9,2)
Churro-3B	8,9 (11,6)	6,0* (7,4)	18,6* (20,0)
LightOnOCR-3-4B	17,7 (23,6)	13,3 (14,4)	13,3 (14,7)
Qwen3-VL-8B	26,7 (30,1)	14,3 (16,2)	18,8 (20,8)
docTR	75,7 (78,6)	57,7 (60,3)	70,8 (74,6)
Tesseract 5.5	74,5 (81,6)	70,5 (76,2)	81,4 (86,9)

Recursos y demos

> Páginas para probar sistemas con una imagen propia y un programa para medir su error. Los marcados con «Sí» **envían la imagen a un servidor externo**: conviene usar documentos sin datos personales ni restricciones de acceso.

Recurso	Qué es	¿Envía la imagen?	Enlace
Tesseract	OCR tradicional que funciona dentro del navegador	No	robertknight.github.io/tesseract-wasm/
docTR	OCR tradicional usado en la prueba de 2026; funciona dentro del navegador	No	demo-doctr-tensorflowjs.mindee.com/
EasyOCR	OCR gratuito para más de 80 idiomas	Sí	www.jaided.ai/easyocr/
Transkribus	Plataforma para transcribir manuscritos e impresos	Sí	www.transkribus.org/es
Google Document AI	Servicio de OCR de una empresa, con prueba gratuita	Sí	docs.cloud.google.com/document-ai/docs/try-docai?hl=es
DeepSeek-OCR	Modelo abierto de visión y lenguaje	Sí	huggingface.co/spaces/merterbak/DeepSeek-OCR-Demo
Indra OCR	Modelo abierto liviano que también reconoce el diseño de la página	Sí	huggingface.co/spaces/datalab-to/indra-ocr
ocrevalUAtion	Calcula CER y WER y resalta las diferencias	No	github.com/impactcentre/ocrevalUAtion