RAG y agentes en EntropIA Lite

Recuperar documentos, generar respuestas y verificar las citas

Agustín Nieto · INHUS-CEHis, UNMdP-CONICET

SICSS Uruguay · 5 de noviembre de 2026

La cadena completa

> *Encuentro 1.* El análisis del layout decide qué es una **unidad documental**: un artículo, un aviso, una columna.

> *Encuentro 2.* El OCR produce un **texto nuevo** a partir de la imagen, con errores que no se distribuyen al azar.

> *Encuentro 3.* La aplicación incorpora **decisiones metodológicas** en sus valores por defecto.

> *Encuentro 4.* Se agregan dos pasos: **recuperar** pasajes del corpus y **generar** un texto a partir de ellos. Los errores de los pasos anteriores llegan a la respuesta.

Tres preguntas

01 ¿Qué diferencia hay entre **encontrar un documento** y **generar una respuesta** sobre él?

02 ¿Qué significa que una respuesta esté **fundamentada** en las fuentes?

03 ¿Qué decisiones debe **validar quien investiga**?

I. Encontrar documentos

Qué deja afuera cada forma de búsqueda.

Buscar es una actividad situada

Shah y Bender discuten las propuestas de reemplazar el buscador por un programa que conversa y responde «como un experto».

Marchionini distingue tres tipos de búsqueda; los sistemas suelen diseñarse para el primero (p. 224):

- consultar un dato;
- aprender sobre un tema;
- investigar.

La investigación histórica corresponde a los otros dos, porque quien busca cambia la pregunta a medida que encuentra documentos:

- **aprender** sobre un tema;
- **investigar**.

«Buscar es una actividad situada social y contextualmente, con una diversidad de objetivos y necesidades de apoyo que no puede reducirse a una combinación de algoritmos que emparejan texto y que generan texto».

«searching is a socially and contextually situated activity with diverse set of goals and needs for support that must not be boiled down to a combination of text matching and text generating algorithms»

SHAH Y BENDER (2022), P. 221

EJEMPLO

Una investigadora busca «huelga» en la prensa uruguaya de 1910–1930. La palabra no significa lo mismo en un diario obrero que en uno patronal. Una respuesta sintetizada borra esa diferencia; una lista de documentos deja ver quién habla.

Una lista de resultados y una respuesta única

LISTA DE RESULTADOS

Muestra el abanico

Quien busca ve varias fuentes con sus datos y puede preguntarse: «¿De dónde salen? ¿Qué más hay en el corpus que no apareció? ¿Qué no está en el corpus, y por qué no?». Son preguntas de **crítica de fuentes**.

RESPUESTA SINTETIZADA

Oculta el abanico

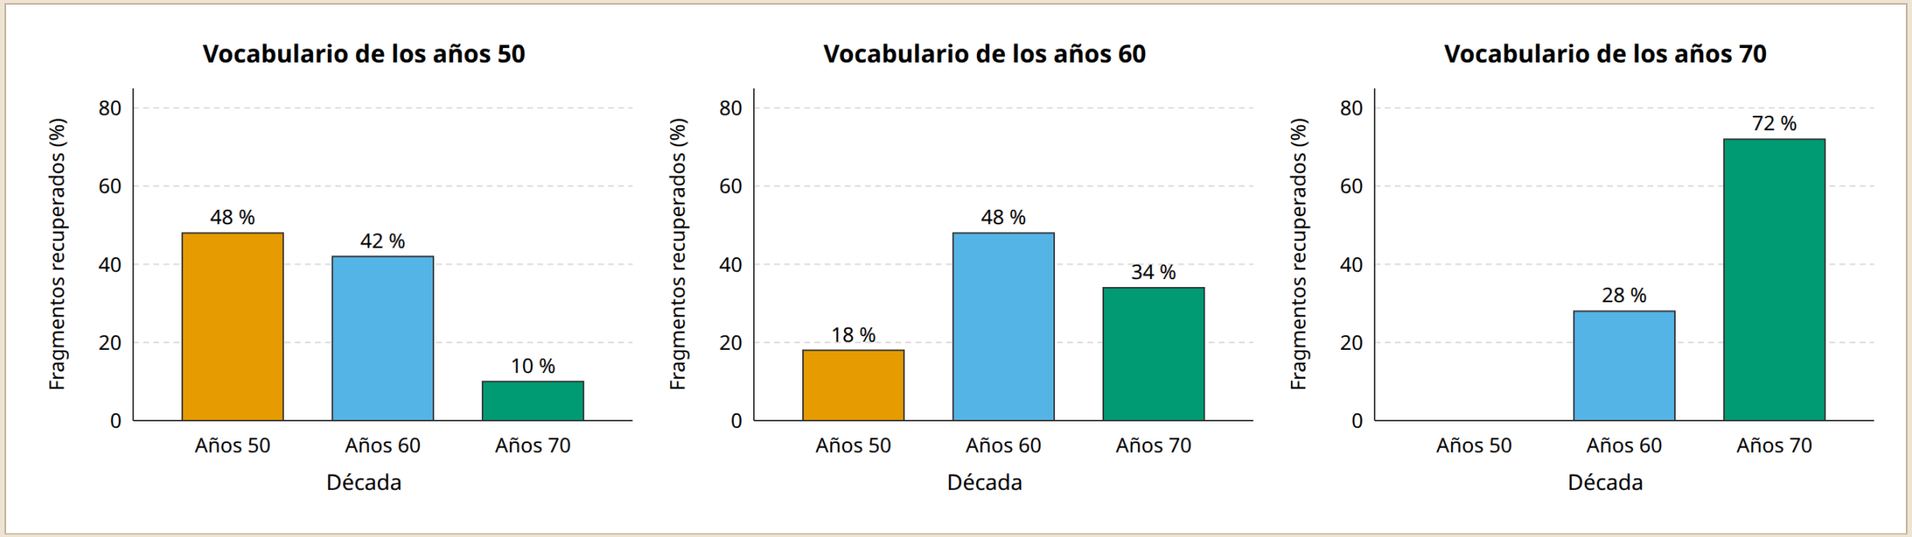
Según Shah y Bender:

· suena **definitiva** y acepta los supuestos de la pregunta;

· al combinar fuentes, **oculta cuáles había** y cuáles se descartaron;

· si es falsa, el error es **difícil de detectar**.

Búsqueda por significado y cambio de vocabulario



Porcentaje de los 50 fragmentos más similares, por década · HistoRAG, fig. 2, p. 11 · traducción propia

La búsqueda por significado convierte cada texto en una lista de números y compara esas listas: encuentra textos de tema parecido aunque usen otras palabras. EntropIA usa para esto el modelo BGE-M3. El manual advierte que un porcentaje alto de semejanza **no indica que dos textos digan lo mismo**.

Un equipo aplicó este tipo de búsqueda a 102.189 artículos de Der Spiegel (1950–1979). En esos años la computadora se llamó primero «cerebro electrónico» y después «Computer» y «EDV». Con el vocabulario de los años setenta, **la búsqueda no devolvió ningún fragmento de los cincuenta**. El vocabulario de la consulta decide qué época aparece.

Combinar búsquedas

El Chat de EntropIA ejecuta a la vez una búsqueda por palabras y una por significado, y **combina las posiciones** de los resultados en las dos listas, no sus puntajes.

Las dos vías encuentran documentos distintos. En TRACE, de los primeros 20 resultados de cada vía, **coincide menos de una quinta parte**; combinadas recuperan el 78,9 % de los documentos pertinentes, contra 70,1 % de la mejor vía sola.

En HistoRAG (Der Spiegel, 1950–1979), la búsqueda por palabra clave halló 163 cartas de lectores y la búsqueda por significado, 134: **solo 21 aparecen en las dos**. Las halladas solo por significado hablan de «racionalización» o «desempleo» sin nombrar la computadora.

Ninguna vía es completa. Conviene saber qué tipo de documento pierde cada una.

II. Cómo funciona un RAG

Recuperar pasajes de un corpus y redactar una respuesta a partir de ellos.

Dos memorias

RAG significa **generación aumentada por recuperación**. Lewis et al. (2020) combinaron dos memorias:

- la **memoria del modelo**: lo aprendido en el entrenamiento, que solo cambia si se lo vuelve a entrenar;
- una **colección de documentos**, que se consulta en cada pregunta y se puede leer y reemplazar.

Al cambiar los documentos cambian las respuestas. Ante «¿Quién es el presidente de Perú?» y otros 81 cargos que cambiaron de titular, con la Wikipedia de 2016 el modelo nombró a los gobernantes de 2016 en el 70 % de los casos; con la de 2018, **solo en el 12 %**.

El modelo también responde con lo que ya sabe: acertó el 11,8 % de las preguntas cuya respuesta **no estaba en ningún documento recuperado**. Al escribir un título de Hemingway, el documento le da la primera palabra y el modelo completa el resto.

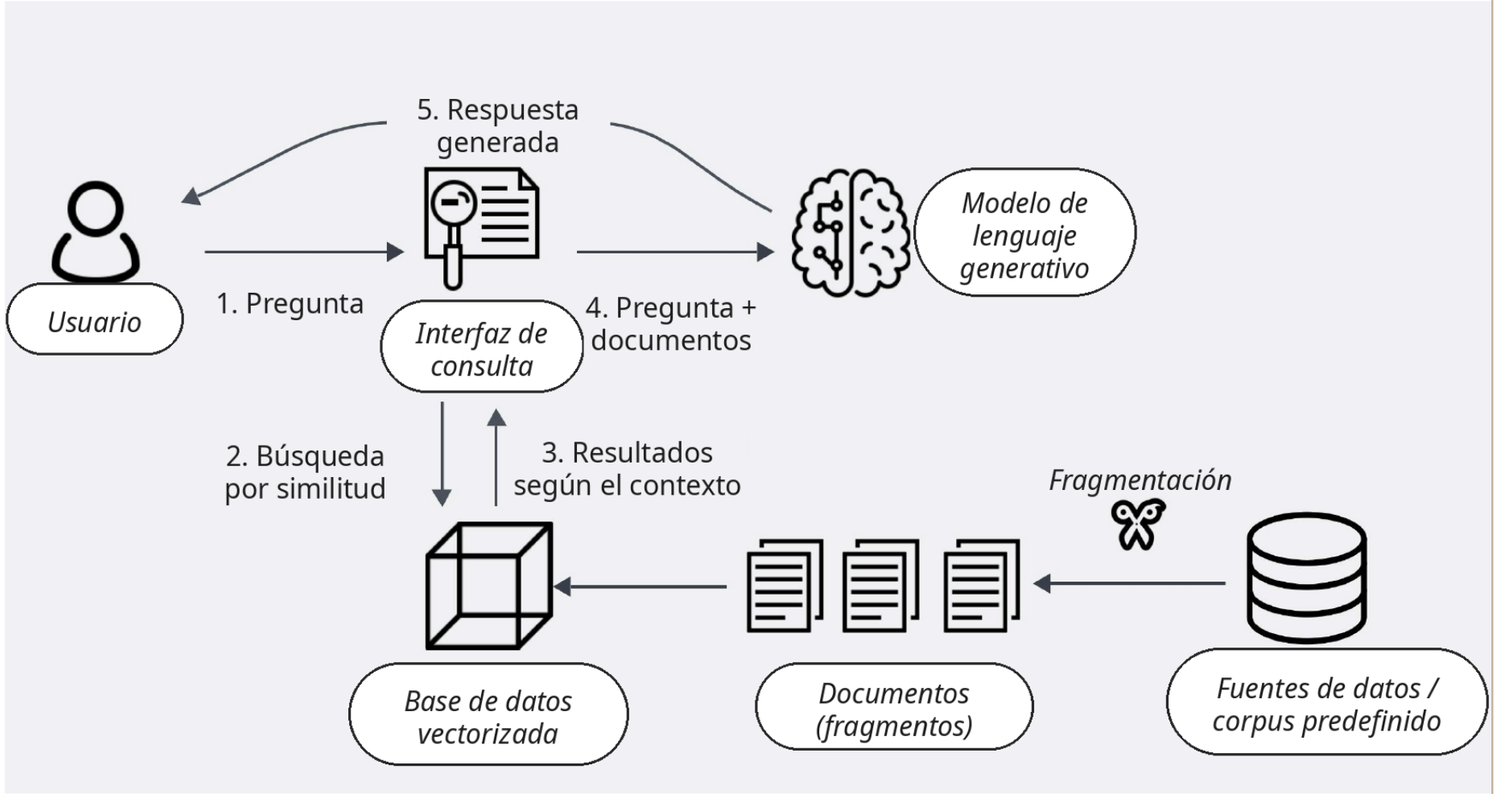
En una misma respuesta conviven datos de los documentos y datos del modelo, y **la respuesta no los distingue**.

Wikipedia, o cualquier fuente externa, «probablemente nunca será del todo fáctica ni estará completamente libre de sesgos».

«will probably never be entirely factual and completely devoid of bias»

LEWIS ET AL. (2020), P. 10

Las etapas de un RAG



Arquitectura de un sistema RAG · Puren et al. (2026), fig. 1, p. 2 · traducción propia

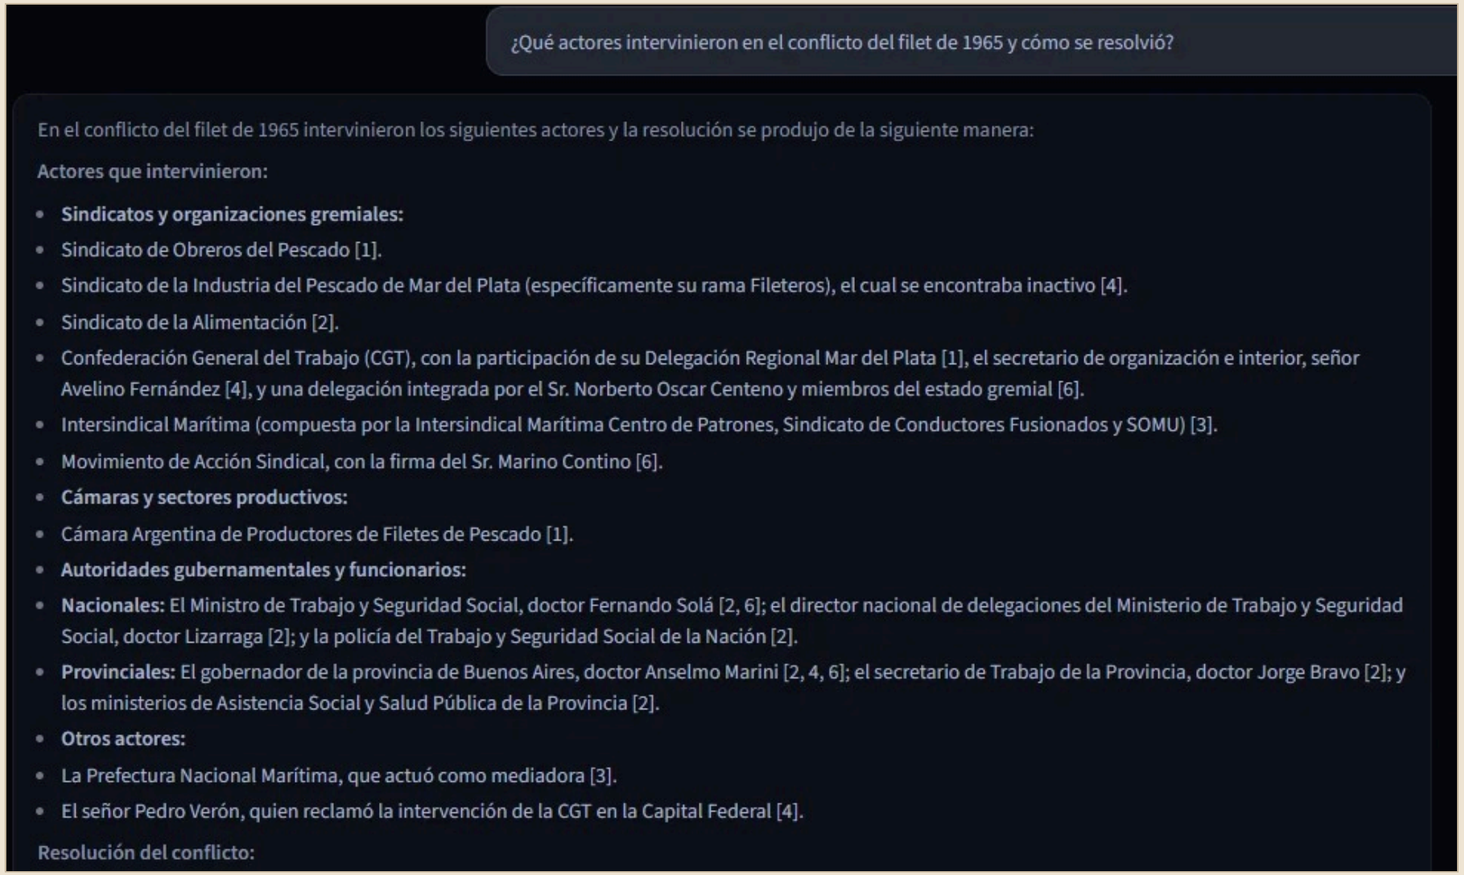
PUREN ET AL. (2026)

Antes de cualquier pregunta, el corpus se divide en **fragmentos** y cada fragmento se convierte en números que permiten compararlo (base de datos vectorizada).

Cuando alguien pregunta (1), el sistema busca los fragmentos más parecidos (2) y los recupera (3). La pregunta y esos fragmentos se envían a un modelo de lenguaje (4), que redacta la respuesta (5).

Cada etapa es una decisión: el tamaño de los fragmentos puede **separar un pasaje de su contexto**, los errores del OCR cambian lo que se encuentra, y la respuesta mezcla cita, paráfrasis e interpretación.

Una respuesta del Chat de EntropIA



Corpus de ejemplo: La Capital (Mar del Plata), 1965 · Manual de EntropIA Lite, captura de la versión 1.1.1

CHAT DE INVESTIGACIÓN

La pregunta es qué actores intervinieron en el conflicto del filet de 1965 y cómo se resolvió. La respuesta enumera sindicatos, cámaras empresarias y funcionarios, y **cada afirmación lleva un número** que remite a un artículo de La Capital.

La respuesta está bien redactada y ordenada, pero eso no indica si es correcta. Para saberlo hay que **abrir cada fuente** y comprobar que el pasaje dice lo que se le atribuye.

El manual lo advierte: que una fuente figure en la respuesta significa que la búsqueda la consideró relevante, **no que respalde lo que dice el modelo**.

III. Cómo busca y recupera EntropIA

Qué se guarda, cómo se divide el texto y qué cantidades usa cada buscador.

Qué guarda EntropIA para poder buscar

> Cada buscador consulta alguna de estas cinco estructuras. Lo que no pasó por ellas **no se puede encontrar**, aunque esté en el archivo.

Estructura	Qué contiene	Cuándo se crea	Quién la usa
Índice de palabras por documento	Una entrada por documento: título, metadatos y el texto de todas sus páginas, en orden.	Al obtener texto o con Análisis → INDEX.	Búsqueda superior, Buscar documentos, Búsquedas (FTS), Escritura y el Chat.
Índice de palabras por fragmento	Una entrada por fragmento de 800 caracteres.	Con EMBED o un lote de embeddings.	Chat e Investigar.
Vector de cada página	1.024 números que resumen el contenido de la página entera.	Con EMBED o un lote de embeddings.	Páginas similares y el Chat (páginas sin fragmentos).
Vector de cada fragmento	1.024 números por cada fragmento de 800 caracteres.	Con EMBED o un lote de embeddings.	Chat e Investigar.
Vocabulario del índice	Cada palabra del corpus y en cuántos documentos aparece.	Junto con el índice de palabras.	Búsqueda aproximada.

Código de EntropIA Lite 1.3.0 (etiqueta v1.3.0): migraciones 0029, 0034 y 0037; processing/embedding.rs · Manual de EntropIA Lite 1.3.0, Anexo A

Un ejemplo: una página de prensa en las cinco estructuras

> Página 1 de un diario de 1911: «La **huelga** de los obreros del puerto continúa…». Los índices de palabras guardan **qué palabras aparecen y dónde**; los vectores guardan **números** que resumen el sentido. Datos inventados.

Índice de palabras por documento

palabra → documentos

huelga	doc. 42 (3 veces), doc. 87, doc. 311
obreros	doc. 42, doc. 95
puerto	doc. 42, doc. 87

Índice de palabras por fragmento

palabra → fragmentos de 800 caracteres

huelga	doc. 42 · p. 1 · frag. 1 y 3
obreros	doc. 42 · p. 1 · frag. 1
puerto	doc. 42 · p. 2 · frag. 2

Vocabulario del índice

palabra → documentos en que aparece

huelga	312
huelgas	95
huelguistas	41
huelqa	2 (error de OCR)

Vector de cada página

una página → 1.024 números

doc. 42 · p. 1 [0,021 −0,113 0,047 … 0,008]

doc. 42 · p. 2 [−0,064 0,015 0,090 … −0,031]

Vector de cada fragmento

un fragmento → 1.024 números

p. 1 · frag. 1 (0–800) [0,034 −0,092 0,051 … 0,012]

p. 1 · frag. 2 (700–1500) [0,018 −0,127 0,040 … 0,005]

Cómo funciona el índice de palabras

> Es un **índice invertido**, como el índice analítico al final de un libro: para cada palabra guarda la lista de documentos en que aparece. Buscar no recorre los textos: consulta esa lista.

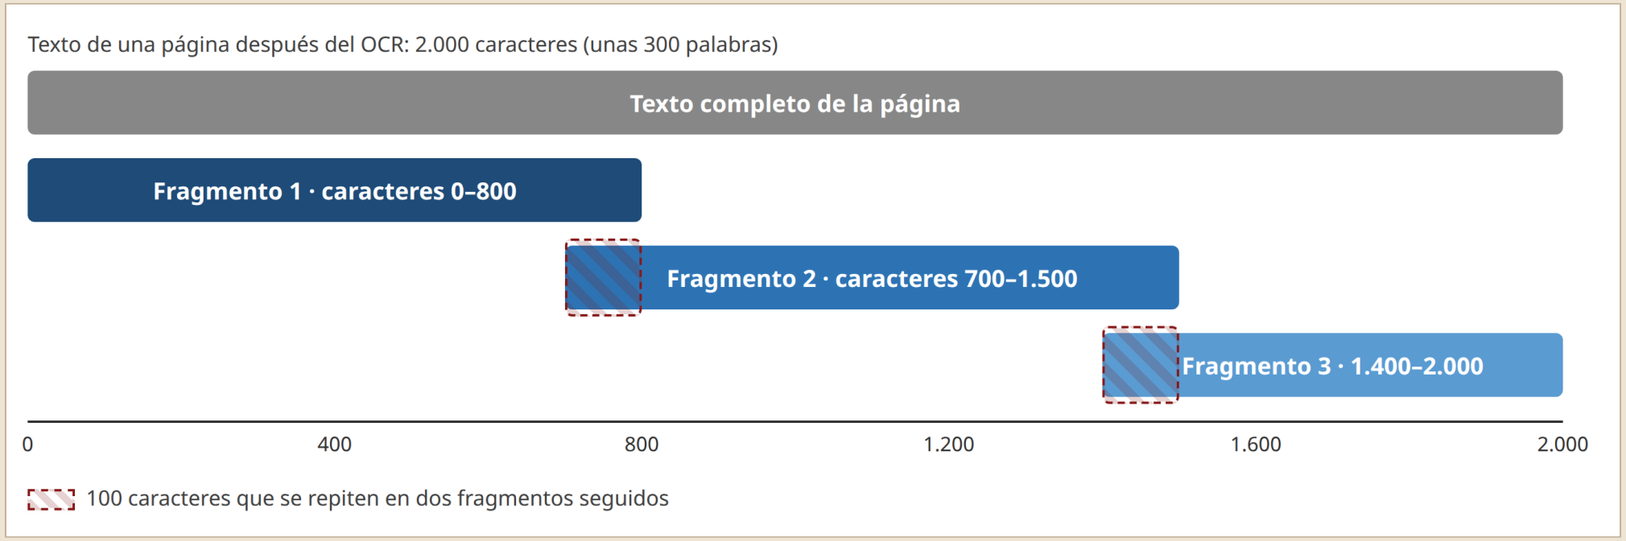
> Antes de indexar, el texto se **divide en palabras** por los espacios y los signos de puntuación, se pasa a minúsculas y se le **quitan los acentos**: «Unión», «union» y «UNIÓN» son la misma entrada. El índice no reduce las palabras a su raíz: «obrero» y «obreros» son entradas distintas.

> El orden de los resultados lo da **BM25**, una fórmula que le pone un puntaje a cada documento. El puntaje sube cuando:
>
> - la palabra **aparece más veces**, pero cada repetición suma menos: diez «huelga» valen apenas el doble que una;
> - la palabra es **rara en el corpus**: «huelguistas» distingue más que «obreros», que aparece en casi todo;
> - el texto es **breve**: una mención en una nota corta pesa más que en un suplemento de veinte páginas.

> El índice no guarda una copia del texto: solo las palabras y dónde están. Por eso hay que reconstruirlo (INDEX) cuando el texto cambia.

Cómo se divide el texto en fragmentos

> El texto de cada página se corta en **ventanas de 800 caracteres** (unas 120 a 130 palabras). Cada ventana empieza 700 caracteres después de la anterior, así que dos fragmentos seguidos **comparten 100 caracteres**. Los cortes se hacen por cantidad de caracteres: pueden partir una palabra, una oración o un artículo, y nunca cruzan de una página a otra.



Esquema propio a partir de plan_rag_chunks (nlp/embeddings.rs, EntropIA Lite 1.3.0)

Cómo se calcula y se compara un vector

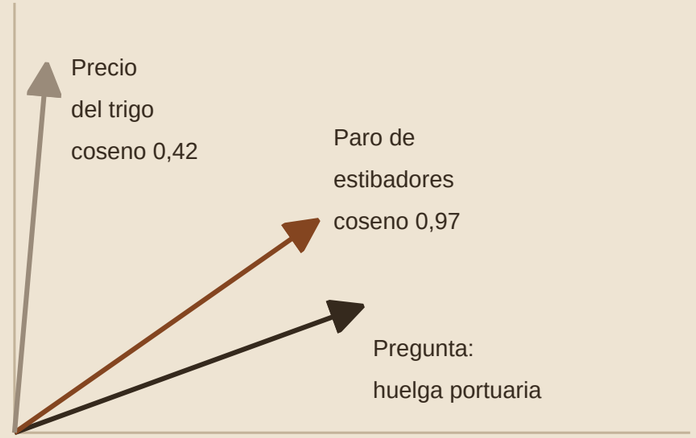
El modelo **BGE-M3**, consultado por internet a través de OpenRouter, convierte un texto en 1.024 números. Textos de tema parecido producen números parecidos.

Página entera. Si tiene más de 6.000 caracteres, se divide en trozos de 6.000, **sin solapamiento**; se calcula un vector por trozo y se promedian, dando más peso a los trozos con más letras.

Fragmento. Un vector por cada fragmento de 800 caracteres. *Pregunta.* Se convierte con el mismo modelo.

Para comparar se usa la **similitud coseno**. Cada lista de números funciona como una flecha: se mide **cuánto se parecen las direcciones**, no el largo. Vale 1 si apuntan igual y baja a medida que se separan.

El Chat e Investigar comparan la pregunta con **todos** los vectores guardados, uno por uno. *Páginas similares* compara con todas las páginas y muestra las 5 más parecidas.



Ejemplo simplificado: dos números en lugar de 1.024; valores inventados.

Código de EntropIA Lite 1.3.0 (etiqueta v1.3.0): nlp/embeddings.rs (EMBEDDING_CHUNK_MAX_CHARS = 6000), rag/retrieval.rs; nlp/commands.rs (rama fix/similar-assets-full-scan, sin publicar)

Qué exige cada búsqueda por palabras

> No todos los buscadores tratan igual una consulta de varias palabras. La diferencia principal está entre **exigir todas las palabras** y **conformarse con alguna**.

Buscador	Qué exige	Cuántos resultados	Orden
Búsqueda superior	Todas las palabras; si no hay resultados, alguna; si tampoco, la frase en título y metadatos.	Hasta 20 documentos.	Por título.
Buscar documentos	Igual que la superior, dentro de la colección abierta.	Todos los que coinciden.	El de la colección.
Búsquedas (FTS) y Escritura → Corpus	Todas las palabras; si no hay resultados, alguna.	Hasta 10 documentos (FTS).	BM25; variantes aproximadas al final.
Chat	Alguna palabra, después de quitar unas 120 palabras vacías (que, de, sobre, the…).	24 por vía.	BM25.
Investigar	Alguna palabra, hasta 12 términos, sin palabras vacías.	24 fragmentos por consulta.	BM25.

Código de EntropIA Lite 1.3.0 (etiqueta v1.3.0): nlp/fts.rs (FtsMatchMode::All y Any), rag/retrieval.rs · EntropIA-Agent f010d01: repositorio.rs (MAX_TOKENS_FTS = 12) · Manual de EntropIA Lite 1.3.0, cap. 7 y Anexo A

Búsqueda aproximada: las variantes del OCR

> El OCR no se equivoca siempre igual: una palabra puede aparecer como «sindicato» en cien páginas y como «sindigato» o «bindicato» en unas pocas. La búsqueda aproximada suma esas variantes y **las marca** («Aproximado: sindigato»), después de los resultados exactos.

Regla	Qué hace EntropIA
Origen de las variantes	Solo palabras que existen en el corpus, con la cantidad de documentos en que aparece cada una.
Diferencia tolerada	Ninguna en palabras de menos de 5 letras; una entre 5 y 7; dos con 8 o más; ninguna si la palabra tiene dígitos (fechas, folios).
Variante mucho más rara	Se toma como mala lectura si aparece en al menos cuatro veces menos documentos: «sindicato» en 100 y «sindigato» en 3.
Formas igual de comunes	Se tratan como palabras distintas y no se mezclan: «obrero» en 300 documentos y «obrera» en 200.
Las dos formas raras	Si ambas aparecen en menos de 10 documentos no hay cómo saber cuál es la correcta: se conservan todas.
Error al escribir	Si quien busca escribe «sindicatp», se agrega la forma parecida mucho más común: «sindicato».
Límite	Hasta 8 malas lecturas por palabra, las más parecidas primero, y una sola corrección.

Manual de EntropIA Lite 1.3.0, Anexo A, A.4 · Código de EntropIA Lite 1.3.0 (etiqueta v1.3.0): nlp/fuzzy.rs (WEIGHT_RATIO = 4, RARE_DOCS = 10, MAX_MISREADINGS = 8) · Murugaraj et al. (2025), p. 8

El Chat: del corpus a 16 candidatos

01

Interpretar

Un modelo decide si hace falta buscar. Si la pregunta depende de la conversación, la reescribe: se busca con la original y con la reescrita.

02

Buscar

Por cada consulta, 4 vías de 24 resultados: fragmentos por significado, fragmentos por palabras, páginas sin fragmentos por significado y por palabras.

03

Combinar

Hasta 8 listas se combinan por posición (RRF, constante 60). Quedan 40 candidatos.

04

Depurar

Se toman los 16 primeros, con un máximo de 3 fragmentos por página.

El Chat: de 16 candidatos a la respuesta

01

Reordenar

Un segundo modelo (cohere/rerank-4-fast) lee la pregunta junto con cada candidato, hasta 6.000 caracteres, y le pone una nota de pertinencia. Las búsquedas anteriores comparaban la pregunta y el texto por separado; este los lee juntos, como quien revisa una pila ya preseleccionada.

02

Ampliar

Cada fragmento elegido se envía con el fragmento anterior y el siguiente. Si dos elegidos están cerca en la misma página, se unen en un solo pasaje.

03

Recortar

Hasta 6 fuentes. Cada pasaje, hasta 2.400 caracteres; una página sin fragmentos, un recorte de 1.600 alrededor de las palabras buscadas. En total, hasta 10.000.

04

Redactar

El modelo responde con citas [n], con temperatura 0,2 y las últimas 6 intervenciones de la conversación como contexto.

Código de EntropIA Lite 1.3.0 (etiqueta v1.3.0): rag/reranker.rs, rag/retrieval.rs (pack_sources), rag/params.rs

Investigar: cómo busca y cómo verifica

> El plan propone hasta **20 consultas** (30 en el perfil «trayectorias»). Cada consulta trae 24 fragmentos por significado y 24 por palabras **dentro de las colecciones elegidas**, los combina, envía 16 al **reordenador**, el mismo modelo del Chat que vuelve a ordenarlos por pertinencia, y conserva hasta 16.

> Busca **solo en fragmentos**: las páginas sin EMBED no participan. No usa variantes aproximadas.

> Antes del informe, un **verificador** revisa cada afirmación con la evidencia citada y la clasifica como **respaldada, parcialmente respaldada, contradicha o no verificable**. Antes, comprueba que la cita textual esté en la fuente, en el lugar indicado.

> El informe reproduce hasta 600 caracteres de cada fragmento citado.

Qué consecuencias tiene para quien investiga

01 El modelo lee **pasajes de unos 800 a 2.400 caracteres**, no artículos completos.

02 Los fragmentos **no respetan el layout**: si el OCR mezcló columnas, el fragmento también.

03 Sin EMBED, una página **no aparece** en la búsqueda por significado ni en Investigar.

04 Páginas similares solo compara páginas vectorizadas con **el mismo modelo y configuración**.

05 El Chat busca con **alguna palabra**: encuentra más, y también más ruido.

06 Con otros parámetros, otra respuesta: **registrar la configuración**.

IV. RAG sobre prensa histórica

Qué ocurre cuando los documentos tienen errores de OCR, varias lenguas y un vocabulario que cambia con el tiempo.

Los errores del OCR llegan a la respuesta

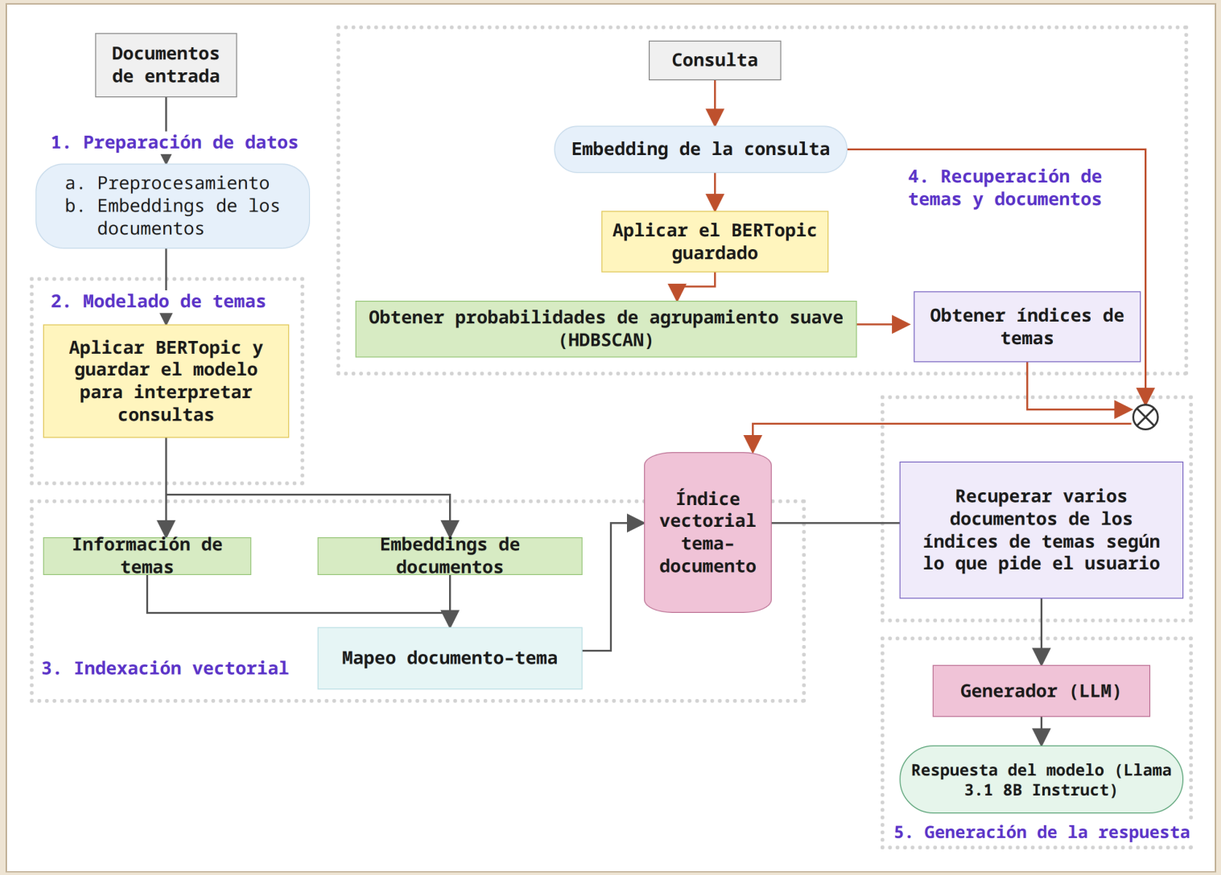
> Zhang et al. compararon respuestas obtenidas con un texto revisado a mano y con textos producidos por seis programas de OCR, sobre 8.561 páginas de siete tipos de documentos, entre ellos prensa.

> Con cualquiera de los seis, el rendimiento final quedó **al menos un 14 % por debajo** del obtenido con el texto revisado.

> Con muchos errores de lectura, el rendimiento cayó **cerca de la mitad** en casi todas las combinaciones probadas.

> La tasa de error del OCR **no predijo bien** la calidad de las respuestas, y el orden de lectura fue el punto más débil.

Topic-RAG: elegir temas antes de buscar



Esquema de Topic-RAG · Murugaraj et al. (2025), fig. 2, p. 5 · traducción propia

MURUGARAJ ET AL. (2025)

El sistema agrupa primero los artículos en **temas** con BERTopic: convierte cada artículo en números, como la búsqueda por significado, junta los que quedan cerca y describe cada grupo con sus palabras más típicas. Ante una pregunta, elige los temas más cercanos y busca solo dentro de ellos.

Se aplicó a 4.711 artículos y avisos de prensa suiza sobre energía nuclear (1971–1986), del proyecto Impresso.

Dos decisiones conviene discutir: los textos en francés y alemán **se tradujeron al inglés con Google Translate** antes de procesarlos, y la evaluación numérica usó 50 preguntas **generadas por un modelo de lenguaje** a partir de un solo artículo cada una.

Topic-RAG ante preguntas de investigación

Historiadores del equipo formularon nueve preguntas y evaluaron las respuestas.

Cuando pedían **listas de artículos**, el sistema devolvía **resúmenes** de las posiciones en debate.

Un tema reunía 1.966 artículos y **atraía casi todas las preguntas**.

Un error en la **separación de artículos** unió dos textos distintos, y el sistema vinculó a un misionero con el debate sobre residuos nucleares. Es un error del layout que reaparece como error de interpretación.

«A quien investiga le importa quién dijo exactamente qué, dónde y cuándo».

«To a researcher, it matters who exactly said what, where and when.»

MURUGARAJ ET AL. (2025), P. 16

HistoRAG: búsqueda e interpretación por separado

Kim-Baumann y Hiltmann diseñaron un RAG a partir de principios del método histórico.

Separan dos fases, como Droysen: **reunir las fuentes** (heurística) e **interpretarlas**. Entre una y otra, el historiador acepta, rechaza o marca cada fragmento.

La búsqueda y la pregunta de análisis son distintas: la primera delimita una parte del corpus; la segunda interroga lo reunido.

Para corpus que abarcan décadas, buscan la **misma cantidad de fragmentos en cada período** (por ejemplo, cada cinco años), como en un muestreo estratificado.

«Para la interpretación histórica, perder una fuente pertinente cuesta mucho más que revisar una que resulta marginal».

«For historical interpretation, missing a relevant source is far more costly than reviewing one that turns out to be marginal.»

KIM-BAUMANN Y HILTMANN (2026), P. 7

Textos intermedios

> HistoRAG llama *Zwischentexte* (textos intermedios) a lo que redacta el modelo: no son respuestas ni conclusiones, sino **propuestas de interpretación** que hay que verificar.

> Al revisarlos, una cita de 1964 sobre un clima de pánico resultó exacta, y el contexto completo enriqueció la lectura.

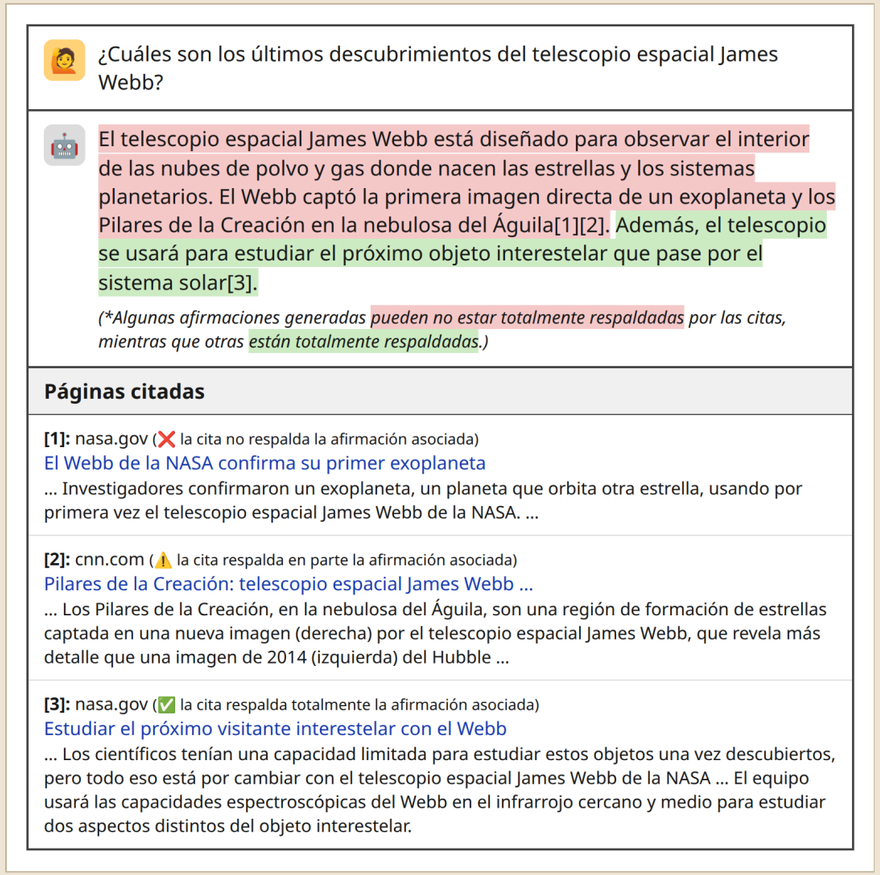
> Pero el modelo leyó «racionalización» con su sentido actual, sin la referencia al movimiento de racionalización de Weimar que tenía para un lector de los años cincuenta.

> Su uso más claro es **formular hipótesis**: que el giro hacia el miedo ocurrió en 1964, antes de lo que señala la bibliografía, queda propuesto, no probado.

V. Citas y verificación

Cómo saber si una cita respalda lo que se afirma.

Cómo se evalúa una cita



Respuesta sobre el telescopio James Webb y sus tres citas · Liu, Zhang y Liang (2023), fig. 1, p. 7001 · traducción propia

LIU, ZHANG Y LIANG (2023)

Liu, Zhang y Liang evaluaron cuatro buscadores que responden con citas (Bing Chat, NeevaAI, perplexity.ai y YouChat) con dos medidas:

· la proporción de afirmaciones **totalmente respaldadas** por sus citas;
· la proporción de citas que **respaldan la afirmación** a la que acompañan.

En el ejemplo, la primera cita no respalda lo que se afirma, la segunda lo respalda en parte y solo la tercera lo respalda por completo. Para los autores, toda afirmación sobre el mundo debe poder verificarse, aunque parezca obvia (p. 7003).

Tres condiciones para usar un RAG en historia

Trazabilidad: poder encontrar con precisión los documentos y los pasajes usados.

Auditabilidad: poder revisar las transformaciones y los parámetros que llevaron a esos pasajes (OCR, fragmentación, búsqueda, modelo).

Discutibilidad: poder discutir la respuesta separando **lo que dice la fuente** de **lo que interpreta el sistema**.

Proponen además: conservar la procedencia, mostrar el contexto de cada fragmento, ofrecer varias fuentes y no una sola versión, registrar la configuración y **abstenerse cuando la evidencia no alcanza** (pp. 4–5).

«Sostenemos que la confianza se construye a condición de hacer del RAG una **cadena de prueba**. Dicho de otro modo, cada enunciado debe estar ligado a pasajes identificables, ubicados en su contexto y acompañados de indicios sobre su selección y sus transformaciones».

«nous soutenons que la confiance se construit à condition de faire du RAG une chaîne de preuve. Autrement dit, chaque énoncé doit être relié à des passages identifiables, replacés dans leur contexte, et assortis d’indices sur leur sélection et leurs transformations»

PUREN ET AL. (2026), P. 2

Atestiguado, inferido, indecidible

01

Atestiguado

Se apoya en un pasaje citado. La afirmación puede verificarse leyendo el pasaje.
Ejemplo: una fecha o un nombre que figura en el artículo citado.

02

Inferido

Se deduce de indicios. La afirmación surge de relacionar pasajes. El razonamiento debe poder explicarse y discutirse.

03

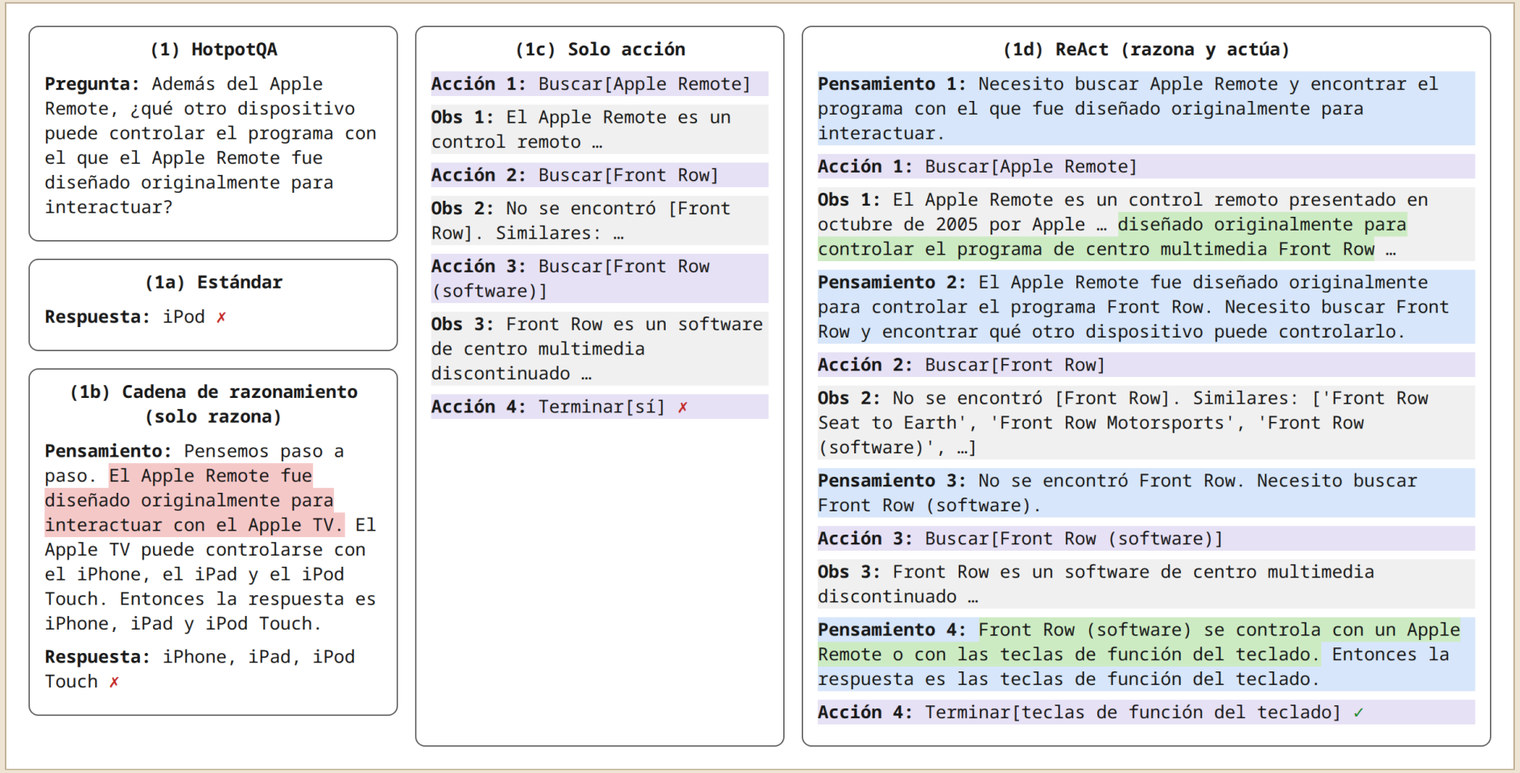
Indecidible

El corpus no alcanza. No puede establecerse con lo recuperado, por falta de documentos, errores de OCR o contexto insuficiente. Exige volver al documento.

VI. Agentes

Programas que deciden qué buscar, leen los resultados y vuelven a buscar.

Razonar, actuar, observar



Cuatro formas de responder la misma pregunta (HotpotQA) · Yao et al. (2023), ReAct, fig. 1, p. 2 · traducción propia

YAO ET AL. (2023)

Un agente es un programa que **alterna pasos**: escribe qué le falta saber, ejecuta una acción (por ejemplo, buscar en Wikipedia), lee el resultado y decide qué hacer después. ReAct propuso este esquema en 2022.

En una revisión manual de casos, el modelo que solo razonaba **inventaba datos** (56 % de sus fallos); ReAct casi no inventaba, pero fallaba por razonamientos equivocados o repetidos (47 %) y por búsquedas sin resultados útiles (23 %).

A diferencia de una respuesta directa, **el registro de pasos puede leerse** y deja ver qué vino del modelo y qué de la búsqueda.

TRACE: un agente para encontrar fuentes



Las seis etapas de TRACE · Bian, Puren y Cafiero (2026), fig. 1, p. 3 · traducción propia

BIAN, PUREN Y CAFIERO (2026)

TRACE no responde preguntas: **devuelve documentos**. Divide la pregunta en subpreguntas, busca con varias técnicas y, para cada fragmento, decide **aceptar, rechazar o dejar en espera**, con una justificación breve que queda registrada.

Se probó con 1.752 preguntas sobre debates parlamentarios y dos diarios de París de 1887. Encontró entre los diez primeros resultados el 85,6 % de los documentos pertinentes; la búsqueda por palabras, el 64,3 %. En preguntas que comparan fuentes, 67,4 % contra 18 %.

La mayoría de los documentos perdidos **se habían encontrado y se juzgaron irrelevantes**.

Qué delegar en un agente

HistoRAG decidió **no construir un agente**. Un agente decide por su cuenta qué buscar, qué priorizar y cómo resumir: cuanto más decide solo, **menos puede ver y discutir el historiador** cómo se llegó al resultado (p. 20).

Los autores admiten agentes para tareas con criterios de corrección claros: dar formato a referencias, detectar duplicados, transcribir formularios. No para **decidir qué fuentes importan ni qué significan**.

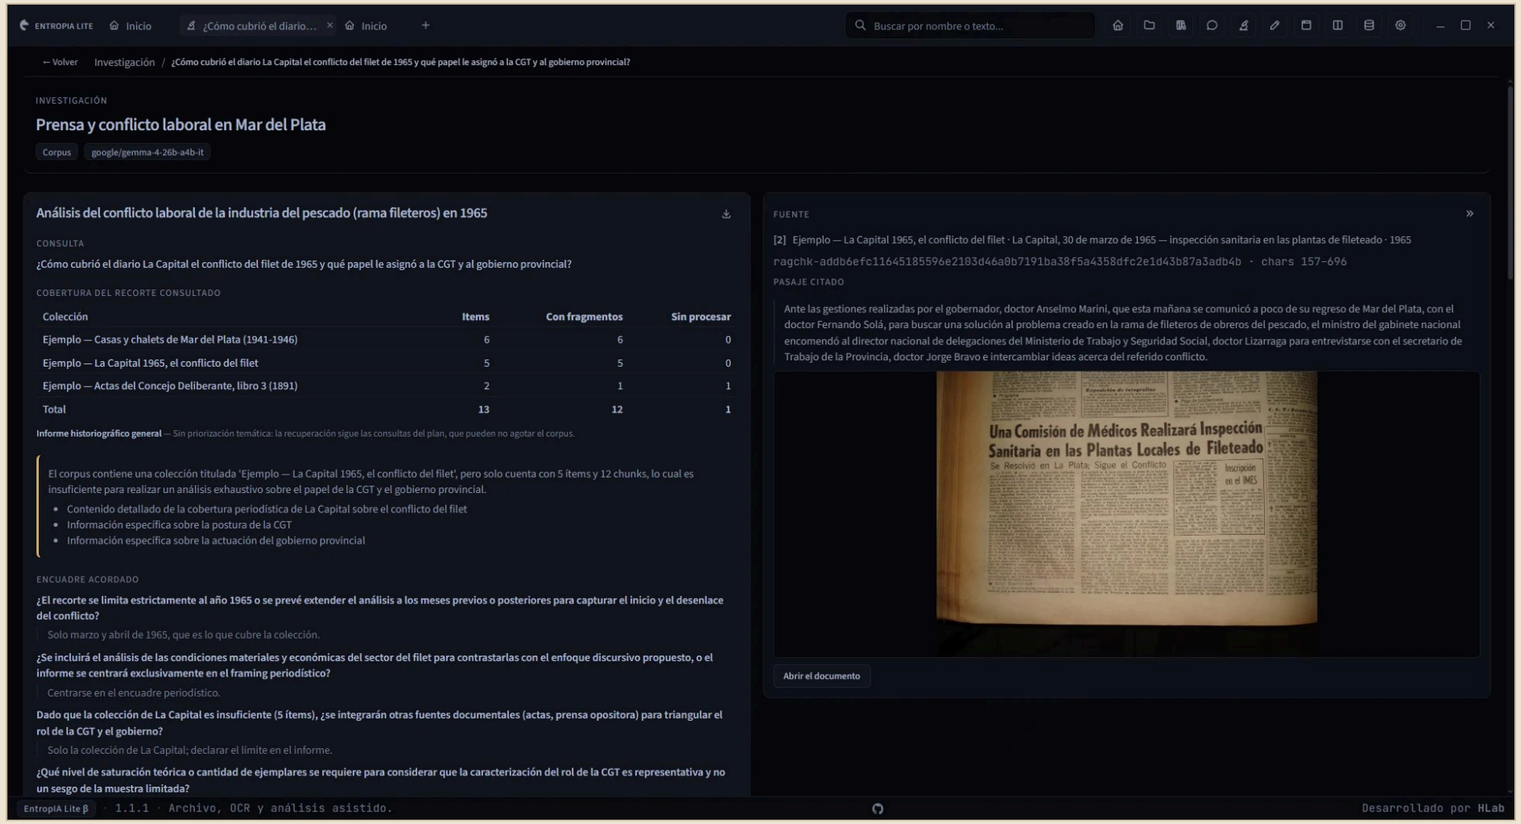
HistBench evaluó agentes con 414 preguntas de historia escritas por más de 40 especialistas. El mejor agente específico acertó el **27,5 %** al primer intento (p. 16), y solo se evaluaron preguntas cerradas.

«Autonomía y transparencia están en tensión. […] La eficiencia que se gana tiene como costo trasladar la capacidad de juicio a procesos que operan de manera opaca».

«autonomy and transparency exist in tension. […] The efficiency gained comes at the cost of epistemic agency transferred to processes that operate opaquely»

KIM-BAUMANN Y HILTMANN (2026), P. 20

Investigar en EntropIA



Informe sobre prensa y conflicto laboral en Mar del Plata · Manual de EntropIA Lite, captura de la versión 1.1.1

AGENTE DE INVESTIGACIÓN

Investigar desarrolla una pregunta en varios pasos y prepara un informe con fuentes. Quien investiga interviene en varios puntos:

· antes del informe, puede editar **hipótesis, alcance y criterios de cierre**;
· antes de buscar, **aprueba o modifica las búsquedas** propuestas;
· puede pausar y fijar un límite de costo;
· el informe muestra **cuántos documentos de cada colección se usaron**;
· una sección editada a mano queda marcada como no verificada.

Protocolo de verificación

01 Anotar **qué búsqueda** se usó: por palabras, aproximada, por significado, Chat o Investigar.

02 Comprobar **qué parte del corpus tenía texto, índice y embeddings**: lo que no está preparado no se encuentra.

03 Repetir la búsqueda por otra vía o con el **vocabulario de otra época**.

04 Abrir cada cita: ¿el pasaje existe, trata el tema y **dice lo que se le atribuye**?

05 Volver a la **imagen** cuando importan nombres, cifras o fechas.

06 Clasificar cada afirmación: **atestiguada, inferida o indecidible**.

07 Registrar el **modelo, los parámetros y la fecha** de la consulta.

Síntesis a partir de Puren et al. (2026), Liu et al. (2023), Onweller et al. (2026), Kim-Baumann y Hiltmann (2026) y el manual de EntropIA Lite

Pruebas

01

Preguntar

Formular una pregunta documental concreta sobre una persona, un hecho, una fecha o un lugar.

02

Comparar

Resolverla por búsqueda por palabras (con y sin aproximadas), Páginas similares, Chat e Investigar. Anotar qué documentos aparecen en cada vía.

03

Verificar

Para cada afirmación del Chat: cita, ¿el pasaje la respalda?, ¿atestiguada, inferida o indecidible?, ¿error de búsqueda o de redacción?

04

Registrar

Omisiones, afirmaciones fuera de contexto e invenciones. Un párrafo sobre los límites de la consulta para el informe final.